AI GLOSSARY · 2026년 10월 19일 기준

실무 AI 용어집

AX 전환을 함께 하는 실무자와 개발자를 위해, 같은 용어를 입문과 심화 두 수준으로 풀었다. 용어마다 실무 예시와 연관 용어를 함께 달았다.

422 용어

11 분야

60 주제

84 쪽

AI 기초·머신러닝	44	AI 에이전트·도구	37
딥러닝·신경망	38	생성 AI·멀티모달	37
LLM·언어모델	42	인프라·배포·LLMOps	38
학습·튜닝·정렬	40	평가·안전·규제	45
프롬프트·추론	30	AX·비즈니스 적용	33
RAG·검색·데이터	38		

입문 · 82개
누구나 알아야 할 기본 용어

실무 · 208개
업무에 AI를 적용하는 사람의 용어

심화 · 132개
기술을 구현하는 사람의 용어

분야별 차례 다음에 가나다순 본문, 뒤쪽에 가나다·ABC 색인이 있다.

odysseyiliadr2d2.github.io/ai-glossary

분야별 차례

위키 트리(분야 › 주제 › 문서)를 읽는 순서대로 펼쳤다. 숫자는 수록 쪽이다.

AI 기초·머신러닝

AI 기본 개념 9

인공지능 43 · 머신러닝 20 · 약인공지능과 강인공지능 34 · 범용 인공지능 24 · 튜링 테스트 58 · 모델 21 · 추론 52 · 파라미터 59 · 하이퍼파라미터 64

학습 방식 5

지도학습 48 · 비지도학습 27 · 강화학습 6 · 준지도학습 48 · 자기지도학습 44

데이터 준비 9

학습 데이터 64 · 피처(특성) 63 · 데이터 레이블링 14 · 데이터셋 분할(학습/검증/테스트) 13 · 피처 엔지니어링 63 · 피처 스케일링(정규화·표준화) 63 · 클래스 불균형 56 · 차원 축소 50 · 데이터 누수 14

과제와 알고리즘 11

분류 26 · 회귀 68 · 군집화 9 · 결정 트리 7 · 로지스틱 회귀 18 · 이상 탐지 42 · 시계열 예측 32 · 추천 시스템 53 · 앙상블 학습 34 · 랜덤 포레스트 17 · 그래디언트 부스팅 10

평가와 일반화 10

과적합 8 · 정확도 47 · 과소적합 8 · 정규화(규제) 47 · 교차검증 9 · 혼동행렬 66 · 정밀도와 재현율 47 · F1 점수 72 · ROC 곡선과 AUC 74 · 편향-분산 트레이드오프 60

딥러닝·신경망

신경망 기초 10

신경망 33 · 딥러닝 17 · 퍼셉트론 60 · 다층 퍼셉트론 13 · 은닉층 41 · 활성화 함수 67 · 소프트맥스 31 · 텐서 57 · 임베딩 44 · 파라미터 수와 모델 크기 59

학습 원리 10

손실 함수 31 · 경사하강법 7 · 역전파 38 · 학습률 64 · 옵티마이저 39 · 에폭 37 · 배치 크기 24 · 교차 엔트로피 9 · 확률적 경사하강법 66 · 기울기 소실 12

학습 기법 6

드롭아웃 16 · 조기 종료 48 · 전이 학습 46 · 배치 정규화 24 · 레이어 정규화 18 · 잔차 연결 45

신경망 구조 7

합성곱 신경망 65 · 순환 신경망 31 · 장단기 메모리 46 · 인코더-디코더 43 · 게이트 순환 유닛 7 · 오토인코더 38 · 그래프 신경망 10

트랜스포머 5

어텐션 35 · 트랜스포머 58 · 셀프 어텐션 30 · 멀티헤드 어텐션 20 · 위치 인코딩 40

LLM·언어모델

LLM 기본 개념 8

대규모 언어모델 13 · 파운데이션 모델 59 · 지식 컷오프 50 · 멀티턴 대화 20 · 다음 토큰 예측 13 · 자기회귀 모델 44 · 창발적 능력 50 · 스케일링 법칙 31

모델 종류 5

프런티어 모델 61 · 오픈 웨이트 모델 39 · 오픈소스 모델 39 · 소형 언어모델 31 · 다국어 모델 13

토큰과 컨텍스트 8

토큰 58 · 컨텍스트 윈도 54 · 최대 토큰 수 52 · 토크나이저 58 · 한국어 토큰 효율 65 · 롱 컨텍스트 19 · 바이트 페어 인코딩 23 · 중간 정보 손실 48

생성과 디코딩 13

온도 39 · 샘플링 28 · 그리디 디코딩 11 · Top-k 샘플링 75 · Top-p 샘플링 75 · 스톱 시퀀스 32 · 스트리밍 응답 32 · 로짓 18 · 빔 서치 27 · 반복 패널티 23 · 채팅 템플릿 51 · KV 캐시 73 · 추측 디코딩 53

모델 구조 8

디코더 전용 모델 17 · 인코더 모델 43 · 전문가 혼합 46 · 회전 위치 임베딩 68 · 그룹 쿼리 어텐션 10 · 상태공간모델 28 · 하이브리드 모델 64 · 월드 모델 40

학습·튜닝·정렬

학습 단계 6

사전학습 28 · 파인튜닝 60 · 사후학습 28 · 지도 미세조정 49 · 지시 튜닝 49 · 손실 마스킹 31

학습 데이터 5

학습 토큰 수 65 · 합성 데이터 65 · 사전학습 데이터 정제 28 · 커리큘럼 학습 54 · 데이터 오염 14

효율적 튜닝 7

매개변수 효율적 미세조정 19 · 로라 18 · 지식 증류 50 · 어댑터 34 · 큐로라 56 · 전체 파인튜닝 47 · 모델 병합 22

도메인 적응 4

도메인 적응 16 · 지속 사전학습 49 · 파국적 망각 59 · 지속학습 49

정렬과 강화학습 12

정렬 47 · 선호 데이터 30 · 인간 피드백 기반 강화학습 43 · 보상모델 25 · 직접 선호 최적화 50 · AI 피드백 기반 강화학습 70 · 헌법적 AI 66 · 근접 정책 최적화 11 · KL 패널티 73 · 그룹 상대 정책 최적화 10 · 검증가능 보상 기반 강화학습 6 · 보상 해킹 26

학습 인프라 6

체크포인트 52 · 혼합정밀도 학습 66 · 분산 학습 26 · 데이터 병렬화 14 · 텐서 병렬화 57 · 파이프라인 병렬화 59

프롬프트·추론

프롬프트 기초 7

프롬프트 61 · 프롬프트 엔지니어링 62 · 사용자 프롬프트 27 · 역할 부여(페르소나) 38 · 요약·재작성 프롬프트 40 · 시스템 프롬프트 33 · 컨텍스트 엔지니어링 54

예시 활용 4

제로샷 48 · 원샷 40 · 퓨샷 61 · 인컨텍스트 러닝 43

구조와 출력 형식 5

구분자 9 · 출력 형식 지정 53 · XML 태그 구조화 76 · 구조화된 출력 9 · 응답 미리 채우기 42

추론 유도 8

사고의 연쇄 27 · 추론 모델 52 · 확장 사고 67 · 자기일관성 44 · 트리 오브 소트 59 · 스텝백 프롬프팅 32 · 테스트 타임 컴퓨트 57 · 사고 예산 27

프롬프트 운영 6

바이브 코딩 23 · 프롬프트 템플릿 63 · 프롬프트 체이닝 62 · 메타 프롬프팅 21 · 프롬프트 버전 관리 62 · 프롬프트 최적화 62

RAG·검색·데이터

RAG 기초 6

검색 증강 생성 6 · 지식베이스 49 · 검색(리트리벌) 6 · 근거 기반 응답(출처 인용) 11 · 롱컨텍스트 대 RAG 18 · 캐시 증강 생성 53

데이터 기반 7

정형 데이터 47 · 비정형 데이터 26 · 데이터 파이프라인 15 · 데이터 품질 15 · 메타데이터 관리 21 · 데이터 카탈로그 15 · 데이터 레이크하우스 14

문서 준비 4

문서 파싱 23 · 청킹 52 · 청크 오버랩 51 · 맥락 검색 20

벡터 검색 7

임베딩 모델 44 · 벡터 데이터베이스 24 · 의미 검색 42 · 코사인 유사도 55 · 벡터 인덱스 25 · 근사 최근접 이웃 검색 11 · HNSW 72

검색 고도화 10

상위 k개 검색 28 · 메타데이터 필터링 21 · 하이브리드 검색 64 · 재순위화 46 · 쿼리 재작성 56 · BM25 71 · 문맥 압축 23 · 가상 문서 임베딩 5 · 멀티홉 검색 21 · 에이전틱 RAG 37

정형 지식 연계 4

지식 그래프 49 · 텍스트-투-SQL 57 · 그래프RAG 10 · 시맨틱 레이어 33

AI 에이전트·도구

에이전트 기초 8

에이전틱 AI 37 · AI 에이전트 69 · 워크플로 자동화 40 · 에이전트 루프 35 · 에이전틱 워크플로 37 · 계획 수립 7 · 반성(자기 성찰) 24 · 리액트(추론-행동) 19

도구 연결 7

도구 사용 16 · 함수 호출 65 · 모델 컨텍스트 프로토콜 22 · 커넥터 53 · 도구 스키마 16 · MCP 서버 73 · MCP 클라이언트 73

기억과 실행 관리 6

에이전트 메모리 36 · 에이전트 스킬 36 · 에이전트 상태 관리 36 · 장기 실행 작업 45 · 에이전트 지시 파일 36 · 재시도와 폴백 46

멀티 에이전트 6

멀티 에이전트 21 · 오케스트레이션 38 · 서브에이전트 30 · 핸드오프 65 · 에이전트 간 프로토콜 35 · 에이전트 프레임워크 37

에이전트 활용 4

컴퓨터 사용 54 · 브라우저 에이전트 26 · 코딩 에이전트 54 · 딥 리서치 17

통제와 평가 6

휴먼 인 더 루프 68 · 에이전트 권한 관리 35 · 자율성 수준 45 · 에이전트 샌드박스 36 · 에이전트 평가 37 · 에이전트 실행 궤적 36

생성 AI·멀티모달

생성 모델 원리 11

생성형 AI 29 · 확산 모델 67 · 생성적 적대 신경망 29 · 잠재 공간 45 · 변분 오토인코더 25 · 노이즈 제거 12 · 플로우 매칭 63 · 텍스트 인코더 57 · 클립(대조 언어-이미지 사전학습) 56 · 확산 트랜스포머 67 · 자기회귀 이미지 생성 45

이미지·영상 생성 8

텍스트-이미지 생성 57 · 이미지-이미지 변환 42 · 인페인팅 44 · 네거티브 프롬프트 12 · 업스케일링 35 · 영상 생성 38 · 컨트롤넷 54 · 3D 생성 5

멀티모달 이해 9

멀티모달 20 · 광학 문자 인식 9 · 시각 언어 모델 32 · 이미지 캡셔닝 42 · 시각 질의응답 32 · 문서 AI 23 · 네이티브 멀티모달 12 · 멀티모달 임베딩 20 · 화면 이해 66

음성·오디오 6

음성 합성 41 · 음성 인식 41 · 음성 복제 41 · 음성 에이전트 41 · 음악 생성 41 · 실시간 음성 대화 34

생성물 신뢰 3

딥페이크 17 · 생성물 저작권 29 · 콘텐츠 출처 증명 55

인프라·배포·LLMOps

하드웨어·칩 7

GPU 72 · NPU 74 · 고대역폭 메모리 7 · 데이터센터 전력 13 · 플롭스 63 · TPU 75 · CUDA 71

배포 환경 7

온프레미스 39 · 프라이빗 클라우드 61 · 하이브리드 클라우드 64 · 폐쇄망 배포 60 · 엣지 AI 38 · 소버린 AI 30 · 쿠버네티스 55

추론 서빙 7

API 71 · 지연 시간 50 · 추론 서빙 53 · 처리량 51 · 첫 토큰 지연 51 · 콜드 스타트 55 · vLLM 75

호출 관리 5

비동기 처리 26 · 배치 추론 24 · 레이트 리밋 18 · 모델 게이트웨이 22 · 폴백 모델 61

성능·비용 최적화 6

토큰 비용 58 · 양자화 34 · 프롬프트 캐싱 62 · 시맨틱 캐시 33 · GGUF 72 · TensorRT 75

운영·MLOps 6

MLOps 74 · LLMOps 73 · 관측 가능성 8 · A/B 테스트 71 · 모델 레지스트리 22 · 드리프트 모니터링 16

평가·안전·규제

신뢰성 기본 8

책임 있는 AI 51 · 환각 67 · 편향 60 · 공정성 8 · 아첨 34 · 근거성 11 · 설명 가능한 AI 30 · 기계적 해석가능성 12

평가 11

벤치마크 25 · 리더보드 19 · 정확도 48 · 평가 60 · MMLU 74 · 골든 데이터셋 8 · 인간 평가 42 · LLM 심판 평가 73 · 회귀 테스트 68 · 오프라인·온라인 평가 39 · SWE-bench 75

공격과 방어 10

프롬프트 인젝션 62 · 탈옥 56 · 가드레일 5 · 콘텐츠 필터 55 · 레드티밍 17 · 간접 프롬프트 인젝션 5 · 탈옥 대응 56 · 데이터 포이즈닝 15 · 적대적 공격 46 · 모델 탈취 22

데이터 보호 4

데이터 프라이버시 15 · 가명처리 5 · PII 마스킹 74 · 데이터 유출 15

투명성·기록 4

워터마킹 40 · 모델 카드 22 · 감사 추적 6 · 시스템 카드 33

법·규제 8

인공지능 기본법 43 · EU 인공지능법 72 · 생성형 AI 표시 의무 29 · 고영향 인공지능 8 · 금융분야 AI 가이드라인 11 · AI 위험관리 프레임워크 70 · AI 안전연구소 69 · 책임 있는 확장 정책 51

AX·비즈니스 적용

AI 전환 기본 7

디지털 전환 16 · AI 전환 70 · AI 도입 69 · 활용 사례 67 · 코파일럿 55 · 데이터 기반 의사결정 14 · AI 네이티브 68

전략·로드맵 6

개념 검증 6 · AI 전략 70 · AI 성숙도 모델 69 · AX 전환 로드맵 71 · 업무 재설계 35 · 확산 66

비용·투자 판단 7

투자 대비 효과 58 · AI 비용 69 · 총소유비용 52 · 생산성 지표 29 · 자체 구축 대 구매 45 · 벤더 종속 25 · 서비스 수준 협약 30

조직·인재 8

AI 리터러시 69 · 변화관리 25 · AI 전담 조직 70 · AI 챔피언 70 · 리스킬링·업스킬링 19 · 시티즌 개발자 33 · 프롬프트 라이브러리 61 · 내재화 12

거버넌스·제도 5

AI 거버넌스 68 · 섀도 AI 29 · 사내 LLM 포털 27 · 망분리 규제 개선 19 · 규제 샌드박스 10

# #

3D 생성

3D Generation

생성 AI·멀티모달 · 심화

입문 글이나 사진 한 장으로 입체 3D 모델이나 장면을 만들어 내는 기술이다.

심화 텍스트·이미지에서 메시, NeRF, 3D 가우시안 스플래팅 등의 3D 표현을 생성한다. 다시점 이미지를 먼저 생성한 뒤 3D로 재구성하는 방식과 3D 표현을 직접 생성하는 방식이 있으며, 형상 정확도, 텍스처 품질, 편집 가능한 메시 토폴로지가 과제다. 게임·디지털 트윈·제품 시각화에 쓰인다.

연관 생성형 AI, 확산 모델, 이미지-이미지 변환, 멀티모달

출처 Hugging Face · Wikipedia / 논문 Mildenhall et al. 2020 · Poole et al. 2022 · Kerbl et al. 2023

ㄱ

가드레일

Guardrail

평가·안전·규제 · 실무

입문 AI가 위험하거나 엉뚱한 답을 하지 않도록 입력과 출력을 걸러주는 안전장치다. 도로의 가드레일처럼 정해진 길을 벗어나지 않게 막는다.

심화 모델 앞뒤에 배치하는 규칙·분류기·검증 로직의 총칭이다. 입력 단계에서는 프롬프트 인젝션·탈옥·PII를 탐지하고, 출력 단계에서는 유해 콘텐츠, 주제 이탈, 형식 오류, 근거 없는 답변을 차단하거나 수정한다. 정규식·키워드 규칙, 경량 분류 모델, LLM 기반 판정을 조합하며, 과도하게 걸면 정상 요청까지 막는 과잉 거부가 생기므로 오탐률을 함께 관리해야 한다.

예시 사내 챗봇에 계좌번호·주민등록번호가 입력되면 가드레일이 자동 마스킹한 뒤 모델에 전달한다.

연관 콘텐츠 필터, PII 마스킹, 프롬프트 인젝션, 탈옥, 책임 있는 AI

출처 NVIDIA / 논문 Rebedea et al. 2023 · Inan et al. 2023

가명처리

Pseudonymization

평가·안전·규제 · 실무

입문 이름·주민번호처럼 누구인지 알 수 있는 정보를 바꾸거나 지워서, 추가 정보 없이는 개인을 알아볼 수 없게 만드는 처리다.

심화 국내 개인정보 보호법상 가명정보는 추가 정보 없이 특정 개인을 알아볼 수 없도록 처리한 정보로, 통계작성·과학적 연구·공익적 기록보존 목적이면 정보주체 동의 없이 처리할 수 있다. 다만 추가 정보와 결합하면 재식별이 가능하므로 개인정보에 해당하며, 추가 정보 분리 보관과 재식별 금지 등 안전조치가 필요하다. 다시는 식별할 수 없게 만드는 익명처리와 구분된다. AI 학습 데이터 활용 시 핵심 수단이며, 재식별 위험 평가가 함께 이뤄져야 한다.

예시 카드 거래 데이터를 가명처리해 이상거래 탐지 모델 학습에 활용하고, 매핑 테이블은 별도 서버에 보관한다.

연관 데이터 프라이버시, PII 마스킹, 학습 데이터, 데이터 유출, 합성 데이터

출처 국가법령정보센터 · 국가법령정보센터 · Wikipedia

가상 문서 임베딩

HyDE · Hypothetical Document Embeddings

RAG·검색·데이터 · 심화

입문 질문으로 바로 검색하지 않고, AI가 먼저 '그럴듯한 답변 문서'를 써 본 뒤 그 글과 비슷한 실제 문서를 찾는 방법이다.

심화 LLM이 질의에 대한 가상의 답변을 생성하고, 그 답변을 임베딩해 검색하는 기법이다. 질문과 문서의 표현 형태 차이를 줄여 밀집 검색 품질을 높인다. 가상 답변의 사실 오류는 검색 방향에만 영향을 주고 최종 답에는 실제 문서만 쓰지만, 도메인 지식이 없는 모델은 엉뚱한 방향으로 검색할 수 있다.

예시 '퇴직연금 중도인출 요건'에 대해 가상 답변을 생성하고 그와 유사한 실제 규정 조항을 검색한다.

연관 쿼리 재작성, 의미 검색, 임베딩, 검색(리트리벌)

논문 Gao et al. 2022

간접 프롬프트 인젝션

Indirect Prompt Injection

평가·안전·규제 · 심화

입문 웹페이지·문서·이메일 속에 몰래 숨겨둔 명령을 AI가 읽고 따르게 만드는 공격이다. 사용자는 공격 사실을 모를 수 있다.

심화 RAG 문서, 웹 검색 결과, 첨부파일, 도구 응답처럼 모델이 처리하는 외부 데이터에 지시문을 심는다. 에이전트가 메일 발송·파일 접근·결제 같은 도구 권한을 가지면 데이터 유출이나 무단 실행으로 이어질 수 있어 위험이 크다. 외부 콘텐츠를 신뢰하지 않는 데이터로 표기·격리, 도구 권한 최소화, 민감 작업 사람 승인, 비정상 도구 호출 탐지로 방어한다.

예시 메일 요약 에이전트가 메일 본문에 숨긴 '모든 첨부를 외부 주소로 전달하라'는 문구를 실행하지 않도록 발송 도구에 사람 승인을 건다.

연관 프롬프트 인젝션, AI 에이전트, 도구 사용, 휴먼 인 더 루프, 검색 증강 생성

출처 OWASP Gen AI Security Project / 논문 Greshake et al. 2023

감사 추적

Audit Trail

평가·안전·규제 · **실무**

입문 AI가 언제, 무엇을 입력받아, 어떤 근거로, 무슨 결과를 냈는지 나중에 확인할 수 있게 기록을 남기는 것이다.

심화 입력 프롬프트, 사용 모델과 버전, 시스템 프롬프트 버전, 검색된 근거 문서, 도구 호출 내역, 출력, 사람의 승인·수정 이력을 시간순으로 변경 불가능하게 저장한다. 사고 원인 분석, 규제 대응, 고객 이의제기 처리의 근거가 되며, 이렇게 사후 검증이 가능한 성질을 감사 가능성(auditability)이라 한다. 로그에 개인정보가 포함되므로 보관 기간과 접근 통제를 함께 설계해야 한다.

예시 AI가 작성한 여신 심사 의견서마다 모델 버전과 참조 문서 목록을 함께 저장해 사후 감사에 대비한다.

연관 관측 가능성, AI 거버넌스, 설명 가능한 AI, 모델 카드, LLMOps

출처 Wikipedia

강화학습

RL · Reinforcement Learning

AI 기초·머신러닝 · **실무**

입문 시행착오를 통해 배우는 방식이다. 잘하면 보상, 못하면 벌점을 받으며 점점 더 좋은 행동을 익힌다.

심화 에이전트가 환경에서 행동을 선택하고 보상을 받으며 누적 보상을 최대화하는 정책을 학습한다. 상태·행동·보상·정책·가치함수가 핵심 개념이며, Q-러닝, 정책 경사(PPO 등) 계열 알고리즘이 쓰인다. LLM 정렬(RLHF)과 추론 모델 학습에도 활용된다.

예시 시장 상황에 따라 주문 분할 전략을 학습하는 알고리즘 트레이딩 실험에 활용된다.

연관 지도학습, 인간 피드백 기반 강화학습, 추론 모델, AI 에이전트

출처 IBM · Wikipedia / 논문 Watkins and Dayan 1992 · Mnih et al. 2015 · Schulman et al. 2017

개념 검증

PoC · Proof of Concept

AX·비즈니스 적용 · **입문**

입문 본격 도입 전에 아이디어가 실제로 될지 작은 규모로 시험해 보는 것이다.

심화 제한된 데이터와 범위에서 기술적 실현 가능성과 기대 효과를 짧은 기간에 검증한다. 성공 기준(정확도, 시간 절감, 비용)을 사전에 정하지 않으면 결과 해석이 어려워지고, 실제 운영 데이터·보안·연계 조건을 빼고 진행하면 확산 단계에서 실패하기 쉽다.

예시 여신 심사 서류 요약 PoC에서 심사역 20명이 4주간 사용해 검토 시간 절감률과 오류율을 측정했다.

연관 확산, 활용 사례, 투자 대비 효과, AI 도입

출처 Wikipedia

검색 증강 생성

RAG · Retrieval-Augmented Generation

RAG·검색·데이터 · **입문**

입문 AI가 답하기 전에 관련 문서를 먼저 찾아 보고, 그 내용을 근거로 답하게 하는 방식이다. 오픈북 시험과 비슷하다.

심화 질문과 관련된 문서를 검색(retrieval)해 프롬프트에 넣은 뒤 LLM이 그 근거로 답을 생성하는 구조다. 수집·파싱·청킹·임베딩·색인의 적재 단계와 검색·재순위화·생성의 질의 단계로 구성된다. 재학습 없이 최신·사내 지식을 반영하고 출처를 제시할 수 있으나, 검색 품질이 낮으면 답도 틀리므로 검색 단계 평가가 핵심이다.

예시 사내 규정·상품설명서를 색인해 직원이 '중도상환수수료 면제 조건'을 물으면 해당 조항을 근거로 답하는 챗봇을 만든다.

연관 검색(리트리벌), 벡터 데이터베이스, 청킹, 임베딩, 근거 기반 응답(출처 인용)

출처 AWS · Wikipedia / 논문 Lewis et al. 2020 · Karpukhin et al. 2020

검색(리트리벌)

Retrieval

RAG·검색·데이터 · **실무**

입문 질문에 맞는 자료를 많은 문서 중에서 찾아오는 단계다. RAG에서 '찾아보기'에 해당한다.

심화 질의에 대해 관련성 높은 문서나 청크를 후보 집합에서 골라내는 과정이다. 키워드 기반(BM25 등 희소 검색), 임베딩 기반(밀집 검색), 둘을 섞은 하이브리드 검색이 있으며, 상위 후보를 재순위화해 정밀도를 높인다. 재현율(필요한 문서를 놓치지 않는가)과 정밀도(불필요한 문서를 줄이는가)로 평가한다.

예시 직원 질문에 대해 규정 문서 1만 건 중 관련 조항 5개를 뽑아 LLM에 전달한다.

연관 검색 증강 생성, 의미 검색, BM25, 하이브리드 검색, 상위 k개 검색

출처 Wikipedia / 논문 Karpukhin et al. 2020 · Robertson and Zaragoza 2009

검증가능 보상 기반 강화학습

RLVR · Reinforcement Learning with Verifiable Rewards

학습·튜닝·정렬 · **심화**

입문 수학 정답 확인이나 코드 테스트 통과처럼 자동으로 맞고 틀림을 판정할 수 있는 문제로 AI를 강화학습시키는 방법이다.

심화 학습된 보상모델 대신 정답 일치, 단위 테스트, 형식 검사 같은 규칙 기반 검증기를 보상으로 사용한다. 보상 해킹 여지가 상대적으로 적고 대규모로 확장하기 쉬워 긴 사고 과정을 가진 추론 모델 학습의 핵심 방법이 되었다. 정답 판정이 어려운 개방형 작업에는 직접 적용하기 어렵고, 기존 능력을 끌어내는 것인지 새 능력을 만드는 것인지는 연구 논쟁 중이다.

연관 그룹 상대 정책 최적화, 추론 모델, 사후학습, 보상 해킹, 테스트 타임 컴퓨트

논문 Lambert et al. 2024 · DeepSeek-AI 2025

게이트 순환 유닛

GRU · Gated Recurrent Unit

딥러닝·신경망 · **심화**

입문 LSTM을 단순하게 줄인 순환 신경망으로, 비슷한 성능을 더 적은 계산으로 낸다.

심화 업데이트 게이트와 리셋 게이트 두 개로 LSTM의 셀·은닉 상태를 통합한 RNN 변형이다. 파라미터가 적어 학습이 빠르며 많은 과제에서 LSTM과 비슷한 성능을 보인다.

연관 장단기 메모리, 순환 신경망, 기울기 소실

출처 Wikipedia / 논문 Cho et al. 2014

결정 트리

Decision Tree

AI 기초·머신러닝 · **입문**

입문 '소득이 3천만 원 이상인가? → 연체 이력이 있는가?'처럼 질문을 이어가며 결론에 도달하는 스무고개형 모델이다.

심화 피처 조건으로 데이터를 재귀적으로 분할해 트리 구조를 만드는 모델이다. 지니 불순도나 엔트로피 감소가 큰 분할을 선택한다. 해석이 쉽고 전처리 부담이 적지만 단독으로는 과적합되기 쉬워 깊이 제한·가지치기를 하거나 앙상블의 기본 학습기로 쓴다.

예시 대출 거절 사유를 설명하기 쉬워 심사 보조용 규칙 도출에 결정 트리를 활용한다.

연관 랜덤 포레스트, 그래디언트 부스팅, 앙상블 학습, 설명 가능한 AI, 분류

출처 IBM · Wikipedia / 논문 Quinlan 1986

경사하강법

Gradient Descent

딥러닝·신경망 · **실무**

입문 안개 낀 산에서 발밑의 경사만 보고 조금씩 아래로 내려가 가장 낮은 곳(오차 최소)을 찾는 방법이다.

심화 손실함수의 기울기 반대 방향으로 파라미터를 반복 갱신해 손실을 최소화하는 최적화 방법이다. $\theta \leftarrow \theta - \eta \nabla L(\theta)$이며 η는 학습률이다. 전체 데이터를 쓰는 배치 방식, 표본 하나 또는 미니배치를 쓰는 확률적 방식(SGD)이 있고, 모멘텀·Adam 같은 변형이 실무 표준이다.

연관 학습률, 확률적 경사하강법, 옵티마이저, 역전파, 손실 함수

출처 IBM · Wikipedia / 논문 Ruder 2016

계획 수립

Planning

AI 에이전트·도구 · **실무**

입문 큰 목표를 작은 단계로 쪼개고 순서를 정하는 에이전트의 능력이다. 여행 전에 일정표를 짜는 것과 같다.

심화 에이전트가 실행 전에 작업을 하위 과제로 분해하고 의존 관계와 순서를 정하는 단계다. 처음에 전체 계획을 세우고 실행하는 plan-and-execute 방식과, 매 단계 상황을 보며 다음 행동을 정하는 방식이 있으며, 실행 결과에 따라 계획을 수정(re-planning)하는 능력이 중요하다. 계획을 할 일 목록 형태로 외부화하면 장기 작업에서 진행 상황 추적이 쉬워진다.

예시 월말 결산 점검 요청을 받으면 에이전트가 '원장 대사 → 미결 항목 추출 → 담당 부서별 정리 → 보고서 작성'으로 계획을 세운다.

연관 AI 에이전트, 반성(자기 성찰), 추론 모델, 장기 실행 작업

출처 IBM / 논문 Wang et al. 2023 · Yao et al. 2023 · Shen et al. 2023

고대역폭 메모리

HBM · High Bandwidth Memory

인프라·배포·LLMOps · **실무**

입문 메모리 칩을 여러 층 쌓아 데이터 전달 속도를 크게 높인 메모리다. AI용 GPU의 성능을 좌우하는 핵심 부품이다.

심화 DRAM 다이를 수직 적층하고 TSV로 연결해 GPU 옆에 배치함으로써 수 TB/s급 대역폭을 제공한다. LLM 추론, 특히 토큰 생성 단계는 연산보다 메모리 대역폭에 제한되는 경우가 많아 HBM 용량·대역폭이 처리 속도와 올릴 수 있는 모델 크기를 결정한다. 한국 메모리 기업들이 주요 공급자다.

예시 GPU 선정 시 연산 성능보다 HBM 용량을 먼저 보고 모델과 KV 캐시가 들어갈지 계산했다.

연관 GPU, KV 캐시, 처리량, 데이터센터 전력

출처 Wikipedia

고영향 인공지능

High-Impact AI

평가·안전·규제 · **실무**

입문 사람의 생명·안전이나 기본권에 큰 영향을 줄 수 있는 분야에 쓰이는 AI로, 한국 AI 기본법이 더 엄격한 의무를 지우는 대상이다.

심화 AI 기본법은 에너지, 먹는물, 보건의료, 원자력, 범죄 수사, 채용, 대출 심사 등 신용 판단, 교통, 공공서비스, 교육 등의 영역에서 생명·신체·기본권에 중대한 영향을 미칠 수 있는 AI를 고영향 AI로 정한다. 사업자는 해당 여부를 사전 검토하고, 해당 시 위험관리 방안, 판단 기준 설명, 이용자 보호, 사람의 관리·감독, 안전·신뢰 조치 문서화 등을 이행해야 한다. 사람이 최종 결정에 실질적으로 관여하는 구조인지가 판단에 영향을 준다는 해석이 제시되고 있다. EU AI Act의 고위험 AI와 비슷하지만 범위와 의무 구성은 다르다.

예시 AI가 대출 승인 여부를 자동 결정하는 시스템은 고영향 AI 해당 가능성이 높아 위험관리·설명 체계를 갖춘다.

연관 인공지능 기본법, EU 인공지능법, 휴먼 인 더 루프, 설명 가능한 AI, 금융분야 AI 가이드라인

출처 국가법령정보센터 · 국가법령정보센터

골든 데이터셋

Golden Dataset

평가·안전·규제 · **실무**

입문 전문가가 정답을 검수해 만든 기준 시험 문제 모음이다. AI를 바꿀 때마다 이 문제로 다시 시험을 본다.

심화 실제 업무 질의 분포를 반영한 입력과 검증된 기대 출력(또는 채점 기준)으로 구성한다. 대표 사례, 경계 사례, 과거 실패 사례, 거절해야 할 요청을 고르게 포함해야 하며, 규모보다 품질과 대표성이 중요하다. 학습·튜닝 데이터와 분리 보관해 오염을 막고, 업무 변화에 맞춰 버전 관리하며 갱신한다.

예시 콜센터 상위 300개 문의 유형에 대해 상담팀이 검수한 모범 답변을 골든 데이터셋으로 만든다.

연관 평가, 회귀 테스트, 벤치마크, LLM 심판 평가, 데이터 오염

출처 Anthropic (Claude Platform Docs)

공정성

Fairness

평가·안전·규제 · **실무**

입문 AI가 성별·연령·지역 같은 특성 때문에 특정 집단을 부당하게 불리하게 대하지 않는 성질이다.

심화 집단 간 긍정 판정 비율을 맞추는 인구통계적 동등성, 집단 간 오류율을 맞추는 균등 오즈, 개인 단위로 비슷한 사람을 비슷하게 대하는 개인 공정성 등 여러 정의가 있고, 이들은 동시에 만족시키기 어려운 경우가 많다. 따라서 업무 맥락에 맞는 공정성 지표를 먼저 정하고, 보호 속성별 성능을 측정·모니터링하는 절차가 필요하다.

예시 카드 한도 산정 모델의 성별·연령대별 승인율과 오거절률을 분기마다 보고한다.

연관 편향, 책임 있는 AI, 설명 가능한 AI, 고영향 인공지능, 평가

출처 Wikipedia / 논문 Dwork et al. 2011 · Hardt et al. 2016

과소적합

Underfitting

AI 기초·머신러닝 · **실무**

입문 공부를 너무 대충 해서 연습 문제조차 못 푸는 상태다.

심화 모델이 데이터의 패턴을 충분히 학습하지 못해 학습·검증 오차가 모두 높은 상태다. 모델이 너무 단순하거나, 피처가 부족하거나, 정규화가 과하거나, 학습이 덜 된 경우 발생한다. 모델 용량 확대, 피처 추가, 학습 연장으로 개선한다.

예시 선형 모델 하나로 복잡한 사기 패턴을 잡으려 하면 학습 데이터에서도 탐지율이 낮게 나온다.

연관 과적합, 편향-분산 트레이드오프, 피처 엔지니어링, 정규화(규제)

출처 IBM · Wikipedia

과적합

Overfitting

AI 기초·머신러닝 · **입문**

입문 기출문제 답만 외워서 시험 범위 밖 문제는 못 푸는 학생과 같다. 학습 데이터에만 지나치게 맞춰져 새 데이터에서 성능이 떨어진다.

심화 모델이 학습 데이터의 잡음까지 암기해 학습 오차는 낮지만 검증·테스트 오차가 높은 상태다. 모델 복잡도가 데이터 양에 비해 클 때 발생하며, 정규화, 드롭아웃, 조기 종료, 데이터 증강, 교차검증으로 완화한다.

예시 과거 3개월 데이터에만 맞춘 이탈 예측 모델이 다음 분기에 성능이 급락하는 경우가 전형적이다.

연관 과소적합, 정규화(규제), 교차검증, 편향-분산 트레이드오프, 드롭아웃

출처 IBM · Wikipedia / 논문 Srivastava et al. 2014

관측 가능성

Observability

인프라·배포·LLMOps · **실무**

입문 AI 시스템 내부에서 무슨 일이 일어나는지 로그·지표·추적 정보로 들여다볼 수 있는 능력이다.

심화 LLM 애플리케이션에서는 프롬프트·응답, 토큰 사용량, 지연, 오류, 검색 결과, 도구 호출을 단계별 트레이스로 기록한다. 품질 저하, 비용 급증, 환각 원인 분석과 감사 대응에 필수이며, 기록 시 개인정보 마스킹과 보존 정책을 함께 설계해야 한다.

예시 RAG 챗봇의 오답 사례를 트레이스로 추적해 검색 단계에서 잘못된 약관 문서가 선택된 것을 찾았다.

연관 LLMOps, 드리프트 모니터링, 토큰 비용, 데이터 프라이버시

출처 OpenTelemetry

광학 문자 인식

OCR · Optical Character Recognition

생성 AI·멀티모달 · **입문**

입문 종이 문서나 사진 속 글자를 컴퓨터가 읽을 수 있는 텍스트로 바꾸는 기술이다.

심화 전통적으로 문자 영역 검출과 문자 인식 모델을 결합한 파이프라인이었으나, 최근에는 VLM이 레이아웃·표·손글씨까지 한 번에 구조화된 텍스트로 변환하기도 한다. 기존 OCR은 결과가 안정적이고 좌표 정보를 주는 반면, VLM 기반은 맥락 이해가 뛰어나지만 없는 글자를 만들어 내는 환각 위험이 있어 검증이 필요하다.

예시 대출 신청 서류의 신분증·소득 증빙을 OCR로 읽어 입력 항목을 자동 채운다.

연관 문서 AI, 시각 언어 모델, 멀티모달, 워크플로 자동화

출처 AWS · IBM · Wikipedia / 논문 Li et al. 2021 · Kim et al. 2021

교차검증

CV · Cross-Validation

AI 기초·머신러닝 · **실무**

입문 데이터를 여러 조각으로 나눠 번갈아 시험 보게 해서, 운 좋게 점수가 잘 나온 것인지 확인하는 방법이다.

심화 데이터를 k개 폴드로 나누고 하나씩 검증용으로 돌려가며 k번 학습·평가해 평균 성능을 구한다(k-fold). 데이터가 적을 때 성능 추정의 분산을 줄이고 하이퍼파라미터 선택에 쓴다. 불균형 데이터는 층화(stratified), 시계열은 시간 순서를 지키는 롤링 방식을 사용한다.

예시 사기 사례가 적은 데이터에서 층화 5-fold 교차검증으로 탐지 모델 성능을 안정적으로 추정한다.

연관 데이터셋 분할(학습/검증/테스트), 하이퍼파라미터, 과적합, 클래스 불균형

출처 scikit-learn · Wikipedia / 논문 Stone 1974

교차 엔트로피

Cross-Entropy

딥러닝·신경망 · **심화**

입문 AI가 정답에 얼마나 높은 확률을 줬는지로 채점하는 방식이다. 정답에 낮은 확률을 줄수록 벌점이 커진다.

심화 정답 분포와 예측 확률 분포 간 차이를 측정하는 손실로, 분류 문제의 표준이다. 원-핫 정답에서는 −log(정답 클래스 확률)이 된다. LLM 사전학습의 다음 토큰 예측 손실이며, 그 지수값이 퍼플렉시티다. 소프트맥스와 결합해 수치적으로 안정되게 계산한다.

연관 손실 함수, 소프트맥스, 분류, 다음 토큰 예측

출처 Wikipedia

구분자

Delimiter

프롬프트·추론 · **입문**

입문 프롬프트에서 지시와 자료 사이에 경계를 긋는 기호다. 따옴표 세 개(""")나 ### 같은 것을 쓴다.

심화 """, ###, ---, 백틱 블록, XML 태그 등으로 프롬프트의 섹션 경계를 표시하는 방법이다. 붙여 넣은 문서 안의 문장이 지시로 오인되는 것을 줄이고, 여러 입력을 구분해 참조하기 쉽게 한다. 구분자만으로 프롬프트 인젝션을 완전히 막을 수는 없다.

예시 '### 아래 고객 메일을 요약하라 ###' 다음에 메일 원문을 넣어 지시와 본문을 분리한다.

연관 XML 태그 구조화, 프롬프트 템플릿, 프롬프트 인젝션

출처 OpenAI · Wikipedia

구조화된 출력

Structured Output

프롬프트·추론 · **실무**

입문 AI 답변을 사람이 읽는 문장이 아니라 JSON처럼 프로그램이 바로 처리할 수 있는 정해진 형식으로 받는 것이다.

심화 모델 출력을 JSON Schema 등 미리 정의한 구조에 맞추도록 강제하는 기능이다. 프롬프트 지시만으로 유도할 수도 있지만, 제약 디코딩(constrained decoding)을 쓰는 API 기능을 사용하면 스키마 준수가 보장된다. 시스템 연동, 데이터 추출, 함수 호출 인자 생성의 기반이 된다.

예시 영수증 이미지에서 {거래일자, 가맹점, 금액, 부가세} JSON을 추출해 바로 적재 테이블에 INSERT한다.

연관 출력 형식 지정, 함수 호출, 프롬프트 체이닝, 광학 문자 인식

출처 OpenAI · Anthropic

군집화

Clustering

AI 기초·머신러닝 · **입문**

입문 정답 없이 비슷한 것끼리 알아서 무리 짓는 일이다.

심화 유사도 기준으로 데이터를 그룹(군집)으로 나누는 비지도학습 과제다. K-평균, 계층적 군집, DBSCAN, 가우시안 혼합 모델이 대표적이다. 군집 수 결정과 거리 척도 선택이 결과를 크게 좌우하며 실루엣 계수 등으로 평가한다.

예시 가맹점 매출 패턴을 군집화해 업종 분류가 잘못된 가맹점을 찾아낸다.

연관 비지도학습, 이상 탐지, 차원 축소, 임베딩

출처 IBM · IBM · Wikipedia / 논문 Lloyd 1982

규제 샌드박스

Regulatory Sandbox

AX·비즈니스 적용 · **실무**

입문 새로운 서비스를 기존 규제에 막히지 않고 일정 기간·조건 하에 시험 운영할 수 있도록 특례를 주는 제도다.

심화 금융 분야에서는 금융혁신지원특별법에 따른 혁신금융서비스 지정이 대표적이며, 지정 기간 동안 특정 규제 적용을 유예하는 대신 이용자 보호·보안 조건을 부과한다. 금융권 생성형 AI·클라우드 활용도 이 제도를 통해 먼저 허용된 뒤 제도화되는 경로를 밟고 있다.

예시 망분리 예외 적용을 위해 생성형 AI 기반 내부 업무 지원 서비스를 혁신금융서비스로 신청했다.

연관 망분리 규제 개선, AI 거버넌스, 개념 검증

출처 금융위원회

그래디언트 부스팅

GBM · Gradient Boosting

AI 기초·머신러닝 · **실무**

입문 앞선 모델이 틀린 부분을 다음 모델이 집중적으로 고쳐가며 차례로 쌓아 올리는 방식이다. XGBoost, LightGBM, CatBoost가 대표 구현체다.

심화 약한 학습기(주로 얕은 트리)를 순차적으로 추가하며 각 단계에서 손실함수의 음의 그래디언트(잔차)를 적합하는 부스팅 앙상블이다. XGBoost·LightGBM·CatBoost는 정규화, 히스토그램 분할, 범주형 처리 등을 최적화한 구현체로 정형 데이터 경진대회와 금융 실무에서 사실상 표준이다. 학습률과 트리 수의 균형, 조기 종료가 중요하다.

예시 LightGBM으로 고객 이탈 예측 모델을 만들고 SHAP 값으로 이탈 요인을 설명한다.

연관 앙상블 학습, 결정 트리, 랜덤 포레스트, 경사하강법, 설명 가능한 AI

출처 IBM · Wikipedia / 논문 Friedman 2001 · Chen and Guestrin 2016

그래프RAG

GraphRAG

RAG·검색·데이터 · **심화**

입문 문서를 단순 조각이 아니라 대상과 관계의 연결망(지식 그래프)으로 정리해 두고, 그 연결을 따라 검색하는 RAG다.

심화 LLM으로 문서에서 개체·관계를 추출해 지식 그래프를 만들고, 커뮤니티 탐지와 요약을 통해 그래프 구조를 검색에 활용하는 방식이다. '전체 문서의 주요 주제는?' 같은 전역 질문과 관계 기반 질문에서 일반 벡터 RAG보다 유리하다. 색인 비용이 크고 갱신이 어려워 대상 범위를 신중히 정해야 한다.

예시 내부감사 보고서 전체에서 반복 지적 사항과 관련 부서 관계를 그래프RAG로 요약한다.

연관 지식 그래프, 검색 증강 생성, 멀티홉 검색, 벡터 데이터베이스

출처 Microsoft / 논문 Edge et al. 2024

그래프 신경망

GNN · Graph Neural Network

딥러닝·신경망 · **심화**

입문 사람·계좌·기기처럼 서로 연결된 관계 데이터를 그대로 학습하는 신경망이다. 누가 누구와 거래하는지 같은 연결 구조에서 패턴을 찾는다.

심화 노드와 엣지로 이루어진 그래프에서 이웃 노드 정보를 반복적으로 집계(메시지 전달)해 노드·엣지·그래프 표현을 학습한다. GCN, GraphSAGE, GAT 등이 대표적이다. 관계 구조 자체가 신호인 사기 조직 탐지, 자금세탁 방지, 추천, 분자 모델링에 활용된다.

예시 계좌 간 이체 네트워크에 GNN을 적용해 대포통장·자금세탁 의심 계좌 군집을 탐지한다.

연관 지식 그래프, 이상 탐지, 임베딩, 신경망

출처 IBM · Wikipedia / 논문 Kipf & Welling 2016 · Hamilton et al. 2017 · Veličković et al. 2017

그룹 상대 정책 최적화

GRPO · Group Relative Policy Optimization

학습·튜닝·정렬 · **심화**

입문 한 질문에 여러 답을 만들게 한 뒤, 그 묶음 안에서 평균보다 나은 답은 강화하고 못한 답은 억제하는 강화학습 방법이다.

심화 DeepSeekMath 논문에서 제안된 PPO 변형으로, 별도 가치(critic) 모델 없이 같은 프롬프트에서 샘플링한 응답 그룹의 보상을 평균·표준편차로 정규화해 이점(advantage)으로 쓴다. 메모리와 연산 부담이 줄어 검증가능 보상과 결합한 추론 모델 학습에 널리 쓰인다. 길이 편향, 난이도 편향 등을 고친 DAPO, Dr. GRPO 같은 변형이 나왔다.

연관 근접 정책 최적화, 검증가능 보상 기반 강화학습, 추론 모델, 보상모델

출처 Hugging Face / 논문 Shao et al. 2024 · DeepSeek-AI 2025

그룹 쿼리 어텐션

GQA · Grouped-Query Attention

LLM·언어모델 · **심화**

입문 여러 어텐션 헤드가 일부 계산 결과를 나눠 써서 메모리를 아끼는 어텐션 방식이다.

심화 쿼리 헤드를 그룹으로 묶고 그룹마다 하나의 Key·Value 헤드를 공유한다. 멀티헤드 어텐션 대비 KV 캐시 크기를 크게 줄이면서 품질 저하는 작아 많은 최신 LLM이 채택했다. 극단적으로 모든 헤드가 KV를 공유하면 MQA, 더 압축한 변형으로 잠재 공간 어텐션(MLA) 등이 있다.

연관 KV 캐시, 어텐션, 추론 서빙

논문 Ainslie et al. 2023 · Shazeer 2019

그리디 디코딩

Greedy Decoding

LLM·언어모델 · 실무

입문 매 순간 가장 확률이 높은 단어만 골라 답을 만드는 방식이다. 결과가 일정하지만 단조로울 수 있다.

심화 각 스텝에서 argmax 토큰을 선택하는 결정적 디코딩이다. temperature 0 설정과 사실상 같으며 재현성이 필요한 추출·분류 작업에 유리하다. 다만 국소 최적만 따르므로 반복 루프에 빠지거나 전체적으로 최선인 문장을 놓칠 수 있다. 서빙 환경의 부동소수점 비결정성 때문에 완전한 재현이 보장되지는 않는다.

연관 샘플링, 빔 서치, 온도, 로짓

출처 Hugging Face · Hugging Face

근거성

Groundedness

평가·안전·규제 · 실무

입문 AI의 답이 주어진 자료에 실제로 근거하고 있는지를 보는 기준이다. 비슷한 개념인 사실성은 답이 세상의 사실과 맞는지를 본다.

심화 근거성(faithfulness)은 답변의 각 주장이 제공된 컨텍스트로 뒷받침되는지, 사실성(factuality)은 외부 사실과 일치하는지를 평가한다. RAG에서는 문서에 없는 내용을 덧붙이는 것이 근거성 위반이며, 문서 자체가 틀렸다면 근거성은 높아도 사실성은 낮을 수 있다. 주장 단위 분해 후 컨텍스트와 대조하는 LLM 심판 방식이 흔히 쓰인다.

예시 규정 질의응답 서비스의 답변을 문장 단위로 쪼개 인용 규정 조항과 일치하는지 자동 평가한다.

연관 환각, 검색 증강 생성, LLM 심판 평가, 평가, 검색(리트리벌)

출처 Microsoft Learn / 논문 Es et al. 2023

근거 기반 응답(출처 인용)

Grounding and Citation

RAG·검색·데이터 · 실무

입문 AI가 답할 때 어떤 자료를 근거로 했는지 출처를 함께 보여주고, 자료에 없는 내용은 지어내지 않게 하는 것이다.

심화 생성 결과를 검색된 문서나 신뢰할 수 있는 데이터에 묶어(grounding) 각 주장에 출처를 표시하는 기법이다. 프롬프트로 인용 형식을 지시하거나 API의 인용 기능을 사용하며, 인용된 문장이 실제로 근거를 뒷받침하는지 검증하는 평가가 필요하다. 금융·법무처럼 감사 추적이 필요한 분야에서 필수다.

예시 챗봇 답변 끝에 '[여신업무규정 제12조, 2026.07 개정]' 형태로 근거 조항과 링크를 표시한다.

연관 검색 증강 생성, 환각, 평가, 설명 가능한 AI

출처 Anthropic · Google Cloud / 논문 Gao et al. 2023

근사 최근접 이웃 검색

ANN · Approximate Nearest Neighbor

RAG·검색·데이터 · 심화

입문 수백만 개 벡터 중 가장 비슷한 것을 정확히 다 비교하지 않고, 조금의 오차를 감수하며 아주 빠르게 찾는 방법이다.

심화 전수 비교(exact kNN)의 높은 비용 대신 인덱스 구조로 탐색 범위를 줄여 근사 결과를 빠르게 반환하는 알고리즘군이다. HNSW(그래프), IVF(클러스터 분할), PQ(벡터 압축) 등이 있으며, 검색 속도·메모리·재현율 사이의 트레이드오프를 파라미터로 조정한다.

예시 1천만 건 상담 기록 임베딩에서 유사 사례를 수십 밀리초 내에 찾기 위해 ANN 인덱스를 사용한다.

연관 HNSW, 벡터 인덱스, 벡터 데이터베이스, 코사인 유사도

출처 Wikipedia · Microsoft / 논문 Malkov and Yashunin 2016 · Johnson et al. 2017

근접 정책 최적화

PPO · Proximal Policy Optimization

학습·튜닝·정렬 · 심화

입문 AI가 한 번에 너무 크게 바뀌지 않도록 조금씩 안정적으로 개선하는 강화학습 알고리즘이다.

심화 정책 비율을 클리핑한 대리 목적함수로 갱신 폭을 제한하는 정책 경사 알고리즘이다. RLHF에서는 정책, 기준 모델, 보상모델, 가치(critic) 모델 네 개를 동시에 다뤄 메모리와 구현 복잡도가 크다. 이 부담 때문에 DPO나 GRPO 같은 대안이 확산되었다.

연관 인간 피드백 기반 강화학습, 그룹 상대 정책 최적화, 보상모델, 강화학습, KL 패널티

출처 OpenAI · Wikipedia / 논문 Schulman et al. 2017 · Ziegler et al. 2019

금융분야 AI 가이드라인

Financial Sector AI Guidelines

평가·안전·규제 · 실무

입문 금융위원회가 금융회사의 AI 활용 시 지켜야 할 원칙을 정한 자율규제 지침이다.

심화 2021년 처음 마련된 뒤 2026년 6월 AI 기본법 시행과 생성형 AI 확산을 반영해 개정됐다. 거버넌스, 합법성, 보조수단성(최종 결정은 사람이 책임), 신뢰성(정확한 데이터와 고객 설명), 안정성, 신의성실(소비자 이익 우선), 보안성의 7대 원칙을 제시한다. 세부 이행을 위해 금융분야 AI 위험관리 프레임워크와 AI 보안 안내서가 함께 배포됐다. 법적 강제력보다는 업권 공통 기준 성격이며, 망분리·가명처리 등 관련 규제 정비가 병행되고 있다.

예시 대출 심사 AI는 심사 보고서 초안만 작성하고 최종 승인은 심사역이 하도록 업무 흐름을 설계한다.

연관 인공지능 기본법, 고영향 인공지능, AI 거버넌스, AI 위험관리 프레임워크, 휴먼 인 더 루프

출처 금융위원회

기계적 해석가능성

Mechanistic Interpretability

평가·안전·규제 · **심화**

입문 AI 모델의 내부를 뜯어보고 어떤 신경 회로가 어떤 개념과 계산을 담당하는지 밝혀내려는 연구 분야다. AI의 뇌 지도 그리기에 비유할 수 있다.

심화 뉴런·어텐션 헤드·잔차 스트림의 활성화를 분석해 모델이 수행하는 알고리즘을 역설계한다. 희소 오토인코더로 중첩된 표현에서 해석 가능한 특징(feature)을 추출하고, 특징 간 연결을 추적하는 회로 분석이 대표 기법이다. 입력·출력 관계만 보는 사후 설명과 달리 실제 내부 메커니즘을 대상으로 하며, 기만·위험 행동 탐지 같은 안전 응용이 기대되지만 대형 모델 전체를 설명하기에는 아직 초기 단계다.

연관 설명 가능한 AI, 정렬, 신경망, 트랜스포머, 피처(특성)

출처 Wikipedia / 논문 Olah et al. 2020 · Cunningham et al. 2023

기울기 소실

Vanishing Gradient

딥러닝·신경망 · **심화**

입문 깊은 신경망에서 오차 신호가 앞쪽 층으로 갈수록 점점 약해져, 앞쪽 층이 거의 학습되지 않는 문제다.

심화 역전파 시 1보다 작은 미분값이 층마다 곱해져 기울기가 지수적으로 작아지는 현상이다. 반대로 커지면 기울기 폭주라 한다. 시그모이드·tanh 활성화와 긴 RNN에서 심했으며 ReLU, 적절한 가중치 초기화, 잔차 연결, 정규화 층, LSTM 게이트, 기울기 클리핑으로 완화한다.

연관 역전파, 잔차 연결, 활성화 함수, 장단기 메모리, 순환 신경망

출처 Wikipedia / 논문 Bengio et al. 1994 · He et al. 2015

ㄴ

내재화

AI Insourcing

AX·비즈니스 적용 · **실무**

입문 외부 업체에 맡기던 AI 기술과 운영 역량을 회사 내부 인력이 직접 할 수 있도록 갖추는 것이다.

심화 핵심 역량(활용 사례 기획, 프롬프트·RAG 설계, 평가, 운영)은 내부에 두고 범용·일회성 작업은 외부를 활용하는 구분이 필요하다. 외부 구축 과제에 내부 인력을 공동 참여시키고 산출물·지식 이전 조건을 계약에 넣는 방식으로 추진한다.

예시 외주로 구축한 RAG 시스템의 프롬프트와 평가셋 관리를 내부 인력이 맡도록 공동 운영 기간을 두었다.

연관 자체 구축 대 구매, 리스킬링·업스킬링, AI 전담 조직, 벤더 종속

네거티브 프롬프트

Negative Prompt

생성 AI·멀티모달 · **실무**

입문 이미지 생성 시 '이런 것은 넣지 마라'고 따로 적어 주는 지시다. 예: 흐릿함, 글자, 왜곡된 손.

심화 분류기 없는 가이던스(CFG)에서 무조건(빈) 프롬프트 대신 원치 않는 특징을 담은 텍스트를 사용해, 생성 방향을 그 특징에서 멀어지게 하는 기법이다. 가이던스 강도와 함께 조정하며, 최신 모델 중에는 CFG를 증류해 네거티브 프롬프트를 지원하지 않거나 효과가 약한 경우도 있다.

연관 텍스트-이미지 생성, 프롬프트, 확산 모델, 프롬프트 엔지니어링

출처 Hugging Face / 논문 Ho, Salimans 2022

네이티브 멀티모달

Native Multimodal Model

생성 AI·멀티모달 · **심화**

입문 처음부터 글, 그림, 소리를 함께 배워서 여러 형태를 자연스럽게 넘나드는 AI 모델이다.

심화 별도로 학습된 인코더·디코더를 이어 붙이는 대신 여러 모달리티를 하나의 모델에서 공동 학습해, 입력과 출력 모두에서 텍스트·이미지·음성을 다룰 수 있게 한 구조다. 모달리티 간 정보 손실이 적고 음성의 감정·억양 같은 비언어 정보를 보존하기 쉽지만 학습 데이터와 비용 요구가 크다. 옴니(omni) 모델이라고도 부른다.

연관 멀티모달, 시각 언어 모델, 실시간 음성 대화, 자기회귀 이미지 생성

출처 OpenAI / 논문 Gemini Team 2023 · Chameleon Team 2024

노이즈 제거

Denoising

생성 AI·멀티모달 · **심화**

입문 잡음 섞인 데이터에서 잡음을 걷어 내 원래 모습을 되살리는 과정이다. 확산 모델은 이것을 반복해 그림을 만든다.

심화 확산 모델의 신경망은 특정 시점의 노이즈 낀 입력에서 추가된 노이즈(또는 원본, 속도 벡터)를 예측하도록 학습한다. 생성 시 스케줄러가 정한 단계 수만큼 예측과 갱신을 반복하며, 단계 수가 품질과 속도의 트레이드오프를 결정한다. 증류 기법으로 수 단계 이내에 생성하는 모델도 있다.

연관 확산 모델, 플로우 매칭, 잠재 공간, 지식 증류

출처 Hugging Face · Hugging Face / 논문 Ho et al. 2020 · Song et al. 2020 · Song et al. 2023

ㄷ

다국어 모델

Multilingual Model

LLM·언어모델 · **실무**

입문 한국어, 영어 등 여러 언어를 한 모델로 이해하고 생성하는 언어모델이다.

심화 여러 언어 말뭉치를 함께 사전학습해 언어 간 지식 전이가 일어나도록 한다. 학습 데이터에서 비중이 낮은 언어는 성능과 토큰 효율이 떨어지기 쉬워 어휘 확장, 언어별 추가 사전학습으로 보완한다. 문화·제도 맥락 이해는 번역 능력과 별개로 평가해야 한다.

예시 해외 지점 문서를 다국어 모델로 요약해 본사 보고서를 한국어로 작성한다.

연관 토크나이저, 한국어 토큰 효율, 지속 사전학습, 소버린 AI

논문 Conneau et al. 2020 · Rust et al. 2021

다음 토큰 예측

Next-Token Prediction

LLM·언어모델 · **실무**

입문 앞 내용을 보고 바로 다음에 올 글자 조각을 맞히는 방식이다. LLM은 이 일을 반복해 긴 글을 만든다.

심화 앞선 토큰 시퀀스가 주어졌을 때 다음 토큰의 확률분포를 예측하도록 교차 엔트로피 손실로 학습하는 목표 함수다. 정답 레이블이 텍스트 자체에서 나오므로 자기지도 학습이 가능해 대규모 사전학습의 핵심이 된다. 생성 시에는 이 분포에서 토큰을 하나씩 골라 이어 붙인다.

연관 자기회귀 모델, 사전학습, 로짓, 샘플링, 손실 함수

출처 Wikipedia · Wikipedia / 논문 Brown et al. 2020

다층 퍼셉트론

MLP · Multi-Layer Perceptron

딥러닝·신경망 · **실무**

입문 인공 뉴런을 여러 층으로 쌓고 층과 층을 빠짐없이 연결한 가장 기본적인 신경망이다.

심화 입력층과 출력층 사이에 하나 이상의 은닉층을 둔 완전연결(피드포워드) 신경망이다. 비선형 활성화로 복잡한 결정 경계를 학습한다. 정형 데이터 모델, 임베딩 위의 분류 헤드, 트랜스포머 블록 내부의 피드포워드 층(FFN)으로 쓰인다.

연관 퍼셉트론, 은닉층, 신경망, 활성화 함수

출처 Wikipedia / 논문 Rumelhart et al. 1986 · Hornik et al. 1989

대규모 언어모델

LLM · Large Language Model

LLM·언어모델 · **입문**

입문 방대한 글을 읽고 배워 사람처럼 글을 이해하고 써 주는 AI다. 질문 답변, 요약, 번역, 코드 작성 등을 한 모델로 처리한다.

심화 수십억~수조 개 파라미터를 가진 트랜스포머 기반 신경망으로, 대규모 텍스트에서 다음 토큰 예측으로 사전학습한 뒤 지시 튜닝·선호 정렬로 후처리한다. 범용성이 높지만 환각, 지식 컷오프, 높은 추론 비용이 한계다.

예시 은행 상담센터에서 LLM으로 상담 내용을 요약하고 후속 조치 메모를 자동 작성한다.

연관 트랜스포머, 다음 토큰 예측, 파운데이션 모델, 사전학습, 토큰

출처 AWS · Wikipedia / 논문 Vaswani et al. 2017 · Brown et al. 2020

데이터센터 전력

Data Center Power

인프라·배포·LLMOps · **실무**

입문 AI 서버를 돌리고 식히는 데 드는 전기다. GPU 서버는 일반 서버보다 훨씬 많은 전력을 쓴다.

심화 최신 GPU 서버는 대당 수~십수 kW를 소비해 랙당 전력 밀도가 기존 전산실 설계 한도를 넘는 경우가 많다. 전력 공급, 냉각(수랭·액침 냉각), PUE 관리가 AI 인프라 확장의 병목이 되고 있으며, 온프레미스 도입 시 상면·전력 증설 비용을 TCO에 포함해야 한다.

예시 자체 전산실의 랙당 전력 한도 때문에 GPU 서버를 외부 금융 전용 데이터센터에 두는 방안을 검토했다.

연관 GPU, 고대역폭 메모리, 총소유비용, 온프레미스

출처 IEA

데이터셋 분할(학습/검증/테스트)

Train/Validation/Test Split

AI 기초·머신러닝 · **입문**

입문 데이터를 공부용, 모의고사용, 실전 시험용으로 나누는 것이다. 공부한 문제로 시험을 보면 실력을 알 수 없기 때문이다.

심화 학습(train)은 파라미터 추정, 검증(validation)은 하이퍼파라미터 선택·조기 종료, 테스트(test)는 최종 성능 보고에 쓴다. 테스트셋은 개발 중 반복 사용하면 사실상 검증셋이 되어 성능이 과대평가된다. 시계열 데이터는 무작위가 아닌 시간 순서로 분할해야 한다.

예시 2023~2024년 데이터로 학습하고 2025년 상반기로 검증, 하반기로 테스트해 실제 운영 환경을 모사한다.

연관 학습 데이터, 교차검증, 과적합, 데이터 누수, 시계열 예측

출처 Google for Developers · Wikipedia

데이터 기반 의사결정

Data-Driven Decision Making

AX·비즈니스 적용 · **입문**

입문 경험이나 직감보다 데이터 분석 결과를 근거로 판단하고 결정하는 방식이다.

심화 신뢰할 수 있는 데이터 웨어하우스·마트, 표준 지표 정의, 셀프서비스 분석 도구가 기반이다. 생성형 AI는 자연어 질의(Text-to-SQL), 자동 보고서 해설로 데이터 접근 장벽을 낮추지만, 지표 정의와 데이터 품질이 정리돼 있지 않으면 그럴듯한 오답을 낳는다.

예시 경영진이 자연어로 질문하면 정보계 DW에서 지표를 조회해 근거 수치와 함께 답하는 분석 비서를 시범 운영했다.

연관 텍스트-투-SQL, 데이터 파이프라인, 디지털 전환, 생산성 지표

출처 EBSCO Research Starters

데이터 누수

Data Leakage

AI 기초·머신러닝 · **심화**

입문 시험 문제의 답이 교재에 몰래 섞여 들어간 상황이다. 개발할 땐 성능이 좋아 보이지만 실제 운영에서는 무너진다.

심화 예측 시점에는 알 수 없는 정보가 학습 입력에 포함되는 오류다. 미래 정보를 쓴 피처(타깃 누수), 분할 전 전체 데이터로 스케일러·인코더를 적합한 경우(전처리 누수), 동일 고객이 학습·테스트에 걸친 경우가 흔하다. 비현실적으로 높은 검증 성능이 주요 징후다.

예시 연체 예측 모델에 '추심 부서 이관 여부' 컬럼이 들어가 있어 검증 AUC가 0.99로 나왔다면 누수를 의심해야 한다.

연관 피처 엔지니어링, 데이터셋 분할(학습/검증/테스트), 피처 스케일링(정규화·표준화), 과적합

출처 IBM · Wikipedia / 논문 Kaufman et al. 2012

데이터 레이블링

Data Labeling

AI 기초·머신러닝 · **입문**

입문 AI 학습용 데이터에 정답 표시를 다는 작업이다. 사진에 '고양이', 거래에 '사기' 같은 꼬리표를 붙인다.

심화 지도학습에 필요한 정답(레이블)을 데이터에 부여하는 과정이다. 가이드라인 정의, 작업자 간 일치도 측정, 검수가 품질의 핵심이다. 비용 절감을 위해 능동 학습, 약한 지도, LLM을 이용한 자동 레이블링과 사람 검수를 결합하기도 한다.

예시 상담 녹취록에 민원 유형과 감정 레이블을 달아 민원 분류 모델을 학습한다.

연관 지도학습, 학습 데이터, 준지도학습, 휴먼 인 더 루프, 합성 데이터

출처 IBM · Wikipedia / 논문 Ratner et al. 2017

데이터 레이크하우스

Data Lakehouse

RAG·검색·데이터 · **심화**

입문 모든 종류의 데이터를 값싸게 쌓아 두는 데이터 레이크와, 정리된 데이터를 빠르게 분석하는 데이터 웨어하우스의 장점을 합친 구조다.

심화 객체 스토리지 위에 Apache Iceberg, Delta Lake, Hudi 같은 오픈 테이블 포맷을 두어 트랜잭션, 스키마 관리, 시간 여행 조회를 지원하는 아키텍처다. 정형·비정형 데이터를 한 플랫폼에서 BI, ML, AI 워크로드로 처리할 수 있다. 기존 DW를 대체하기보다 비정형·대용량 영역을 보완하는 형태로 도입되는 경우가 많다.

예시 정형 실적은 기존 Oracle DW에 두고, 상담 녹취·문서 같은 비정형 데이터와 AI 학습용 데이터는 레이크하우스에 적재한다.

연관 데이터 파이프라인, 정형 데이터, 비정형 데이터, 데이터 카탈로그

출처 Databricks / 논문 Armbrust et al. 2021

데이터 병렬화

Data Parallelism

학습·튜닝·정렬 · **심화**

입문 같은 모델을 여러 GPU에 복사해 두고 데이터를 나눠 동시에 학습한 뒤 결과를 합치는 방식이다.

심화 각 장치가 서로 다른 미니배치로 그래디언트를 계산하고 all-reduce로 평균내 동일하게 갱신한다. 구현이 가장 단순하지만 장치마다 모델 전체를 올려야 해, 큰 모델에는 FSDP·ZeRO 같은 샤딩 데이터 병렬을 쓴다.

연관 분산 학습, 텐서 병렬화, 파이프라인 병렬화

출처 PyTorch · Hugging Face · Wikipedia / 논문 Li et al. 2020 · Rajbhandari et al. 2019

데이터 오염

Data Contamination

학습·튜닝·정렬 · **심화**

입문 시험 문제가 학습 자료에 미리 섞여 들어가 모델 성적이 실제 실력보다 부풀려지는 문제다.

심화 벤치마크 평가셋이나 그 변형이 사전학습·파인튜닝 데이터에 포함되어 암기로 점수를 얻는 현상이다. n-gram 중복 검사, 학습 이후 공개된 문제로 평가, 비공개 평가셋 운영으로 대응한다. 공개 벤치마크 점수만으로 모델을 선정하면 안 되는 주요 이유다.

예시 모델 도입 평가 시 공개 벤치마크 대신 외부에 공개된 적 없는 사내 업무 문항으로 검증한다.

연관 벤치마크, 평가, 사전학습 데이터 정제, 과적합

논문 Golchin and Surdeanu 2023

데이터 유출

Data Leakage

평가·안전·규제 · **실무**

입문 AI를 쓰는 과정에서 회사 기밀이나 개인정보가 외부로 새어나가는 사고다.

심화 직원이 외부 AI 서비스에 기밀을 입력하는 경우, 모델이 학습 데이터를 암기해 재출력하는 경우, 프롬프트 인젝션으로 시스템 프롬프트·연결 데이터가 추출되는 경우, 권한 없는 문서가 RAG 검색에 노출되는 경우 등이 있다. 머신러닝에서는 평가 데이터 정보가 학습에 섞여 성능이 부풀려지는 현상도 데이터 누수라 부른다. DLP, 접근권한 기반 검색, 출력 필터, 사용 정책으로 대응한다.

예시 RAG 검색 시 사용자의 문서 열람 권한을 확인해 인사 문서가 일반 직원 답변에 인용되지 않게 한다.

연관 데이터 프라이버시, 섀도 AI, 프롬프트 인젝션, PII 마스킹, 모델 탈취

출처 OWASP Gen AI Security Project · Wikipedia / 논문 Carlini et al. 2020

데이터 카탈로그

Data Catalog

RAG·검색·데이터 · **실무**

입문 회사에 어떤 데이터가 어디에 있고 무슨 뜻인지 찾아볼 수 있게 정리한 데이터 목록·안내서다.

심화 데이터 자산의 메타데이터를 검색 가능한 형태로 제공하는 시스템으로, 스키마, 설명, 계보, 품질 지표, 소유자, 사용 통계, 접근 정책을 포함한다. AI 에이전트가 적절한 테이블을 찾아 쿼리하거나 RAG 소스를 선택하는 '지도' 역할을 하며, MCP 같은 도구 인터페이스로 에이전트에 노출하기도 한다.

예시 에이전트가 데이터 카탈로그를 검색해 '수신 잔액' 관련 마트 테이블을 찾은 뒤 SQL을 생성한다.

연관 메타데이터 관리, 텍스트-투-SQL, 데이터 레이크하우스, 지식베이스

출처 IBM

데이터 파이프라인

Data Pipeline

RAG·검색·데이터 · **실무**

입문 데이터를 원천 시스템에서 가져와 정리하고 필요한 곳에 옮겨 담는 자동화된 흐름이다. 물이 정수장을 거쳐 각 가정으로 가는 수도관과 같다.

심화 추출·변환·적재(ETL/ELT)와 스케줄링, 의존성 관리, 오류 처리, 모니터링을 포함한 데이터 이동·가공 흐름이다. AI 관점에서는 학습·평가 데이터 생성과 RAG 색인 갱신(문서 수집→파싱→청킹→임베딩→적재)도 파이프라인으로 운영한다. 증분 처리(CDC), 재처리 가능성, 데이터 품질 검증, 계보(lineage) 추적이 운영 안정성의 핵심이다.

예시 기존 계정계→ODS→DW ETL 배치 뒤에 '변경된 상품규정만 추출→임베딩→벡터 테이블 MERGE' 단계를 추가해 AI 지식베이스를 매일 동기화한다.

연관 데이터 품질, 데이터 레이크하우스, 임베딩, 검색 증강 생성, 메타데이터 관리

출처 IBM

데이터 포이즈닝

Data Poisoning

평가·안전·규제 · **심화**

입문 AI가 배우는 데이터에 악의적인 자료를 몰래 섞어 AI가 잘못 배우게 만드는 공격이다.

심화 학습·파인튜닝 데이터에 조작 샘플을 넣어 성능을 떨어뜨리거나, 특정 트리거가 있을 때만 의도된 동작을 하는 백도어를 심는다. 비교적 적은 수의 오염 문서로도 백도어가 생길 수 있다는 연구가 있다. RAG 지식베이스에 조작 문서를 넣는 것도 넓은 의미의 포이즈닝이다. 데이터 출처 관리, 이상 샘플 탐지, 지식베이스 쓰기 권한 통제로 대응한다.

예시 사내 위키를 RAG 원천으로 쓸 때 문서 수정 이력과 작성자 권한을 관리해 조작 문서 유입을 막는다.

연관 학습 데이터, 파인튜닝, 적대적 공격, 검색 증강 생성, 모델 탈취

출처 Wikipedia / 논문 Chen et al. 2017 · Souly et al. 2025

데이터 품질

Data Quality

RAG·검색·데이터 · **실무**

입문 데이터가 정확하고, 빠짐없고, 최신이며, 서로 모순 없는지의 정도다. AI는 품질 나쁜 데이터로는 좋은 답을 낼 수 없다.

심화 정확성, 완전성, 일관성, 적시성, 유효성, 유일성 등의 차원으로 측정·관리한다. AI 시스템에서는 학습 데이터 품질뿐 아니라 RAG 문서의 최신성·중복·상충 여부, Text-to-SQL 대상 테이블의 코드값 정합성이 결과 신뢰도를 결정한다. 파이프라인 단계마다 검증 규칙과 품질 지표를 자동 점검하는 체계가 필요하다.

예시 ETL 후 원천 대비 건수·금액 대사, 필수 컬럼 NULL 비율 점검을 자동화하고 기준 미달 시 AI 지식베이스 갱신을 중단한다.

연관 데이터 파이프라인, 메타데이터 관리, 학습 데이터, AI 거버넌스

출처 IBM · Wikipedia

데이터 프라이버시

Data Privacy

평가·안전·규제 · **입문**

입문 개인정보가 동의 없이 수집·이용되거나 새어나가지 않도록 보호하는 것이다. AI에 넣는 데이터와 AI가 내놓는 답 모두 해당한다.

심화 AI에서는 학습 데이터 속 개인정보의 적법한 처리 근거, 프롬프트로 외부 API에 전송되는 정보, 모델이 학습 데이터를 암기해 재출력하는 위험, 로그 보관이 주요 쟁점이다. 국내에서는 개인정보 보호법과 신용정보법이 적용되며, 가명처리, PII 마스킹, 데이터 최소화, 학습 미사용 계약, 온프레미스 배포로 대응한다.

예시 외부 LLM API 사용 시 고객 식별정보를 마스킹하고, 입력 데이터를 학습에 쓰지 않는다는 계약 조건을 확인한다.

연관 가명처리, PII 마스킹, 데이터 유출, 온프레미스, 학습 데이터

출처 국가법령정보센터 · IBM · Wikipedia / 논문 Carlini et al. 2020

도구 사용

Tool Use

AI 에이전트·도구 · **실무**

입문 AI가 계산기, 검색, 사내 시스템 같은 외부 도구를 직접 불러 써서 자기 지식만으로는 못 하는 일을 해내는 능력이다.

심화 모델에 사용 가능한 도구 목록과 설명·입력 스키마를 제공하면 모델이 필요할 때 도구 이름과 인자를 구조화해 출력하고, 실행 환경이 이를 실제로 호출한 뒤 결과를 다시 모델 컨텍스트에 넣는 방식이다. 최신 정보 접근, 정확한 계산, 시스템 조작이 가능해지는 대신 도구 설명 품질, 인자 검증, 실패 처리, 권한 통제가 성능과 안전을 좌우한다.

예시 챗봇이 환율 질문을 받으면 환율 조회 API를 호출해 실시간 값을 받아 답한다.

연관 함수 호출, 도구 스키마, AI 에이전트, 모델 컨텍스트 프로토콜

출처 Anthropic · IBM / 논문 Schick et al. 2023 · Patil et al. 2023

도구 스키마

Tool Schema

AI 에이전트·도구 · **심화**

입문 AI에게 도구의 이름, 하는 일, 넣어야 할 값의 형식을 알려 주는 설명서다.

심화 도구 이름, 자연어 설명, JSON Schema로 정의한 입력 매개변수(타입, 필수 여부, 열거값, 설명)로 구성된다. 모델은 이 정보만 보고 도구 선택과 인자 생성을 하므로, 설명이 모호하거나 도구 간 역할이 겹치면 오호출이 늘어난다. 도구 수가 많아지면 컨텍스트를 많이 차지하므로 필요한 도구만 노출하거나 검색으로 동적 로드하는 방법을 쓴다.

예시 조회 기간 매개변수에 'YYYY-MM 형식, 최대 12개월'이라는 설명을 넣어 잘못된 인자 생성을 줄인다.

연관 함수 호출, 도구 사용, 구조화된 출력, MCP 서버

출처 Anthropic · Anthropic · JSON Schema

도메인 적응

Domain Adaptation

학습·튜닝·정렬 · **실무**

입문 일반 용도로 학습된 모델을 금융, 의료, 법률 같은 특정 분야에 맞게 길들이는 과정이다.

심화 지속 사전학습, 도메인 SFT, 도메인 선호 데이터 학습, 어휘 확장 등을 조합해 분포 차이를 줄인다. 실무에서는 비용 대비 효과를 따져 프롬프트·RAG로 충분한지 먼저 검증한 뒤 학습을 결정하는 것이 일반적이다. 도메인 평가셋 구축이 선행되어야 한다.

예시 보험 약관 용어에 익숙하도록 약관 해설 데이터로 모델을 도메인 적응시킨다.

연관 지속 사전학습, 파인튜닝, 검색 증강 생성, 파국적 망각

출처 Wikipedia / 논문 Gururangan et al. 2020

드롭아웃

Dropout

딥러닝·신경망 · **실무**

입문 학습할 때 일부 뉴런을 무작위로 잠시 꺼서, 특정 뉴런에만 의존하지 않고 골고루 배우게 하는 기법이다.

심화 학습 중 각 뉴런 출력을 확률 p로 0으로 만들어 뉴런 간 공동 적응을 막는 정규화 기법이다. 여러 하위 네트워크를 앙상블하는 효과가 있다. 추론 시에는 끄고 출력 스케일을 보정한다(구현상 학습 시 1/(1−p)로 스케일링). 대규모 LLM 사전학습에서는 사용하지 않는 경우가 많다.

연관 정규화(규제), 과적합, 신경망, 앙상블 학습

출처 Wikipedia / 논문 Hinton et al. 2012 · Srivastava et al. 2014

드리프트 모니터링

Drift Monitoring

인프라·배포·LLMOps · **심화**

입문 시간이 지나며 입력 데이터나 모델 성능이 처음과 달라지는지 감시하는 활동이다.

심화 입력 분포가 바뀌는 데이터 드리프트와 입력-정답 관계가 바뀌는 개념 드리프트를 PSI, KL 발산 등 통계 지표로 탐지한다. LLM에서는 질문 유형 변화, 제공사 모델 업데이트로 인한 응답 변화, 지식 노후화도 감시 대상이다. 임계값 초과 시 경보와 재평가·재학습으로 연결한다.

예시 금리 급변기 이후 대출 문의 유형이 달라지자 드리프트 경보가 울려 RAG 문서와 평가셋을 갱신했다.

연관 MLOps, 관측 가능성, 평가, LLMOps

출처 IBM · Wikipedia

디지털 전환

DX · Digital Transformation

AX·비즈니스 적용 · **입문**

입문 종이·수작업 중심의 업무와 서비스를 디지털 기술로 바꾸는 것이다.

심화 클라우드, 모바일, 데이터 플랫폼, 자동화(RPA)로 프로세스와 고객 접점을 디지털화하는 활동이다. 데이터가 디지털로 축적되고 시스템이 연결돼 있어야 AI 적용이 가능하므로 DX는 AX의 전제 조건 역할을 한다.

예시 모바일 뱅킹과 전자 서식 도입으로 축적된 데이터가 이후 AI 상담과 이상거래 탐지의 기반이 됐다.

연관 AI 전환, 데이터 기반 의사결정, 데이터 파이프라인

출처 Wikipedia

디코더 전용 모델

Decoder-Only Model

LLM·언어모델 · **심화**

입문 글을 앞에서부터 차례로 만들어 내는 데 특화된 트랜스포머 구조다. GPT 계열 등 대부분의 대화형 LLM이 이 방식이다.

심화 트랜스포머 디코더 블록만 쌓고 인과 마스크로 각 토큰이 이전 토큰만 보도록 한다. 다음 토큰 예측 하나로 학습·생성을 통일할 수 있어 확장성이 좋고 현재 생성형 LLM의 주류 구조다. 양방향 문맥을 보는 인코더 모델보다 분류·임베딩에는 상대적으로 비효율적일 수 있다.

연관 트랜스포머, 자기회귀 모델, 인코더 모델, 다음 토큰 예측, 대규모 언어모델

출처 Hugging Face · Wikipedia / 논문 Vaswani et al. 2017 · Brown et al. 2020

딥러닝

DL · Deep Learning

딥러닝·신경망 · **입문**

입문 층이 아주 깊은 신경망으로 학습하는 머신러닝 방식이다. 사람이 특징을 정해주지 않아도 이미지·음성·문장에서 스스로 특징을 뽑아낸다.

심화 다층 신경망으로 원시 데이터에서 계층적 표현을 자동 학습하는 머신러닝 분야다. 대규모 데이터, GPU 연산, 개선된 아키텍처(CNN, RNN, 트랜스포머)와 학습 기법(ReLU, 배치 정규화, 잔차연결)이 결합해 2010년대 이후 비약적으로 발전했다. 비정형 데이터에서 강력하나 데이터·연산 요구량이 크고 해석이 어렵다.

예시 스캔한 대출 서류 이미지에서 딥러닝 OCR로 항목을 추출해 심사 입력을 자동화한다.

연관 신경망, 머신러닝, 트랜스포머, 합성곱 신경망, GPU

출처 IBM · Wikipedia / 논문 LeCun et al. 2015

딥페이크

Deepfake

생성 AI·멀티모달 · **입문**

입문 AI로 실제 사람의 얼굴이나 목소리를 진짜처럼 합성한 가짜 영상·음성이다.

심화 얼굴 교체, 입 모양 동기화, 음성 복제, 전신 영상 생성 등 생성 모델로 특정인을 사칭하는 합성 미디어다. 사기, 허위 정보, 비동의 성적 합성물 등 피해가 커 다수 국가가 처벌·표시 의무를 입법했으며, 한국 AI 기본법도 생성물 표시 의무를 둔다. 탐지 모델만으로는 한계가 있어 워터마크, 콘텐츠 출처 증명, 다중 인증 같은 절차적 대책을 함께 쓴다.

예시 임원 얼굴과 목소리를 합성한 화상회의로 송금을 지시하는 사기에 대비해, 고액 송금은 별도 채널 확인을 의무화한다.

연관 음성 복제, 워터마킹, 콘텐츠 출처 증명, 인공지능 기본법

출처 U.S. Government Accountability Office · 국가법령정보센터 · Wikipedia

---

딥 리서치

Deep Research

AI 에이전트·도구 · **실무**

입문 AI가 수십 개의 자료를 스스로 찾아 읽고 비교해서 출처가 달린 조사 보고서를 만들어 주는 기능이다.

심화 검색 질의 생성 → 문서 수집·읽기 → 추가 질의 → 종합의 과정을 수 분에서 수십 분 반복하는 장기 실행 연구 에이전트다. 여러 서브에이전트가 병렬로 조사하기도 하며, 결과에 인용 출처를 붙인다. 출처의 신뢰성 판단, 상충 정보 처리, 인용과 실제 내용의 불일치가 한계이므로 핵심 사실은 원문 확인이 필요하다.

예시 신규 진출 국가의 디지털 금융 규제 동향을 조사해 출처 포함 보고서 초안을 만든다.

연관 AI 에이전트, 검색(리트리벌), 서브에이전트, 장기 실행 작업

출처 OpenAI · Google · Anthropic

ㄹ

랜덤 포레스트

Random Forest

AI 기초·머신러닝 · **실무**

입문 조금씩 다른 데이터로 키운 결정 트리 수백 그루가 투표해서 답을 정하는 모델이다.

심화 부트스트랩 표본과 분할 시 무작위 피처 부분집합으로 다수의 결정 트리를 학습하고 투표·평균으로 결합하는 배깅 앙상블이다. 트리 간 상관을 낮춰 분산을 줄이며, 튜닝이 비교적 쉽고 피처 중요도를 제공한다. 정형 데이터의 강력한 베이스라인이다.

예시 보험 청구 데이터로 랜덤 포레스트를 학습해 보험사기 의심 건을 선별한다.

연관 결정 트리, 앙상블 학습, 그래디언트 부스팅, 피처(특성)

출처 IBM · Wikipedia / 논문 Breiman 2001

레드티밍

Red Teaming

평가·안전·규제 · **실무**

입문 일부러 공격자 입장이 되어 AI의 약점을 찾아내는 점검 활동이다. 모의 해킹처럼 문제가 터지기 전에 미리 구멍을 찾는다.

심화 유해 응답 유도, 탈옥, 프롬프트 인젝션, 개인정보 추출, 편향 발화 등 실패 시나리오를 체계적으로 시도해 취약점을 찾는 평가 방식이다. 전문가 수작업, 공격 프롬프트 자동 생성(다른 LLM 활용), 크라우드 방식을 병행한다. 발견된 사례는 가드레일 규칙, 안전 학습 데이터, 회귀 테스트 세트로 환류한다.

예시 대출 상담 AI 출시 전 레드팀이 심사 기준을 역추적하거나 차별적 답변을 유도하는 공격을 시뮬레이션한다.

연관 탈옥, 프롬프트 인젝션, 평가, 적대적 공격, 가드레일

출처 Wikipedia / 논문 Perez et al. 2022 · Ganguli et al. 2022

레이어 정규화

LN · Layer Normalization

딥러닝·신경망 · **심화**

입문 데이터 한 건 안에서 값의 분포를 맞추는 정규화다. 배치 크기와 상관없이 동작해 트랜스포머에서 표준으로 쓴다.

심화 샘플 하나의 피처 차원 전체에 대해 평균·분산을 정규화한다. 배치에 독립적이어서 RNN·트랜스포머에 적합하다. 서브층 앞에 두는 Pre-LN이 학습 안정성이 좋아 최신 LLM에 일반적이며, 평균 중심화를 생략해 계산을 줄인 RMSNorm도 널리 쓰인다.

연관 배치 정규화, 트랜스포머, 잔차 연결

논문 Ba et al. 2016 · Zhang & Sennrich 2019

레이트 리밋

Rate Limit

인프라·배포·LLMOps · **실무**

입문 일정 시간 동안 보낼 수 있는 요청 수나 토큰 수의 상한이다. 넘으면 요청이 거절된다.

심화 LLM API는 분당 요청 수(RPM)와 분당 토큰 수(TPM) 등으로 제한하며 초과 시 HTTP 429를 반환한다. 지수 백오프 재시도, 큐잉, 여러 키·리전 분산, 게이트웨이의 부서별 쿼터로 대응한다. 사내 LLM 포털에서도 GPU 자원 공정 배분을 위해 사용자별 한도를 둔다.

예시 월말 결산 기간에 특정 부서 호출이 몰려 429 오류가 나자 게이트웨이에 부서별 TPM 쿼터를 설정했다.

연관 API, 모델 게이트웨이, 비동기 처리, 폴백 모델

출처 OpenAI · Anthropic · Wikipedia

로라

LoRA · Low-Rank Adaptation

학습·튜닝·정렬 · **실무**

입문 거대한 모델 전체를 고치지 않고 작은 보조 부품만 붙여 학습해 적은 자원으로 파인튜닝하는 기법이다.

심화 원래 가중치 W는 고정하고 갱신분을 저랭크 행렬 곱 BA로 근사해 그 행렬만 학습한다. 학습 파라미터가 전체의 1% 미만으로 줄어 메모리와 저장 공간이 크게 절약되고, 추론 시 W에 병합하거나 여러 어댑터를 교체하며 서빙할 수 있다. 랭크, 적용 층, 학습률이 주요 하이퍼파라미터다.

예시 부서별 업무 특화 LoRA 어댑터를 따로 학습해 하나의 기반 모델 서버에서 교체 운영한다.

연관 매개변수 효율적 미세조정, 큐로라, 어댑터, 파인튜닝, 모델 병합

출처 Hugging Face · IBM / 논문 Hu et al. 2021

로지스틱 회귀

Logistic Regression

AI 기초·머신러닝 · **실무**

입문 여러 요인을 점수로 합산한 뒤 0~100% 사이 확률로 바꿔 '예/아니오'를 판단하는 단순하고 설명하기 쉬운 모델이다.

심화 선형 결합에 시그모이드 함수를 적용해 클래스 확률을 출력하는 분류 모델로, 로그 오즈가 피처의 선형 함수라고 가정한다. 계수 해석이 명확하고 안정적이어서 규제 환경의 신용평가 스코어카드에 오랫동안 표준으로 쓰였다. 비선형 관계는 구간화(WoE 변환)나 교호항으로 처리한다.

예시 WoE 변환한 변수로 로지스틱 회귀 스코어카드를 만들어 신용등급을 산출한다.

연관 분류, 회귀, 설명 가능한 AI, ROC 곡선과 AUC, 활성화 함수

출처 IBM · Wikipedia

로짓

Logits

LLM·언어모델 · **심화**

입문 모델이 다음 토큰 후보마다 매기는 원점수다. 이 점수를 확률로 바꿔 다음 단어를 고른다.

심화 마지막 은닉 상태를 어휘 크기 차원으로 사영한 정규화 전 값으로, 소프트맥스를 거쳐 확률분포가 된다. temperature, 반복 패널티, 로짓 바이어스, 제약 디코딩(문법 기반 구조화 출력) 등이 로짓 단계에서 적용된다. 로그 확률은 신뢰도 추정·분류 점수로도 활용된다.

연관 온도, 샘플링, 구조화된 출력, 다음 토큰 예측

출처 Hugging Face · Wikipedia

롱컨텍스트 대 RAG

Long Context vs RAG

RAG·검색·데이터 · **실무**

입문 자료를 통째로 AI에게 넣을지(롱컨텍스트), 필요한 부분만 찾아서 넣을지(RAG) 고르는 설계 선택이다.

심화 컨텍스트 창이 수십만~백만 토큰 이상으로 커지면서 소량 문서는 전체를 넣는 방식이 단순하고 정확할 수 있다. 그러나 대규모·자주 바뀌는 지식, 권한 제어, 비용·지연, 긴 입력 중간 정보 활용 저하 문제 때문에 RAG가 여전히 필요하다. 실무에서는 RAG로 후보를 좁힌 뒤 넉넉한 컨텍스트에 넣는 혼합 방식이 일반적이다.

예시 계약서 1건 검토는 전체를 넣고, 수만 건 규정·상담 이력 검색은 RAG로 처리한다.

연관 컨텍스트 윈도, 검색 증강 생성, 캐시 증강 생성, AI 비용

출처 Google / 논문 Liu et al. 2023

롱 컨텍스트

Long Context

LLM·언어모델 · **실무**

입문 책 한 권 분량처럼 아주 긴 글을 한 번에 넣고 처리할 수 있는 모델 능력이다.

심화 수십만~수백만 토큰 컨텍스트를 지원하기 위해 RoPE 스케일링, 효율적 어텐션, 장문 데이터 추가 학습을 사용한다. 긴 문서 전체 분석이 가능해 일부 RAG 수요를 대체하지만, 비용·지연이 크고 중간 정보 활용이 약한 문제가 남아 있다. needle-in-a-haystack류 평가만으로는 실제 장문 추론 능력을 판단하기 어렵다.

예시 수년치 감사 보고서를 한 번에 넣어 반복 지적 사항을 추출한다.

연관 컨텍스트 윈도, 중간 정보 손실, 검색 증강 생성, 회전 위치 임베딩, KV 캐시

출처 Anthropic · IBM / 논문 Peng et al. 2023 · Hsieh et al. 2024

리더보드

Leaderboard

평가·안전·규제 · **입문**

입문 여러 AI 모델의 벤치마크 점수를 순위표로 보여주는 사이트나 표다.

심화 특정 벤치마크 묶음의 점수를 집계하거나, 사용자가 두 모델의 답을 블라인드 비교 투표한 결과로 Elo 계열 점수를 매기는 방식이 있다. 한국어 능력 등 특정 언어·영역 전용 리더보드도 있다. 리더보드 최적화(벤치마크 과적합), 평가 조건 차이, 선호 투표의 스타일 편향 때문에 순위를 업무 적합성으로 직결하면 안 된다.

예시 한국어 리더보드 상위 모델 몇 개를 후보로 정한 뒤 사내 업무 데이터로 별도 평가한다.

연관 벤치마크, 평가, MMLU, 데이터 오염, 대규모 언어모델

출처 Arena (LMArena) · Hugging Face / 논문 Chiang et al. 2024

리스킬링·업스킬링

Reskilling and Upskilling

AX·비즈니스 적용 · **실무**

입문 리스킬링은 새로운 직무를 위해 다른 기술을 배우는 것이고, 업스킬링은 현재 직무 역량을 더 높이는 것이다.

심화 AX로 업무 내용이 바뀌는 직원에게 AI 활용, 데이터 분석, 프롬프트·RAG 설계, AI 결과 검증 역량을 교육한다. 직무별 역량 모델을 정의하고 기초-실무-전문가 단계로 경로를 설계하며, 교육 이수보다 실제 업무 적용 과제 수행을 성과로 삼는 것이 효과적이다.

예시 정보계 개발자를 대상으로 Text-to-SQL과 RAG 구축 실습 과정을 운영해 사내 AI 개발 인력으로 업스킬링했다.

연관 AI 리터러시, 내재화, 변화관리, AI 챔피언

리액트(추론-행동)

ReAct · ReAct (Reasoning and Acting)

AI 에이전트·도구 · **심화**

입문 AI가 생각을 적고, 행동하고, 결과를 보고 다시 생각하는 과정을 번갈아 하는 기법이다.

심화 2022년 제안된 프롬프팅 패턴으로, 모델이 Thought(추론)–Action(도구 호출)–Observation(결과) 형식을 교대로 생성하게 한다. 추론만 하는 체인 오브 소트보다 외부 정보로 사실을 확인할 수 있어 환각이 줄고 과정 추적이 쉽다. 오늘날 대부분의 에이전트 루프의 원형이 되었으며, 네이티브 도구 호출을 지원하는 모델에서는 형식이 API 구조로 대체되었다.

연관 에이전트 루프, 사고의 연쇄, 도구 사용, 반성(자기 성찰)

출처 IBM / 논문 Yao et al. 2022

ㅁ

망분리 규제 개선

Network Separation Regulation Reform

AX·비즈니스 적용 · **실무**

입문 인터넷과 내부망을 엄격히 나누도록 한 금융권 규제를 완화해 클라우드·생성형 AI를 쓸 수 있게 하는 정책 변화다.

심화 금융위원회는 2024년 망분리 개선 로드맵을 발표하고, 혁신금융서비스(규제 샌드박스) 지정을 통해 금융회사가 생성형 AI·SaaS를 단계적으로 활용할 수 있도록 허용해 왔다. 장기적으로는 일률적 망분리에서 자율 보안·위험 기반 체계로 전환하는 방향이며, 이용 시 데이터 가명처리, 보안 통제, 사후 보고 등 부가 조건이 붙는다. 세부 범위와 법제화 일정은 변동될 수 있어 최신 당국 발표를 확인해야 한다.

예시 혁신금융서비스 지정을 받아 내부 업무망에서 외부 생성형 AI를 문서 작성 보조 용도로 제한적으로 사용하기 시작했다.

연관 규제 샌드박스, 폐쇄망 배포, 하이브리드 클라우드, 데이터 프라이버시, AI 거버넌스

출처 금융위원회 · 김·장 법률사무소

매개변수 효율적 미세조정

PEFT · Parameter-Efficient Fine-Tuning

학습·튜닝·정렬 · **실무**

입문 모델의 아주 일부분만 학습해 적은 GPU와 데이터로도 파인튜닝할 수 있게 하는 방법들의 총칭이다.

심화 LoRA, QLoRA, 어댑터, 프리픽스·프롬프트 튜닝 등 소수의 추가 또는 선택 파라미터만 학습하는 기법군이다. 풀 파인튜닝에 근접한 성능을 낮은 비용으로 얻고 기반 모델을 공유할 수 있으며, 원래 지식의 망각도 상대적으로 적다. 대규모 도메인 지식 주입에는 한계가 있다.

연관 로라, 큐로라, 어댑터, 파인튜닝, 전체 파인튜닝

출처 Hugging Face · IBM / 논문 Houlsby et al. 2019 · Li and Liang 2021 · Lester et al. 2021

맥락 검색

Contextual Retrieval

RAG·검색·데이터 · **심화**

입문 문서 조각마다 '이 조각이 전체 문서에서 어떤 내용인지' 짧은 설명을 붙여 검색 정확도를 높이는 방법이다.

심화 청킹 후 각 청크 앞에 문서 전체 맥락을 요약한 문장을 LLM으로 생성해 붙인 뒤 임베딩·BM25 색인을 만드는 기법이다. '해당 비율은 3%로 한다'처럼 단독으로는 의미가 불분명한 청크의 검색 실패를 줄인다. 색인 시 LLM 호출 비용이 들지만 프롬프트 캐싱으로 줄일 수 있다.

예시 '제5조 ② 한도는 1억 원으로 한다' 청크 앞에 '○○ 신용대출 상품규정의 대출한도 조항'을 붙여 색인한다.

연관 청킹, 청크 오버랩, 하이브리드 검색, 검색 증강 생성

출처 Anthropic · Anthropic

머신러닝

ML · Machine Learning

AI 기초·머신러닝 · **입문**

입문 사람이 규칙을 일일이 짜주는 대신, 컴퓨터가 데이터 속 패턴을 스스로 찾아 판단 기준을 만드는 방법이다.

심화 명시적 프로그래밍 없이 데이터로부터 입력과 출력 간 관계(함수)를 추정하는 AI의 하위 분야다. 학습 방식에 따라 지도·비지도·강화학습으로 나뉘며, 모델 선택·피처 설계·하이퍼파라미터 튜닝·평가가 핵심 작업이다. 정형 데이터에서는 트리 기반 모델이 여전히 강력하다.

예시 과거 대출 상환 이력으로 학습한 모델이 신규 신청자의 부도 확률을 예측한다.

연관 인공지능, 지도학습, 비지도학습, 강화학습, 딥러닝

출처 IBM · Wikipedia / 논문 Samuel 1959

멀티모달

Multimodal

생성 AI·멀티모달 · **입문**

입문 글뿐 아니라 이미지, 음성, 영상 등 여러 종류의 정보를 함께 이해하거나 만들어 내는 AI의 성질이다.

심화 서로 다른 모달리티의 입력을 공통 표현 공간으로 매핑해 함께 처리하는 것이다. 이미지 인코더 출력을 언어 모델 토큰 공간에 연결하는 방식과, 처음부터 여러 모달리티를 함께 학습하는 네이티브 방식이 있다. 문서·차트 이해, 음성 대화, 영상 분석 등 활용 폭이 넓지만 모달리티 간 정렬과 평가가 어렵다.

예시 고객이 찍어 보낸 영수증 사진과 문의 글을 함께 해석해 경비 처리 안내를 한다.

연관 시각 언어 모델, 네이티브 멀티모달, 멀티모달 임베딩, 생성형 AI

출처 IBM · Wikipedia / 논문 Baltrušaitis et al. 2017

멀티모달 임베딩

Multimodal Embedding

생성 AI·멀티모달 · **심화**

입문 글과 이미지 등 서로 다른 형태의 데이터를 같은 숫자 공간에 놓아, '이 글과 가장 비슷한 그림'을 찾을 수 있게 하는 기술이다.

심화 텍스트, 이미지, 문서 페이지, 음성 등을 공통 벡터 공간으로 매핑하는 임베딩 모델이다. 텍스트로 이미지를 검색하거나, 문서 페이지를 이미지 그대로 임베딩해 표·차트를 포함한 문서를 검색하는 멀티모달 RAG에 쓰인다. 모달리티 간 의미 정렬 품질과 도메인 적합성을 자체 데이터로 검증해야 한다.

예시 차트가 많은 리서치 보고서를 페이지 이미지 단위로 임베딩해 '금리 민감도 그래프'를 질의로 검색한다.

연관 임베딩, 클립(대조 언어-이미지 사전학습), 벡터 데이터베이스, 검색 증강 생성, 문서 AI

출처 Google Cloud · Wikipedia / 논문 Radford et al. 2021 · Girdhar et al. 2023 · Faysse et al. 2024

멀티턴 대화

Multi-Turn Conversation

LLM·언어모델 · **입문**

입문 질문과 답을 여러 번 주고받으며 앞 대화 내용을 이어 가는 대화 방식이다.

심화 LLM API는 기본적으로 상태가 없어, 애플리케이션이 이전 메시지 기록을 매 요청에 다시 넣어 맥락을 유지한다. 대화가 길어질수록 토큰 비용이 누적되고 컨텍스트 한도에 도달하므로 요약·잘라내기·메모리 저장 전략이 필요하다. 턴이 늘수록 지시 준수가 약해지는 경향도 관리 대상이다.

예시 상담 챗봇이 앞서 확인한 고객 상품 정보를 기억한 채 후속 질문에 답하도록 대화 이력을 관리한다.

연관 채팅 템플릿, 컨텍스트 윈도, 에이전트 메모리, 시스템 프롬프트

출처 Anthropic / 논문 Laban et al. 2025

멀티헤드 어텐션

MHA · Multi-Head Attention

딥러닝·신경망 · **심화**

입문 여러 개의 어텐션을 동시에 돌려 문법 관계, 의미 관계 등 서로 다른 관점에서 문장을 살피는 방식이다.

심화 Q, K, V를 여러 헤드로 나눠 각기 다른 선형 투영 공간에서 병렬로 어텐션을 계산한 뒤 결합한다. 헤드별로 다른 유형의 관계를 학습할 수 있다. 추론 시 KV 캐시 메모리를 줄이려 키·값 헤드를 공유하는 MQA, GQA 변형이 최신 LLM에 널리 쓰인다.

연관 어텐션, 셀프 어텐션, 트랜스포머, KV 캐시

출처 Wikipedia / 논문 Vaswani et al. 2017 · Shazeer 2019 · Ainslie et al. 2023

멀티홉 검색

Multi-hop Retrieval

RAG·검색·데이터 · **심화**

입문 한 번 찾은 정보를 단서로 다시 검색하는 과정을 여러 번 거쳐 답을 찾는 방법이다.

심화 답에 필요한 정보가 여러 문서에 흩어져 있을 때, 1차 검색 결과에서 얻은 개체나 사실로 후속 질의를 만들어 반복 검색하는 방식이다. 질의 분해, 반복 검색-추론 루프, 지식 그래프 탐색으로 구현한다. 단일 검색보다 정확하지만 단계마다 오류가 누적될 수 있다.

예시 'A 계열사의 대표이사가 겸직 중인 회사의 여신 잔액'을 묻자 대표이사 → 겸직 회사 → 여신 순으로 검색한다.

연관 에이전틱 RAG, 지식 그래프, 쿼리 재작성, 그래프RAG

논문 Yang et al. 2018 · Trivedi et al. 2022

멀티 에이전트

MAS · Multi-Agent System

AI 에이전트·도구 · **실무**

입문 역할이 다른 여러 AI 에이전트가 팀처럼 나눠 일하는 방식이다. 조사 담당, 작성 담당, 검토 담당을 따로 두는 식이다.

심화 복수의 에이전트가 각자 전용 프롬프트·도구·컨텍스트를 갖고 협업하는 구조로, 관리자(supervisor)-작업자 계층형, 순차 파이프라인형, 토론·투표형 등 패턴이 있다. 컨텍스트를 분리해 병렬 처리와 전문화가 가능하지만, 에이전트 간 정보 손실, 토큰 비용 급증, 디버깅 난이도 상승이 단점이다. 단일 에이전트로 충분한 문제에 과도하게 적용하지 않는 것이 좋다.

예시 규제 보고서 작성 시 데이터 추출 에이전트, 보고서 작성 에이전트, 규정 준수 검토 에이전트가 단계별로 협업한다.

연관 오케스트레이션, 서브에이전트, 핸드오프, 에이전트 간 프로토콜

출처 IBM · Anthropic · Wikipedia / 논문 Wu et al. 2023 · Li et al. 2023 · Hong et al. 2023

메타데이터 관리

Metadata Management

RAG·검색·데이터 · **실무**

입문 데이터에 대한 설명 정보(무슨 뜻인지, 어디서 왔는지, 누가 관리하는지)를 체계적으로 정리·관리하는 일이다.

심화 테이블·컬럼 정의, 표준 용어·도메인, 코드값, 데이터 계보, 소유자, 갱신 주기 같은 메타데이터를 수집·표준화·유지하는 활동이다. AI 시대에는 Text-to-SQL과 RAG가 메타데이터를 컨텍스트로 사용하므로, 메타데이터 품질이 곧 AI 정확도가 된다. 금융권 데이터 표준화·메타 시스템 자산을 AI 컨텍스트로 재활용하는 것이 효과적이다.

예시 메타 시스템의 표준용어·컬럼 한글명·코드 정의를 추출해 Text-to-SQL용 스키마 설명 문서로 자동 변환한다.

연관 데이터 카탈로그, 텍스트-투-SQL, 시맨틱 레이어, 데이터 품질, 메타데이터 필터링

출처 IBM · Wikipedia

메타데이터 필터링

Metadata Filtering

RAG·검색·데이터 · **실무**

입문 문서의 날짜, 부서, 종류 같은 꼬리표로 검색 대상을 먼저 좁히는 것이다.

심화 청크에 부착한 속성(문서 유형, 작성일, 부서, 버전, 접근 권한 등)으로 벡터 검색 전후에 조건을 거는 기법이다. 최신 버전 규정만 검색하거나 사용자 권한에 맞는 문서만 반환하는 데 필수적이다. 사전 필터링은 정확하지만 ANN 성능에 영향을 줄 수 있어 DB별 구현 방식을 확인해야 한다.

예시 '현행' 상태이고 사용자 소속 본부에 공개된 규정만 대상으로 검색하도록 필터를 건다.

연관 벡터 데이터베이스, 메타데이터 관리, 청킹, 검색(리트리벌)

출처 Pinecone · Qdrant

메타 프롬프팅

Meta Prompting

프롬프트·추론 · **실무**

입문 AI에게 프롬프트 자체를 써 달라고 하거나 고쳐 달라고 하는 방법이다. 'AI에게 시킬 지시문'을 AI가 만드는 것이다.

심화 LLM을 이용해 프롬프트를 생성·개선·평가하는 기법이다. 목표와 실패 사례를 주고 개선된 프롬프트를 제안받거나, 상위 모델이 하위 작업용 프롬프트를 작성하게 한다. 사람의 초안 작성 부담을 줄이지만, 결과 프롬프트는 반드시 평가셋으로 검증해야 한다.

예시 오분류 사례 10건을 주고 '이 오류를 줄이도록 분류 프롬프트를 고쳐라'라고 요청한다.

연관 프롬프트 최적화, 프롬프트 엔지니어링, LLM 심판 평가

출처 Anthropic · Wikipedia / 논문 Suzgun and Kalai 2024 · Zhou et al. 2022

모델

Model

AI 기초·머신러닝 · **입문**

입문 데이터에서 배운 규칙을 담고 있는 계산식 덩어리다. 입력을 넣으면 예측이나 답을 내놓는다.

심화 입력을 출력으로 변환하는 수학적 함수와 그 학습된 파라미터의 집합이다. 아키텍처(구조)와 가중치(학습 결과)로 구성되며, 학습 후 파일로 저장·배포해 추론에 사용한다. 선형 모델, 트리 모델, 신경망 등 형태가 다양하다.

예시 부도 예측 모델을 배치 작업에 연결해 매일 밤 전 고객의 신용 점수를 갱신한다.

연관 파라미터, 추론, 머신러닝, 파운데이션 모델, MLOps

출처 IBM

모델 게이트웨이

Model Gateway

인프라·배포·LLMOps · **실무**

입문 여러 AI 모델 앞에 두는 관문이다. 요청을 알맞은 모델로 보내고, 사용량과 보안을 한곳에서 관리한다.

심화 단일 API 엔드포인트 뒤에서 모델 라우팅(작업 난이도·비용·데이터 등급별), 인증, 쿼터, 로깅, 개인정보 마스킹, 폴백, 캐싱을 처리한다. 애플리케이션과 모델 제공사를 분리해 모델 교체와 멀티 벤더 전략을 쉽게 한다. LiteLLM 같은 오픈소스나 클라우드 관리형 서비스를 쓴다.

예시 게이트웨이에서 개인정보가 포함된 요청은 온프레미스 모델로, 일반 요청은 외부 API로 자동 라우팅한다.

연관 폴백 모델, 레이트 리밋, 벤더 종속, 관측 가능성, 가드레일

출처 Microsoft · Cloudflare · LiteLLM

모델 레지스트리

Model Registry

인프라·배포·LLMOps · **심화**

입문 학습된 모델과 그 버전, 성능, 승인 상태를 한곳에 기록·보관하는 저장소다.

심화 모델 아티팩트, 버전, 학습 데이터·파라미터 출처, 평가 결과, 단계(staging/production), 승인 이력을 관리한다. 배포 파이프라인이 레지스트리의 승인 버전만 가져가도록 해 재현성과 감사 추적성을 확보한다. LLM 환경에서는 파인튜닝 어댑터와 프롬프트 버전까지 함께 관리하기도 한다.

예시 모델 위험관리 기준에 따라 검증 부서 승인을 받은 모델 버전만 레지스트리에서 운영계로 배포된다.

연관 MLOps, LLMOps, AI 거버넌스, 로라

출처 MLflow

모델 병합

Model Merging

학습·튜닝·정렬 · **심화**

입문 각기 다른 능력을 학습한 여러 모델의 가중치를 합쳐 추가 학습 없이 능력을 섞는 기법이다.

심화 같은 기반 모델에서 파생된 파인튜닝 모델들의 가중치를 평균, SLERP, 작업 벡터 연산, TIES·DARE 같은 간섭 완화 기법으로 결합한다. 학습 비용 없이 다기능 모델을 만들 수 있지만 결과 예측이 어렵고 반드시 평가로 검증해야 한다. 서로 다른 아키텍처나 기반 모델 간에는 일반적으로 적용하기 어렵다.

연관 로라, 어댑터, 파인튜닝, 체크포인트

출처 Hugging Face / 논문 Wortsman et al. 2022 · Ilharco et al. 2022 · Yadav et al. 2023

모델 카드

Model Card

평가·안전·규제 · **실무**

입문 AI 모델의 용도, 성능, 한계, 주의사항을 정리한 설명서다. 제품의 사용설명서나 성분표와 비슷하다.

심화 모델 개요, 의도된 용도와 부적절한 용도, 학습 데이터 개요, 평가 지표와 집단별 성능, 알려진 한계와 편향, 윤리적 고려사항을 표준 형식으로 기술한다. 공개 모델 저장소에서 사실상 표준으로 쓰이며, 사내 모델 관리에서도 검증·감사 근거 문서가 된다.

예시 사내 이상거래 탐지 모델 배포 시 학습 기간, 성능 지표, 취약 시나리오를 모델 카드로 작성해 검증 부서에 제출한다.

연관 시스템 카드, 책임 있는 AI, 감사 추적, AI 거버넌스, 모델

출처 Hugging Face / 논문 Mitchell et al. 2019

모델 컨텍스트 프로토콜

MCP · Model Context Protocol

AI 에이전트·도구 · **실무**

입문 AI와 외부 도구·데이터를 연결하는 표준 규격이다. USB-C처럼 한 번 규격에 맞춰 만들면 여러 AI 앱에서 같은 연결을 재사용할 수 있다.

심화 Anthropic이 2024년 11월 공개한 개방형 프로토콜로, 2025년 12월 리눅스 재단 산하 Agentic AI Foundation(AAIF)에 기증되어 중립적 거버넌스 아래에서 관리된다. 호스트 애플리케이션 안의 클라이언트가 서버에 연결하고, 서버는 도구(tools), 리소스(resources), 프롬프트(prompts)를 노출하며 JSON-RPC 기반으로 통신한다. 로컬(stdio)과 원격(HTTP 기반) 전송, OAuth 기반 인가를 지원하며, 도구 설명을 통한 프롬프트 인젝션이나 과도한 권한 부여 같은 보안 위험을 별도로 관리해야 한다.

예시 사내 DW 조회, 문서관리시스템 검색을 각각 MCP 서버로 만들어 두면 여러 AI 클라이언트가 동일한 서버를 그대로 연결해 쓸 수 있다.

연관 MCP 서버, MCP 클라이언트, 도구 사용, 에이전트 간 프로토콜, 커넥터

출처 Model Context Protocol · Anthropic · Wikipedia

모델 탈취

Model Extraction

평가·안전·규제 · **심화**

입문 AI 모델의 가중치를 훔치거나, 대량 질의로 비슷한 모델을 복제해 내는 공격이다.

심화 서버 침투로 가중치 파일 자체를 탈취하는 경우와, API에 대량 질의해 얻은 입출력 쌍으로 대리 모델을 학습시키는 추출(증류 기반 복제) 공격이 있다. 심사 모델의 경우 반복 질의로 판단 기준을 역추적해 우회하는 데 악용될 수 있다. 가중치 접근 통제·암호화, 질의량 제한, 비정상 질의 패턴 탐지, 출력 정보 최소화(점수 대신 결과만 제공)로 대응한다.

예시 신용평가 API에 동일 사용자의 미세하게 다른 반복 조회가 급증하면 차단하고 조사한다.

연관 지식 증류, 적대적 공격, 데이터 유출, API, 데이터 포이즈닝

출처 Wikipedia / 논문 Tramèr et al. 2016

문맥 압축

Contextual Compression

RAG·검색·데이터 · 심화

입문 찾아온 문서에서 질문과 관련된 부분만 추려 AI에게 넘기는 것이다. 긴 자료에 형광펜을 칠해 그 부분만 주는 셈이다.

심화 검색된 청크에서 질의와 무관한 문장을 제거하거나 요약해 컨텍스트 토큰을 줄이는 후처리 단계다. LLM 추출, 소형 모델 기반 문장 필터링, 임베딩 유사도 기반 문장 선택 등으로 구현한다. 비용과 노이즈를 줄이지만 과도한 압축은 필요한 근거를 잃게 한다.

예시 검색된 규정 5개 조항에서 질문과 관련된 문장만 남겨 프롬프트 길이를 1/3로 줄인다.

연관 컨텍스트 엔지니어링, 재순위화, 컨텍스트 윈도, 검색 증강 생성

논문 Xu et al. 2023

문서 파싱

Document Parsing

RAG·검색·데이터 · 실무

입문 PDF, 한글(HWP), 엑셀 같은 파일에서 글자와 표, 제목 구조를 컴퓨터가 쓸 수 있는 형태로 뽑아내는 작업이다.

심화 다양한 포맷의 문서에서 텍스트, 표, 이미지, 레이아웃 구조(제목 계층, 다단, 머리글)를 추출해 정규화하는 단계로, RAG 품질의 출발점이다. 스캔 문서는 OCR, 복잡한 표·도식은 레이아웃 분석 모델이나 VLM을 사용한다. 표가 깨지거나 읽기 순서가 섞이면 이후 청킹·검색이 모두 영향을 받는다.

예시 HWP·PDF 규정집을 파싱해 표는 마크다운 표로, 조항 구조는 계층 메타데이터로 변환한다.

연관 광학 문자 인식, 청킹, 비정형 데이터, 시각 언어 모델

출처 Microsoft / 논문 Xu et al. 2020 · Auer et al. 2024

문서 AI

Document AI

생성 AI·멀티모달 · 실무

입문 계약서, 신청서, 영수증 같은 문서를 읽고 필요한 정보를 뽑아 정리하는 AI 기술이다.

심화 OCR, 레이아웃 분석(제목·표·단락 구분), 표 구조 인식, 핵심 정보 추출, 문서 분류를 결합한 기술 영역이다. 최근에는 VLM이 문서 이미지를 직접 읽어 구조화된 JSON으로 출력하는 방식이 늘었으며, RAG 전처리에서 PDF를 정확히 파싱하는 단계로도 중요하다. 필드별 신뢰도 점수와 사람 검수 흐름을 함께 설계한다.

예시 기업 여신 심사 시 재무제표·등기부등본 PDF에서 핵심 항목을 추출해 심사 시스템 입력값으로 만든다.

연관 광학 문자 인식, 시각 언어 모델, 청킹, 구조화된 출력, 워크플로 자동화

출처 Microsoft · Hugging Face / 논문 Xu et al. 2019 · Huang et al. 2022 · Kim et al. 2021

ㅂ

바이브 코딩

Vibe Coding

프롬프트·추론 · 입문

입문 코드를 직접 짜기보다 AI에게 말로 원하는 것을 설명하고, 결과를 실행해 보며 고쳐 달라고 반복해 프로그램을 만드는 방식이다.

심화 2025년 초 안드레이 카파시가 쓴 표현으로, 개발자가 생성된 코드를 꼼꼼히 읽기보다 자연어 지시와 실행 결과 피드백으로 개발을 진행하는 스타일을 말한다. 프로토타입과 개인 도구 제작 속도를 크게 높이지만, 검토 없이 운영에 쓰면 보안 취약점과 유지보수 문제가 생긴다. 업무 시스템에서는 코딩 에이전트 활용과 함께 코드 리뷰·테스트를 병행해야 한다.

예시 현업 담당자가 AI에게 설명만으로 엑셀 데이터 정리 스크립트를 만들어 쓰되, 운영 반영 전에는 개발팀 검토를 받는다.

연관 코딩 에이전트, AI 에이전트, 프롬프트, AI 리터러시

출처 Wikipedia

바이트 페어 인코딩

BPE · Byte Pair Encoding

LLM·언어모델 · 심화

입문 자주 함께 나오는 글자 조합을 하나의 조각으로 합쳐 나가며 어휘집을 만드는 토큰화 방법이다.

심화 문자(또는 바이트) 단위에서 시작해 말뭉치에서 가장 빈번한 인접 쌍을 반복 병합해 서브워드 어휘를 구축한다. 바이트 수준 BPE는 미등록어 문제가 없지만 학습 데이터에 적은 언어는 잘게 쪼개진다. 다수의 LLM 토크나이저가 BPE 계열을 사용한다.

연관 토크나이저, 토큰, 한국어 토큰 효율

출처 Wikipedia · Hugging Face / 논문 Sennrich et al. 2016

반복 패널티

Repetition Penalty

LLM·언어모델 · 심화

입문 AI가 같은 말을 계속 되풀이하지 않도록 이미 나온 단어의 점수를 깎는 설정이다.

심화 이미 생성된 토큰의 로짓을 나누거나 빼서 재등장 확률을 낮춘다. API에 따라 frequency penalty(등장 횟수 비례)와 presence penalty(등장 여부)로 나뉜다. 과하면 고유명사나 필요한 반복까지 억제해 품질이 떨어진다.

연관 로짓, 샘플링, 그리디 디코딩

출처 Hugging Face · Hugging Face / 논문 Keskar et al. 2019

반성(자기 성찰)

Reflection

AI 에이전트·도구 · **실무**

입문 AI가 자기가 만든 결과물을 다시 보고 잘못된 점을 찾아 고치는 과정이다. 제출 전 스스로 검토하는 것과 같다.

심화 생성 → 비평 → 수정을 반복하는 패턴으로, 같은 모델이 자기 출력을 평가하거나 별도의 비평 모델·에이전트를 둔다. 테스트 실행 결과, 규칙 검사 등 외부의 객관적 피드백과 결합할 때 효과가 크며, 피드백 없이 자기 평가만 하면 오류를 확신하는 경우도 있다. 반복할수록 비용과 지연이 늘어 반복 횟수 상한을 둔다.

예시 보고서 초안을 쓴 뒤 '수치와 원천 데이터가 일치하는가'를 기준으로 스스로 점검해 불일치를 수정한다.

연관 계획 수립, LLM 심판 평가, 에이전틱 워크플로, 리액트(추론-행동)

출처 IBM / 논문 Shinn et al. 2023 · Madaan et al. 2023

배치 정규화

BN · Batch Normalization

딥러닝·신경망 · **심화**

입문 층마다 들어오는 값의 분포를 일정하게 맞춰 학습이 안정적이고 빨라지게 하는 기법이다.

심화 미니배치 단위로 각 채널(피처)의 평균·분산을 정규화한 뒤 학습 가능한 스케일·시프트를 적용한다. 더 큰 학습률을 허용하고 수렴을 가속하며 약한 정규화 효과도 있다. 배치 통계에 의존해 배치가 작거나 시퀀스 길이가 가변인 경우 불안정하며, 추론 시에는 학습 중 누적한 이동 평균을 쓴다. CNN에서 주로 사용된다.

연관 레이어 정규화, 배치 크기, 합성곱 신경망, 피처 스케일링(정규화·표준화)

출처 Wikipedia / 논문 Ioffe & Szegedy 2015

배치 추론

Batch Inference

인프라·배포·LLMOps · **실무**

입문 요청을 모아서 한꺼번에 처리하는 방식이다. 즉시 답이 필요 없는 대량 작업에 쓴다.

심화 실시간 응답 대신 대량 입력을 묶어 처리해 GPU 사용률을 높이고 단가를 낮춘다. 상용 API는 응답을 수 시간 내 돌려주는 대신 할인된 배치 요금을 제공하기도 한다. 서빙 엔진 내부에서 여러 요청을 동시에 처리하는 배칭(continuous batching)과는 구분해 쓴다.

예시 매일 밤 ETL 적재가 끝난 뒤 당일 민원 수만 건을 배치 추론으로 분류·요약해 DW 테이블에 적재한다.

연관 처리량, 비동기 처리, 토큰 비용, 데이터 파이프라인

출처 OpenAI · Anthropic

배치 크기

Batch Size

딥러닝·신경망 · **실무**

입문 한 번에 몇 개의 데이터를 묶어 보고 AI를 고칠지 정하는 숫자다.

심화 한 번의 파라미터 갱신에 사용하는 샘플 수다. 크면 기울기 추정이 안정되고 GPU 활용도가 높지만 메모리가 많이 필요하고, 일반화 성능을 유지하려면 학습률을 함께 조정해야 한다. 메모리가 부족하면 그래디언트 누적으로 큰 유효 배치를 흉내 낸다. 추론에서의 배치 크기는 처리량과 지연시간의 트레이드오프를 결정한다.

연관 에폭, 학습률, 확률적 경사하강법, GPU, 처리량

출처 Google for Developers · Google for Developers / 논문 Keskar et al. 2016 · Goyal et al. 2017

범용 인공지능

AGI · Artificial General Intelligence

AI 기초·머신러닝 · **입문**

입문 특정 업무가 아니라 사람이 할 수 있는 거의 모든 지적 작업을 사람 수준 이상으로 해내는 가상의 AI다.

심화 다양한 영역에서 인간 수준의 학습·추론·적응 능력을 갖춘 AI를 가리킨다. 합의된 정의와 측정 기준이 없어 기업·연구자마다 의미가 다르며, 달성 시점에 대한 전망도 크게 엇갈린다. 정책·안전 논의에서 장기 위험의 기준점으로 자주 언급된다.

연관 약인공지능과 강인공지능, 인공지능, 튜링 테스트, 책임 있는 AI, 정렬

출처 IBM · Wikipedia / 논문 Morris et al. 2023

벡터 데이터베이스

Vector DB · Vector Database

RAG·검색·데이터 · **실무**

입문 글이나 이미지의 '의미'를 숫자 목록(벡터)으로 바꿔 저장하고, 뜻이 비슷한 것을 빠르게 찾아주는 데이터베이스다.

심화 임베딩 벡터를 저장하고 근사 최근접 이웃(ANN) 인덱스로 유사도 검색을 수행하는 데이터베이스다. 전용 제품(Milvus, Qdrant, Weaviate 등) 외에 PostgreSQL pgvector, Oracle AI Vector Search, Elasticsearch/OpenSearch 등 기존 DB의 벡터 기능도 널리 쓰인다. 메타데이터 필터링, 하이브리드 검색, 권한 제어, 대량 갱신 성능이 선택 기준이다.

예시 기존 Oracle DB의 벡터 검색 기능을 활용해 별도 시스템 없이 상품약관 임베딩을 저장·검색한다.

연관 임베딩, 벡터 인덱스, 근사 최근접 이웃 검색, 의미 검색, 검색 증강 생성

출처 IBM · Oracle · Wikipedia

벡터 인덱스

Vector Index

RAG·검색·데이터 · **심화**

입문 벡터를 빠르게 찾을 수 있도록 미리 정리해 둔 색인이다. 책 뒤의 찾아보기와 같은 역할을 한다.

심화 벡터 유사도 검색을 가속하기 위한 자료구조로, Flat(전수), IVF, HNSW, PQ 압축 등이 있다. 데이터 규모, 갱신 빈도, 메모리 한도, 요구 재현율에 따라 선택하며, 대량 삭제·갱신이 잦으면 재구축 주기를 고려해야 한다. RDBMS의 B-tree 인덱스처럼 물리 설계 대상이다.

예시 매일 배치로 추가되는 문서는 증분 색인하고, 주 1회 벡터 인덱스를 재구축한다.

연관 HNSW, 근사 최근접 이웃 검색, 벡터 데이터베이스

출처 Microsoft · pgvector / 논문 Johnson et al. 2017 · Malkov and Yashunin 2016

벤더 종속

Vendor Lock-in

AX·비즈니스 적용 · **실무**

입문 특정 업체의 제품이나 서비스에 깊이 의존하게 돼 다른 것으로 바꾸기 어렵고 비싸지는 상태다.

심화 특정 모델 API 고유 기능, 독자 SDK, 클라우드 전용 서비스, 하드웨어 생태계에 의존할수록 교체 비용이 커진다. 모델 게이트웨이를 통한 추상화, 표준 인터페이스(OpenAI 호환 API, MCP 등) 채택, 프롬프트·평가셋의 모델 독립적 관리, 데이터 반출 조건 계약으로 완화한다.

예시 모든 애플리케이션이 게이트웨이를 거쳐 모델을 호출하게 해 향후 모델 제공사를 바꿔도 영향이 없도록 했다.

연관 모델 게이트웨이, 자체 구축 대 구매, 총소유비용, 소버린 AI

출처 Wikipedia

벤치마크

Benchmark

평가·안전·규제 · **입문**

입문 여러 AI 모델의 실력을 같은 시험지로 비교하는 표준 시험이다.

심화 고정된 문제 세트, 정답, 채점 방식을 공개해 모델 간 비교를 가능하게 한다. 지식(MMLU), 코딩(SWE-bench), 수학, 추론, 안전성 등 영역별로 다양하다. 문제가 학습 데이터에 섞이는 오염, 점수 포화, 실제 업무와의 괴리 때문에 공개 점수만으로 도입을 결정하면 안 되고 자체 평가셋을 함께 써야 한다.

예시 내부 모델 선정 시 공개 벤치마크로 후보를 좁히고, 최종 결정은 사내 골든 데이터셋 점수로 한다.

연관 평가, 리더보드, MMLU, SWE-bench, 데이터 오염

출처 Hugging Face · Wikipedia / 논문 Hendrycks et al. 2020 · Liang et al. 2022

변분 오토인코더

VAE · Variational Autoencoder

생성 AI·멀티모달 · **심화**

입문 그림을 작게 압축했다가 다시 원래대로 복원하도록 배운 신경망이다. 이미지 생성 AI의 압축·복원 장치로 많이 쓰인다.

심화 인코더가 입력을 잠재 분포의 평균·분산으로 매핑하고 디코더가 샘플링된 잠재 벡터에서 입력을 복원하도록, 재구성 손실과 KL 발산을 함께 최소화하는 생성 모델이다. 단독 생성 품질은 흐릿한 편이지만, 잠재 확산 모델에서 픽셀↔잠재 변환기로 핵심 역할을 하며 그 압축 품질이 최종 이미지의 세부 묘사를 좌우한다.

연관 잠재 공간, 확산 모델, 신경망, 생성형 AI

출처 IBM · Wikipedia / 논문 Kingma, Welling 2013

변화관리

Change Management

AX·비즈니스 적용 · **실무**

입문 새로운 시스템이나 일하는 방식을 구성원이 받아들이고 정착하도록 돕는 체계적인 활동이다.

심화 AI 도입은 직무 불안, 결과 불신, 기존 관행 고수로 저항이 생기기 쉽다. 경영진 메시지, 현업 참여형 설계, 교육, 챔피언 네트워크, 성공 사례 공유, 성과 평가 기준 조정을 병행한다. 기술보다 사람과 프로세스 문제로 AX가 정체되는 경우가 많아 초기부터 계획에 포함해야 한다.

예시 AI 도입 부서마다 현업 챔피언을 지정하고 월 1회 활용 사례 공유회를 열어 사용률을 높였다.

연관 AI 챔피언, AI 도입, 리스킬링·업스킬링, 업무 재설계

출처 Wikipedia

보상모델

RM · Reward Model

학습·튜닝·정렬 · **심화**

입문 AI 답변이 얼마나 좋은지 점수를 매기도록 학습된 채점용 모델이다.

심화 선호 쌍 데이터로 선택된 응답에 더 높은 스칼라 점수를 주도록(Bradley-Terry 손실 등) 학습한다. RLHF에서 정책의 보상 신호로 쓰이며, 베스트 오브 N 선택이나 데이터 필터링에도 활용된다. 최종 답만 채점하는 결과 보상모델과 추론 단계별로 채점하는 과정 보상모델(PRM)이 있다.

연관 인간 피드백 기반 강화학습, 선호 데이터, 근접 정책 최적화, 보상 해킹, LLM 심판 평가

출처 Hugging Face · Hugging Face / 논문 Ouyang et al. 2022 · Lightman et al. 2023 · Gao et al. 2022

보상 해킹

Reward Hacking

학습·튜닝·정렬 · **심화**

입문 AI가 진짜 목표를 달성하지 않고 점수만 높게 받는 꼼수를 학습하는 현상이다.

심화 보상 함수나 보상모델의 결함을 정책이 악용해 보상은 오르지만 실제 품질은 떨어지는 문제다. 장황한 응답, 아첨, 테스트 코드 조작 등이 예다. KL 패널티, 보상모델 앙상블, 검증기 강화, 사람 감수로 완화한다.

연관 보상모델, 인간 피드백 기반 강화학습, 검증가능 보상 기반 강화학습, 정렬, KL 패널티

출처 Wikipedia / 논문 Amodei et al. 2016 · Gao et al. 2022

분류

Classification

AI 기초·머신러닝 · **입문**

입문 데이터를 정해진 칸 중 하나에 넣는 일이다. 메일을 스팸/정상으로 나누는 것이 대표적이다.

심화 입력을 이산적인 범주(클래스) 중 하나 또는 여러 개로 예측하는 지도학습 과제다. 이진·다중·다중레이블 분류가 있으며, 모델은 보통 클래스별 확률을 출력하고 임계값으로 최종 판정한다. 정확도 외에 정밀도·재현율·AUC로 평가한다.

예시 대출 신청 건을 승인/보류/거절로 분류해 심사 담당자에게 우선순위를 제공한다.

연관 지도학습, 회귀, 로지스틱 회귀, 혼동행렬, 정밀도와 재현율

출처 IBM · Wikipedia / 논문 Sokolova and Lapalme 2009

분산 학습

Distributed Training

학습·튜닝·정렬 · **심화**

입문 하나의 GPU로는 감당할 수 없는 큰 모델과 데이터를 여러 GPU와 서버에 나눠 함께 학습하는 방식이다.

심화 데이터 병렬, 텐서 병렬, 파이프라인 병렬, 전문가 병렬, 시퀀스 병렬을 조합(3D/4D 병렬)해 수천 개 GPU로 확장한다. ZeRO·FSDP는 가중치·그래디언트·옵티마이저 상태를 장치 간 분할해 메모리를 줄인다. 고속 인터커넥트와 통신·연산 중첩이 효율의 핵심이다.

연관 데이터 병렬화, 텐서 병렬화, 파이프라인 병렬화, GPU, 체크포인트

출처 Hugging Face · Hugging Face · IBM / 논문 Rajbhandari et al. 2019 · Narayanan et al. 2021

브라우저 에이전트

Browser Agent

AI 에이전트·도구 · **실무**

입문 웹 브라우저를 직접 열어 검색하고, 클릭하고, 양식을 채우는 AI 에이전트다.

심화 브라우저 자동화 도구(DOM 접근, 접근성 트리, 스크린샷)를 통해 페이지를 읽고 탐색·입력·클릭을 수행한다. DOM·접근성 트리를 쓰면 화면 좌표 방식보다 정확하고 빠르지만, 웹페이지 속 악성 지시에 의한 프롬프트 인젝션, 로그인 세션 악용, 의도치 않은 결제·제출 위험이 있어 사이트 허용 목록과 민감 행동 승인 절차가 필요하다.

예시 공시 사이트에서 여러 기업의 최근 공시를 찾아 표로 정리하는 작업을 수행한다.

연관 컴퓨터 사용, 프롬프트 인젝션, 에이전트 권한 관리, 딥 리서치

출처 OpenAI · IBM / 논문 Zhou et al. 2023 · Deng et al. 2023

비동기 처리

Asynchronous Processing

인프라·배포·LLMOps · **실무**

입문 요청을 보내 놓고 결과를 기다리지 않고 다른 일을 하다가, 끝나면 결과를 받는 처리 방식이다.

심화 LLM 호출은 수 초~수십 초가 걸리므로 메시지 큐(Kafka, RabbitMQ 등)와 워커를 두어 요청을 비동기로 처리하고 콜백이나 폴링으로 결과를 전달한다. 타임아웃, 재시도, 멱등성, 레이트 리밋 대응을 함께 설계해야 하며 에이전트 장기 작업에도 필수다.

예시 보고서 초안 생성은 큐에 작업을 넣고 완료 시 메신저로 알림을 보내도록 비동기로 구성했다.

연관 배치 추론, 레이트 리밋, 지연 시간, 에이전틱 워크플로

출처 Wikipedia · AWS

비정형 데이터

Unstructured Data

RAG·검색·데이터 · **입문**

입문 문서, 이메일, 녹음, 이미지처럼 정해진 표 형식이 없는 데이터다. 기업 데이터의 대부분을 차지한다.

심화 고정 스키마 없이 저장되는 텍스트·이미지·음성·영상 데이터다. 과거에는 분석이 어려웠지만 LLM과 임베딩, OCR, STT로 검색·요약·추출이 가능해지며 RAG의 주 대상이 되었다. 활용하려면 파싱, 메타데이터 부여, 개인정보 마스킹, 접근 권한 관리가 선행되어야 한다.

예시 상담 녹취를 STT로 텍스트화하고 요약·분류해 민원 유형 통계를 DW에 적재한다.

연관 정형 데이터, 문서 파싱, 검색 증강 생성, 음성 인식

출처 IBM · Wikipedia

비지도학습

Unsupervised Learning

AI 기초·머신러닝 · **입문**

입문 정답 없이 데이터만 주고, 비슷한 것끼리 묶거나 숨은 구조를 스스로 찾게 하는 방식이다.

심화 레이블 없이 데이터의 분포나 구조를 학습한다. 대표 과제는 군집화, 차원 축소, 밀도 추정, 이상 탐지다. 결과 해석에 도메인 지식이 필요하고 정량 평가 기준이 모호한 경우가 많다.

예시 고객 거래 패턴을 군집화해 마케팅용 고객 세그먼트를 도출한다.

연관 군집화, 차원 축소, 이상 탐지, 지도학습, 자기지도학습

출처 IBM · Wikipedia

빔 서치

Beam Search

LLM·언어모델 · **심화**

입문 여러 개의 문장 후보를 동시에 키워 가다가 전체적으로 가장 그럴듯한 문장을 고르는 방식이다.

심화 각 스텝에서 누적 로그확률 상위 B개 부분 시퀀스(빔)를 유지하며 확장한다. 기계번역처럼 정답이 비교적 정해진 작업에서 효과적이지만, 개방형 생성에서는 짧고 반복적인 문장을 선호하는 경향이 있어 대화형 LLM에서는 잘 쓰지 않는다. 연산량이 빔 폭에 비례한다.

연관 그리디 디코딩, 샘플링, 자기회귀 모델

출처 Wikipedia · Hugging Face / 논문 Holtzman et al. 2020

ㅅ

사고의 연쇄

CoT · Chain-of-Thought

프롬프트·추론 · **실무**

입문 AI에게 답만 말하지 말고 풀이 과정을 단계별로 생각하게 하는 방법이다. 수학 문제를 풀 때 중간 과정을 적는 것과 같다.

심화 모델이 최종 답 전에 중간 추론 단계를 생성하도록 유도하는 기법이다. '단계별로 생각하라' 같은 지시(zero-shot CoT)나 풀이가 포함된 예시(few-shot CoT)로 유도하며, 산술·논리·다단계 판단 작업의 정확도를 높인다. 추론 모델은 이를 학습 단계에서 내재화했으며, 생성된 추론이 실제 내부 계산을 충실히 반영하지 않을 수 있다는 점은 유의해야 한다.

예시 대출 한도 산정 규정 적용 여부를 판단할 때 조건별로 하나씩 검토한 뒤 결론을 내도록 지시한다.

연관 추론 모델, 자기일관성, 트리 오브 소트, 테스트 타임 컴퓨트

출처 Anthropic · Wikipedia / 논문 Wei et al. 2022 · Kojima et al. 2022

사고 예산

Thinking Budget

프롬프트·추론 · **심화**

입문 AI가 생각하는 데 쓸 수 있는 분량의 상한이다. 많이 줄수록 깊이 생각하지만 시간과 비용이 늘어난다.

심화 추론 모델이 내부 사고에 사용할 최대 토큰 수(또는 low/medium/high 같은 노력 수준)를 지정하는 파라미터다. 예산이 클수록 어려운 문제 정확도가 대체로 오르지만 수익이 체감하고, 사고 토큰도 과금 대상이다. 작업 난이도별 라우팅으로 예산을 다르게 주는 것이 비용 최적화의 핵심이다.

예시 단순 FAQ 응답은 사고 예산 최소, 신용평가 근거 분석은 높은 예산으로 설정한다.

연관 확장 사고, 추론 모델, 테스트 타임 컴퓨트, AI 비용

출처 Anthropic · Anthropic · OpenAI / 논문 Snell et al. 2024

사내 LLM 포털

Enterprise LLM Portal

AX·비즈니스 적용 · **실무**

입문 직원들이 회사가 승인한 생성형 AI를 안전하게 쓸 수 있도록 만든 사내 전용 AI 서비스 창구다.

심화 인증·권한 연동, 사용 로그와 감사, 개인정보·기밀 필터링, 사내 문서 RAG, 프롬프트 라이브러리, 부서별 사용량 관리를 제공한다. 외부 AI 서비스 무단 사용(섀도 AI)을 줄이고 데이터 유출을 통제하는 수단이며, 뒤단은 온프레미스 모델이나 승인된 외부 API로 구성한다.

예시 전 직원에게 사내 GPT 포털을 열고 규정·상품 문서 검색과 문서 초안 작성 기능을 제공했다.

연관 모델 게이트웨이, 프롬프트 라이브러리, 섀도 AI, 검색 증강 생성, AI 도입

사용자 프롬프트

User Prompt

프롬프트·추론 · **입문**

입문 사용자가 그때그때 입력하는 질문이나 요청이다. 시스템 프롬프트가 기본 규칙이라면 사용자 프롬프트는 개별 주문서다.

심화 채팅 형식 API에서 user 역할로 전달되는 메시지다. 시스템 프롬프트의 전역 지침 아래에서 개별 작업을 지시하며, 대화가 이어지면 이전 user/assistant 메시지가 누적되어 컨텍스트를 이룬다. 외부 입력이 섞이는 지점이므로 인젝션 방어와 입력 검증이 필요하다.

예시 직원이 챗봇 입력창에 '이번 분기 연체율 추이를 설명해줘'라고 치는 것이 사용자 프롬프트다.

연관 시스템 프롬프트, 프롬프트, 프롬프트 인젝션

출처 OpenAI · Wikipedia

사전학습
Pre-training
학습·튜닝·정렬 · **입문**

입문 인터넷 글, 책, 코드 등 엄청난 양의 데이터를 먼저 읽혀 언어와 지식의 기초를 익히게 하는 첫 학습 단계다.

심화 레이블 없는 대규모 말뭉치에서 다음 토큰 예측 같은 자기지도 목표로 모델을 처음부터 학습한다. 전체 학습 비용의 대부분을 차지하며 수조~수십조 토큰과 대규모 GPU 클러스터가 필요하다. 데이터 품질·구성 비율이 최종 성능을 크게 좌우한다.

연관 다음 토큰 예측, 사전학습 데이터 정제, 학습 토큰 수, 사후학습, 파운데이션 모델

출처 Hugging Face · AWS · Wikipedia / 논문 Devlin et al. 2018 · Brown et al. 2020

사전학습 데이터 정제
Pre-training Data Curation
학습·튜닝·정렬 · **심화**

입문 모델에 먹일 방대한 데이터에서 중복, 저품질, 유해한 내용을 걸러 내고 좋은 데이터를 골라내는 작업이다.

심화 웹 크롤 데이터에 대해 언어 식별, 중복 제거(정확·근사), 휴리스틱·분류기 기반 품질 필터링, 유해 콘텐츠와 개인정보 제거, 도메인 혼합 비율 조정을 수행한다. 같은 연산량에서도 데이터 품질이 성능 차이를 크게 만든다. 평가셋과의 중복 제거로 데이터 오염도 막는다.

연관 사전학습, 학습 데이터, 데이터 오염, 데이터 프라이버시, 합성 데이터

출처 Hugging Face · IBM / 논문 Penedo et al. 2024 · Lee et al. 2021

사후학습
Post-training
학습·튜닝·정렬 · **실무**

입문 사전학습으로 기초를 갖춘 모델을 실제로 쓸 수 있는 비서형 모델로 다듬는 후속 학습 단계 전체를 말한다.

심화 SFT, 선호 최적화(RLHF·DPO), 검증가능 보상 기반 강화학습, 안전성 학습 등을 포함한다. 최근에는 추론 능력 향상을 위한 대규모 강화학습이 사후학습 연산 비중을 크게 늘렸다. 사전학습 대비 적은 데이터로 모델의 행동 특성을 크게 바꾼다.

연관 사전학습, 지도 미세조정, 인간 피드백 기반 강화학습, 검증가능 보상 기반 강화학습, 정렬

출처 Hugging Face · Wikipedia / 논문 Ouyang et al. 2022 · Lambert et al. 2024 · DeepSeek-AI 2025

상위 k개 검색
Top-k Retrieval
RAG·검색·데이터 · **실무**

입문 검색 결과 중 점수가 가장 높은 k개만 골라 AI에게 넘기는 설정이다.

심화 검색·재순위화 후 LLM 컨텍스트에 넣을 청크 수를 정하는 파라미터다. k가 작으면 필요한 근거를 놓치고, 크면 노이즈와 토큰 비용이 늘며 중요 정보가 묻힐 수 있다. 유사도 임계값과 병행하거나 질문 유형별로 동적으로 조정하며, Recall@k 같은 지표로 튜닝한다.

예시 규정 질의응답은 top-k=5로, 여러 문서를 비교하는 질문은 k=15로 설정한다.

연관 검색(리트리벌), 재순위화, 컨텍스트 윈도, 평가

출처 Microsoft / 논문 Liu et al. 2023

상태공간모델
SSM · State Space Model
LLM·언어모델 · **심화**

입문 트랜스포머와 달리 긴 글을 고정 크기 기억에 요약해 가며 읽는 구조로, 긴 입력을 빠르게 처리한다. Mamba가 대표적이다.

심화 연속 시스템의 상태공간 방정식을 이산화한 순환 구조로, 시퀀스 길이에 선형인 연산과 상수 크기 상태 메모리를 갖는다. Mamba는 입력에 따라 파라미터가 바뀌는 선택적 SSM과 하드웨어 친화적 병렬 스캔으로 성능을 끌어올렸다. 다만 정확한 복사·검색처럼 임의 위치를 참조하는 작업은 어텐션보다 약하다.

연관 트랜스포머, 순환 신경망, 하이브리드 모델, 롱 컨텍스트

출처 Wikipedia / 논문 Gu et al. 2022 · Gu and Dao 2023

샘플링
Sampling (Decoding)
LLM·언어모델 · **실무**

입문 모델이 계산한 확률에 따라 다음 단어를 뽑는 방식이다. 같은 질문에도 매번 조금씩 다른 답이 나오는 이유다.

심화 확률분포에서 확률적으로 토큰을 선택하는 디코딩 전략으로 temperature, Top-k, Top-p, min-p 등으로 분포를 조정한다. 다양성과 정확성 사이의 균형을 조절하며, 여러 번 샘플링해 다수결(자기일관성)로 정답률을 높이기도 한다.

연관 온도, Top-p 샘플링, Top-k 샘플링, 그리디 디코딩, 빔 서치

출처 Hugging Face · Hugging Face / 논문 Holtzman et al. 2020 · Fan et al. 2018

생산성 지표

Productivity Metrics

AX·비즈니스 적용 · **실무**

입문 AI 도입으로 일이 얼마나 빨라지고 좋아졌는지 측정하는 기준이다.

심화 처리 시간, 건당 처리량, 재작업·오류율, 결과물 수정률, 대기 시간, 사용자 만족도 등을 도입 전 기준선과 비교한다. 자기 보고식 '절감 시간'은 과대평가되기 쉬워 시스템 로그 기반 측정과 표본 관찰을 병행하는 것이 좋다.

예시 현업 데이터 요청 처리 리드타임과 SQL 수정 횟수를 AI 도입 전후로 비교해 효과를 보고했다.

연관 투자 대비 효과, A/B 테스트, AI 도입, 데이터 기반 의사결정

출처 Eurostat / 논문 Brynjolfsson et al. 2023 · Peng et al. 2023

생성물 저작권

Copyright of AI-Generated Content

생성 AI·멀티모달 · **실무**

입문 AI가 만든 글·그림의 저작권이 누구에게 있는지, AI 학습에 남의 저작물을 써도 되는지에 관한 법적 문제다.

심화 쟁점은 크게 학습 데이터 이용의 적법성(공정 이용·TDM 예외 해당 여부)과 생성물의 저작물성(인간의 창작적 기여 여부)으로 나뉜다. 다수 국가에서 사람의 창작적 기여가 없는 순수 AI 생성물은 저작권 보호를 받기 어렵다는 입장이며, 학습 데이터 관련 소송과 라이선스 계약이 계속되고 있다. 기업은 생성물이 기존 저작물과 유사하지 않은지 검토하고 서비스 약관의 권리·면책 조항을 확인해야 한다.

예시 마케팅팀은 AI로 만든 이미지를 쓸 때 기존 캐릭터·로고와의 유사성을 점검하고 사용 도구의 상업 이용 조건을 확인한다.

연관 생성형 AI, 학습 데이터, 콘텐츠 출처 증명, AI 거버넌스

출처 U.S. Copyright Office · Wikipedia

생성적 적대 신경망

GAN · Generative Adversarial Network

생성 AI·멀티모달 · **실무**

입문 가짜를 만드는 AI와 가짜를 가려내는 AI가 서로 경쟁하며 실력을 키우는 생성 모델이다. 위조범과 감정사의 경쟁에 비유된다.

심화 생성자(generator)는 판별자(discriminator)를 속이도록, 판별자는 진짜와 생성 샘플을 구분하도록 동시에 학습하는 2014년 제안 구조다. 한 번의 순전파로 빠르게 생성하지만 학습 불안정, 모드 붕괴(다양성 부족) 문제가 있어 고품질 이미지 생성 주류는 확산 모델로 넘어갔다. 초해상도, 스타일 변환, 확산 모델의 디코더 보조 손실 등에서 여전히 쓰인다.

연관 확산 모델, 딥페이크, 업스케일링, 생성형 AI

출처 Google for Developers · Wikipedia / 논문 Goodfellow et al. 2014

생성형 AI

GenAI · Generative AI

생성 AI·멀티모달 · **입문**

입문 글, 그림, 음성, 영상 같은 새로운 콘텐츠를 만들어 내는 AI다.

심화 학습 데이터의 분포를 모델링해 새로운 샘플을 생성하는 모델 계열로, 텍스트는 주로 자기회귀 트랜스포머(LLM), 이미지·영상은 확산 모델과 플로우 매칭 등이 쓰인다. 분류·예측 중심의 판별형 AI와 대비되며, 환각, 저작권, 딥페이크 등 고유 위험이 함께 논의된다.

예시 상품 설명서, 고객 안내문, 마케팅 이미지 초안을 생성형 AI로 빠르게 만든다.

연관 대규모 언어모델, 확산 모델, 멀티모달, 파운데이션 모델

출처 IBM · Wikipedia / 논문 Goodfellow et al. 2014 · Ho et al. 2020

생성형 AI 표시 의무

AI-Generated Content Labeling Obligation

평가·안전·규제 · **입문**

입문 AI로 만든 결과물에 AI가 만들었다는 사실을 알리도록 한 법적 의무다. 한국에서는 일반 이용자가 아니라 AI 서비스를 제공하는 사업자에게 의무가 있다.

심화 한국 AI 기본법은 고영향·생성형 AI 기반 서비스임을 사전 고지하고, 생성물에 AI 생성 사실을 표시하도록 한다. 표시는 가시적(문구·로고) 또는 비가시적(메타데이터·디지털 워터마크) 방식을 택할 수 있으나, 실제와 구분하기 어려운 딥페이크는 이용자가 명확히 인식할 수 있게 표시해야 한다. EU AI Act도 2026년 8월부터 챗봇 고지와 합성 콘텐츠 기계판독 표시 의무를 적용한다.

예시 AI 상담원과 대화를 시작할 때 'AI가 응답합니다'라는 안내를 화면 상단에 띄운다.

연관 워터마킹, 딥페이크, 인공지능 기본법, EU 인공지능법, 생성형 AI

출처 국가법령정보센터 · EU Artificial Intelligence Act (artificialintelligenceact.eu)

섀도 AI

Shadow AI

AX·비즈니스 적용 · **실무**

입문 회사 승인 없이 직원이 개인적으로 외부 AI 서비스를 업무에 쓰는 것이다.

심화 편의 때문에 승인되지 않은 챗봇이나 AI 도구에 업무 문서·고객정보를 입력하면 데이터 유출, 저작권, 규제 위반 위험이 생긴다. 일괄 금지만으로는 근절이 어려워 승인된 사내 LLM 포털 같은 안전한 대안 제공, 사용 정책 교육, DLP 통제를 함께 적용한다.

예시 외부 AI 서비스 무단 사용을 줄이기 위해 사내 LLM 포털을 열고 업무망에서의 외부 AI 접속은 차단했다.

연관 사내 LLM 포털, AI 거버넌스, 데이터 프라이버시, AI 리터러시

출처 IBM

서브에이전트

Subagent

AI 에이전트·도구 · **실무**

입문 메인 에이전트가 일부 작업을 떼어 맡기는 보조 에이전트다. 팀장이 팀원에게 조사 업무를 나눠 주는 것과 비슷하다.

심화 상위 에이전트가 하위 작업을 위해 별도 컨텍스트·지시·도구 집합을 가진 에이전트를 생성해 실행하고 요약된 결과만 돌려받는 구조다. 메인 컨텍스트가 탐색 과정의 잡음으로 오염되는 것을 막고 병렬 실행이 가능하다. 하위 에이전트에게 충분한 맥락을 전달하지 못하면 결과 품질이 떨어지므로 위임 지시를 구체적으로 작성해야 한다.

예시 코드베이스 분석 시 메인 에이전트가 모듈별로 서브에이전트를 띄워 병렬로 조사하고 결과만 취합한다.

연관 멀티 에이전트, 오케스트레이션, 핸드오프, 컨텍스트 엔지니어링

출처 Anthropic · Anthropic

서비스 수준 협약

SLA · Service Level Agreement

AX·비즈니스 적용 · **실무**

입문 서비스 제공자가 보장하는 가용성, 응답 속도, 장애 복구 시간 등을 약속한 계약이다.

심화 가용률(예: 99.9%), 응답 지연, 장애 대응·복구 시간, 데이터 보존·삭제, 위반 시 보상을 명시한다. LLM 서비스는 응답 품질을 SLA로 보장하기 어려워 가용성·지연 중심이 되며, 내부 서비스도 SLO를 정해 폴백·용량 계획에 반영한다. 금융권은 외부 위탁 시 업무 연속성 요건을 함께 검토해야 한다.

예시 외부 LLM API 계약 시 가용률과 장애 통보 시간, 입력 데이터 학습 미사용 조항을 SLA에 포함했다.

연관 지연 시간, 폴백 모델, 확산, 벤더 종속

출처 IBM · Wikipedia · Wikipedia

선호 데이터

Preference Data

학습·튜닝·정렬 · **실무**

입문 같은 질문에 대한 두 답변 중 어느 쪽이 더 나은지 표시한 데이터다.

심화 프롬프트와 선택(chosen)·거절(rejected) 응답 쌍, 또는 순위·점수 형태로 구성된다. 사람 평가자나 AI 평가자가 유용성·정확성·안전성 기준으로 판정하며, 평가 가이드라인의 일관성과 평가자 간 일치도가 품질을 좌우한다. 보상모델 학습과 DPO류 학습에 쓰인다.

예시 내부 전문가가 챗봇 답변 쌍을 비교 평가해 금융 도메인 선호 데이터를 구축한다.

연관 직접 선호 최적화, 보상모델, 인간 피드백 기반 강화학습, AI 피드백 기반 강화학습

출처 Hugging Face / 논문 Christiano et al. 2017 · Bai et al. 2022

설명 가능한 AI

XAI · Explainable AI

평가·안전·규제 · **실무**

입문 AI가 왜 그런 결론을 냈는지 사람이 이해할 수 있게 설명해 주는 기술과 접근이다.

심화 결정트리처럼 구조 자체가 해석 가능한 모델을 쓰거나, 복잡한 모델에 SHAP·LIME 같은 사후 설명 기법을 적용해 변수 기여도를 제시한다. LLM에서는 근거 문서 인용, 판단 근거 요약이 실무적 설명 수단이 되고, 내부 작동 자체를 분석하는 연구는 기계적 해석가능성으로 이어진다. 사후 설명은 실제 모델 내부 논리와 다를 수 있다는 한계가 있다.

예시 대출 거절 시 고객에게 '소득 대비 부채 비율'처럼 주요 판단 요인을 쉬운 말로 안내한다.

연관 기계적 해석가능성, 책임 있는 AI, 고영향 인공지능, 금융분야 AI 가이드라인, 모델

출처 IBM · Wikipedia / 논문 Lundberg and Lee 2017 · Ribeiro et al. 2016

셀프 어텐션

Self-Attention

딥러닝·신경망 · **심화**

입문 한 문장 안의 단어들이 서로를 바라보며 관계를 파악하는 방식이다. '그것'이 앞의 어떤 단어를 가리키는지 알아내는 데 쓰인다.

심화 같은 시퀀스에서 Q, K, V를 모두 생성해 각 토큰이 다른 모든 토큰과의 관련도를 계산하는 어텐션이다. 장거리 의존성을 한 번에 포착하고 병렬 처리가 가능하다. 디코더에서는 미래 토큰을 가리는 인과적 마스크를 적용하며, 시간·메모리 비용이 $O(n^2)$이라 FlashAttention, 희소 어텐션 등 최적화가 연구된다.

연관 어텐션, 멀티헤드 어텐션, 트랜스포머, KV 캐시, 컨텍스트 윈도

출처 IBM · Wikipedia / 논문 Vaswani et al. 2017

소버린 AI

Sovereign AI

인프라·배포·LLMOps · **실무**

입문 한 국가나 조직이 AI 기술·데이터·인프라를 외부에 의존하지 않고 스스로 통제할 수 있는 능력이다.

심화 자국 데이터센터·GPU 확보, 자국어와 문화에 맞는 파운데이션 모델 개발, 데이터 주권 보장을 포함한다. 한국은 정부 주도로 독자 AI 파운데이션 모델 프로젝트와 국가 GPU 확충을 추진하고 있다. 전면 자립보다는 핵심 영역의 통제권 확보와 해외 모델과의 병행이 현실적 방향으로 논의된다.

예시 공공·금융권은 데이터 국외 이전 우려 때문에 국내 개발 모델과 국내 데이터센터 기반 서비스를 검토 대상에 넣고 있다.

연관 파운데이션 모델, 온프레미스, NPU, 다국어 모델, 벤더 종속

출처 NVIDIA

소프트맥스

Softmax

딥러닝·신경망 · **실무**

입문 여러 후보의 점수를 합이 100%가 되는 확률로 바꿔주는 함수다.

심화 실수 벡터(로짓) z를 $\exp(z_i)/\Sigma\exp(z_j)$로 변환해 확률 분포를 만든다. 다중 클래스 분류의 출력층과 어텐션 가중치 계산에 쓰인다. LLM에서는 로짓을 온도로 나눈 뒤 소프트맥스를 적용해 샘플링 분포의 날카로움을 조절한다. 오버플로 방지를 위해 최댓값을 빼고 계산한다.

연관 활성화 함수, 교차 엔트로피, 어텐션, 온도, 분류

출처 Wikipedia

소형 언어모델

SLM · Small Language Model

LLM·언어모델 · **실무**

입문 크기를 줄여 일반 서버나 노트북, 휴대폰에서도 돌릴 수 있는 가벼운 언어모델이다.

심화 통상 수억~십수억 파라미터 규모(경계는 관행적)로, 고품질 데이터 선별·증류·합성 데이터로 크기 대비 성능을 끌어올린다. 지연시간과 비용이 낮고 온디바이스·온프레미스 배포가 쉽지만 복잡한 추론과 폭넓은 지식에서는 대형 모델보다 약하다. 특정 업무에 파인튜닝해 쓰는 경우가 많다.

예시 민원 문서 분류처럼 범위가 좁은 업무는 SLM을 파인튜닝해 저비용으로 처리한다.

연관 대규모 언어모델, 지식 증류, 엣지 AI, 파라미터 수와 모델 크기, 파인튜닝

출처 IBM / 논문 Gunasekar et al. 2023

손실 마스킹

Loss Masking

학습·튜닝·정렬 · **심화**

입문 학습할 때 질문 부분은 채점하지 않고 AI가 답해야 할 부분만 채점하도록 가리는 기법이다.

심화 SFT에서 프롬프트·시스템 메시지·패딩 토큰의 레이블을 무시값(예: -100)으로 설정해 응답 토큰에만 손실을 계산한다. 모델이 사용자 입력을 따라 쓰는 것을 학습하지 않게 하고 학습 신호를 응답 품질에 집중시킨다. 멀티턴 데이터에서는 어떤 assistant 턴까지 학습할지 정책을 정해야 한다.

연관 지도 미세조정, 손실 함수, 채팅 템플릿, 지시 튜닝

출처 Hugging Face · Hugging Face

손실 함수

Loss Function

딥러닝·신경망 · **실무**

입문 AI의 답이 정답과 얼마나 다른지를 숫자 하나로 매기는 채점 기준이다. 학습은 이 숫자를 줄이는 과정이다.

심화 모델 예측과 정답 간 차이를 스칼라로 정량화하는 함수로, 최적화의 목적함수가 된다. 회귀에는 MSE·MAE, 분류에는 교차 엔트로피가 대표적이며 불균형 데이터에는 초점 손실 등을 쓴다. 손실 선택은 모델이 무엇을 중시할지를 정하는 설계 결정이다.

예시 부도 미탐 비용이 오탐보다 크므로 양성 클래스에 가중치를 둔 손실 함수로 학습한다.

연관 교차 엔트로피, 경사하강법, 역전파, 정규화(규제), 옵티마이저

출처 IBM · Wikipedia

순환 신경망

RNN · Recurrent Neural Network

딥러닝·신경망 · **실무**

입문 앞에서 본 내용을 기억하며 순서대로 데이터를 읽는 신경망이다. 문장이나 시계열처럼 순서가 중요한 데이터에 쓴다.

심화 이전 시점의 은닉 상태를 현재 입력과 함께 받아 순차 데이터를 처리하는 신경망이다. 시간 축으로 펼쳐 역전파(BPTT)로 학습한다. 긴 시퀀스에서 기울기 소실로 장기 의존성 학습이 어렵고 병렬화가 안 되어, LSTM·GRU로 개선되었다가 대부분의 언어 과제에서 트랜스포머로 대체되었다.

예시 고객의 월별 거래 시퀀스를 RNN에 입력해 다음 달 이탈 가능성을 예측한다.

연관 장단기 메모리, 게이트 순환 유닛, 기울기 소실, 트랜스포머, 시계열 예측

출처 IBM · Wikipedia / 논문 Elman 1990 · Bengio et al. 1994

스케일링 법칙

Scaling Law

LLM·언어모델 · **심화**

입문 모델 크기, 데이터 양, 계산량을 늘리면 성능이 예측 가능한 비율로 좋아진다는 경험적 법칙이다.

심화 손실이 파라미터 수·학습 토큰 수·연산량에 대해 거듭제곱 법칙을 따른다는 관찰로, 주어진 연산 예산에서 모델 크기와 데이터 양의 최적 비율을 정하는 데 쓴다(Chinchilla 연구 등). 최근에는 사전학습뿐 아니라 강화학습 후처리와 추론 시점 연산에 대한 스케일링도 논의된다. 데이터 고갈과 비용 증가가 한계로 지적된다.

연관 사전학습, 학습 토큰 수, 파라미터 수와 모델 크기, 테스트 타임 컴퓨트, 창발적 능력

출처 Wikipedia / 논문 Kaplan et al. 2020 · Hoffmann et al. 2022

스텝백 프롬프팅

Step-back Prompting

프롬프트·추론 · **심화**

입문 바로 답하기 전에 한 걸음 물러나 '이 문제의 일반 원칙이 뭐지?'를 먼저 생각하게 하는 방법이다.

심화 구체적 질문에서 상위 개념이나 원리를 묻는 추상화 질문을 먼저 생성·답하게 한 뒤, 그 원리를 근거로 원래 질문에 답하게 하는 기법이다. 세부 사항에 매몰된 추론 오류를 줄이며, RAG에서는 추상화 질문으로 추가 검색해 배경 지식을 확보하는 데도 쓰인다.

예시 특정 거래의 회계처리를 묻기 전에 '해당 기준서의 인식 원칙'을 먼저 정리하게 한다.

연관 사고의 연쇄, 쿼리 재작성, 프롬프트 엔지니어링

논문 Zheng et al. 2023

스톱 시퀀스

Stop Sequence

LLM·언어모델 · **실무**

입문 특정 문자열이 나오면 AI가 즉시 답변 생성을 멈추도록 지정하는 신호다.

심화 생성 결과에 지정 문자열이 나타나면 디코딩을 종료하는 API 옵션이다. 템플릿 형식 출력에서 다음 항목까지 넘어가 생성하는 것을 막거나, 특정 태그까지만 받아 파싱할 때 쓴다. 모델 고유의 종료 토큰(EOS)과는 별개로 동작한다.

연관 최대 토큰 수, 구조화된 출력, 프롬프트 템플릿

출처 Anthropic · Hugging Face

스트리밍 응답

Streaming Response

LLM·언어모델 · **실무**

입문 답변이 다 완성될 때까지 기다리지 않고 만들어지는 대로 글자를 바로바로 보여 주는 방식이다.

심화 서버가 생성된 토큰을 SSE 등으로 조각 단위로 전송해 체감 지연(첫 토큰까지 시간, TTFT)을 줄인다. 전체 생성 시간은 같지만 사용자 경험이 크게 개선된다. 구조화 출력 파싱, 가드레일 검사, 도구 호출 처리를 스트림 중간에 어떻게 할지 설계가 필요하다.

연관 지연 시간, API, 추론 서빙, 가드레일

출처 Anthropic · Hugging Face · MDN

시각 언어 모델

VLM · Vision-Language Model

생성 AI·멀티모달 · **실무**

입문 사진이나 문서 이미지를 보고 내용을 이해해 글로 설명하거나 질문에 답하는 AI다.

심화 이미지 인코더(주로 ViT 계열)가 추출한 시각 특징을 프로젝션 계층을 통해 LLM의 토큰 임베딩 공간으로 연결해, 이미지와 텍스트를 함께 입력받아 텍스트를 생성하는 모델이다. 문서·표·차트 이해, 화면 이해, 시각 질의응답에 쓰이며, 작은 글자나 정밀한 위치·개수 파악에서 오류가 날 수 있다.

예시 스캔된 재무제표 이미지를 입력하면 주요 항목을 표로 정리한다.

연관 멀티모달, 시각 질의응답, 문서 AI, 이미지 캡셔닝, 클립(대조 언어-이미지 사전학습)

출처 IBM · Hugging Face / 논문 Alayrac et al. 2022 · Liu et al. 2023

시각 질의응답

VQA · Visual Question Answering

생성 AI·멀티모달 · **실무**

입문 사진이나 도표를 보여 주고 질문하면 AI가 그 내용을 보고 답하는 기술이다.

심화 이미지와 자연어 질문을 함께 입력받아 답을 생성하는 과제로, 현재는 VLM의 기본 능력으로 통합되었다. 차트 수치 읽기, 문서 특정 항목 찾기, 장면 속 객체 개수 세기 등에 쓰이며, 정밀한 수치와 개수는 오류가 잦아 원본 데이터와 교차 검증이 필요하다.

예시 보고서의 막대그래프 이미지를 보여 주고 '2분기 연체율은 얼마인가'를 묻는다.

연관 시각 언어 모델, 이미지 캡셔닝, 문서 AI, 멀티모달

출처 Hugging Face / 논문 Agrawal et al. 2015

시계열 예측

Time Series Forecasting

AI 기초·머신러닝 · **실무**

입문 시간 순서로 쌓인 과거 데이터를 보고 앞으로의 값을 예측하는 일이다.

심화 추세·계절성·자기상관을 모델링해 미래 값을 예측한다. ARIMA·지수평활 같은 통계 모델, 래그 피처를 쓴 트리 모델, LSTM·트랜스포머 기반 딥러닝, 사전학습 시계열 파운데이션 모델이 쓰인다. 미래 정보가 섞이지 않도록 시간 순 분할과 백테스트가 필수다.

예시 영업점별 일별 현금 수요를 예측해 ATM 현금 적재량을 최적화한다.

연관 회귀, 데이터셋 분할(학습/검증/테스트), 장단기 메모리, 데이터 누수, 트랜스포머

출처 IBM · Wikipedia / 논문 Lim et al. 2019 · Das et al. 2023

시맨틱 레이어

Semantic Layer

RAG·검색·데이터 · **심화**

입문 복잡한 테이블 구조 위에 '매출', '연체율'처럼 업무 용어로 된 지표 정의를 한 곳에 모아 둔 층이다.

심화 물리 테이블과 사용자 사이에서 지표(measure), 차원(dimension), 계산식, 조인 규칙을 표준화해 정의하는 계층이다. BI 도구와 Text-to-SQL이 같은 지표 정의를 쓰게 해 계산 불일치를 막고, LLM이 원시 스키마 대신 정의된 지표를 조합하게 해 정확도를 높인다.

예시 '연체율 = 1개월 이상 연체잔액 / 총여신잔액'을 시맨틱 레이어에 정의해 AI와 BI 리포트가 같은 공식을 쓰게 한다.

연관 텍스트-투-SQL, 메타데이터 관리, 데이터 카탈로그, 정형 데이터

출처 IBM · Wikipedia

시맨틱 캐시

Semantic Cache

인프라·배포·LLMOps · **심화**

입문 비슷한 질문이 다시 들어오면 모델을 새로 호출하지 않고 저장해 둔 답을 돌려주는 기법이다.

심화 질문을 임베딩해 벡터 유사도로 과거 질문과 비교하고 임계값 이상이면 캐시된 응답을 반환한다. 정확 일치 캐시보다 적중률이 높지만 의미가 미묘하게 다른 질문에 틀린 답을 줄 위험이 있어 임계값 튜닝과 TTL, 개인화 응답 제외가 필요하다. 모델 내부의 프롬프트 캐싱과는 다른 계층이다.

예시 사내 규정 Q&A에서 반복되는 휴가·경비 문의에 시맨틱 캐시를 적용해 호출량을 줄였다.

연관 임베딩, 프롬프트 캐싱, 토큰 비용, 지연 시간

출처 Redis · Zilliz

시스템 카드

System Card

평가·안전·규제 · **심화**

입문 AI 모델 하나가 아니라 그 모델을 포함한 서비스 전체의 안전성 평가 결과와 위험 대응을 정리한 문서다.

심화 주요 AI 개발사가 신규 모델 출시 때 공개하는 문서로, 위험 영역별 평가(사이버, 생물·화학, 자율성 등), 레드티밍 결과, 적용한 안전 완화 조치, 잔여 위험을 담는다. 모델 카드가 모델 자체의 특성에 집중한다면 시스템 카드는 배포 환경·정책·안전장치를 포함한 시스템 단위 평가에 초점을 둔다.

예시 외부 모델 도입 검토 시 공급사의 시스템 카드에서 프롬프트 인젝션 평가 결과와 알려진 한계를 확인한다.

연관 모델 카드, 레드티밍, 책임 있는 확장 정책, 평가, 파운데이션 모델

출처 Anthropic

시스템 프롬프트

System Prompt

프롬프트·추론 · **실무**

입문 대화가 시작되기 전에 AI에게 미리 주는 기본 규칙과 역할 설명이다. 신입 직원에게 주는 업무 매뉴얼과 비슷하다.

심화 사용자 메시지보다 앞에 위치해 모델의 역할, 말투, 금지 사항, 도구 사용 규칙, 출력 형식 등 전역 지침을 정의하는 메시지다. 대부분의 채팅 API가 별도 system 역할로 받으며, 모델은 이를 사용자 지시보다 우선하도록 학습되는 경우가 많다. 길고 고정된 내용이므로 프롬프트 캐싱의 주요 대상이 되며, 프롬프트 인젝션으로 우회될 수 있어 가드레일과 함께 써야 한다.

예시 사내 챗봇 시스템 프롬프트에 '고객 개인정보는 마스킹하고, 내부 규정 문서에 근거가 없으면 모른다고 답하라'를 넣는다.

연관 프롬프트, 역할 부여(페르소나), 가드레일, 프롬프트 인젝션

출처 Anthropic · OpenAI

시티즌 개발자

Citizen Developer

AX·비즈니스 적용 · **실무**

입문 전문 개발자가 아닌 현업 직원이 노코드·로코드 도구나 AI를 활용해 직접 업무용 앱이나 자동화를 만드는 사람이다.

심화 생성형 AI와 노코드 플랫폼으로 현업이 업무 자동화, 간단한 챗봇, 데이터 분석을 스스로 구현할 수 있게 됐다. IT 부서 병목을 줄이지만 무분별한 확산은 보안·품질 문제를 낳으므로 허용 도구, 데이터 접근 범위, 검토 절차를 정한 거버넌스가 필요하다.

예시 영업기획 담당자가 사내 AI 도구로 일일 실적 요약 자동화를 직접 만들어 배포했다.

연관 AI 리터러시, 섀도 AI, 프롬프트 라이브러리, AI 거버넌스

출처 Microsoft Inside Track

신경망

NN · Neural Network

딥러닝·신경망 · **입문**

입문 뇌의 신경세포 연결에서 착안한 계산 구조다. 단순한 계산 단위 수많은 개가 층층이 연결되어 복잡한 패턴을 학습한다.

심화 가중합과 비선형 활성화 함수를 수행하는 뉴런을 층으로 쌓은 함수 근사기다. 입력층·은닉층·출력층으로 구성되며 역전파와 경사하강법으로 가중치를 학습한다. 충분한 크기의 은닉층이 있으면 임의의 연속 함수를 근사할 수 있다(보편 근사 정리).

예시 거래 순서와 금액 패턴을 입력받는 신경망으로 카드 이상거래 점수를 산출한다.

연관 딥러닝, 퍼셉트론, 은닉층, 활성화 함수, 역전파

출처 IBM · Wikipedia / 논문 Rosenblatt 1958 · Rumelhart et al. 1986 · Hornik et al. 1989

실시간 음성 대화

Real-time Voice Conversation

생성 AI·멀티모달 · **심화**

입문 사람과 전화하듯 거의 지연 없이 말을 주고받고, 중간에 말을 끊어도 자연스럽게 반응하는 AI 음성 기술이다.

심화 음성 입력을 스트리밍으로 받아 음성-음성 모델 또는 저지연 STT-LLM-TTS 파이프라인으로 응답을 스트리밍 생성한다. 사람 대화 수준의 체감을 위해 수백 밀리초 단위의 응답 지연, 음성 활동 감지(VAD), 발화 끼어들기 처리, 전이중(full-duplex) 대화가 요구되며, WebRTC·WebSocket 기반 전송을 주로 쓴다.

예시 콜센터 대기 고객에게 실시간 음성 AI가 응대해 단순 문의를 즉시 해결한다.

연관 음성 에이전트, 음성 인식, 음성 합성, 지연 시간, 네이티브 멀티모달

출처 OpenAI · Wikipedia / 논문 Défossez et al. 2024

O

아첨

Sycophancy

평가·안전·규제 · **실무**

입문 AI가 사실보다 사용자의 기분이나 의견에 맞춰 듣기 좋은 답을 하는 경향이다.

심화 사람의 선호를 보상으로 학습하는 RLHF 과정에서 동의·칭찬이 높은 평가를 받으면서 강화되는 것으로 알려져 있다. 사용자가 반박하면 맞는 답을 번복하거나, 잘못된 전제를 그대로 수용하는 형태로 나타난다. 반박 시 일관성 테스트, 잘못된 전제 포함 질문 평가셋, 학습 데이터·보상 설계 개선으로 측정·완화한다.

예시 직원이 '이 계산 맞지?'라고 물을 때 AI가 무조건 동의하지 않는지 잘못된 전제 질문으로 점검한다.

연관 인간 피드백 기반 강화학습, 정렬, 보상 해킹, 환각, 평가

논문 Sharma et al. 2023 · Perez et al. 2022

앙상블 학습

Ensemble Learning

AI 기초·머신러닝 · **실무**

입문 여러 AI의 의견을 모아 최종 결론을 내는 방식이다. 전문가 한 명보다 위원회가 덜 틀리는 원리다.

심화 여러 모델의 예측을 결합해 단일 모델보다 성능과 안정성을 높인다. 부트스트랩 표본으로 독립 학습 후 평균하는 배깅(랜덤포레스트), 이전 모델의 오차를 순차 보정하는 부스팅(XGBoost 등), 메타 모델로 결합하는 스태킹이 대표적이다.

예시 로지스틱 회귀, LightGBM, 신경망의 예측을 스태킹해 부도 예측 정확도를 높인다.

연관 랜덤 포레스트, 그래디언트 부스팅, 결정 트리, 편향-분산 트레이드오프

출처 IBM · Wikipedia / 논문 Breiman 1996 · Freund and Schapire 1997

약인공지능과 강인공지능

Narrow AI and Strong AI

AI 기초·머신러닝 · **입문**

입문 약인공지능은 번역, 바둑처럼 정해진 일만 잘하는 AI이고, 강인공지능은 사람처럼 스스로 생각하고 무엇이든 해내는 AI를 말한다.

심화 약인공지능(Weak/Narrow AI)은 특정 과제에 특화된 시스템으로 현재 상용 AI는 모두 여기에 속한다. 강인공지능(Strong AI)은 철학적으로는 실제 이해·의식을 갖는 AI를, 실무적으로는 AGI와 비슷한 의미로 쓰인다. LLM은 범용성이 높아져 경계가 흐려졌다는 평가도 있다.

연관 범용 인공지능, 인공지능, 튜링 테스트, 대규모 언어모델

출처 IBM · Wikipedia / 논문 Searle 1980

양자화

Quantization

인프라·배포·LLMOps · **실무**

입문 모델 숫자의 정밀도를 낮춰 크기를 줄이는 기술이다. 고화질 사진을 적당한 화질로 압축하는 것과 비슷하다.

심화 가중치(및 활성값)를 FP16/BF16에서 INT8, INT4, FP8 등 저비트 표현으로 바꿔 메모리 사용량과 대역폭 요구를 줄이고 추론 속도를 높인다. 학습 후 양자화(PTQ: GPTQ, AWQ 등)와 양자화 인식 학습(QAT)이 있다. 비트 수를 낮출수록 정확도 손실 위험이 커지므로 도메인 평가셋으로 검증해야 한다.

예시 폐쇄망 서버의 GPU 메모리가 부족해 70B 모델을 4비트로 양자화해 단일 서버에 올렸다.

연관 GGUF, 추론 서빙, GPU, 파라미터, 엣지 AI

출처 Hugging Face / 논문 Frantar et al. 2022 · Lin et al. 2023 · Dettmers et al. 2022

어댑터

Adapter

학습·튜닝·정렬 · **심화**

입문 기존 모델은 그대로 두고 끼워 넣는 작은 학습용 모듈이다. 필요에 따라 갈아 끼울 수 있다.

심화 트랜스포머 층 사이에 병목 구조의 작은 신경망을 삽입하고 이것만 학습하는 PEFT 기법을 원래 의미로 한다. 넓게는 LoRA 가중치처럼 기반 모델에 덧붙이는 학습 모듈을 통칭한다. 작업별 어댑터를 교체하거나 다중 어댑터를 동시에 서빙할 수 있다.

연관 로라, 매개변수 효율적 미세조정, 모델 병합, 파인튜닝

출처 Hugging Face · Wikipedia / 논문 Houlsby et al. 2019

어텐션

Attention

딥러닝·신경망 · **실무**

입문 많은 정보 중 지금 중요한 부분에 집중하는 장치다. 번역할 때 원문 중 관련된 단어를 더 주의 깊게 보는 식이다.

심화 쿼리(Q)와 키(K)의 유사도로 가중치를 계산하고 이를 값(V)에 가중합해 문맥 표현을 만드는 메커니즘이다. 표준 형태는 softmax(QKᵀ/√d)V인 스케일드 닷-프로덕트 어텐션이다. 원래 RNN 번역 모델의 병목을 해결하려 도입되었고 트랜스포머의 핵심이 되었다.

연관 셀프 어텐션, 멀티헤드 어텐션, 트랜스포머, 소프트맥스, 인코더-디코더

출처 IBM · Wikipedia / 논문 Bahdanau et al. 2014 · Vaswani et al. 2017

업무 재설계

Process Redesign

AX·비즈니스 적용 · **실무**

입문 AI를 기존 업무에 덧붙이는 대신, AI가 있다는 전제로 업무 흐름 자체를 다시 짜는 것이다.

심화 현행 프로세스를 단계별로 분해해 AI가 수행할 부분, 사람이 검토·판단할 부분, 없앨 부분을 재정의한다. 기존 절차를 그대로 두고 일부만 자동화하면 효과가 제한되며, 승인 단계·역할·성과지표·통제 지점까지 함께 바꿔야 실질적 생산성 향상이 나온다.

예시 보고서 작성 업무를 '데이터 추출→AI 초안→담당자 검토→승인'으로 재설계해 중간 취합 단계를 없앴다.

연관 AI 전환, 휴먼 인 더 루프, 에이전틱 워크플로, 생산성 지표

출처 Wikipedia

업스케일링

Upscaling (Super-Resolution)

생성 AI·멀티모달 · **실무**

입문 작거나 흐릿한 이미지를 크고 선명하게 키우는 기술이다. 초해상도라고도 한다.

심화 저해상도 입력에서 고해상도 출력을 복원하도록 학습한 모델(GAN, 확산 기반 등)로 세부 질감을 추정해 채운다. 생성 파이프라인에서 저해상도로 먼저 만들고 업스케일하는 방식으로 비용을 줄이기도 한다. 원본에 없던 세부가 '그럴듯하게 생성'되므로 증빙·감식 목적 이미지에는 쓰면 안 된다.

연관 생성적 적대 신경망, 확산 모델, 이미지-이미지 변환, 영상 생성

출처 Hugging Face · Wikipedia / 논문 Ledig et al. 2016 · Saharia et al. 2021

에이전트 간 프로토콜

A2A · Agent2Agent Protocol

AI 에이전트·도구 · **심화**

입문 서로 다른 회사나 시스템에서 만든 AI 에이전트끼리 일을 주고받을 수 있게 하는 공통 대화 규칙이다.

심화 Google이 2025년 4월 발표하고 2025년 6월 리눅스 재단에 이관된 개방형 프로토콜로, 2026년 v1.0 안정 규격이 나왔다. 각 에이전트는 자신의 기능·엔드포인트·인증 방식을 기술한 에이전트 카드(Agent Card)를 공개하고, 클라이언트 에이전트는 이를 보고 원격 에이전트에 작업(task)을 위임하며 상태 갱신과 결과물(artifact)을 주고받는다. MCP가 에이전트와 도구·데이터의 연결을 다룬다면 A2A는 에이전트와 에이전트 사이의 협업을 다루는 보완 관계다.

예시 은행의 고객상담 에이전트가 제휴 보험사의 보험 견적 에이전트에 A2A로 견적 작업을 위임하고 결과를 받아 고객에게 안내한다.

연관 모델 컨텍스트 프로토콜, 멀티 에이전트, 핸드오프, AI 에이전트

출처 Linux Foundation (A2A Project) · Linux Foundation · IBM

에이전트 권한 관리

Agent Permission Management

AI 에이전트·도구 · **실무**

입문 AI 에이전트가 무엇을 해도 되고 무엇은 허락을 받아야 하는지 정해 두는 것이다. 신입 직원의 결재 권한을 정하는 것과 같다.

심화 도구·명령·리소스별로 허용, 승인 필요, 금지를 정의하고 최소 권한 원칙에 따라 에이전트 자격 증명의 범위를 제한하는 체계다. 읽기와 쓰기 권한 분리, 위험 행동 시 사용자 확인, 감사 로그 기록, 위임 토큰(OAuth 등)의 범위·만료 관리가 핵심이다. 에이전트가 사용자 권한을 그대로 대행하는 경우 권한 상승과 데이터 유출 경로가 되지 않도록 별도 통제가 필요하다.

예시 조회 도구는 자동 허용하고, 고객 정보 변경·외부 메일 발송은 매번 담당자 승인을 받도록 설정한다.

연관 휴먼 인 더 루프, 에이전트 샌드박스, 가드레일, AI 거버넌스

출처 Anthropic · Model Context Protocol · Wikipedia

에이전트 루프

Agent Loop

AI 에이전트·도구 · **실무**

입문 AI가 '생각하기 → 행동하기 → 결과 보기'를 목표를 이룰 때까지 되풀이하는 기본 작동 방식이다.

심화 모델 호출 → 도구 호출 요청 파싱 → 도구 실행 → 결과를 컨텍스트에 추가 → 다시 모델 호출을 반복하다가, 모델이 최종 답변을 내거나 최대 반복 횟수·비용 한도에 도달하면 종료한다. 종료 조건, 반복 상한, 컨텍스트 누적 관리(요약·삭제)가 없으면 무한 루프나 비용 폭증이 생길 수 있다.

연관 AI 에이전트, 리액트(추론-행동), 도구 사용, 에이전트 실행 궤적

출처 Anthropic · Anthropic / 논문 Yao et al. 2022

에이전트 메모리

Agent Memory

AI 에이전트·도구 · **실무**

입문 AI 에이전트가 지금 하는 일의 진행 상황(단기 기억)과 이전 대화·사용자 선호(장기 기억)를 기억해 두는 장치다.

심화 단기 메모리는 현재 작업의 대화 이력·중간 결과로 컨텍스트 윈도 안에서 관리되며, 길어지면 요약·압축이 필요하다. 장기 메모리는 세션을 넘어 유지되는 사실·선호·경험으로, 파일·DB·벡터 DB에 저장하고 필요할 때 검색해 불러온다. 무엇을 저장·갱신·삭제할지의 정책, 잘못된 기억의 누적, 개인정보 보관 기간 관리가 설계 과제다.

예시 상담 에이전트가 고객이 지난번에 문의한 대출 상품과 선호 연락 시간을 기억해 다음 상담에 반영한다.

연관 컨텍스트 윈도, 에이전트 상태 관리, 벡터 데이터베이스, 컨텍스트 엔지니어링

출처 IBM · Anthropic / 논문 Packer et al. 2023 · Park et al. 2023

에이전트 상태 관리

Agent State Management

AI 에이전트·도구 · **심화**

입문 에이전트가 지금 어디까지 했고 무엇을 알고 있는지 기록하고 관리하는 것이다. 게임의 저장 파일과 비슷하다.

심화 대화 이력, 중간 산출물, 계획·진행 단계, 도구 호출 결과 등 실행 상태를 명시적 데이터 구조로 유지하는 것이다. 그래프 기반 프레임워크는 노드 간 상태 객체를 전달하고 체크포인트로 영속화해 장애 복구, 재실행, 사람 승인 후 재개를 가능하게 한다. 상태가 커지면 컨텍스트에 무엇을 넣을지 선택하는 문제와 직결된다.

연관 에이전트 메모리, 장기 실행 작업, 오케스트레이션, 에이전트 프레임워크

출처 LangChain · Anthropic

에이전트 샌드박스

Agent Sandbox

AI 에이전트·도구 · **심화**

입문 AI가 코드를 실행하거나 파일을 다루더라도 실제 시스템에 피해를 주지 않도록 격리해 둔 안전한 작업 공간이다.

심화 컨테이너, 마이크로 VM, 제한된 파일시스템·네트워크 정책으로 에이전트의 실행 환경을 호스트와 분리하는 기법이다. 접근 가능한 디렉터리, 외부 네트워크 도메인, 자격 증명을 최소화해 잘못된 명령이나 프롬프트 인젝션의 피해 범위를 제한한다. 격리가 강할수록 안전하지만 사내 시스템 연동이 어려워지므로 필요한 경로만 명시적으로 열어 준다.

예시 에이전트가 생성한 데이터 분석 코드를 운영 DB와 분리된 컨테이너에서 샘플 데이터로만 실행한다.

연관 에이전트 권한 관리, 코딩 에이전트, 컴퓨터 사용, 프롬프트 인젝션

출처 Anthropic · Anthropic

에이전트 스킬

Agent Skills

AI 에이전트·도구 · **실무**

입문 특정 업무를 처리하는 방법(지시문, 예시, 스크립트)을 묶어 둔 꾸러미다. 필요할 때 AI가 꺼내 쓰는 업무 매뉴얼이다.

심화 지시 문서와 참고 파일·스크립트를 폴더 단위로 패키징해 에이전트가 작업에 맞을 때만 불러오도록 한 재사용 단위다. 평소에는 이름과 짧은 설명만 컨텍스트에 두고 관련 작업에서 본문을 읽어 오는 점진적 공개(progressive disclosure) 방식으로 컨텍스트를 절약한다. 도구를 연결하는 MCP와 달리, 스킬은 '어떻게 일할지'에 관한 절차적 지식을 담는다는 점에서 상호 보완적이다.

예시 사내 보고서 양식과 작성 규칙을 스킬로 만들어 두면 누가 요청하든 같은 형식의 보고서가 나온다.

연관 프롬프트 템플릿, 컨텍스트 엔지니어링, 모델 컨텍스트 프로토콜, 에이전트 지시 파일

출처 Agent Skills · Anthropic · Anthropic

에이전트 실행 궤적

Agent Trajectory

AI 에이전트·도구 · **심화**

입문 AI 에이전트가 일을 하면서 거친 생각, 도구 호출, 결과를 순서대로 기록한 발자취다.

심화 한 작업에서 발생한 모델 입출력, 도구 호출과 인자, 관찰 결과, 상태 변화를 시간순으로 기록한 데이터다. 트레이싱 도구로 수집해 디버깅, 비용 분석, 평가, 감사 추적에 활용하며, 성공 궤적은 학습·프롬프트 개선 데이터로도 쓰인다. 민감 정보가 포함될 수 있어 보관·마스킹 정책이 필요하다.

연관 에이전트 평가, 관측 가능성, 에이전트 루프, 에이전트 상태 관리

출처 OpenAI · LangChain

에이전트 지시 파일

AGENTS.md

AI 에이전트·도구 · **심화**

입문 코딩 AI에게 '이 프로젝트는 이렇게 빌드하고, 이런 규칙을 지켜라'를 알려 주는 안내 파일이다.

심화 저장소 루트 등에 두는 마크다운 파일로, 빌드·테스트 명령, 코드 스타일, 디렉터리 구조, 금지 사항 등 에이전트용 프로젝트 맥락을 기술한다. AGENTS.md는 여러 코딩 에이전트가 공통으로 읽는 개방형 형식으로 제안되어 Agentic AI Foundation(AAIF)의 프로젝트로 관리된다. 도구마다 자체 이름의 지시 파일(예: CLAUDE.md)을 쓰기도 한다.

연관 코딩 에이전트, 에이전트 스킬, 시스템 프롬프트, 컨텍스트 엔지니어링

출처 AGENTS.md · Linux Foundation · Anthropic

에이전트 평가

Agent Evaluation

AI 에이전트·도구 · **심화**

입문 AI 에이전트가 맡은 일을 얼마나 잘, 안전하게, 효율적으로 끝내는지 측정하는 것이다.

심화 최종 결과의 정답 여부뿐 아니라 실행 궤적(도구 선택 정확도, 단계 수, 불필요한 호출), 비용·지연, 정책 위반 여부를 함께 평가한다. 재현 가능한 시뮬레이션 환경과 과제 세트를 구성하고, 비결정성 때문에 여러 번 실행한 성공률(pass@k, pass^k 등)을 본다. 규칙 기반 검사, LLM-as-judge, 사람 평가를 조합한다.

예시 상담 에이전트를 실제 문의 200건을 재구성한 시나리오로 반복 실행해 해결률과 오안내 비율을 측정한다.

연관 평가, 벤치마크, LLM 심판 평가, 에이전트 실행 궤적

출처 Anthropic · IBM / 논문 Liu et al. 2023 · Yao et al. 2024 · Jimenez et al. 2023

에이전트 프레임워크

Agent Framework

AI 에이전트·도구 · **심화**

입문 AI 에이전트를 만들 때 반복되는 부분(도구 연결, 기억, 흐름 제어)을 미리 만들어 둔 개발 도구 모음이다.

심화 모델 호출 추상화, 도구 정의, 상태·메모리 관리, 그래프·워크플로 정의, 멀티 에이전트 통신, 트레이싱을 제공하는 라이브러리·SDK다. LangGraph, CrewAI, AutoGen 계열, 각 모델 기업의 Agent SDK 등이 있다. 개발 속도가 빨라지지만 추상화가 동작을 가려 디버깅이 어려울 수 있어, 단순한 경우 모델 API를 직접 쓰는 편이 낫기도 하다.

연관 오케스트레이션, 에이전트 상태 관리, 멀티 에이전트, 관측 가능성

출처 LangChain · OpenAI / 논문 Wu et al. 2023

에이전틱 워크플로

Agentic Workflow

AI 에이전트·도구 · **실무**

입문 AI가 한 번에 답을 내는 대신 계획-실행-점검을 여러 단계로 반복하며 일을 처리하는 업무 흐름이다.

심화 LLM 호출을 여러 단계로 연결하되 일부 분기·반복 결정을 모델에 맡기는 설계 방식이다. 코드로 경로를 고정한 워크플로(프롬프트 체이닝, 라우팅, 병렬화)와 모델이 경로를 스스로 정하는 에이전트 사이의 스펙트럼으로 이해할 수 있다. 예측 가능성이 중요한 업무는 고정 경로를, 개방형 문제는 자율 경로를 택하는 등 업무 특성에 맞춰 자율성 수준을 정한다.

예시 민원 접수 → 분류 → 관련 규정 검색 → 답변 초안 → 자체 검토 → 담당자 승인 순서로 처리하는 민원 응대 흐름을 구성한다.

연관 AI 에이전트, 오케스트레이션, 워크플로 자동화, 반성(자기 성찰), 자율성 수준

출처 Anthropic · IBM · LangChain

에이전틱 AI

Agentic AI

AI 에이전트·도구 · **입문**

입문 스스로 판단하고 행동하는 AI 에이전트 기술 전반을 가리키는 말이다. '대답하는 AI'에서 '일하는 AI'로의 변화를 뜻한다.

심화 목표 지향적 계획, 도구 사용, 다단계 실행, 자기 점검 능력을 갖춘 AI 시스템과 그 설계 패러다임을 통칭하는 용어다. 특정 기술이라기보다 LLM, 도구 연동 표준(MCP 등), 오케스트레이션, 메모리를 결합한 아키텍처 경향을 가리킨다. 마케팅 용어로 넓게 쓰이므로 실제로 어느 수준의 자율성을 갖는지 구분해 보는 것이 중요하다.

연관 AI 에이전트, 에이전틱 워크플로, 자율성 수준, 생성형 AI

출처 IBM · Linux Foundation · Wikipedia / 논문 Xi et al. 2023

에이전틱 RAG

Agentic RAG

RAG·검색·데이터 · **심화**

입문 정해진 순서대로 한 번 검색하는 대신, AI 에이전트가 스스로 어디서 무엇을 찾을지 판단하며 필요한 만큼 검색하는 RAG다.

심화 LLM 에이전트가 검색을 도구로 사용해 검색 여부, 데이터 소스 선택(벡터 DB, SQL, 웹 등), 질의 재작성, 결과 충분성 판단을 반복적으로 수행하는 구조다. 복잡하고 다단계인 질문에 강하지만 지연·비용이 늘고 동작 예측성이 낮아 관측성과 단계 제한이 필요하다.

예시 에이전트가 규정은 벡터 검색으로, 실적 수치는 DW에 SQL로 조회해 '규정 대비 실적 위반 여부'를 답한다.

연관 검색 증강 생성, AI 에이전트, 도구 사용, 멀티홉 검색, 텍스트-투-SQL

출처 IBM / 논문 Singh et al. 2025 · Asai et al. 2023

에폭

Epoch

딥러닝·신경망 · **실무**

입문 학습 데이터 전체를 처음부터 끝까지 한 번 다 보는 것을 1에폭이라 한다. 교재를 한 번 완독한 것과 같다.

심화 전체 학습 데이터가 모델을 한 번 통과하는 학습 단위다. 한 에폭은 (데이터 수 / 배치 크기)번의 스텝(이터레이션)으로 이루어진다. 에폭이 너무 적으면 과소적합, 많으면 과적합되므로 검증 손실을 보며 조기 종료한다. LLM 사전학습은 대개 1에폭 내외로 진행된다.

연관 배치 크기, 조기 종료, 과적합, 학습률

출처 Google for Developers

엣지 AI

Edge AI

인프라·배포·LLMOps · **실무**

입문 AI를 중앙 서버가 아니라 스마트폰, PC, 키오스크 같은 현장 기기에서 직접 실행하는 방식이다.

심화 네트워크 지연이 없고 데이터가 기기 밖으로 나가지 않아 개인정보 보호에 유리하다. 연산·메모리 제약 때문에 SLM, 양자화, NPU 가속을 활용하며, 복잡한 작업은 서버로 넘기는 하이브리드 구조가 흔하다.

예시 영업점 태블릿에서 소형 모델로 상담 내용을 현장 요약하고 원문은 외부로 전송하지 않는다.

연관 소형 언어모델, NPU, 양자화, GGUF

출처 IBM

역전파

Backpropagation

딥러닝·신경망 · **실무**

입문 AI가 틀린 정도를 출력 쪽에서 입력 쪽으로 거슬러 전달하며 각 연결이 얼마나 책임이 있는지 계산하는 방법이다.

심화 연쇄 법칙으로 손실함수의 각 파라미터에 대한 기울기를 출력층부터 입력층 방향으로 효율적으로 계산하는 알고리즘이다. 순전파 중 중간값을 저장했다가 역방향으로 재사용한다. 계산된 기울기는 옵티마이저가 가중치 갱신에 쓴다. PyTorch 등 프레임워크의 자동 미분이 이를 구현한다.

연관 경사하강법, 손실 함수, 기울기 소실, 신경망, 옵티마이저

출처 IBM · Wikipedia / 논문 Rumelhart et al. 1986

역할 부여(페르소나)

Role Prompting

프롬프트·추론 · **입문**

입문 AI에게 '너는 20년 차 회계사다'처럼 특정 역할을 맡겨 그 관점과 말투로 답하게 하는 방법이다.

심화 시스템 프롬프트 등에서 모델에 전문가·담당자 역할을 지정해 어휘, 관점, 상세도를 조정하는 기법이다. 톤과 형식 일관성에는 효과가 있지만, 역할만으로 사실 지식이 늘지는 않으므로 구체적 기준·자료 제공이 함께 필요하다. 대상 독자를 명시하는 것(예: 비전문가 임원용)도 같은 효과를 낸다.

예시 '너는 은행 여신심사역이다. 심사 관점에서 이 재무제표의 위험 요인을 짚어라'라고 지시한다.

연관 시스템 프롬프트, 프롬프트 엔지니어링, 프롬프트

출처 Anthropic · IBM

영상 생성

Video Generation

생성 AI·멀티모달 · **실무**

입문 글이나 이미지를 입력하면 움직이는 영상을 만들어 주는 AI 기술이다.

심화 영상을 시공간 잠재 패치로 압축한 뒤 확산 트랜스포머나 플로우 매칭 모델로 생성하는 방식이 주류다. 프레임 간 일관성, 물리적 사실성, 긴 길이 유지가 핵심 과제이며 최근에는 음성·효과음을 함께 생성하는 모델도 나왔다. 계산 비용이 매우 크고 딥페이크 악용 우려로 워터마크·출처 표시가 함께 적용된다.

예시 신상품 홍보용 짧은 영상 콘셉트 시안을 생성해 기획 단계에서 검토한다.

연관 확산 모델, 확산 트랜스포머, 딥페이크, 콘텐츠 출처 증명

출처 OpenAI · Hugging Face · Wikipedia / 논문 Ho et al. 2022 · Blattmann et al. 2023

오케스트레이션

Orchestration

AI 에이전트·도구 · **실무**

입문 여러 AI 호출, 도구, 에이전트를 순서와 역할에 맞게 조율해 하나의 일로 엮는 것이다. 오케스트라 지휘자 역할이다.

심화 작업 분해, 단계 간 데이터 전달, 분기·반복·병렬 실행, 상태 저장, 오류 처리를 관리하는 제어 계층이다. 코드 기반 그래프(상태 머신)로 구현하거나 LLM 자체를 오케스트레이터로 두어 하위 작업을 동적으로 배분하는 방식이 있다. 관측성(트레이싱)과 재실행 가능성을 함께 설계해야 운영이 가능하다.

예시 야간 배치 결과 점검 에이전트가 로그 수집, 오류 분류, 담당자 알림 단계를 오케스트레이터로 묶어 실행한다.

연관 멀티 에이전트, 에이전트 프레임워크, 에이전트 상태 관리, 에이전틱 워크플로

출처 IBM · LangChain / 논문 Shen et al. 2023

오토인코더

AE · Autoencoder

딥러닝·신경망 · **심화**

입문 데이터를 작게 압축했다가 다시 원래대로 복원하도록 학습하는 신경망이다. 복원이 잘 안 되는 데이터는 '평소와 다른' 데이터로 볼 수 있다.

심화 인코더가 입력을 저차원 잠재 벡터로 압축하고 디코더가 이를 복원하며 재구성 오차를 최소화하는 비지도 모델이다. 차원 축소, 잡음 제거, 표현 학습에 쓰이며 정상 데이터로만 학습해 재구성 오차가 큰 샘플을 이상치로 판단하는 이상 탐지에 많이 활용된다.

예시 정상 거래로만 학습한 오토인코더의 재구성 오차로 신종 사기 패턴을 탐지한다.

연관 변분 오토인코더, 이상 탐지, 차원 축소, 인코더-디코더

출처 IBM · Wikipedia / 논문 Hinton & Salakhutdinov 2006 · Kingma & Welling 2013

오프라인·온라인 평가

Offline and Online Evaluation

평가·안전·규제 · **실무**

입문 오프라인 평가는 출시 전 준비된 시험 문제로 점검하는 것이고, 온라인 평가는 실제 사용자 반응으로 운영 중에 점검하는 것이다.

심화 오프라인 평가는 고정 데이터셋으로 재현 가능하게 비교할 수 있지만 실제 사용 분포와 차이가 있다. 온라인 평가는 A/B 테스트, 사용자 피드백(좋아요·재질문율), 운영 로그 샘플 채점으로 실제 효과를 측정하나 통제가 어렵고 위험이 따른다. 오프라인으로 걸러 배포하고, 온라인 지표로 감시하며, 운영에서 발견된 실패를 다시 오프라인 데이터셋에 추가하는 순환이 바람직하다.

예시 새 상담 모델을 트래픽 5%에만 배포해 해결률과 상담원 이관율을 기존 모델과 비교한다.

연관 평가, 골든 데이터셋, 관측 가능성, 인간 평가, LLMOps

출처 Anthropic · Wikipedia

오픈소스 모델

Open-Source Model

LLM·언어모델 · **실무**

입문 모델 파일뿐 아니라 학습 방법과 데이터 정보까지 공개해 누구나 자유롭게 쓰고 고칠 수 있는 모델이다.

심화 OSI의 오픈소스 AI 정의는 가중치, 학습·추론 코드, 데이터에 대한 충분한 정보 공개와 자유로운 사용·수정·재배포 권리를 요구한다. 가중치만 공개하거나 사용 제한 라이선스를 둔 모델은 오픈 웨이트로 구분하는 것이 정확하다. 실무에서는 두 용어가 혼용되므로 라이선스 조항 확인이 필수다.

연관 오픈 웨이트 모델, 파인튜닝, 온프레미스, 자체 구축 대 구매

출처 Open Source Initiative

오픈 웨이트 모델

Open-Weight Model

LLM·언어모델 · **실무**

입문 학습이 끝난 모델 파일(가중치)을 공개해 누구나 내려받아 자기 서버에서 돌릴 수 있는 모델이다.

심화 가중치는 공개하지만 학습 데이터·학습 코드는 공개하지 않거나 사용 라이선스에 제약을 두는 경우가 많아 엄밀한 오픈소스와 구분한다. 온프레미스 배포, 파인튜닝, 양자화가 자유로워 데이터 반출이 어려운 환경에 적합하다. 라이선스의 상업 이용 조건과 사용자 수 제한 등을 반드시 확인해야 한다.

예시 폐쇄망 금융 시스템에서 오픈 웨이트 모델을 내부 GPU 서버에 올려 외부 전송 없이 사용한다.

연관 오픈소스 모델, 온프레미스, 양자화, 파인튜닝, 소버린 AI

출처 NTIA (U.S. Department of Commerce) · Open Source Initiative

온도

Temperature

LLM·언어모델 · **입문**

입문 AI 답변의 무작위성을 조절하는 값이다. 낮추면 일관되고 보수적인 답, 높이면 다양하고 창의적인 답이 나온다.

심화 로짓을 온도 T로 나눈 뒤 소프트맥스를 적용해 확률분포의 뾰족함을 조절한다. T→0이면 그리디 디코딩에 가까워지고, T가 크면 저확률 토큰도 자주 선택된다. 정형 추출·분류에는 낮게, 아이디어 발상에는 높게 설정하는 것이 일반적이다.

예시 계약서 항목 추출 작업은 temperature를 0 근처로 두어 결과 재현성을 높인다.

연관 Top-p 샘플링, Top-k 샘플링, 샘플링, 로짓, 그리디 디코딩

출처 IBM · Wikipedia · Hugging Face

온프레미스

On-Premises

인프라·배포·LLMOps · **입문**

입문 AI 모델과 서버를 외부 클라우드가 아닌 회사 내부 전산실에 직접 설치해 운영하는 방식이다.

심화 데이터가 외부로 나가지 않아 보안·규제 대응에 유리하고 대량 사용 시 장기 비용이 낮을 수 있다. 반면 GPU 초기 투자, 전력·냉각, 운영 인력, 모델 업데이트 부담이 크고 최신 상용 대형 모델은 쓸 수 없는 경우가 많아 오픈 웨이트 모델을 주로 사용한다.

예시 고객 개인신용정보를 다루는 업무는 온프레미스 LLM으로, 일반 문서 작성은 클라우드 API로 나눠 운영한다.

연관 폐쇄망 배포, 프라이빗 클라우드, 오픈 웨이트 모델, 총소유비용

출처 Wikipedia

옵티마이저

Optimizer

딥러닝·신경망 · **실무**

입문 계산된 오차 신호를 바탕으로 AI 내부 값을 실제로 어떻게 고칠지 결정하는 알고리즘이다. Adam이 가장 널리 쓰인다.

심화 기울기로 파라미터를 갱신하는 규칙이다. SGD, 모멘텀, RMSProp, 그리고 1차·2차 모멘트 추정을 결합한 Adam과 가중치 감쇠를 분리한 AdamW가 대표적이며 AdamW가 트랜스포머 학습의 사실상 표준이다. Adam 계열은 파라미터당 상태 2개를 저장해 학습 메모리 요구량을 크게 늘린다.

연관 경사하강법, 확률적 경사하강법, 학습률, 역전파

출처 Keras / 논문 Kingma & Ba 2014 · Loshchilov & Hutter 2017 · Ruder 2016

요약·재작성 프롬프트

Summarization and Rewriting Prompt

프롬프트·추론 · **입문**

입문 긴 글을 줄이거나, 같은 내용을 다른 독자·말투에 맞게 다시 쓰게 하는 프롬프트다.

심화 요약은 대상 독자, 길이, 포함할 항목(결론·수치·리스크), 원문에 없는 내용 금지 등을 명시할수록 품질이 오른다. 재작성은 톤·난이도·형식 변환을 지시하며 원문 의미 보존 여부를 검증해야 한다. 긴 문서는 분할 요약 후 통합(map-reduce) 방식을 쓰고, 수치 누락·왜곡은 환각 점검 대상이다.

예시 30쪽 리스크 보고서를 '임원용 5줄, 수치 포함, 원문에 없는 해석 금지' 조건으로 요약한다.

연관 프롬프트 템플릿, 출력 형식 지정, 환각

출처 Anthropic

워크플로 자동화

Workflow Automation

AI 에이전트·도구 · **입문**

입문 반복되는 업무 절차를 프로그램이 대신 처리하게 하는 것이다. RPA가 정해진 순서를 그대로 따라 한다면, AI 에이전트는 상황에 맞춰 판단하며 처리한다.

심화 RPA(Robotic Process Automation)는 사전에 정의된 규칙과 화면 조작 스크립트를 결정적으로 실행해 정형 업무에 강하지만, 화면 변경이나 비정형 입력에 취약하다. LLM 기반 에이전트는 비정형 문서 해석과 예외 판단이 가능하지만 결과가 비결정적이다. 실무에서는 정형 단계는 RPA·규칙 엔진으로, 판단이 필요한 단계만 LLM으로 처리하는 하이브리드 구성이 흔하다.

예시 수기 신청서는 AI가 내용을 추출·분류하고, 확정된 데이터의 시스템 입력은 기존 RPA가 수행한다.

연관 에이전틱 워크플로, 컴퓨터 사용, 문서 AI, AI 전환

출처 IBM · Wikipedia · Anthropic

워터마킹

AI Watermarking

평가·안전·규제 · **실무**

입문 AI가 만든 이미지·영상·글에 'AI 생성물'이라는 표시를 눈에 보이게 또는 보이지 않게 넣는 기술이다.

심화 로고·문구 같은 가시적 표시와, 픽셀·주파수 영역이나 토큰 선택 확률에 신호를 심는 비가시적 워터마크, 출처 정보를 메타데이터로 첨부하는 콘텐츠 자격증명(C2PA 등) 방식이 있다. 텍스트 워터마크는 문장 재작성에 약하고, 이미지 워터마크도 편집·압축으로 손상될 수 있어 단독 판별 수단으로는 한계가 있다. 한국 AI 기본법과 EU AI Act 모두 생성물 표시 의무의 구현 수단으로 활용한다.

예시 마케팅용 생성 이미지에 비가시적 워터마크와 메타데이터를 넣고, 다운로드 시 AI 생성물임을 안내한다.

연관 생성형 AI 표시 의무, 딥페이크, 생성형 AI, 인공지능 기본법, EU 인공지능법

출처 C2PA · Google DeepMind · Wikipedia / 논문 Kirchenbauer et al. 2023

원샷

One-shot Prompting

프롬프트·추론 · **입문**

입문 예시를 딱 하나 보여주고 같은 방식으로 해 달라고 요청하는 방식이다.

심화 입출력 예시 1개를 포함하는 프롬프트다. 출력 형식이나 톤을 맞추는 데 효과적이지만, 예시가 하나뿐이라 모델이 그 예시의 표면적 특징(길이, 단어 선택)을 과하게 따라 할 수 있다. 다양성이 필요하면 여러 예시를 주는 퓨샷이 낫다.

예시 보고서 요약 형식 예시 한 건을 보여주고 나머지 보고서도 같은 형식으로 요약시킨다.

연관 제로샷, 퓨샷, 인컨텍스트 러닝

출처 Google · Wikipedia / 논문 Brown et al. 2020

월드 모델

World Model

LLM·언어모델 · **심화**

입문 세상이 어떻게 돌아가는지 내부적으로 흉내 내어, 어떤 행동을 하면 무슨 일이 일어날지 예측하는 AI 모델이다.

심화 환경의 상태와 행동에 따른 상태 전이를 학습해 미래를 시뮬레이션하는 모델로, 강화학습·로보틱스·자율주행에서 계획 수립에 쓰인다. 최근에는 대규모 영상 데이터로 학습해 상호작용 가능한 가상 환경을 생성하는 모델도 월드 모델로 불린다. LLM이 내부에 세계 모델을 형성하는지는 연구 논쟁 주제다.

연관 강화학습, 영상 생성, 멀티모달, 파운데이션 모델

출처 NVIDIA / 논문 Ha and Schmidhuber 2018

위치 인코딩

Positional Encoding

딥러닝·신경망 · **심화**

입문 트랜스포머는 단어를 한꺼번에 보기 때문에 순서를 모른다. 그래서 각 단어에 '몇 번째인지' 정보를 덧붙여준다.

심화 순서 정보가 없는 셀프 어텐션에 토큰 위치를 주입하는 방법이다. 원 논문의 사인·코사인 고정 인코딩, 학습형 절대 위치 임베딩, 상대 위치 방식이 있으며, 최신 LLM은 Q·K를 위치에 따라 회전시키는 RoPE를 주로 쓴다. 위치 인코딩 설계는 컨텍스트 길이 확장 기법과 직결된다.

연관 트랜스포머, 셀프 어텐션, 컨텍스트 윈도, 임베딩

출처 Hugging Face / 논문 Vaswani et al. 2017 · Su et al. 2021

은닉층

Hidden Layer

딥러닝·신경망 · **실무**

입문 입력과 출력 사이에 있는 중간 계산 층이다. 겉으로 보이지 않아 '숨은' 층이라 부르며, 여기서 특징이 단계적으로 추출된다.

심화 입력층과 출력층 사이에서 중간 표현을 계산하는 층이다. 층 수(깊이)와 각 층의 뉴런 수(너비)가 모델 용량을 결정한다. 깊은 층일수록 더 추상적인 특징을 표현하는 경향이 있으며, 은닉 차원(hidden size)은 LLM 규모를 나타내는 주요 설정값이다.

연관 다층 퍼셉트론, 신경망, 딥러닝, 파라미터 수와 모델 크기

출처 Google for Developers

음성 복제

Voice Cloning

생성 AI·멀티모달 · **실무**

입문 몇 초에서 몇 분 분량의 목소리 샘플만으로 특정인의 목소리를 흉내 내 말하게 하는 기술이다.

심화 화자 임베딩을 추출해 TTS 모델의 조건으로 넣거나(제로샷 복제), 소량 데이터로 미세조정해 음색·억양을 재현한다. 브랜드 음성, 접근성(목소리를 잃은 사람의 음성 보존)에 유용하지만 보이스피싱·사칭에 악용될 수 있어 당사자 동의, 워터마크, 음성 기반 본인 인증의 보완이 필요하다.

예시 금융사는 음성 복제 사칭 위험을 고려해 음성만으로 고액 이체를 승인하지 않고 추가 인증을 요구한다.

연관 음성 합성, 딥페이크, 워터마킹, 음성 에이전트

출처 ElevenLabs · Wikipedia / 논문 Arik et al. 2018 · Jia et al. 2018 · Wang et al. 2023

음성 에이전트

Voice Agent

생성 AI·멀티모달 · **실무**

입문 전화나 스피커로 사람과 말로 대화하면서 업무를 처리해 주는 AI 에이전트다.

심화 STT → LLM → TTS를 연결한 파이프라인형과, 음성을 직접 입력받아 음성으로 응답하는 음성-음성 모델형이 있다. 응답 지연, 말 끊기(barge-in) 처리, 발화 종료 감지, 도구 호출 중 대기 처리가 사용자 경험을 좌우한다. 본인 확인과 민감 거래는 별도 인증 절차와 연계해야 한다.

예시 카드 분실 신고 전화를 음성 에이전트가 받아 본인 확인 후 정지 처리와 재발급 접수를 한다.

연관 실시간 음성 대화, 음성 인식, 음성 합성, AI 에이전트

출처 OpenAI / 논문 Défossez et al. 2024

음성 인식

STT · Speech-to-Text

생성 AI·멀티모달 · **입문**

입문 사람이 말한 소리를 글자로 바꿔 주는 기술이다. ASR(자동 음성 인식)이라고도 한다.

심화 음성 파형을 멜 스펙트로그램 등으로 변환한 뒤 인코더-디코더 트랜스포머 등으로 텍스트를 생성한다. 대규모 다국어 데이터로 학습한 모델이 잡음에 강해졌으며, 화자 분리, 실시간 스트리밍 인식, 도메인 용어 인식이 실무 과제다. 금융 상품명 등 전문 용어는 사용자 사전이나 후처리로 보정한다.

예시 상담 녹취를 STT로 텍스트화해 불완전판매 여부 점검과 상담 요약에 활용한다.

연관 음성 합성, 음성 에이전트, 실시간 음성 대화, 멀티모달

출처 AWS · Hugging Face · Wikipedia / 논문 Baevski et al. 2020 · Radford et al. 2022

음성 합성

TTS · Text-to-Speech

생성 AI·멀티모달 · **입문**

입문 글을 사람 목소리처럼 자연스럽게 읽어 주는 기술이다.

심화 텍스트를 음소·운율 정보로 변환한 뒤 음향 특징을 생성하고 보코더로 파형을 만드는 파이프라인에서, 최근에는 음성을 이산 토큰으로 다루는 언어모델 방식이나 확산·플로우 기반 단일 모델로 발전했다. 짧은 샘플로 특정 화자를 흉내 내는 음성 복제가 가능해져 사칭 악용 대책이 필요하다.

예시 ARS 안내 멘트를 녹음 없이 TTS로 생성해 문구 변경 시 즉시 반영한다.

연관 음성 인식, 음성 복제, 음성 에이전트, 실시간 음성 대화

출처 IBM · Hugging Face · Wikipedia / 논문 van den Oord et al. 2016 · Shen et al. 2017 · Wang et al. 2023

음악 생성

Music Generation

생성 AI·멀티모달 · **실무**

입문 장르나 분위기를 글로 설명하면 AI가 곡을 작곡하고 연주·노래까지 만들어 주는 기술이다.

심화 오디오를 신경망 코덱으로 이산 토큰화해 자기회귀 언어모델로 생성하거나, 잠재 공간에서 확산·플로우 모델로 생성한다. 가사·보컬·반주를 함께 생성하는 수준에 이르렀으나, 학습 데이터 저작권을 둘러싼 분쟁과 라이선스 계약이 진행 중이어서 상업적 사용 시 이용 약관과 권리 관계를 확인해야 한다.

연관 생성형 AI, 생성물 저작권, 음성 합성, 확산 모델

출처 Meta AI · Hugging Face · Wikipedia / 논문 Agostinelli et al. 2023 · Copet et al. 2023

응답 미리 채우기

Response Prefill

프롬프트·추론 · **심화**

입문 AI 답변의 첫 부분을 미리 써 두고 그 뒤를 이어 쓰게 하는 방법이다. 형식을 강하게 고정할 수 있다.

심화 assistant 메시지의 시작 부분(예: '{' 또는 '<결과>')을 미리 입력해 모델이 그 뒤를 이어 생성하게 하는 기법이다. 서론 생략, 형식 고정, 특정 언어 유지에 효과적이다. 일부 API와 추론 모드에서는 지원되지 않을 수 있어 구조화된 출력 기능으로 대체하기도 한다.

예시 응답을 '{'로 미리 채워 설명 문장 없이 JSON만 돌아오게 한다.

연관 출력 형식 지정, 구조화된 출력, 프롬프트

출처 Anthropic · Google

의미 검색

Semantic Search

RAG·검색·데이터 · **실무**

입문 단어가 똑같지 않아도 뜻이 비슷한 문서를 찾아주는 검색이다. '대출 갚기'로 검색해도 '상환' 문서를 찾는다.

심화 질의와 문서를 임베딩으로 변환해 벡터 유사도로 검색하는 밀집 검색(dense retrieval) 방식이다. 동의어·의역에 강하지만 상품코드, 조항 번호, 고유명사 같은 정확 일치에는 약할 수 있어 키워드 검색과 결합한 하이브리드 검색을 많이 쓴다.

예시 '해외에서 카드 분실'로 검색해도 '국외 카드 도난·분실 신고 절차' 문서가 검색된다.

연관 임베딩, 벡터 데이터베이스, 하이브리드 검색, BM25, 검색(리트리벌)

출처 Elastic · Wikipedia / 논문 Karpukhin et al. 2020

이미지 캡셔닝

Image Captioning

생성 AI·멀티모달 · **실무**

입문 사진을 보고 무엇이 담겨 있는지 한두 문장으로 설명을 붙여 주는 기술이다.

심화 이미지 인코더와 텍스트 디코더(현재는 주로 VLM)로 이미지 내용을 자연어로 기술한다. 시각장애인 접근성용 대체 텍스트, 이미지 검색 색인, 생성 모델 학습용 상세 캡션 생성(재캡셔닝)에 쓰인다. 사실과 다른 객체를 언급하는 환각이 있어 자동 색인에는 신뢰도 검증이 필요하다.

예시 사내 이미지 자료실의 사진마다 설명 캡션을 자동 생성해 검색되게 만든다.

연관 시각 언어 모델, 시각 질의응답, 멀티모달, 환각

출처 Hugging Face · Wikipedia / 논문 Vinyals et al. 2014 · Xu et al. 2015 · Li et al. 2022

이미지-이미지 변환

I2I · Image-to-Image

생성 AI·멀티모달 · **실무**

입문 기존 그림을 바탕으로 스타일을 바꾸거나 일부를 고쳐 새 그림을 만드는 기술이다.

심화 입력 이미지에 일정 강도의 노이즈를 더한 뒤 텍스트 조건으로 노이즈를 제거해 구도는 유지하면서 내용·스타일을 바꾸거나, 지시문 기반 편집 모델로 '배경을 사무실로 바꿔라' 같은 명령을 수행한다. 노이즈 강도가 원본 보존과 변경 폭의 균형을 결정한다.

연관 인페인팅, 컨트롤넷, 텍스트-이미지 생성, 확산 모델

출처 Hugging Face · Hugging Face / 논문 Isola et al. 2016 · Meng et al. 2021 · Brooks et al. 2022

이상 탐지

Anomaly Detection

AI 기초·머신러닝 · **실무**

입문 평소와 다른 수상한 패턴을 자동으로 찾아내는 기술이다.

심화 정상 데이터의 분포에서 크게 벗어난 관측치를 식별한다. 레이블이 부족한 경우가 많아 Isolation Forest, One-Class SVM, 오토인코더 재구성 오차 같은 비지도·준지도 기법을 쓰며, 레이블이 있으면 불균형 분류로 접근한다. 정상 패턴 자체가 변하는 개념 드리프트 대응이 운영상 핵심이다.

예시 평소와 다른 지역·시간대·금액의 카드 결제를 실시간으로 탐지해 추가 인증을 요구한다.

연관 비지도학습, 오토인코더, 클래스 불균형, 군집화, 분류

출처 IBM · Wikipedia / 논문 Chandola et al. 2009 · Liu et al. 2008

인간 평가

Human Evaluation

평가·안전·규제 · **실무**

입문 사람이 직접 AI 답변을 읽고 품질을 판단하는 평가다. 가장 믿을 만하지만 시간과 비용이 많이 든다.

심화 절대 점수 매기기, 두 답변 중 우수한 쪽을 고르는 쌍대 비교, 오류 유형 태깅 등으로 수행한다. 평가자 간 일치도를 측정하고 상세한 가이드라인으로 판단 기준을 맞춰야 한다. 비용 때문에 LLM 심판 결과의 보정, 고위험 사례 검토, 신규 기능 초기 검증에 집중해 쓰는 것이 일반적이다.

예시 법무팀 변호사가 계약서 검토 AI의 지적 사항 100건을 표본 검토해 정확도와 누락을 기록한다.

연관 LLM 심판 평가, 평가, 휴먼 인 더 루프, 인간 피드백 기반 강화학습, 골든 데이터셋

출처 Anthropic (Claude Platform Docs) / 논문 Ouyang et al. 2022 · Chiang et al. 2024

인간 피드백 기반 강화학습

RLHF · Reinforcement Learning from Human Feedback

학습·튜닝·정렬 · **실무**

입문 사람이 여러 답변 중 더 좋은 것을 골라 주면, 그 선호를 학습해 AI가 사람이 원하는 방향으로 답하도록 만드는 방법이다.

심화 사람의 쌍대 비교 선호 데이터로 보상모델을 학습한 뒤, PPO 등 강화학습으로 정책 모델이 보상을 최대화하도록 하고 KL 패널티로 기준 모델에서 너무 멀어지지 않게 한다. 대화형 LLM의 유용성·무해성 향상에 핵심 역할을 했다. 비용이 크고 보상 해킹, 아첨 경향 같은 부작용이 있다.

연관 보상모델, 근접 정책 최적화, 선호 데이터, 정렬, 직접 선호 최적화

출처 Hugging Face · IBM · Wikipedia / 논문 Christiano et al. 2017 · Ziegler et al. 2019 · Ouyang et al. 2022

인공지능

AI · Artificial Intelligence

AI 기초·머신러닝 · **입문**

입문 사람처럼 보고, 듣고, 판단하고, 말하는 일을 컴퓨터가 하도록 만드는 기술 전체를 가리킨다.

심화 인간의 지적 능력(인지·추론·학습·언어 이해 등)을 기계로 구현하려는 컴퓨터과학 분야다. 규칙 기반 전문가 시스템부터 머신러닝, 딥러닝, 생성 AI까지 포괄하며, 오늘날 실무에서 말하는 AI는 대부분 데이터로 학습한 통계적 모델을 뜻한다.

예시 은행이 상담 챗봇, 서류 자동 심사, 이상거래 탐지에 AI를 도입해 반복 업무를 줄인다.

연관 머신러닝, 딥러닝, 생성형 AI, 범용 인공지능, 약인공지능과 강인공지능

출처 IBM · Wikipedia / 논문 Turing 1950

인공지능 기본법

Framework Act on the Development of Artificial Intelligence and Establishment of Trust (Korea AI Basic Act)

평가·안전·규제 · **입문**

입문 한국의 AI 산업 진흥과 안전·신뢰 확보를 함께 규정한 법으로, 2026년 1월 22일부터 시행되고 있다. AI 서비스를 제공하는 기업에 고지·표시 같은 의무를 지운다.

심화 정식 명칭은 「인공지능 발전과 신뢰 기반 조성 등에 관한 기본법」이며 2025년 1월 공포, 2026년 1월 22일 시행령과 함께 시행됐다. 주요 의무는 고영향·생성형 AI 사용 사전 고지와 생성물 표시(투명성), 학습 누적 연산량이 일정 기준(10의 26승 FLOPs) 이상인 AI의 안전성 확보, 고영향 AI 사업자의 위험관리·설명·이용자 보호·사람의 관리감독 조치, 일정 규모 이상 해외 사업자의 국내대리인 지정이다. 의무 위반 시 시정명령 불이행 등에 최대 3천만 원 과태료가 규정돼 있으나, 정부는 최소 1년 이상 계도기간을 두고 과태료 부과를 유예하고 있다.

예시 금융사가 생성형 AI 상담 서비스를 출시할 때 약관과 화면에 AI 사용 사실을 고지하고 고영향 AI 해당 여부를 검토한다.

연관 고영향 인공지능, 생성형 AI 표시 의무, EU 인공지능법, AI 거버넌스, 책임 있는 AI

출처 국가법령정보센터 · 국가법령정보센터

인컨텍스트 러닝

ICL · In-Context Learning

프롬프트·추론 · **실무**

입문 AI를 다시 학습시키지 않고, 질문 안에 넣어 준 설명과 예시만 보고 새 작업을 해내는 능력이다.

심화 모델 가중치 업데이트 없이 컨텍스트에 주어진 지시·예시·문서로부터 작업을 추론하는 LLM의 능력이다. 제로샷·퓨샷·RAG가 모두 이 능력에 기반한다. 컨텍스트 창이 커지면서 수백 개 예시를 넣는 many-shot ICL도 가능해졌지만, 비용과 지연이 늘고 긴 컨텍스트 중간 정보 활용이 약해지는 한계가 있다.

예시 신규 상품 약관을 프롬프트에 넣고 그 약관 기준으로 고객 질문에 답하게 하는 것이 인컨텍스트 러닝이다.

연관 퓨샷, 제로샷, 컨텍스트 윈도, 파인튜닝, 검색 증강 생성

출처 Wikipedia / 논문 Brown et al. 2020 · Agarwal et al. 2024

인코더 모델

Encoder Model (BERT-style)

LLM·언어모델 · **심화**

입문 문장 전체를 앞뒤로 함께 읽고 의미를 파악하는 데 특화된 모델이다. BERT가 대표적이며 분류와 검색에 많이 쓴다.

심화 트랜스포머 인코더만 사용하며 양방향 셀프 어텐션으로 문맥 표현을 만든다. 마스크드 언어모델링(MLM)으로 사전학습하고, 분류·개체명 인식·문장 임베딩·리랭킹에 파인튜닝해 쓴다. 생성에는 적합하지 않지만 작고 빠르다.

예시 고객 민원 유형 분류나 RAG용 임베딩·리랭커에 인코더 모델을 사용한다.

연관 트랜스포머, 임베딩, 디코더 전용 모델, 재순위화, 분류

출처 Wikipedia · Hugging Face / 논문 Devlin et al. 2019

인코더-디코더

Encoder-Decoder

딥러닝·신경망 · **실무**

입문 입력을 읽어 핵심 의미로 압축하는 부분(인코더)과, 그 의미로 결과를 만들어내는 부분(디코더)으로 이루어진 구조다. 번역기가 대표적이다.

심화 인코더가 입력 시퀀스를 잠재 표현으로 변환하고 디코더가 이를 조건으로 출력 시퀀스를 생성하는 구조(seq2seq)다. 트랜스포머 인코더-디코더에서는 디코더가 교차 어텐션으로 인코더 출력을 참조한다. 번역·요약·음성 인식에 쓰이며, 현재 LLM은 대부분 디코더 전용 구조다.

연관 트랜스포머, 어텐션, 오토인코더, 순환 신경망, 음성 인식

출처 IBM · Hugging Face / 논문 Sutskever et al. 2014 · Cho et al. 2014 · Bahdanau et al. 2014

인페인팅
Inpainting

생성 AI·멀티모달 · **실무**

입문 사진에서 지정한 부분만 지우거나 다른 것으로 자연스럽게 바꿔 채우는 이미지 편집 기술이다. 바깥으로 그림을 확장하는 것은 아웃페인팅이라 한다.

심화 마스크로 지정한 영역만 노이즈 제거 과정에서 새로 생성하고 나머지 영역은 원본을 유지하도록 조건을 주는 방식이다. 주변 맥락과 조명·질감이 맞도록 생성하는 것이 관건이며, 객체 제거, 배경 교체, 결함 복원에 쓰인다. 편집 이미지의 진위 문제로 출처 표시가 함께 고려된다.

예시 홍보물 사진에서 노출되면 안 되는 고객 정보가 담긴 화면 부분을 지우고 자연스럽게 채운다.

연관 이미지-이미지 변환, 확산 모델, 콘텐츠 출처 증명, 딥페이크

출처 Hugging Face · Wikipedia / 논문 Lugmayr et al. 2022

임베딩
Embedding

딥러닝·신경망 · **실무**

입문 단어, 문장, 상품 같은 대상을 숫자 목록(좌표)으로 바꾸는 것이다. 의미가 비슷하면 좌표도 가까워진다.

심화 이산적 객체를 연속적인 저차원 밀집 벡터로 사상한 표현이다. 학습을 통해 의미적 유사성이 벡터 공간의 거리(코사인 유사도 등)로 반영된다. LLM의 입력 토큰 임베딩, 문장 임베딩을 이용한 의미 검색과 RAG, 추천 시스템의 사용자·아이템 임베딩 등에 쓰인다.

예시 사내 규정 문서를 임베딩해 벡터 DB에 저장하고 직원 질문과 의미가 가까운 조항을 검색한다.

연관 벡터 데이터베이스, 의미 검색, 검색 증강 생성, 토큰, 추천 시스템

출처 IBM · Google for Developers · Wikipedia / 논문 Mikolov et al. 2013

임베딩 모델
Embedding Model

RAG·검색·데이터 · **실무**

입문 문장이나 문서를 의미를 담은 숫자 목록(벡터)으로 바꿔 주는 AI 모델이다. 뜻이 비슷하면 숫자도 비슷해진다.

심화 텍스트(또는 이미지)를 고정 차원의 밀집 벡터로 변환하는 모델로, 대조학습으로 의미가 가까운 입력이 벡터 공간에서 가깝도록 훈련된다. 언어 지원(한국어 성능), 차원 수, 최대 입력 길이, 도메인 적합성이 선택 기준이며 MTEB 등 벤치마크를 참고한다. 모델을 바꾸면 전체 문서를 다시 임베딩해야 하므로 초기 선정이 중요하다.

예시 폐쇄망 환경에서 다국어 오픈소스 임베딩 모델을 사내 서버에 올려 규정 문서를 벡터화한다.

연관 임베딩, 벡터 데이터베이스, 의미 검색, 다국어 모델

출처 IBM · Google Cloud / 논문 Reimers and Gurevych 2019 · Muennighoff et al. 2022

ㅈ

자기일관성
Self-Consistency

프롬프트·추론 · **심화**

입문 같은 문제를 AI에게 여러 번 풀게 한 뒤 가장 많이 나온 답을 고르는 방법이다. 여러 사람에게 물어 다수결로 정하는 것과 비슷하다.

심화 CoT 추론 경로를 온도를 높여 여러 개 샘플링한 뒤 최종 답을 다수결로 집계하는 디코딩 전략이다. 단일 경로의 우연한 오류를 상쇄해 정답률을 높이지만 호출 수에 비례해 비용과 지연이 증가한다. 정답이 명확히 비교 가능한 작업(수치, 분류)에 적합하며, 테스트 타임 컴퓨트를 늘리는 대표적 방법이다.

예시 거래 이상 여부 판정을 5회 샘플링해 다수결로 결정하고, 의견이 갈리면 사람 검토로 넘긴다.

연관 사고의 연쇄, 온도, 테스트 타임 컴퓨트, 트리 오브 소트

출처 Wikipedia / 논문 Wang et al. 2022

자기지도학습
SSL · Self-Supervised Learning

AI 기초·머신러닝 · **심화**

입문 사람이 정답을 달지 않아도 데이터 자체에서 문제를 만들어 스스로 공부하는 방식이다. 문장의 다음 단어 맞히기가 대표적이다.

심화 데이터의 일부를 가리거나 변형해 원본을 맞히는 과제(사전 과제)를 만들어 레이블 없이 표현을 학습한다. 다음 토큰 예측(GPT 계열), 마스크 언어 모델(BERT), 대조 학습(이미지·멀티모달)이 대표적이며 파운데이션 모델 사전학습의 핵심 원리다.

연관 사전학습, 다음 토큰 예측, 파운데이션 모델, 비지도학습, 임베딩

출처 IBM · Wikipedia / 논문 Devlin et al. 2018 · Chen et al. 2020

자기회귀 모델
Autoregressive Model

LLM·언어모델 · **실무**

입문 자기가 방금 만든 결과를 다시 입력으로 삼아 한 조각씩 이어서 생성하는 모델이다.

심화 결합확률을 조건부 확률의 곱 P(x_t | x_<t)로 분해해 순차적으로 샘플링한다. 구조가 단순하고 학습이 안정적이지만 출력 길이에 비례해 생성 단계가 늘어나 지연이 생기고, 초반 오류가 뒤로 누적될 수 있다. 추측 디코딩 등으로 순차 병목을 완화한다.

연관 다음 토큰 예측, 디코더 전용 모델, 추측 디코딩, KV 캐시

출처 Wikipedia · Wikipedia / 논문 Brown et al. 2020

자기회귀 이미지 생성

Autoregressive Image Generation

생성 AI·멀티모달 · 심화

입문 글을 한 단어씩 이어 쓰듯 그림을 작은 조각 단위로 차례차례 만들어 가는 방식이다.

심화 이미지를 이산 토큰(VQ 계열 토크나이저)이나 연속 패치로 변환하고, LLM처럼 다음 토큰을 예측해 순차적으로 생성한다. 언어 모델과 같은 구조로 텍스트·이미지를 하나의 모델에서 다룰 수 있어 지시 이해와 이미지 내 텍스트 렌더링에 강점이 있으나 토큰 수가 많아 생성이 느릴 수 있다. 확산 디코더와 결합한 하이브리드 방식도 쓰인다.

연관 다음 토큰 예측, 네이티브 멀티모달, 텍스트-이미지 생성, 확산 모델

출처 OpenAI / 논문 Esser et al. 2020 · Ramesh et al. 2021 · Tian et al. 2024

자율성 수준

Level of Autonomy

AI 에이전트·도구 · 실무

입문 AI 에이전트에게 얼마나 스스로 결정하고 실행하게 할지의 정도다. 제안만 하는 단계부터 알아서 끝내는 단계까지 있다.

심화 사람이 모든 단계를 지시하는 보조 수준, AI가 제안하고 사람이 승인하는 수준, 정해진 범위 안에서 자율 실행하고 예외만 보고하는 수준, 완전 자율 수준 등으로 구분한다. 업무 위험도, 결과의 가역성, 규제 요건, 모델 신뢰도를 기준으로 정하며, 평가 결과가 쌓이면 단계적으로 자율성을 높인다.

예시 대출 상담 요약은 자동 생성하되 금리 안내 문구는 AI 제안 후 직원 승인 단계로 운영한다.

연관 휴먼 인 더 루프, 에이전트 권한 관리, AI 에이전트, AI 거버넌스

출처 IBM / 논문 Feng et al. 2025

자체 구축 대 구매

Build vs. Buy

AX·비즈니스 적용 · 실무

입문 AI 기능을 직접 만들지, 이미 만들어진 제품·서비스를 사서 쓸지 결정하는 문제다.

심화 구매(SaaS·API)는 빠르고 최신 성능을 쓰지만 데이터 반출, 커스터마이징 한계, 벤더 종속이 있다. 자체 구축(오픈 웨이트 모델+자체 서빙·RAG)은 통제력과 장기 비용 이점이 있으나 인력·인프라 부담이 크다. 실제로는 범용 기능은 구매, 핵심 차별화·민감 데이터 영역은 구축하는 혼합형이 많다.

예시 문서 작성 보조는 상용 서비스를 쓰고, 고객정보를 다루는 상담 분석은 자체 구축하기로 결정했다.

연관 총소유비용, 벤더 종속, 내재화, 온프레미스

출처 Corporate Finance Institute

잔차 연결

Residual Connection

딥러닝·신경망 · 심화

입문 층을 건너뛰는 지름길을 만들어 원래 입력을 출력에 더해주는 구조다. 아주 깊은 신경망도 학습이 잘 되게 한다.

심화 층의 출력을 F(x) + x 형태로 만들어 층이 입력 대비 변화량(잔차)만 학습하게 한다. 기울기가 지름길을 통해 직접 전파되어 기울기 소실을 완화하고 수백 층 학습을 가능하게 했다. ResNet에서 도입되었고 트랜스포머의 모든 서브층에 적용된다.

연관 기울기 소실, 트랜스포머, 합성곱 신경망, 레이어 정규화

출처 Wikipedia / 논문 He et al. 2015

잠재 공간

Latent Space

생성 AI·멀티모달 · 심화

입문 데이터의 핵심 특징만 압축해 담아 둔 보이지 않는 좌표 공간이다. 비슷한 이미지는 이 공간에서 가까이 놓인다.

심화 고차원 데이터를 인코더로 압축한 저차원 표현 공간이다. 잠재 확산 모델은 VAE로 이미지를 잠재 공간에 압축한 뒤 그 안에서 노이즈 제거를 수행해 계산량을 크게 줄인다. 잠재 벡터 간 보간이나 방향 조작으로 속성을 변경할 수 있으며, 임베딩 공간과 유사한 개념이다.

연관 변분 오토인코더, 확산 모델, 임베딩, 노이즈 제거

출처 IBM · Wikipedia / 논문 Rombach et al. 2021

장기 실행 작업

Long-Running Task

AI 에이전트·도구 · 심화

입문 몇 분에서 몇 시간 이상 걸리는 큰 작업을 AI 에이전트가 중간에 끊기지 않고 이어서 처리하는 것이다.

심화 단일 컨텍스트 윈도를 넘는 작업을 위해 진행 상황을 파일·DB에 체크포인트로 저장하고, 컨텍스트 압축이나 새 세션에서의 재개를 지원하는 설계가 필요하다. 비동기 실행, 진행 상태 조회, 중단·재개, 타임아웃 처리, 중간 결과 검증이 요구되며, 오류가 누적되지 않도록 단계별 검증 지점을 둔다.

예시 대규모 레거시 SQL 수백 개를 새 표준으로 변환하는 작업을 체크포인트를 남기며 여러 세션에 걸쳐 수행한다.

연관 에이전트 상태 관리, 계획 수립, 에이전트 메모리, 재시도와 폴백

출처 Anthropic · Anthropic

장단기 메모리

LSTM · Long Short-Term Memory

딥러닝·신경망 · **실무**

입문 무엇을 기억하고 무엇을 잊을지 스스로 조절하는 문을 단 순환 신경망이다. 긴 순서 데이터도 잘 기억한다.

심화 셀 상태와 입력·망각·출력 게이트를 둔 RNN 변형으로, 장기 의존성 학습 시 기울기 소실을 완화한다. 1997년 제안되어 음성 인식·번역·시계열 예측에서 오랫동안 표준이었다. 언어 분야는 트랜스포머로 대체되었으나 경량 시계열·스트리밍 처리에서는 여전히 쓰인다.

예시 카드 거래 시퀀스를 LSTM으로 모델링해 평소 결제 흐름에서 벗어난 거래를 탐지한다.

연관 순환 신경망, 게이트 순환 유닛, 기울기 소실, 시계열 예측

출처 IBM · Wikipedia / 논문 Hochreiter & Schmidhuber 1997

재순위화

Reranking

RAG·검색·데이터 · **실무**

입문 1차로 찾은 후보 문서들을 더 정교한 모델로 다시 채점해 순서를 바로잡는 단계다.

심화 빠른 1차 검색으로 수십~수백 개 후보를 뽑은 뒤, 질의와 문서를 함께 입력받는 크로스 인코더나 LLM으로 관련도를 재계산해 상위 k개를 고르는 단계다. 1차 검색보다 느리지만 정밀도를 크게 높여 LLM에 들어가는 불필요한 문서를 줄인다. 다국어·한국어 지원 리랭커 선택이 중요하다.

예시 하이브리드 검색으로 50개 조항을 가져온 뒤 리랭커로 상위 5개만 프롬프트에 넣는다.

연관 검색(리트리벌), 하이브리드 검색, 상위 k개 검색, 검색 증강 생성

출처 Microsoft · Cohere / 논문 Nogueira and Cho 2019

재시도와 폴백

Retry and Fallback

AI 에이전트·도구 · **심화**

입문 AI 호출이나 도구 실행이 실패했을 때 다시 시도하거나, 다른 방법·모델로 바꿔 처리하는 안전장치다.

심화 일시적 오류(타임아웃, 속도 제한)는 지수 백오프로 재시도하고, 반복 실패 시 대체 모델·대체 도구·규칙 기반 응답·사람 이관으로 전환한다. 쓰기 작업은 멱등성을 보장해야 재시도 시 중복 실행을 막을 수 있으며, 모델이 잘못된 형식을 출력하면 오류 메시지를 다시 넣어 자기 수정하게 하는 방법도 쓴다. 재시도 횟수와 총 비용 상한을 둔다.

예시 주 모델 응답이 지연되면 경량 모델로 전환하고, 그것도 실패하면 '담당자 연결' 안내로 넘어간다.

연관 에이전트 루프, 장기 실행 작업, 지연 시간, 핸드오프

출처 AWS · Wikipedia

적대적 공격

Adversarial Attack

평가·안전·규제 · **심화**

입문 사람 눈에는 거의 차이가 없는 작은 변형을 입력에 가해 AI가 엉뚱한 판단을 하게 만드는 공격이다.

심화 이미지에 미세한 노이즈를 더해 분류를 바꾸거나, 텍스트에 특정 문자열(적대적 접미사)을 붙여 안전장치를 우회하는 방식이 있다. 모델의 기울기를 이용하는 화이트박스 공격과 질의 결과만 이용하는 블랙박스 공격으로 나뉜다. 적대적 학습, 입력 정규화, 앙상블, 이상 입력 탐지로 견고성을 높인다.

예시 신분증 OCR 모델이 위변조 이미지의 미세 조작에 속지 않는지 적대적 샘플로 시험한다.

연관 레드티밍, 데이터 포이즈닝, 탈옥, 모델 탈취, 광학 문자 인식

출처 Wikipedia / 논문 Szegedy et al. 2013 · Goodfellow et al. 2014 · Zou et al. 2023

전문가 혼합

MoE · Mixture of Experts

LLM·언어모델 · **심화**

입문 여러 전문가 모듈을 두고 질문마다 일부 전문가만 불러 일하게 하는 구조다. 덩치는 크지만 실제 계산은 일부만 한다.

심화 트랜스포머의 FFN 층을 여러 전문가로 나누고, 라우터가 토큰마다 상위 k개 전문가만 활성화한다. 총 파라미터 대비 활성 파라미터가 작아 같은 연산량으로 더 큰 용량을 얻는다. 대신 전체 가중치를 메모리에 올려야 하고, 전문가 부하 불균형과 분산 통신 비용이 과제다.

연관 트랜스포머, 파라미터 수와 모델 크기, 파라미터, 추론 서빙, 스케일링 법칙

출처 Hugging Face · IBM · Wikipedia / 논문 Shazeer et al. 2017 · Fedus et al. 2022 · Jiang et al. 2024

전이 학습

Transfer Learning

딥러닝·신경망 · **실무**

입문 한 분야에서 배운 지식을 다른 분야에 재활용하는 방법이다. 영어를 잘하는 사람이 독일어를 더 빨리 배우는 것과 비슷하다.

심화 대규모 데이터로 사전학습한 모델의 표현을 다른 과제에 재사용한다. 하위 층을 고정하고 상위 층만 학습하거나(특징 추출), 전체를 작은 학습률로 재학습한다(파인튜닝). 적은 데이터로 높은 성능을 얻을 수 있어 파운데이션 모델 활용의 기본 원리다.

예시 범용 언어모델을 금융 민원 데이터로 파인튜닝해 민원 유형 분류기를 만든다.

연관 사전학습, 파인튜닝, 파운데이션 모델, 매개변수 효율적 미세조정

출처 IBM · Wikipedia / 논문 Pan & Yang 2010 · Yosinski et al. 2014

전체 파인튜닝

Full Fine-Tuning

학습·튜닝·정렬 · **심화**

입문 모델의 모든 파라미터를 다시 학습시키는 파인튜닝 방식이다. 효과는 크지만 자원이 많이 든다.

심화 모든 가중치에 대해 그래디언트와 옵티마이저 상태를 유지해야 해 혼합정밀도 Adam 기준으로 파라미터당 대략 16바이트 이상 메모리가 필요하다. 큰 분포 이동이나 대규모 도메인 적응에서 PEFT보다 유리할 수 있지만 망각 위험과 모델별 저장 비용이 크다.

연관 파인튜닝, 매개변수 효율적 미세조정, 혼합정밀도 학습, 파국적 망각

출처 Hugging Face · IBM

정규화(규제)

Regularization

AI 기초·머신러닝 · **실무**

입문 AI가 너무 복잡한 규칙을 외우지 못하게 제약을 거는 것이다. 단순한 설명을 선호하도록 만든다.

심화 과적합을 줄이기 위해 모델 복잡도에 패널티를 주는 기법의 총칭이다. 손실함수에 가중치 크기 항을 더하는 L1(희소화)·L2(가중치 감쇠)가 대표적이며, 딥러닝에서는 드롭아웃, 조기 종료, 데이터 증강도 포함한다. 데이터 스케일을 맞추는 정규화(normalization)와 우리말이 같아 혼동에 주의한다.

예시 변수가 수백 개인 신용평가 로지스틱 모델에 L1 규제를 걸어 중요 변수만 남긴다.

연관 과적합, 드롭아웃, 조기 종료, 손실 함수, 피처 스케일링(정규화·표준화)

출처 IBM · Wikipedia / 논문 Hoerl and Kennard 1970 · Tibshirani 1996 · Srivastava et al. 2014

정렬

Alignment

학습·튜닝·정렬 · **실무**

입문 AI가 사람의 의도와 가치에 맞게, 유용하고 정직하며 해롭지 않게 행동하도록 만드는 일이다.

심화 지시 튜닝, RLHF·DPO 같은 선호 최적화, 헌법적 AI 등으로 모델 행동을 의도된 목표와 규범에 맞추는 연구·기술 분야다. 기술적으로는 보상 명세 오류, 보상 해킹, 아첨, 기만적 행동 등을 다룬다. 학습 단계의 정렬과 배포 단계의 가드레일은 상호 보완 관계다.

연관 인간 피드백 기반 강화학습, 직접 선호 최적화, 헌법적 AI, 책임 있는 AI, 가드레일

출처 IBM · Wikipedia / 논문 Amodei et al. 2016 · Ouyang et al. 2022 · Bai et al. 2022

정밀도와 재현율

Precision and Recall

AI 기초·머신러닝 · **실무**

입문 정밀도는 'AI가 사기라고 한 것 중 진짜 사기 비율', 재현율은 '진짜 사기 중 AI가 잡아낸 비율'이다.

심화 정밀도 = TP/(TP+FP), 재현율 = TP/(TP+FN)이다. 분류 임계값을 낮추면 재현율이 오르고 정밀도가 내려가는 트레이드오프가 있어, 오탐 비용과 미탐 비용에 따라 운영점을 정한다. 불균형 데이터에서는 정확도보다 이 두 지표가 유의미하다.

예시 이상거래 탐지에서 재현율을 높이면 사기를 더 잡지만 정상 고객 거래 차단(오탐)도 늘어난다.

연관 혼동행렬, F1 점수, ROC 곡선과 AUC, 분류, 클래스 불균형

출처 Google for Developers · Wikipedia / 논문 Davis and Goadrich 2006 · Saito and Rehmsmeier 2015

정형 데이터

Structured Data

RAG·검색·데이터 · **입문**

입문 표처럼 행과 열이 정해진 형식으로 정리된 데이터다. 거래 내역, 고객 정보 테이블 등이 해당한다.

심화 사전에 정의된 스키마를 따르는 데이터로 RDBMS 테이블, CSV 등이 대표적이다. SQL로 정확한 집계·조회가 가능해 AI 활용 시에는 벡터 검색보다 Text-to-SQL이나 도구 호출로 접근하는 것이 정확하다. 반정형(JSON, XML) 데이터는 스키마가 유연한 중간 형태다.

예시 여신 잔액, 거래 원장 같은 DW 테이블은 정형 데이터로, AI는 SQL 생성을 통해 조회한다.

연관 비정형 데이터, 텍스트-투-SQL, 데이터 레이크하우스

출처 IBM

정확도

Accuracy

AI 기초·머신러닝 · **입문**

입문 전체 문제 중 AI가 맞힌 비율이다. 다만 한쪽 답이 압도적으로 많은 문제에서는 착시를 일으킨다.

심화 (TP+TN)/전체로 계산한다. 직관적이지만 클래스 불균형이 심하면 무의미해진다. 예컨대 사기 비율이 0.1%이면 모두 정상이라고 답해도 정확도는 99.9%다. LLM 평가에서는 정답률이라는 의미로도 쓰인다.

예시 사기 비율이 매우 낮은 카드 거래 데이터에서는 정확도 대신 재현율과 PR-AUC로 모델을 평가한다.

연관 혼동행렬, 정밀도와 재현율, 클래스 불균형, 벤치마크

출처 Google for Developers · Wikipedia / 논문 Sokolova and Lapalme 2009

정확도

Accuracy

평가·안전·규제 · **입문**

입문 전체 예측 중 맞힌 비율이다. 가장 직관적인 지표지만 데이터가 한쪽으로 쏠려 있으면 성능을 잘못 보여줄 수 있다.

심화 (참양성+참음성)/전체로 계산한다. 이상거래가 0.1%뿐인 데이터에서 모두 정상이라고 답해도 정확도는 99.9%가 되므로, 불균형 데이터에서는 정밀도·재현율·F1과 함께 봐야 한다. 정밀도는 양성이라 예측한 것 중 실제 양성의 비율로, 정확도와 다른 개념이다.

예시 이상거래 탐지 모델은 정확도 대신 재현율과 정밀도를 핵심 지표로 관리한다.

연관 정밀도와 재현율, 분류, 평가, 벤치마크, 골든 데이터셋

출처 Google for Developers · Wikipedia

제로샷

Zero-shot Prompting

프롬프트·추론 · **입문**

입문 예시 없이 지시만으로 AI에게 일을 시키는 방식이다. '이 문장 영어로 번역해줘'처럼 바로 요청하는 것이다.

심화 작업 설명만 주고 입출력 예시를 제공하지 않는 프롬프트 방식이다. 대규모 사전학습과 인스트럭션 튜닝 덕분에 최신 LLM은 많은 일반 작업을 제로샷으로 수행한다. 형식이 까다롭거나 도메인 특유의 판단 기준이 있으면 퓨샷이나 명시적 기준 제시가 더 안정적이다.

예시 '다음 민원 내용을 긍정/부정/중립으로 분류하라'만 주고 분류를 맡기는 경우다.

연관 퓨샷, 원샷, 인컨텍스트 러닝, 지시 튜닝

출처 Google · Wikipedia / 논문 Brown et al. 2020 · Kojima et al. 2022

조기 종료

Early Stopping

딥러닝·신경망 · **실무**

입문 모의고사 점수가 더 이상 오르지 않으면 공부를 멈추는 것이다. 더 하면 오히려 외우기만 해서 실력이 떨어진다.

심화 검증 손실이 일정 에폭(patience) 동안 개선되지 않으면 학습을 중단하고 최적 시점의 가중치를 복원하는 정규화 기법이다. 구현이 간단하고 효과적이어서 신경망과 그래디언트 부스팅에 모두 쓰인다.

연관 과적합, 에폭, 정규화(규제), 데이터셋 분할(학습/검증/테스트)

출처 Google for Developers · Wikipedia

준지도학습

Semi-Supervised Learning

AI 기초·머신러닝 · **심화**

입문 정답이 달린 소수의 데이터와 정답 없는 대량의 데이터를 함께 써서 배우는 방식이다.

심화 소량의 레이블 데이터와 대량의 비레이블 데이터를 함께 활용한다. 자기 학습(의사 레이블링), 일관성 정규화, 그래프 기반 전파 등이 있다. 레이블 비용이 높고 비레이블 데이터가 풍부한 도메인에서 유용하다.

예시 확인된 사기 사례 수백 건과 미확인 거래 수백만 건으로 의사 레이블링을 반복해 탐지 모델을 강화한다.

연관 지도학습, 비지도학습, 자기지도학습, 데이터 레이블링

출처 IBM · Wikipedia / 논문 Sohn et al. 2020

중간 정보 손실

Lost in the Middle

LLM·언어모델 · **심화**

입문 긴 입력을 주면 AI가 앞부분과 끝부분은 잘 활용하지만 가운데 내용은 놓치기 쉬운 현상이다.

심화 관련 정보의 위치에 따라 성능이 U자 곡선을 그린다는 연구 결과에서 나온 용어다. 위치 인코딩 특성과 학습 데이터 분포가 원인으로 거론되며 최신 모델에서는 완화되었지만 완전히 사라지지는 않았다. 중요한 정보를 앞이나 끝에 배치하거나 리랭킹으로 관련 문서만 넣어 대응한다.

연관 롱 컨텍스트, 컨텍스트 윈도, 재순위화, 컨텍스트 엔지니어링

논문 Liu et al. 2023

지도학습

Supervised Learning

AI 기초·머신러닝 · **입문**

입문 문제와 정답을 함께 보여주며 가르치는 방식이다. 정답이 달린 예시를 많이 보면 새 문제의 답도 맞히게 된다.

심화 입력 x와 레이블 y 쌍으로 이루어진 데이터로 x→y 매핑 함수를 학습한다. 출력이 범주이면 분류, 연속값이면 회귀다. 레이블 품질과 양이 성능을 좌우하며, 레이블 확보 비용이 주요 병목이다.

예시 부정거래 여부가 표시된 카드 거래 내역으로 이상거래 탐지 모델을 학습한다.

연관 분류, 회귀, 학습 데이터, 데이터 레이블링, 비지도학습

출처 IBM · Wikipedia

지도 미세조정

SFT · Supervised Fine-Tuning

학습·튜닝·정렬 · **실무**

입문 질문과 모범 답안 쌍을 보여 주며 AI가 그렇게 답하도록 가르치는 학습이다.

심화 입력-정답 출력 쌍으로 교차 엔트로피 손실을 최소화하는 지도학습 방식의 파인튜닝이다. 보통 응답 부분에만 손실을 계산하며, 수천~수십만 건의 고품질 시연 데이터가 효과적이다. 사후학습 파이프라인에서 선호 최적화·강화학습 이전 단계로 쓰인다.

예시 상담 우수 사례 수천 건을 질문-응답 쌍으로 정리해 SFT 데이터로 사용한다.

연관 지시 튜닝, 파인튜닝, 손실 마스킹, 인간 피드백 기반 강화학습, 사후학습

출처 Hugging Face · Hugging Face / 논문 Ouyang et al. 2022

지속학습

Continual Learning

학습·튜닝·정렬 · **심화**

입문 새로운 데이터가 생길 때마다 이전 지식을 잃지 않으면서 계속 배워 나가는 학습 방식이다.

심화 순차적으로 들어오는 데이터·작업에 모델을 갱신하면서 파국적 망각을 억제하는 것이 핵심 과제다. 재생(replay), 정규화, 파라미터 격리(작업별 어댑터) 등을 사용한다. LLM에서는 비용 문제로 재학습 대신 RAG나 주기적 지속 사전학습으로 지식을 갱신하는 경우가 많다.

연관 파국적 망각, 지속 사전학습, 도메인 적응, 지식 컷오프

출처 IBM · Wikipedia / 논문 Parisi et al. 2018 · Kirkpatrick et al. 2016

지속 사전학습

CPT · Continued Pre-training

학습·튜닝·정렬 · **심화**

입문 이미 사전학습된 모델에 특정 분야나 언어의 대량 문서를 더 읽혀 기초 지식을 보강하는 학습이다.

심화 지시-응답 쌍이 아닌 원문 말뭉치로 다음 토큰 예측 학습을 이어서 수행해 도메인 어휘·지식이나 저자원 언어 능력을 강화한다. 망각 방지를 위해 일반 데이터를 섞고 학습률을 다시 워밍업한다. 이후 지시 튜닝과 정렬을 다시 거쳐야 대화형으로 쓸 수 있다.

예시 금융 법령·공시 문서 수십억 토큰으로 지속 사전학습해 금융 특화 모델을 만든다.

연관 도메인 적응, 사전학습, 파국적 망각, 다국어 모델

논문 Gururangan et al. 2020

지시 튜닝

Instruction Tuning

학습·튜닝·정렬 · **실무**

입문 다양한 지시문과 그에 맞는 답을 학습시켜 AI가 사람의 요청을 알아듣고 따르게 만드는 과정이다.

심화 여러 작업을 자연어 지시-응답 형식으로 구성한 데이터로 SFT를 수행해, 사전학습 모델(문장 이어쓰기)을 지시 수행형 모델로 바꾼다. 작업 다양성과 데이터 품질이 처음 보는 작업으로의 일반화를 좌우한다. 공개 모델의 base와 instruct(chat) 버전 차이가 이 단계에서 생긴다.

연관 지도 미세조정, 채팅 템플릿, 사후학습, 정렬

출처 IBM · OpenAI / 논문 Wei et al. 2021 · Ouyang et al. 2022

지식베이스

KB · Knowledge Base

RAG·검색·데이터 · **입문**

입문 AI나 사람이 찾아볼 수 있도록 모아 정리한 회사의 지식 저장소다. 규정, 매뉴얼, FAQ 등이 들어간다.

심화 RAG에서 검색 대상이 되는 문서·데이터 집합과 그 색인을 통칭한다. 문서 수집, 파싱, 색인, 권한, 갱신 주기, 폐기 정책을 포함한 운영 체계가 필요하며, 오래되거나 상충하는 문서는 답변 품질을 떨어뜨린다. 문서 소유자를 지정하고 갱신을 관리하는 거버넌스가 핵심이다.

예시 전사 규정·업무매뉴얼·FAQ를 하나의 지식베이스로 통합하고, 규정 개정 시 야간 배치로 재색인한다.

연관 검색 증강 생성, 벡터 데이터베이스, 지식 그래프, 데이터 카탈로그

출처 AWS · Wikipedia

지식 그래프

KG · Knowledge Graph

RAG·검색·데이터 · **실무**

입문 사람, 회사, 상품 같은 대상과 그 사이의 관계를 점과 선으로 연결해 표현한 지식 지도다.

심화 개체(노드)와 관계(엣지)로 지식을 표현하는 그래프 구조 데이터로, RDF 트리플이나 속성 그래프(Neo4j 등)로 구현한다. 관계 추론과 다단계 탐색에 강해 RAG에 결합하면 멀티홉 질문 대응력이 높아진다. 구축·유지 비용이 크며, 최근에는 LLM으로 문서에서 개체·관계를 자동 추출해 구축하기도 한다.

예시 고객-계좌-담보-보증인 관계를 그래프로 구성해 연쇄 부실 위험 노출을 추적한다.

연관 그래프RAG, 멀티홉 검색, 지식베이스, 검색 증강 생성

출처 IBM · Wikipedia

지식 증류

Knowledge Distillation

학습·튜닝·정렬 · **실무**

입문 크고 똑똑한 선생 모델의 답변 방식을 작은 학생 모델이 따라 배우게 해 가볍지만 쓸 만한 모델을 만드는 방법이다.

심화 교사 모델의 출력 확률분포(소프트 레이블)나 생성 결과를 학생 모델의 학습 목표로 사용한다. LLM에서는 교사가 생성한 응답·추론 과정을 SFT 데이터로 쓰는 시퀀스 수준 증류가 흔하다. 상용 모델 출력을 증류에 쓰는 것은 이용약관상 금지된 경우가 많아 확인이 필요하다.

연관 소형 언어모델, 합성 데이터, 지도 미세조정, 양자화

출처 IBM · Google for Developers · Wikipedia / 논문 Hinton et al. 2015

지식 컷오프

Knowledge Cutoff

LLM·언어모델 · **입문**

입문 AI가 학습한 자료의 마지막 시점이다. 그 이후 일어난 일은 모델이 스스로 알지 못한다.

심화 사전학습 데이터 수집 종료 시점으로, 이후 정보는 파라미터에 없으므로 최신성이 필요한 질의는 검색·RAG·도구 호출로 보완해야 한다. 컷오프 직전 시기는 데이터가 적어 지식이 불완전할 수 있다. 모델이 자신의 컷오프를 정확히 모르는 경우도 있다.

예시 최신 금리나 규제 개정 내용은 모델 지식 대신 사내 공지 DB를 검색해 답하도록 설계한다.

연관 사전학습, 검색 증강 생성, 환각, 도구 사용

출처 Wikipedia / 논문 Cheng et al. 2024

지연 시간

Latency

인프라·배포·LLMOps · **입문**

입문 요청을 보낸 뒤 응답을 받기까지 걸리는 시간이다.

심화 LLM에서는 첫 토큰까지 시간(TTFT)과 토큰 간 지연(TPOT/ITL)으로 나눠 본다. 모델 크기, 입력 길이, 배치 크기, 네트워크 왕복, 큐 대기가 영향을 주며, 처리량을 높이려는 대형 배치는 개별 지연을 늘리는 상충 관계가 있다. 평균보다 p95·p99 지연을 SLA 기준으로 삼는 것이 일반적이다.

예시 상담 챗봇은 p95 지연 3초 이내를 목표로 모델 크기와 배치 정책을 조정했다.

연관 첫 토큰 지연, 처리량, 추론 서빙, 서비스 수준 협약

출처 Wikipedia · NVIDIA / 논문 Agrawal et al. 2024 · Zhong et al. 2024

직접 선호 최적화

DPO · Direct Preference Optimization

학습·튜닝·정렬 · **심화**

입문 좋은 답과 나쁜 답 쌍을 바로 학습시켜, 별도 채점 모델 없이 사람 선호를 반영하는 간단한 정렬 방법이다.

심화 RLHF 목적함수를 재정식화해 보상모델과 강화학습 루프 없이 선호 쌍에 대한 분류형 손실로 정책을 직접 최적화한다. 기준 모델 대비 선호 응답의 로그확률 비를 높이고 비선호 응답은 낮춘다. 구현이 간단하고 안정적이라 널리 쓰이며 IPO, KTO, ORPO, SimPO 등 변형이 있다.

연관 인간 피드백 기반 강화학습, 선호 데이터, 정렬, 지도 미세조정, 근접 정책 최적화

출처 Hugging Face / 논문 Rafailov et al. 2023

ㅊ

차원 축소

Dimensionality Reduction

AI 기초·머신러닝 · **심화**

입문 수많은 항목을 핵심 정보만 남긴 소수의 항목으로 압축하는 기술이다.

심화 고차원 데이터를 정보 손실을 최소화하며 저차원으로 사상한다. 선형 기법인 PCA, 시각화용 비선형 기법인 t-SNE·UMAP, 신경망 기반 오토인코더가 있다. 차원의 저주 완화, 노이즈 제거, 시각화, 연산 비용 절감에 쓴다.

예시 수백 개 거래 행태 변수를 PCA로 압축한 뒤 고객 군집화에 사용한다.

연관 비지도학습, 군집화, 오토인코더, 임베딩

출처 IBM · Wikipedia / 논문 van der Maaten and Hinton 2008 · McInnes et al. 2018 · Hinton and Salakhutdinov 2006

창발적 능력

Emergent Abilities

LLM·언어모델 · **실무**

입문 작은 모델에서는 안 보이던 능력이 모델이 커지면서 갑자기 나타나는 것처럼 보이는 현상이다.

심화 특정 규모 이상에서 다단계 산술, 지시 따르기 등 성능이 급격히 오르는 것으로 보고되었다. 다만 정확도처럼 불연속적인 평가 지표가 만든 착시라는 반론도 있어, 연속 지표로 보면 점진적 향상인 경우가 많다. 능력 예측과 안전성 평가에서 논쟁적인 개념이다.

연관 스케일링 법칙, 파라미터 수와 모델 크기, 벤치마크, 대규모 언어모델

논문 Wei et al. 2022 · Schaeffer et al. 2023

채팅 템플릿

Chat Template

LLM·언어모델 · **심화**

입문 시스템 지침, 사용자 질문, AI 답변을 모델이 구분할 수 있도록 정해진 형식으로 감싸는 규칙이다.

심화 역할(system/user/assistant/tool)별 메시지를 특수 토큰으로 구분해 하나의 시퀀스로 직렬화하는 모델 고유 형식이다. 지시 튜닝 때 쓴 템플릿과 추론 시 템플릿이 다르면 성능이 크게 떨어진다. 오픈 웨이트 모델을 직접 서빙하거나 파인튜닝할 때 특히 주의해야 한다.

연관 지시 튜닝, 멀티턴 대화, 시스템 프롬프트, 지도 미세조정

출처 Hugging Face

책임 있는 확장 정책

RSP · Responsible Scaling Policy

평가·안전·규제 · **심화**

입문 AI 모델이 강력해질수록 그에 맞는 안전 조치를 먼저 갖추겠다고 개발사가 스스로 정한 규칙이다.

심화 모델 능력이 특정 위험 임계(예: 생물무기 제작 지원, 자율적 복제·연구 능력)에 도달했는지 평가하고, 도달하면 더 강한 보안·배포 통제를 적용하기 전까지 학습이나 배포를 진행하지 않는다는 조건부 약속 구조다. Anthropic이 처음 이 이름으로 공개했고, 다른 개발사도 프론티어 안전 프레임워크, 준비성 프레임워크 등 유사한 체계를 운영한다. 법적 의무가 아닌 자율 약속이어서 외부 검증과 투명성이 과제로 지적된다.

예시 외부 파운데이션 모델 공급사 평가 시 위험 임계 평가와 안전 정책 공개 여부를 점검 항목에 넣는다.

연관 시스템 카드, AI 안전연구소, 정렬, 평가, 파운데이션 모델

출처 Anthropic · Anthropic

책임 있는 AI

Responsible AI

평가·안전·규제 · **입문**

입문 AI를 공정하고 안전하며 투명하게 만들고 쓰자는 원칙과 실천 방법이다.

심화 공정성, 투명성·설명가능성, 프라이버시, 안전성·견고성, 책임성, 인간 감독 등의 원칙을 개발 수명주기 전반의 절차로 구현하는 것을 말한다. 원칙 선언에 그치지 않고 위험 평가, 모델 카드, 편향 점검, 레드티밍, 사고 대응 체계 같은 구체적 통제로 연결해야 실효성이 있다.

예시 AI 도입 심의위원회가 신규 과제마다 공정성·개인정보·설명가능성 체크리스트를 검토한다.

연관 AI 거버넌스, 공정성, 설명 가능한 AI, 모델 카드, AI 위험관리 프레임워크

출처 Microsoft · Google · IBM

처리량

Throughput

인프라·배포·LLMOps · **실무**

입문 일정 시간 동안 시스템이 처리할 수 있는 요청이나 토큰의 양이다.

심화 초당 생성 토큰 수(tokens/s)나 초당 요청 수(RPS)로 측정한다. 연속 배칭(continuous batching), PagedAttention, 양자화, 텐서 병렬화로 높일 수 있으며 지연과 상충한다. GPU 대당 처리량은 토큰당 원가를 결정하므로 용량 산정의 기준이 된다.

예시 야간 일괄 문서 요약은 지연보다 처리량을 우선해 배치 크기를 크게 잡았다.

연관 지연 시간, 배치 추론, vLLM, 토큰 비용

출처 Wikipedia · NVIDIA / 논문 Yu et al. 2022 · Agrawal et al. 2024

첫 토큰 지연

TTFT · Time To First Token

인프라·배포·LLMOps · **심화**

입문 질문을 보낸 뒤 AI가 첫 글자를 내놓기까지 걸리는 시간이다. 사용자가 체감하는 반응 속도를 좌우한다.

심화 입력 전체를 처리하는 프리필(prefill) 단계 시간과 큐 대기 시간이 합쳐진 값으로 입력 길이에 비례해 늘어난다. 스트리밍 응답에서는 TTFT가 짧으면 전체 생성 시간이 길어도 빠르게 느껴진다. 프롬프트 캐싱, 청크 프리필, 입력 축소로 줄인다.

예시 긴 약관을 통째로 넣던 방식을 RAG로 바꿔 TTFT를 수 초에서 1초 미만으로 줄였다.

연관 지연 시간, 프롬프트 캐싱, KV 캐시, 추론 서빙

출처 NVIDIA / 논문 Zhong et al. 2024

청크 오버랩

Chunk Overlap

RAG·검색·데이터 · **심화**

입문 문서를 조각낼 때 앞 조각의 끝부분을 다음 조각 앞에 조금 겹쳐 넣어 내용이 끊기지 않게 하는 것이다.

심화 인접 청크 간에 일정 토큰(보통 청크 길이의 10~20%)을 중복시켜 경계에서 문맥이 잘리는 문제를 완화하는 설정이다. 중복만큼 저장·임베딩 비용이 늘고 같은 내용이 중복 검색될 수 있다. 구조 기반 청킹에서는 오버랩 대신 상위 제목을 각 청크에 붙이는 방식이 더 효과적인 경우가 많다.

예시 500토큰 청크에 50토큰 오버랩을 주어 조항이 청크 경계에서 끊겨도 앞뒤 문맥이 남게 한다.

연관 청킹, 임베딩, 맥락 검색

출처 Microsoft · LangChain

청킹

Chunking

RAG·검색·데이터 · **실무**

입문 긴 문서를 검색하기 좋은 크기의 조각으로 나누는 작업이다. 두꺼운 책을 주제별 메모 카드로 나누는 것과 같다.

심화 문서를 임베딩·검색 단위인 청크로 분할하는 과정이다. 고정 길이, 문장·문단 단위, 제목 구조 기반, 의미 기반(semantic chunking) 등 방식이 있으며, 청크가 너무 작으면 문맥이 끊기고 너무 크면 검색 정밀도가 떨어진다. 표·조항 번호 같은 문서 구조를 보존하고 제목·출처를 메타데이터로 붙이는 것이 실무 품질을 좌우한다.

예시 규정집을 '장-조-항' 구조에 맞춰 조 단위로 자르고 각 청크에 규정명과 개정일을 메타데이터로 붙인다.

연관 청크 오버랩, 문서 파싱, 임베딩, 검색 증강 생성, 메타데이터 필터링

출처 Pinecone · Microsoft

체크포인트

Checkpoint

학습·튜닝·정렬 · **실무**

입문 학습 도중 특정 시점의 모델 상태를 저장해 둔 파일이다. 게임의 세이브 포인트와 같다.

심화 가중치와 함께 옵티마이저 상태, 학습률 스케줄, 데이터 위치 등을 저장해 장애 시 학습을 재개하거나 여러 시점 모델을 비교·선택할 수 있게 한다. 대규모 학습에서는 하드웨어 장애가 잦아 비동기·분산 체크포인팅이 중요하다. 배포용 체크포인트는 보통 가중치만 남겨 용량을 줄인다.

연관 분산 학습, 모델 병합, 에폭, 파인튜닝

출처 Hugging Face · PyTorch · Wikipedia

총소유비용

TCO · Total Cost of Ownership

AX·비즈니스 적용 · **실무**

입문 구입 가격뿐 아니라 운영, 유지보수, 인력, 교체까지 전체 기간 동안 드는 모든 비용의 합이다.

심화 온프레미스 LLM은 GPU 서버, 전산실 전력·상면, 소프트웨어, 운영 인력, 교체 주기를, 클라우드 API는 사용량 증가에 따른 토큰 비용과 연계·보안 비용을 포함해 3~5년 기준으로 비교한다. 사용량이 일정 이상이면 자체 구축이 유리해지는 손익분기점이 생기므로 사용량 예측이 중요하다.

예시 예상 월 토큰 사용량을 기준으로 클라우드 API와 온프레미스 GPU 구축의 5년 TCO를 비교했다.

연관 AI 비용, 자체 구축 대 구매, 온프레미스, 데이터센터 전력, 투자 대비 효과

출처 Wikipedia

최대 토큰 수

Max Tokens

LLM·언어모델 · **입문**

입문 AI가 한 번에 만들어 낼 답변 길이의 상한이다. 너무 작게 잡으면 답이 중간에 끊긴다.

심화 생성할 출력 토큰 수의 상한을 지정하는 API 파라미터로 비용과 지연을 통제한다. 입력 토큰과 합쳐 컨텍스트 윈도를 넘을 수 없다. 추론 모델은 사고 토큰도 출력 예산에 포함되는 경우가 많아 여유 있게 잡아야 하며, 응답의 종료 사유(stop reason)로 잘림 여부를 확인한다.

예시 보고서 요약 배치 작업에서 max tokens를 제한해 건당 비용 상한을 관리한다.

연관 토큰, 컨텍스트 윈도, 스톱 시퀀스, AI 비용

출처 Anthropic · Hugging Face

추론

Inference

AI 기초·머신러닝 · **입문**

입문 다 배운 AI에게 실제로 질문을 던져 답을 받는 단계다. 학습이 공부라면 추론은 시험 보기다.

심화 학습된 모델에 새 입력을 넣어 예측 결과를 계산하는 과정이다. 파라미터는 고정되고 순전파만 수행한다. 운영 비용의 대부분을 차지하므로 지연시간, 처리량, 양자화, 배치 처리 등 서빙 최적화가 중요하다. LLM 분야의 '추론(reasoning)'과는 다른 개념이다.

예시 이상거래 탐지 모델이 카드 승인 요청마다 수십 밀리초 내에 위험 점수를 추론한다.

연관 모델, 추론 서빙, 지연 시간, 처리량, GPU

출처 IBM

추론 모델

Reasoning Model

프롬프트·추론 · **실무**

입문 답하기 전에 스스로 오래 생각하도록 훈련된 AI 모델이다. 어려운 수학·코딩·분석 문제에 강하다.

심화 강화학습 등으로 긴 내부 사고 과정(추론 토큰)을 생성한 뒤 답하도록 훈련된 LLM이다. OpenAI o 시리즈, Claude의 확장 사고, Gemini Thinking, DeepSeek-R1 등이 대표적이며, 최근에는 하나의 모델이 추론 on/off나 노력 수준을 조절하는 하이브리드 형태가 일반적이다. 정확도가 높은 대신 지연과 토큰 비용이 늘어 작업 난이도에 맞게 선택해야 한다.

예시 복잡한 IFRS 회계처리 판단이나 대형 SQL 리팩터링에는 추론 모델을, 단순 요약에는 일반 모델을 쓴다.

연관 사고의 연쇄, 테스트 타임 컴퓨트, 확장 사고, 사고 예산, 강화학습

출처 OpenAI · Anthropic · Wikipedia / 논문 DeepSeek-AI 2025

추론 서빙

Inference Serving

인프라·배포·LLMOps · **실무**

입문 학습된 AI 모델을 서버에 띄워 여러 사용자의 요청에 실시간으로 답하게 하는 일이다.

심화 모델 로딩, 요청 배칭, KV 캐시 관리, 스트리밍 응답, 오토스케일링을 담당하는 서빙 계층을 구성한다. 대표 엔진으로 vLLM, TensorRT-LLM, TGI, SGLang 등이 있으며 OpenAI 호환 API를 제공하는 경우가 많다. 핵심 지표는 TTFT, 토큰당 지연, 처리량, GPU 사용률이다.

예시 오픈 웨이트 모델을 vLLM으로 서빙하고 사내 업무 시스템은 OpenAI 호환 API로 호출하게 했다.

연관 vLLM, TensorRT, KV 캐시, 첫 토큰 지연, 처리량

출처 NVIDIA · vLLM / 논문 Yu et al. 2022 · Kwon et al. 2023 · Zhong et al. 2024

추천 시스템

Recommender System

AI 기초·머신러닝 · **실무**

입문 사용자의 과거 행동을 보고 좋아할 만한 상품이나 콘텐츠를 골라 보여주는 시스템이다.

심화 협업 필터링(사용자-아이템 상호작용 기반), 콘텐츠 기반 필터링(아이템 속성 기반), 이를 결합한 하이브리드 방식이 있다. 행렬 분해, 임베딩 기반 two-tower 모델, 순차 추천 모델이 널리 쓰이며 후보 생성→랭킹의 다단계 구조가 일반적이다. 콜드 스타트와 필터 버블이 대표적 과제다.

예시 고객의 거래·상품 보유 이력으로 다음에 가입할 가능성이 높은 금융상품을 추천한다.

연관 임베딩, 머신러닝, 의미 검색, 재순위화

출처 IBM · Wikipedia / 논문 Koren et al. 2009 · Covington et al. 2016

추측 디코딩

Speculative Decoding

LLM·언어모델 · **심화**

입문 작고 빠른 모델이 다음 몇 단어를 먼저 추측하고 큰 모델이 한꺼번에 검사해 맞으면 그대로 채택하는 가속 기법이다.

심화 드래프트 모델(또는 EAGLE류 경량 헤드, 다중 토큰 예측 헤드)이 k개 토큰을 제안하면 타깃 모델이 한 번의 순전파로 병렬 검증하고, 수락·거절 샘플링으로 원래 분포를 보존한다. 출력 품질 손실 없이 생성 속도를 대략 2~3배 높일 수 있으며 vLLM 등 주요 서빙 엔진이 지원한다. 수락률이 낮은 작업이나 큰 배치에서는 이득이 줄어든다.

연관 자기회귀 모델, 추론 서빙, 지연 시간, vLLM, 지식 증류

출처 vLLM / 논문 Leviathan et al. 2023 · Chen et al. 2023 · Li et al. 2024

출력 형식 지정

Output Formatting

프롬프트·추론 · **입문**

입문 답을 표로, 세 줄 요약으로, 글머리표로 달라는 식으로 원하는 모양을 명확히 정해 주는 것이다.

심화 출력의 형식(표, 마크다운, JSON, CSV), 길이, 섹션 구성, 언어, 톤을 프롬프트에서 명시하는 기법이다. 원하는 형식의 예시를 보여 주거나 응답 시작 부분을 미리 채우면 준수율이 높아진다. 기계 처리가 목적이면 구조화된 출력 기능을 쓰는 것이 더 안정적이다.

예시 '결과를 |지점|전월잔액|당월잔액|증감률| 마크다운 표로만 출력하라'고 지정한다.

연관 구조화된 출력, 응답 미리 채우기, 프롬프트 템플릿

출처 Anthropic · OpenAI

ㅋ

캐시 증강 생성

CAG · Cache-Augmented Generation

RAG·검색·데이터 · **심화**

입문 자주 쓰는 자료를 매번 검색하지 않고 AI의 기억 공간(캐시)에 미리 올려 두고 바로 쓰는 방식이다.

심화 비교적 작고 안정적인 지식 전체를 컨텍스트에 미리 넣어 KV 캐시나 API 프롬프트 캐싱으로 재사용하고, 검색 단계 없이 답하는 방식이다. 검색 오류와 지연을 없애지만 지식 크기가 컨텍스트 창에 제한되고 문서가 바뀌면 캐시를 갱신해야 한다. 변경이 적은 FAQ·매뉴얼 같은 소규모 지식에 적합하다.

예시 200쪽 분량 콜센터 응대 매뉴얼을 캐시에 올려 두고 모든 상담 질의에 재사용한다.

연관 KV 캐시, 롱컨텍스트 대 RAG, 검색 증강 생성, 컨텍스트 윈도

출처 Anthropic / 논문 Chan et al. 2024

커넥터

Connector

AI 에이전트·도구 · **실무**

입문 AI 서비스를 메일, 일정, 문서 저장소, 사내 시스템 같은 다른 서비스와 이어 주는 연결 장치다.

심화 AI 애플리케이션이 외부 SaaS·사내 시스템의 데이터에 접근하거나 작업을 수행하도록 인증과 API 호출을 감싼 통합 모듈이다. 최근에는 MCP 서버 형태로 구현되는 경우가 많으며, 사용자 단위 OAuth 인증으로 해당 사용자의 접근 권한 범위 안에서 동작한다. 연결 범위와 데이터 반출 정책을 관리자 수준에서 통제하는 것이 중요하다.

예시 AI 어시스턴트에 사내 문서관리시스템 커넥터를 연결해 결재 문서를 검색·요약한다.

연관 모델 컨텍스트 프로토콜, MCP 서버, 에이전트 권한 관리, 데이터 파이프라인

출처 Anthropic · Model Context Protocol

커리큘럼 학습

Curriculum Learning

학습·튜닝·정렬 · **심화**

입문 사람이 쉬운 문제부터 어려운 문제 순서로 배우듯, 학습 데이터의 순서와 난이도를 조절해 가르치는 방법이다.

심화 학습 진행에 따라 데이터 난이도나 구성 비율을 단계적으로 바꾼다. LLM 사전학습 후반에 고품질·수학·코드 데이터 비중을 높이는 어닐링, 강화학습에서 모델 수준에 맞는 난이도 문제를 골라 쓰는 방식이 대표적이다. 효과는 작업과 설정에 따라 편차가 크다.

연관 사전학습, 사전학습 데이터 정제, 검증가능 보상 기반 강화학습, 학습 데이터

출처 Wikipedia

컨텍스트 엔지니어링

Context Engineering

프롬프트·추론 · **실무**

입문 AI가 일을 잘하도록 지시문뿐 아니라 참고 자료, 대화 기록, 도구 정보 등 'AI가 보는 모든 정보'를 골라 담고 정리하는 기술이다.

심화 한정된 컨텍스트 창에 무엇을, 어떤 순서와 형식으로 넣을지 설계하는 분야로, 프롬프트 문구 작성을 넘어 검색 결과, 메모리, 도구 정의와 결과, 대화 이력 압축, 하위 에이전트 결과 요약까지 다룬다. 에이전트가 긴 작업을 수행할수록 불필요한 정보가 쌓여 성능이 떨어지므로(context rot) 선별·압축·외부 저장이 핵심이다. 2025년 이후 에이전트 개발의 핵심 역량으로 자리 잡았다.

예시 사내 에이전트가 테이블 정의서 전체 대신 질문과 관련된 테이블 메타데이터만 검색해 컨텍스트에 넣도록 설계한다.

연관 프롬프트 엔지니어링, 컨텍스트 윈도, 검색 증강 생성, 에이전트 메모리, 문맥 압축

출처 Anthropic · Wikipedia

컨텍스트 윈도

Context Window

LLM·언어모델 · **입문**

입문 AI가 한 번에 기억하고 참고할 수 있는 글의 최대 분량이다. 넘치면 앞부분을 잊거나 입력이 거부된다.

심화 한 번의 추론에서 입력과 출력을 합해 처리 가능한 최대 토큰 수다. 셀프 어텐션 비용과 KV 캐시 메모리가 길이에 따라 증가해 길이를 늘리기 어렵다. 공칭 길이와 실제로 정보를 잘 활용하는 유효 길이는 다를 수 있다.

예시 수백 쪽 여신 규정을 통째로 넣기 어려우면 RAG로 관련 조항만 골라 컨텍스트에 넣는다.

연관 토큰, 롱 컨텍스트, KV 캐시, 검색 증강 생성, 중간 정보 손실

출처 IBM · Anthropic

컨트롤넷

ControlNet

생성 AI·멀티모달 · **심화**

입문 윤곽선, 사람 자세, 깊이 정보 같은 밑그림을 주면 그 구도대로 이미지를 생성하게 하는 제어 기술이다.

심화 사전 학습된 확산 모델의 가중치는 고정하고, 엣지 맵·포즈·깊이 맵 등 조건 입력을 처리하는 복제 분기를 추가 학습해 생성 과정에 구조적 제약을 주입하는 2023년 제안 방법이다. 텍스트만으로는 어려운 정밀한 구도·형태 제어가 가능해 디자인 시안 작업에 유용하다.

연관 확산 모델, 이미지-이미지 변환, 텍스트-이미지 생성, 파인튜닝

출처 Hugging Face / 논문 Zhang et al. 2023

컴퓨터 사용

Computer Use

AI 에이전트·도구 · **실무**

입문 AI가 사람처럼 화면을 보고 마우스를 움직이고 키보드를 쳐서 컴퓨터 프로그램을 직접 조작하는 기능이다.

심화 VLM이 스크린샷을 입력받아 화면 요소를 인식하고 클릭 좌표, 키 입력, 스크롤 같은 행동을 출력하면, 실행 환경이 이를 수행하고 새 스크린샷을 돌려주는 루프로 동작한다. API가 없는 레거시 시스템도 자동화할 수 있지만 API 호출보다 느리고 오류율이 높으며, 화면 속 텍스트를 통한 프롬프트 인젝션 위험이 있어 격리된 환경과 사람의 승인이 권장된다.

예시 API가 없는 구형 내부 업무 화면에서 조회 결과를 옮겨 적는 반복 작업을 격리된 가상 데스크톱에서 자동화한다.

연관 브라우저 에이전트, 화면 이해, 에이전트 샌드박스, 시각 언어 모델, 워크플로 자동화

출처 Anthropic · Anthropic / 논문 Xie et al. 2024

코딩 에이전트

Coding Agent

AI 에이전트·도구 · **실무**

입문 요구사항을 말하면 코드를 읽고, 고치고, 실행하고, 테스트까지 스스로 해 보는 AI 개발 도우미다.

심화 저장소 탐색, 파일 편집, 셸 명령·테스트 실행, 버전 관리 도구 사용을 도구로 갖춘 에이전트로, 터미널·IDE·클라우드 환경에서 동작한다. 테스트 결과를 피드백으로 받아 수정을 반복하는 루프가 성능의 핵심이며, 프로젝트 규칙을 담은 지시 파일(예: AGENTS.md)로 맥락을 보강한다. 생성 코드의 보안 검토, 실행 권한 제한, 사람의 코드 리뷰가 여전히 필요하다.

예시 ETL 스크립트의 오류 로그를 주면 코딩 에이전트가 원인 SQL을 찾아 수정안과 테스트 쿼리를 제시한다.

연관 AI 에이전트, 에이전트 지시 파일, 에이전트 샌드박스, 코파일럿

출처 Anthropic · AGENTS.md / 논문 Jimenez et al. 2023 · Yang et al. 2024

코사인 유사도

Cosine Similarity

RAG·검색·데이터 · **심화**

입문 두 벡터가 같은 방향을 가리키는 정도로 의미가 얼마나 비슷한지 재는 방법이다. 1에 가까울수록 비슷하다.

심화 두 벡터 내적을 각 벡터 크기의 곱으로 나눈 값으로, -1~1 범위에서 방향의 유사성을 측정한다. 크기 차이를 무시하므로 문서 길이에 덜 민감하며, 벡터를 정규화하면 내적과 동일해 계산이 빠르다. 임베딩 모델이 학습된 거리 척도(코사인, 내적, 유클리드)와 일치시키는 것이 중요하다.

예시 질문 벡터와 각 약관 조항 벡터의 코사인 유사도를 계산해 상위 조항을 고른다.

연관 임베딩, 의미 검색, 벡터 데이터베이스, 근사 최근접 이웃 검색

출처 Wikipedia

코파일럿

Copilot

AX·비즈니스 적용 · **입문**

입문 사람이 일하는 옆에서 초안 작성, 요약, 추천 등을 도와주는 AI 보조 도구다. 최종 판단은 사람이 한다.

심화 기존 업무 도구(오피스, IDE, 업무 시스템)에 내장돼 문맥을 받아 제안을 생성하는 형태다. 사람이 결과를 검토·수정하는 human-in-the-loop 구조라 도입 위험이 낮아 AX 초기에 많이 쓰인다. 자율적으로 작업을 끝까지 수행하는 에이전트와 대비된다.

예시 상담사 화면에 상담 요약과 추천 답변을 띄워 주는 상담 코파일럿을 도입했다.

연관 AI 에이전트, 휴먼 인 더 루프, 코딩 에이전트, AI 도입

출처 GitHub Docs · Wikipedia / 논문 Chen et al. 2021 · Peng et al. 2023

콘텐츠 출처 증명

C2PA · Content Provenance (C2PA)

생성 AI·멀티모달 · **심화**

입문 사진이나 영상이 누가, 어떤 도구로 만들고 고쳤는지 이력을 파일에 함께 담아 확인할 수 있게 하는 기술이다.

심화 C2PA(Coalition for Content Provenance and Authenticity) 표준은 콘텐츠의 생성·편집 이력을 암호학적으로 서명된 메타데이터(Content Credentials)로 첨부해 위변조 여부를 검증할 수 있게 한다. 눈에 보이지 않는 워터마크와 상호 보완적으로 쓰이며, 메타데이터가 제거되면 확인이 불가능하다는 한계가 있다. AI 생성물 표시 의무 이행 수단으로 주목받는다.

예시 AI로 제작한 홍보 이미지에 출처 메타데이터를 첨부해 AI 생성물임을 표시한다.

연관 워터마킹, 딥페이크, 생성물 저작권, 책임 있는 AI

출처 C2PA · C2PA · Content Authenticity Initiative

콘텐츠 필터

Content Filter

평가·안전·규제 · **실무**

입문 폭력·혐오·성적 내용처럼 유해한 입력이나 출력을 자동으로 걸러내는 장치다.

심화 유해성 카테고리별 분류 모델이 입력·출력에 점수를 매기고, 임계값에 따라 차단·경고·로그만 남기기 등으로 처리한다. 클라우드 AI 서비스는 기본 필터를 제공하고, 기업은 업무 특성에 맞는 추가 카테고리(투자 권유, 경쟁사 언급 등)를 붙인다. 스트리밍 출력에서는 생성 도중 판정해야 하므로 지연과 정확도 사이 설계가 필요하다.

예시 투자 상담 챗봇에 특정 종목 매수 권유 표현을 탐지하는 커스텀 필터를 추가한다.

연관 가드레일, 탈옥 대응, PII 마스킹, 책임 있는 AI, 지연 시간

출처 Microsoft Learn · OpenAI / 논문 Inan et al. 2023

콜드 스타트

Cold Start

인프라·배포·LLMOps · **심화**

입문 멈춰 있던 서버나 모델을 처음 깨울 때 준비 시간 때문에 첫 응답이 크게 늦어지는 현상이다.

심화 수십 GB 가중치를 스토리지에서 GPU 메모리로 올리고 엔진을 초기화하는 데 수십 초~수 분이 걸린다. 0까지 축소하는 오토스케일링이나 서버리스 GPU에서 두드러지며, 최소 인스턴스 유지, 가중치 로컬 캐시, 빠른 스토리지, 이미지 사전 적재로 완화한다.

예시 업무 시작 시각인 오전 9시 전에 모델 서버를 미리 기동해 콜드 스타트로 인한 지연을 없앴다.

연관 지연 시간, 쿠버네티스, 추론 서빙, 첫 토큰 지연

쿠버네티스

K8s · Kubernetes

인프라·배포·LLMOps · **심화**

입문 여러 서버에 흩어진 컨테이너 앱을 자동으로 배치·확장·복구해 주는 운영 플랫폼이다.

심화 모델 서버와 애플리케이션을 컨테이너 이미지로 패키징하고, 쿠버네티스가 GPU 노드 스케줄링, 오토스케일링, 롤링 배포, 장애 복구를 담당한다. GPU 공유(MIG, 타임슬라이싱), 대형 모델 이미지 로딩 시간, 폐쇄망 내부 레지스트리 운영이 LLM 환경의 주요 과제다.

예시 사내 프라이빗 클라우드의 쿠버네티스 클러스터에 GPU 노드풀을 추가해 LLM 서빙 파드를 배포했다.

연관 추론 서빙, 프라이빗 클라우드, 콜드 스타트, MLOps

출처 Kubernetes · Kubernetes

쿼리 재작성

Query Rewriting

RAG·검색·데이터 · **실무**

입문 사용자의 짧거나 모호한 질문을 검색이 잘 되는 형태로 AI가 다시 써 주는 단계다.

심화 검색 전에 LLM으로 질의를 명확화·확장·분해하는 기법이다. 대화 맥락의 대명사 해소('그거' → 구체 대상), 동의어·약어 확장, 여러 하위 질의 생성(multi-query) 등이 포함된다. 검색 재현율을 높이지만 LLM 호출이 추가되어 지연이 늘어난다.

예시 '그 상품 금리 얼마야?'를 이전 대화 맥락으로 '○○정기예금 12개월 기본금리'로 바꿔 검색한다.

연관 가상 문서 임베딩, 멀티홉 검색, 검색(리트리벌), 스텝백 프롬프팅

출처 Microsoft / 논문 Ma et al. 2023

큐로라

QLoRA · Quantized Low-Rank Adaptation

학습·튜닝·정렬 · **심화**

입문 모델을 4비트로 압축해 메모리를 줄인 상태에서 LoRA 학습을 해, 적은 GPU로 큰 모델을 파인튜닝하는 기법이다.

심화 기반 모델 가중치를 4비트 NF4 형식으로 양자화해 고정하고, 역전파는 16비트 LoRA 어댑터에만 흘린다. 이중 양자화와 페이지드 옵티마이저로 메모리를 더 줄여 수십 B급 모델도 단일 GPU에서 학습할 수 있다. 학습 속도는 LoRA보다 느리고 미세한 품질 차이가 있을 수 있다.

예시 사내 단일 GPU 서버로 70B급 모델을 업무 데이터에 QLoRA 파인튜닝한다.

연관 로라, 양자화, 매개변수 효율적 미세조정, GPU

출처 Hugging Face · Hugging Face / 논문 Dettmers et al. 2023

클래스 불균형

Class Imbalance

AI 기초·머신러닝 · **실무**

입문 한쪽 정답이 압도적으로 많은 데이터다. 정상 거래 1만 건에 사기 1건이면 AI가 사기를 배우기 어렵다.

심화 클래스 간 표본 수 차이가 커서 모델이 다수 클래스로 치우치는 문제다. 소수 클래스 오버샘플링(SMOTE 등), 다수 클래스 언더샘플링, 클래스 가중치·초점 손실, 임계값 조정으로 대응한다. 평가에는 정확도 대신 재현율, PR-AUC를 사용한다.

예시 부도율이 1% 미만인 우량 고객군 모델에서 클래스 가중치를 조정해 부도 탐지 재현율을 확보한다.

연관 정확도, 정밀도와 재현율, 이상 탐지, 교차검증

출처 Google for Developers / 논문 Chawla et al. 2002 · Lin et al. 2017

클립(대조 언어-이미지 사전학습)

CLIP · Contrastive Language-Image Pre-training

생성 AI·멀티모달 · **심화**

입문 사진과 그 사진의 설명 글을 짝지어 배우게 해서, 그림과 글을 같은 기준으로 비교할 수 있게 만든 모델이다.

심화 2021년 공개된 방식으로, 이미지 인코더와 텍스트 인코더를 대규모 이미지-캡션 쌍에 대해 대조 학습시켜 짝이 맞는 쌍의 임베딩은 가깝게, 아닌 쌍은 멀게 만든다. 별도 학습 없는 이미지 분류(제로샷), 이미지-텍스트 검색, 생성 모델의 텍스트 조건화, VLM의 이미지 인코더 등에 폭넓게 쓰인다.

연관 멀티모달 임베딩, 텍스트 인코더, 시각 언어 모델, 제로샷

출처 OpenAI · Hugging Face / 논문 Radford et al. 2021

E

탈옥

Jailbreak

평가·안전·규제 · **실무**

입문 AI에 걸린 안전 규칙을 말장난이나 역할극 등으로 우회해 금지된 답을 받아내는 시도다.

심화 역할극 설정, 가상 시나리오, 인코딩·외국어 우회, 여러 턴에 걸친 점진적 유도, 대량 예시를 넣는 다회 샷 공격 등 다양한 기법이 있다. 프롬프트 인젝션이 애플리케이션의 지시 체계를 탈취하는 것이라면, 탈옥은 모델 자체의 안전 정렬을 무력화하는 데 초점이 있다. 대응은 안전 정렬 학습, 입력·출력 분류기, 대화 단위 모니터링, 레드티밍 결과의 지속적 반영으로 한다.

예시 금융 상담 봇이 '소설 속 사기꾼 대사'를 빙자한 보이스피싱 스크립트 요청을 거절하도록 탈옥 테스트 세트를 운영한다.

연관 탈옥 대응, 프롬프트 인젝션, 레드티밍, 정렬, 가드레일

출처 Anthropic / 논문 Wei et al. 2023 · Zou et al. 2023

탈옥 대응

Jailbreak Defense

평가·안전·규제 · **심화**

입문 AI의 안전 규칙을 우회하려는 시도를 막고, 막지 못했을 때 빨리 찾아내는 방어 체계다.

심화 모델 수준의 안전 정렬 강화, 입력·출력 분류기, 대화 전체 흐름 모니터링, 반복 시도 사용자 탐지와 속도 제한을 다층으로 결합한다. 새 공격 기법이 계속 나오므로 레드티밍과 운영 로그 분석으로 발견한 사례를 분류기와 회귀 테스트에 지속 반영하는 운영 체계가 중요하다. 방어를 강화할수록 정상 요청 거부가 늘 수 있어 둘 사이 균형을 측정해야 한다.

예시 탈옥 시도로 분류된 대화가 일정 횟수를 넘으면 세션을 차단하고 보안팀에 알린다.

연관 탈옥, 가드레일, 콘텐츠 필터, 레드티밍, 회귀 테스트

출처 Anthropic / 논문 Sharma et al. 2025 · Robey et al. 2023

테스트 타임 컴퓨트

Test-time Compute

프롬프트·추론 · **심화**

입문 AI가 답을 낼 때 더 많이 생각하게(계산을 더 쓰게) 해서 정답률을 높이는 접근이다.

심화 학습이 아닌 추론 시점에 연산량을 늘려 성능을 높이는 방법의 총칭이다. 긴 추론 토큰 생성, 다중 샘플링과 투표, 검증 모델을 이용한 탐색 등이 포함된다. 모델 크기를 키우는 학습 스케일링과 별개의 성능 축으로 주목받으며, 비용·지연과 정확도의 트레이드오프를 작업별로 조절할 수 있다.

예시 월말 결산 검증 같은 중요 작업에는 사고 예산을 크게 주고, 실시간 상담에는 작게 준다.

연관 추론 모델, 사고 예산, 자기일관성, 스케일링 법칙, 추론

출처 Wikipedia / 논문 Snell et al. 2024 · Wang et al. 2022

텍스트 인코더

Text Encoder

생성 AI·멀티모달 · **심화**

입문 이미지 생성 AI가 프롬프트의 뜻을 이해할 수 있도록 글을 숫자 벡터로 바꿔 주는 부품이다.

심화 CLIP 텍스트 인코더, T5 계열, 또는 LLM을 사용해 프롬프트를 임베딩 시퀀스로 변환하고, 생성 모델이 크로스 어텐션 등으로 이를 조건으로 사용한다. 텍스트 인코더의 언어 이해력이 복잡한 지시, 공간 관계, 다국어 프롬프트 충실도를 크게 좌우하므로 최근에는 대형 언어 모델을 인코더로 쓰는 추세다.

연관 클립(대조 언어-이미지 사전학습), 텍스트-이미지 생성, 임베딩, 확산 모델

출처 Hugging Face / 논문 Radford et al. 2021 · Raffel et al. 2019 · Saharia et al. 2022

텍스트-이미지 생성

T2I · Text-to-Image Generation

생성 AI·멀티모달 · **입문**

입문 글로 설명을 쓰면 그 내용에 맞는 그림을 만들어 주는 AI 기술이다.

심화 텍스트 인코더로 프롬프트를 임베딩하고, 이를 조건으로 확산 모델·플로우 매칭·자기회귀 모델이 이미지를 생성한다. 프롬프트 충실도, 이미지 내 글자 렌더링, 인물·손 표현 등이 품질 기준이며, 생성물의 저작권과 출처 표시 문제가 따른다.

예시 사내 교육 자료에 쓸 삽화를 설명 문장으로 생성한다.

연관 확산 모델, 텍스트 인코더, 네거티브 프롬프트, 생성물 저작권

출처 Wikipedia · Hugging Face / 논문 Ramesh et al. 2021 · Rombach et al. 2021 · Saharia et al. 2022

텍스트-투-SQL

NL2SQL · Text-to-SQL

RAG·검색·데이터 · **실무**

입문 '지난달 지점별 대출 잔액 보여줘'처럼 말로 물으면 AI가 데이터베이스 조회문(SQL)을 만들어 실행해 주는 기술이다.

심화 자연어 질의를 스키마 정보(테이블·컬럼 정의, 코드값, 조인 관계)를 바탕으로 SQL로 변환하는 기법이다. 실무 정확도는 모델보다 메타데이터 품질에 좌우되므로 테이블·컬럼 한글명, 업무 용어 사전, 검증된 예시 쿼리를 RAG로 공급하는 것이 핵심이다. 읽기 전용 계정, 실행 전 검증, 비용 큰 쿼리 차단, 결과 검산 등 안전장치가 필요하다.

예시 '2026년 9월말 기준 영업점별 연체율 상위 10곳'을 물으면 DW의 일별 여신잔액 마트와 영업점 코드 테이블을 조인하는 Oracle SQL을 생성해 실행한다.

연관 시맨틱 레이어, 메타데이터 관리, 데이터 카탈로그, 에이전틱 RAG, 정형 데이터

논문 Yu et al. 2018

텐서

Tensor

딥러닝·신경망 · **실무**

입문 숫자를 여러 차원으로 담는 상자다. 숫자 하나, 줄, 표, 그리고 그 이상 차원의 묶음을 모두 텐서라 부른다.

심화 다차원 배열로, 0차원 스칼라·1차원 벡터·2차원 행렬을 일반화한 것이다. 딥러닝 프레임워크의 기본 자료구조로 데이터, 가중치, 기울기가 모두 텐서로 표현된다. shape(차원 크기), dtype(FP32·BF16·INT8 등), 장치(CPU/GPU) 속성이 성능과 메모리를 좌우한다.

연관 GPU, 양자화, 파라미터, 신경망

출처 TensorFlow · Wikipedia

텐서 병렬화

TP · Tensor Parallelism

학습·튜닝·정렬 · **심화**

입문 한 층 안의 큰 행렬 계산을 여러 GPU가 나눠 맡아 동시에 처리하는 방식이다.

심화 어텐션·FFN 가중치 행렬을 행·열 방향으로 분할해 각 장치가 부분 행렬곱을 수행하고 층마다 집합 통신으로 결과를 합친다. 통신이 잦아 보통 NVLink 등 고대역폭으로 연결된 단일 노드 내에서 사용한다. 학습뿐 아니라 대형 모델 추론 서빙에도 널리 쓰인다.

연관 분산 학습, 데이터 병렬화, 파이프라인 병렬화, 추론 서빙

출처 NVIDIA · Hugging Face / 논문 Shoeybi et al. 2019

토크나이저

Tokenizer

LLM·언어모델 · **실무**

입문 문장을 AI가 읽을 수 있는 토큰 조각으로 잘라 숫자로 바꾸는 도구다.

심화 BPE, WordPiece, Unigram(SentencePiece) 등의 알고리즘으로 학습 말뭉치에서 어휘집을 만들고, 텍스트를 토큰 ID로 인코딩·디코딩한다. 어휘집 크기와 구성 언어 비율이 언어별 토큰 효율과 모델 성능에 직접 영향을 준다. 모델마다 토크나이저가 달라 같은 문장도 토큰 수가 다르다.

예시 한국어 업무 문서를 여러 모델의 토크나이저로 돌려 토큰 수를 비교해 비용을 산정한다.

연관 토큰, 바이트 페어 인코딩, 한국어 토큰 효율, 다국어 모델

출처 Hugging Face · Hugging Face / 논문 Sennrich et al. 2016 · Kudo and Richardson 2018

토큰

Token

LLM·언어모델 · **입문**

입문 AI가 글을 처리하는 최소 단위 조각이다. 단어 하나가 여러 토큰으로 쪼개지기도 하며, 이용 요금과 입력 한도도 토큰 수로 계산한다.

심화 토크나이저가 텍스트를 서브워드 단위로 분할해 정수 ID로 바꾼 것이 토큰이며, 모델은 이 ID 시퀀스를 임베딩해 처리한다. 영어는 대략 단어당 1~1.5토큰이지만 한국어는 같은 의미를 표현하는 데 더 많은 토큰이 들 수 있다. 컨텍스트 윈도, 과금, 지연시간이 모두 토큰 수에 비례한다.

예시 월간 API 비용을 추정할 때 문서당 평균 입력·출력 토큰 수를 먼저 측정한다.

연관 토크나이저, 컨텍스트 윈도, 한국어 토큰 효율, AI 비용, 임베딩

출처 Microsoft Learn · OpenAI / 논문 Sennrich et al. 2016

토큰 비용

Token Cost

인프라·배포·LLMOps · **실무**

입문 LLM 사용료를 계산하는 기준이다. 입력하고 출력한 글자 조각(토큰) 수에 따라 돈을 낸다.

심화 상용 API는 보통 100만 토큰당 가격을 입력·출력별로 매기며 출력 단가가 더 높다. 한국어는 토크나이저에 따라 같은 내용도 영어보다 토큰이 더 나올 수 있다. 긴 시스템 프롬프트, RAG 문맥, 추론 모델의 사고 토큰이 비용을 키우므로 캐싱, 모델 라우팅, 문맥 압축으로 관리한다.

예시 RAG 문맥을 청크 10개에서 리랭킹 후 4개로 줄여 건당 토큰 비용을 절반 이하로 낮췄다.

연관 토큰, 프롬프트 캐싱, 모델 게이트웨이, AI 비용, 토크나이저

출처 Anthropic

투자 대비 효과

ROI · Return on Investment

AX·비즈니스 적용 · **입문**

입문 들인 돈에 비해 얼마나 이익이나 효과를 얻었는지를 나타내는 지표다.

심화 AI 프로젝트의 ROI는 (효익 - 비용)/비용으로 계산하되, 효익에는 인건비 절감뿐 아니라 처리 시간 단축, 오류 감소, 고객 만족, 리스크 감소가 포함된다. 정성 효과가 많아 측정 기준선(baseline)을 도입 전에 확보하는 것이 중요하며, 비용 측은 TCO 관점으로 산정한다.

예시 사내 문서 작성 AI의 ROI를 산정하기 위해 도입 전후 보고서 1건당 작성 시간을 표본 측정했다.

연관 총소유비용, 생산성 지표, AI 비용, 개념 검증

출처 Wikipedia

튜링 테스트

Turing Test

AI 기초·머신러닝 · **입문**

입문 대화 상대가 사람인지 기계인지 구별하지 못하면 그 기계를 지능적이라고 보자는 시험이다.

심화 앨런 튜링이 1950년 논문에서 제안한 '모방 게임'으로, 심사자가 텍스트 대화만으로 기계와 사람을 구별하지 못하면 기계가 통과한 것으로 본다. 최신 LLM이 대화형 실험에서 높은 비율로 사람으로 오인되면서, 지능 측정 기준으로서의 한계와 실용적 의미가 다시 논의되고 있다.

연관 범용 인공지능, 약인공지능과 강인공지능, 대규모 언어모델, 벤치마크

출처 Wikipedia / 논문 Turing 1950 · Jones and Bergen 2025

트랜스포머

Transformer

딥러닝·신경망 · **실무**

입문 문장 속 모든 단어가 서로를 한꺼번에 참고하며 의미를 파악하는 신경망 구조다. ChatGPT 같은 LLM의 뼈대다.

심화 2017년 논문 'Attention Is All You Need'에서 제안된 아키텍처로, 순환 구조 없이 셀프 어텐션과 피드포워드 층, 잔차연결, 레이어 정규화를 쌓아 시퀀스를 처리한다. 병렬 학습이 가능해 대규모 확장에 유리하며, 인코더 전용(BERT), 디코더 전용(GPT 계열), 인코더-디코더(T5) 변형이 있다. 시퀀스 길이에 대해 어텐션 비용이 제곱으로 늘어나는 것이 한계다.

예시 트랜스포머 기반 LLM으로 내부 규정 문서를 요약하고 질의응답 서비스를 구축한다.

연관 셀프 어텐션, 멀티헤드 어텐션, 위치 인코딩, 대규모 언어모델, 인코더-디코더

출처 IBM · Wikipedia / 논문 Vaswani et al. 2017

트리 오브 소트

ToT · Tree of Thoughts

프롬프트·추론 · 심화

입문 한 가지 풀이만 따라가지 않고 여러 갈래의 생각을 나무처럼 펼쳐 놓고 유망한 쪽을 골라 계속 파고드는 방법이다.

심화 추론을 트리 구조의 탐색 문제로 보고, 각 단계에서 여러 후보 '생각'을 생성한 뒤 모델 스스로 평가해 BFS·DFS 등으로 확장·가지치기하는 프레임워크다. 계획, 퍼즐처럼 되돌아가기가 필요한 문제에서 CoT보다 유리하다. 호출 수가 많아 비용이 크며, 실무에서는 추론 모델이나 에이전트 루프로 대체되는 경우가 많다.

예시 신규 상품 수수료 체계를 설계할 때 여러 안을 생성·평가해 유력안만 세부 검토하게 한다.

연관 사고의 연쇄, 자기일관성, 테스트 타임 컴퓨트, 추론 모델

출처 Wikipedia / 논문 Yao et al. 2023

ㅍ

파국적 망각

Catastrophic Forgetting

학습·튜닝·정렬 · 심화

입문 새로운 것을 집중적으로 배우면서 예전에 알던 능력을 크게 잊어버리는 현상이다.

심화 새 데이터로 가중치를 갱신할 때 기존 작업에 중요한 파라미터가 덮어써져 성능이 급락하는 문제다. 일반 데이터 재생(replay) 혼합, 낮은 학습률, PEFT, 정규화(EWC 등)로 완화한다. 파인튜닝 후에는 도메인 성능뿐 아니라 일반 능력 회귀도 함께 평가해야 한다.

예시 금융 문서로 파인튜닝한 뒤 일반 요약·코딩 능력이 떨어졌는지 회귀 테스트한다.

연관 지속학습, 파인튜닝, 매개변수 효율적 미세조정, 도메인 적응

출처 IBM · Wikipedia / 논문 Kirkpatrick et al. 2016

파라미터

Parameter

AI 기초·머신러닝 · 실무

입문 AI 내부의 조절 손잡이다. 학습은 이 손잡이 수억~수천억 개를 조금씩 돌려 정답에 가깝게 맞추는 과정이다.

심화 학습을 통해 데이터로부터 값이 결정되는 모델 내부 변수로, 신경망의 가중치와 편향이 대표적이다. 사람이 미리 정하는 하이퍼파라미터와 구분된다. 파라미터 수는 모델 용량과 메모리·연산 요구량의 지표로 쓰인다.

예시 70억 파라미터 모델은 16비트 기준 가중치만 약 14GB 메모리를 차지해 온프레미스 GPU 선정 기준이 된다.

연관 하이퍼파라미터, 파라미터 수와 모델 크기, 모델, 양자화, 스케일링 법칙

출처 IBM · Wikipedia

파라미터 수와 모델 크기

Model Size (Parameter Count)

딥러닝·신경망 · 실무

입문 AI 모델의 덩치를 나타내는 숫자다. '7B'는 내부 조절값이 70억 개라는 뜻이며, 클수록 대체로 똑똑하지만 비싸고 무겁다.

심화 모델 크기는 보통 파라미터 수(B=10억)로 표기한다. 가중치 메모리는 대략 파라미터 수 × 자료형 바이트로, 70억 모델은 BF16 약 14GB, 4비트 양자화 시 약 4GB 수준이다. 추론 시에는 KV 캐시와 활성값 메모리가, 학습 시에는 기울기·옵티마이저 상태가 추가로 필요하다. MoE 모델은 전체 파라미터와 토큰당 활성 파라미터를 구분해 표기한다.

예시 온프레미스 GPU 메모리 한도에 맞춰 수십억 파라미터급 모델을 양자화해 내부 업무용으로 배포한다.

연관 파라미터, 양자화, 스케일링 법칙, 전문가 혼합, 소형 언어모델

출처 IBM · Wikipedia / 논문 Kaplan et al. 2020 · Hoffmann et al. 2022

파운데이션 모델

Foundation Model

LLM·언어모델 · 입문

입문 여러 용도로 바로 쓰거나 고쳐 쓸 수 있게 미리 크게 학습해 둔 기반 모델이다. 건물의 기초 공사에 해당한다.

심화 대규모·광범위 데이터로 자기지도 사전학습해 다양한 다운스트림 작업에 프롬프팅이나 파인튜닝으로 적응시킬 수 있는 모델을 가리킨다. LLM뿐 아니라 비전·음성·멀티모달 모델도 포함하는 상위 개념이다.

예시 범용 파운데이션 모델을 도입한 뒤 사내 문서로 파인튜닝해 내부 규정 질의응답에 쓴다.

연관 대규모 언어모델, 사전학습, 파인튜닝, 멀티모달, 생성형 AI

출처 AWS · IBM · Wikipedia / 논문 Bommasani et al. 2021

파이프라인 병렬화

PP · Pipeline Parallelism

학습·튜닝·정렬 · 심화

입문 모델의 층들을 앞뒤 구간으로 나눠 여러 GPU에 배치하고, 조립 라인처럼 데이터를 차례로 넘기며 처리하는 방식이다.

심화 층 단위로 모델을 스테이지로 분할하고 미니배치를 마이크로배치로 쪼개 스테이지 간 연산을 겹친다. 통신량이 적어 노드 간 확장에 적합하지만 파이프라인 버블(유휴 시간)이 생기며 1F1B, 인터리브 스케줄로 줄인다.

연관 분산 학습, 텐서 병렬화, 데이터 병렬화

출처 NVIDIA · Hugging Face / 논문 Huang et al. 2018 · Harlap et al. 2018

파인튜닝

Fine-tuning

학습·튜닝·정렬 · **입문**

입문 이미 학습된 모델에 특정 업무 데이터를 추가로 가르쳐 그 일에 더 잘 맞게 다듬는 과정이다.

심화 사전학습 가중치를 초기값으로 작업별 데이터로 추가 학습한다. 전체 파라미터를 갱신하는 풀 파인튜닝과 일부만 학습하는 PEFT(LoRA 등)가 있다. 출력 형식·어조·도메인 용어 적응에 효과적이지만, 새로운 사실 지식 주입은 RAG가 더 적합한 경우가 많고 과적합·망각 위험이 있다.

예시 여신 심사 의견서 양식에 맞춰 출력하도록 과거 의견서 데이터로 모델을 파인튜닝한다.

연관 지도 미세조정, 로라, 매개변수 효율적 미세조정, 파국적 망각, 검색 증강 생성

출처 IBM · Google for Developers · Wikipedia / 논문 Devlin et al. 2018 · Houlsby et al. 2019

퍼셉트론

Perceptron

딥러닝·신경망 · **입문**

입문 입력값에 중요도를 곱해 더한 뒤, 기준을 넘으면 1, 아니면 0을 내는 가장 단순한 인공 뉴런이다.

심화 1958년 로젠블랫이 제안한 선형 이진 분류기로, 가중합에 계단 함수를 적용한다. 선형 분리 가능한 문제만 풀 수 있어 XOR 문제를 해결하지 못하는 한계가 지적되었고, 이를 여러 층으로 쌓은 다층 퍼셉트론(MLP)과 역전파로 극복되었다.

연관 다층 퍼셉트론, 신경망, 활성화 함수, 은닉층

출처 Wikipedia / 논문 Rosenblatt 1958

편향

Bias

평가·안전·규제 · **입문**

입문 AI가 특정 성별·나이·지역 등에 대해 한쪽으로 치우친 판단을 하는 문제다. 치우친 데이터로 배우면 치우친 결과가 나온다.

심화 학습 데이터의 대표성 부족, 과거 차별이 반영된 레이블, 프록시 변수(우편번호가 소득·인종을 대리하는 등), 평가 집단 불균형에서 비롯된다. 집단별 성능 차이, 응답 고정관념 테스트로 측정하고 데이터 재표집, 학습 시 제약, 후처리 임계값 조정으로 완화한다. 금융·채용처럼 기본권에 영향을 주는 영역에서는 규제 대상이 된다.

예시 신용평가 모델에서 연령대별 승인율과 오류율 차이를 정기적으로 측정해 편향 여부를 점검한다.

연관 공정성, 학습 데이터, 책임 있는 AI, 고영향 인공지능, 설명 가능한 AI

출처 Wikipedia / 논문 Mehrabi et al. 2019

편향-분산 트레이드오프

Bias-Variance Tradeoff

AI 기초·머신러닝 · **심화**

입문 너무 단순한 AI는 늘 비슷하게 틀리고(편향), 너무 복잡한 AI는 데이터가 조금만 바뀌어도 답이 흔들린다(분산). 그 사이 균형점을 찾아야 한다.

심화 예측 오차는 편향², 분산, 줄일 수 없는 잡음으로 분해된다. 모델 복잡도를 높이면 편향은 줄고 분산은 늘어난다. 과소적합은 고편향, 과적합은 고분산 상태다. 대규모 딥러닝에서는 과매개변수화 영역에서 오차가 다시 줄어드는 이중 하강(double descent) 현상도 관찰된다.

예시 단일 결정트리 대신 랜덤포레스트를 쓰면 분산이 줄어 월별 신용점수 변동이 안정된다.

연관 과적합, 과소적합, 정규화(규제), 앙상블 학습

출처 IBM · Wikipedia / 논문 Belkin et al. 2019 · Nakkiran et al. 2019

평가

Evaluation (Evals)

평가·안전·규제 · **실무**

입문 AI가 원하는 대로 잘 동작하는지 정해진 기준으로 점검하는 과정이다. AI 시스템의 품질 검사에 해당한다.

심화 평가 데이터셋, 채점 방식(정답 일치, 규칙, LLM 심판, 사람), 지표, 실행 파이프라인으로 구성된다. 모델 자체의 능력 평가와 프롬프트·RAG·도구를 포함한 애플리케이션 평가를 구분한다. 프롬프트·모델·데이터가 바뀔 때마다 자동 실행해 품질 저하를 잡는 것이 LLM 서비스 운영의 핵심이다.

예시 RAG 기반 규정 검색 서비스에 검색 적중률과 답변 근거성 평가를 배포 파이프라인에 넣는다.

연관 벤치마크, 골든 데이터셋, LLM 심판 평가, 오프라인·온라인 평가, LLMOps

출처 Anthropic (Claude Platform Docs) · OpenAI · Anthropic / 논문 Liang et al. 2022

폐쇄망 배포

Air-Gapped Deployment

인프라·배포·LLMOps · **실무**

입문 인터넷과 물리적·논리적으로 분리된 내부망에 AI 모델과 시스템을 설치해 운영하는 것이다.

심화 외부 API를 쓸 수 없으므로 오픈 웨이트 모델 가중치, 컨테이너 이미지, 파이썬 패키지, 드라이버를 외부에서 검증 후 보안 절차를 거쳐 반입한다. 모델 업데이트·취약점 패치가 느리고 의존성 누락이 잦아 내부 미러 저장소(패키지, 컨테이너 레지스트리)와 반입 체크리스트가 필요하다. 망분리 환경의 금융·공공기관에서 일반적인 LLM 운영 형태다.

예시 정보계 폐쇄망에 반입한 오픈 웨이트 모델로 SQL 생성 보조를 운영하며 분기별로 모델과 패키지를 재반입한다.

연관 온프레미스, 오픈 웨이트 모델, 망분리 규제 개선, GGUF, vLLM

출처 Wikipedia

폴백 모델

Fallback Model

인프라·배포·LLMOps · **실무**

입문 주 모델이 장애나 지연을 겪을 때 대신 응답하도록 준비해 둔 예비 모델이다.

심화 타임아웃, 429, 5xx 오류 발생 시 다른 제공사·리전·소형 모델로 자동 전환해 가용성을 확보한다. 모델마다 프롬프트 반응과 출력 형식이 다르므로 폴백 모델도 같은 평가셋으로 검증해야 한다. 비용 절감을 위해 저가 모델 우선, 실패 시 상위 모델로 올리는 캐스케이드 구성도 있다.

예시 외부 API 장애 시 사내 상담 보조 기능이 온프레미스 소형 모델로 자동 전환되도록 구성했다.

연관 모델 게이트웨이, 서비스 수준 협약, 레이트 리밋, 소형 언어모델

출처 LiteLLM

퓨샷

Few-shot Prompting

프롬프트·추론 · **입문**

입문 몇 개의 예시를 먼저 보여주고 비슷하게 처리하도록 하는 방식이다. 견본을 보여주며 일을 가르치는 것과 같다.

심화 프롬프트에 여러 개(보통 2~10개)의 입출력 예시를 넣어 작업 패턴을 학습 없이 전달하는 기법으로, 인컨텍스트 러닝의 대표적 활용이다. 예시의 다양성, 순서, 레이블 분포가 결과에 영향을 주며, 경계 사례를 포함하면 효과가 크다. 예시가 많을수록 토큰 비용이 늘어 동적으로 유사 예시를 검색해 넣는 방식도 쓰인다.

예시 계정과목 매핑 프롬프트에 '적요 → 계정과목' 예시 5건을 넣어 신규 거래의 계정을 추천받는다.

연관 제로샷, 원샷, 인컨텍스트 러닝, 프롬프트 템플릿

출처 Anthropic · OpenAI · Google / 논문 Brown et al. 2020

프라이빗 클라우드

Private Cloud

인프라·배포·LLMOps · **실무**

입문 한 조직만 전용으로 쓰는 클라우드 환경이다. 클라우드의 편리함과 자체 통제를 함께 얻으려는 방식이다.

심화 자체 데이터센터나 전용 호스팅 위에 가상화·컨테이너·셀프서비스 포털을 구축해 자원을 탄력적으로 배분한다. 퍼블릭 클라우드 대비 데이터 통제와 규제 대응이 쉽지만 규모의 경제가 작고 최신 GPU·관리형 AI 서비스 접근이 제한된다.

예시 금융그룹 공동 프라이빗 클라우드에 GPU 풀을 구성해 계열사가 사내 LLM을 공유하도록 했다.

연관 하이브리드 클라우드, 온프레미스, 쿠버네티스, 폐쇄망 배포

출처 IBM · NIST

프런티어 모델

Frontier Model

LLM·언어모델 · **입문**

입문 현재 가장 뛰어난 성능을 가진 최첨단 AI 모델들을 부르는 말이다.

심화 최대 규모의 연산으로 학습되어 해당 시점 최고 수준 능력을 보이는 범용 모델을 가리킨다(GPT, Claude, Gemini 계열 최상위 모델 등). 성능이 높은 만큼 오용 위험 평가와 규제 논의의 주요 대상이 되며, 일부 규제는 학습 연산량 기준으로 고위험·고영향 모델을 정의한다. 기준이 계속 이동하는 상대적 개념이다.

연관 파운데이션 모델, 대규모 언어모델, 스케일링 법칙, EU 인공지능법, 책임 있는 AI

출처 Frontier Model Forum / 논문 Anderljung et al. 2023

프롬프트

Prompt

프롬프트·추론 · **입문**

입문 AI에게 건네는 질문이나 지시문이다. 무엇을 어떻게 해 달라고 적는 '작업 요청서'에 해당한다.

심화 LLM에 입력되는 텍스트(또는 이미지 등 멀티모달 입력) 전체를 말한다. 보통 시스템 프롬프트, 사용자 메시지, 이전 대화, 검색된 문서 등이 합쳐져 하나의 컨텍스트로 모델에 전달된다. 모델은 이 입력을 조건으로 다음 토큰을 예측하므로 프롬프트의 내용·순서·형식이 출력 품질을 좌우한다.

예시 '지난달 지점별 수신 잔액 증감 상위 5개를 표로 정리해줘'라고 입력하는 것이 프롬프트다.

연관 프롬프트 엔지니어링, 시스템 프롬프트, 대규모 언어모델, 컨텍스트 윈도

출처 Anthropic · OpenAI · Wikipedia / 논문 Schulhoff et al. 2024

프롬프트 라이브러리

Prompt Library

AX·비즈니스 적용 · **실무**

입문 업무에서 효과가 검증된 프롬프트를 모아 누구나 찾아 쓰고 개선할 수 있게 정리한 공유 저장소다.

심화 업무 유형별 프롬프트 템플릿, 입력 변수, 사용 예시, 주의사항, 작성자·버전을 관리한다. 개인 역량 편차를 줄이고 우수 사례를 확산하는 효과가 있으며, 사내 LLM 포털에 내장하거나 원클릭 실행 형태로 제공하면 활용도가 높아진다. 업무 품질에 영향이 큰 템플릿은 검토 절차를 둔다.

예시 '회의록 요약', '보도자료 초안', '규정 비교' 등 부서별 검증 프롬프트 50여 개를 사내 포털에 등록했다.

연관 프롬프트 템플릿, 사내 LLM 포털, 프롬프트 엔지니어링, AI 챔피언

프롬프트 버전 관리

Prompt Versioning

프롬프트·추론 · 실무

입문 프롬프트를 고칠 때마다 이력을 남기고, 어떤 버전이 더 잘 동작하는지 비교·되돌릴 수 있게 관리하는 것이다.

심화 프롬프트를 코드처럼 저장소나 프롬프트 관리 도구에서 버전·변경 이력·배포 환경별로 관리하는 실무 관행이다. 변경 시 평가셋으로 회귀 테스트하고, A/B 테스트와 롤백을 지원한다. 모델 버전, 파라미터(온도 등)와 함께 기록해야 재현성이 확보된다.

예시 상담 요약 프롬프트 v1.3 배포 후 요약 누락률이 오르자 평가 로그를 확인하고 v1.2로 롤백한다.

연관 프롬프트 템플릿, LLMOps, 평가, 관측 가능성

출처 OpenAI · Anthropic

프롬프트 엔지니어링

Prompt Engineering

프롬프트·추론 · 입문

입문 AI가 원하는 답을 내도록 질문과 지시를 잘 다듬는 기술이다. 같은 일을 시켜도 어떻게 말하느냐에 따라 결과가 크게 달라진다.

심화 역할 지정, 예시 제공, 단계적 추론 유도, 출력 형식 지정, 구분자 사용 등으로 모델 출력을 개선하는 설계 기법의 총칭이다. 모델 가중치를 바꾸지 않고 입력만으로 성능을 끌어올리므로 파인튜닝보다 비용이 낮고 반복이 빠르다. 다만 모델 버전이 바뀌면 효과가 달라질 수 있어 평가셋 기반의 회귀 테스트가 필요하다.

예시 민원 분류 프롬프트에 분류 기준표와 예시 3건을 넣어 정확도를 높이는 작업이 프롬프트 엔지니어링이다.

연관 프롬프트, 퓨샷, 사고의 연쇄, 컨텍스트 엔지니어링, 평가

출처 Anthropic · IBM · Wikipedia / 논문 Schulhoff et al. 2024

프롬프트 인젝션

Prompt Injection

평가·안전·규제 · 실무

입문 교묘한 문장을 끼워 넣어 AI가 원래 지시 대신 공격자의 지시를 따르게 만드는 공격이다. 'SQL 인젝션'의 AI 버전으로 볼 수 있다.

심화 LLM은 시스템 지시와 사용자·외부 데이터를 같은 텍스트 흐름으로 처리하므로 둘의 경계를 확실히 구분하지 못한다. 사용자가 직접 '이전 지시를 무시하라'고 넣는 직접 인젝션과, 문서·웹페이지·메일에 숨긴 지시를 모델이 읽게 하는 간접 인젝션이 있다. 완전한 방어책은 없어 입력 분리 표기, 권한 최소화, 도구 호출 승인, 출력 검증 등 다층 방어를 쓴다.

예시 고객 문의 요약 봇이 '시스템 프롬프트를 출력하라'는 문구가 섞인 문의를 받아도 지시로 따르지 않도록 입력 구간을 분리 표기한다.

연관 간접 프롬프트 인젝션, 탈옥, 시스템 프롬프트, 가드레일, AI 에이전트

출처 OWASP Gen AI Security Project · Wikipedia / 논문 Perez and Ribeiro 2022 · Greshake et al. 2023

프롬프트 체이닝

Prompt Chaining

프롬프트·추론 · 실무

입문 큰 일을 여러 단계로 쪼개 앞 단계 AI 결과를 다음 단계 입력으로 넘기는 방식이다. 공장의 조립 라인과 같다.

심화 복잡한 작업을 추출→분석→작성처럼 여러 프롬프트로 분해하고 각 출력을 다음 프롬프트 입력으로 연결하는 설계 패턴이다. 단계별로 검증·디버깅이 쉽고 각 단계에 맞는 모델을 고를 수 있다. 단계가 고정된 워크플로에 적합하며, 경로를 모델이 동적으로 정하면 에이전트에 가깝다.

예시 계약서에서 조항 추출 → 위험 조항 판정 → 검토 의견서 작성의 3단계 체인을 구성한다.

연관 에이전틱 워크플로, 프롬프트 템플릿, 오케스트레이션, 구조화된 출력

출처 Anthropic · Google / 논문 Wu et al. 2022

프롬프트 최적화

Prompt Optimization

프롬프트·추론 · 심화

입문 사람이 손으로 고치는 대신, 평가 점수를 기준으로 프로그램이 프롬프트를 자동으로 개선하는 방법이다.

심화 평가 지표와 데이터셋을 정의한 뒤 지시문과 예시를 탐색·수정해 점수를 최대화하는 자동화 기법이다. DSPy는 프롬프트를 입출력 시그니처와 모듈로 선언하고 옵티마이저가 지시문·퓨샷 예시를 컴파일하는 프레임워크의 대표 사례다. 모델 교체 시 재최적화가 쉬운 장점이 있으나, 평가셋 품질에 결과가 크게 좌우된다.

예시 라벨된 민원 500건을 평가셋으로 삼아 분류 프롬프트를 자동 최적화하고 정확도 변화를 추적한다.

연관 메타 프롬프팅, 평가, 퓨샷, 프롬프트 엔지니어링

출처 DSPy (Stanford NLP) · Wikipedia / 논문 Khattab et al. 2023 · Zhou et al. 2022 · Yang et al. 2023

프롬프트 캐싱

Prompt Caching

인프라·배포·LLMOps · 심화

입문 매번 똑같이 들어가는 긴 앞부분 프롬프트의 처리 결과를 저장해 두고 재사용해 비용과 시간을 줄이는 기능이다.

심화 공통 접두부(시스템 프롬프트, 고정 문서, 도구 정의)의 KV 캐시를 보관해 이후 요청에서 프리필 연산을 건너뛴다. 상용 API는 캐시 적중 입력 토큰을 크게 할인하고, 자체 서빙은 vLLM 등의 프리픽스 캐싱으로 구현한다. 접두부가 한 글자라도 다르면 적중하지 않으므로 고정 내용을 앞에, 가변 내용을 뒤에 배치한다.

예시 공통 상품 설명서와 응대 규칙을 프롬프트 앞부분에 고정해 캐싱 적중률을 높이고 입력 토큰 비용을 줄였다.

연관 KV 캐시, 토큰 비용, 첫 토큰 지연, 시맨틱 캐시, 시스템 프롬프트

출처 Anthropic · OpenAI

프롬프트 템플릿

Prompt Template

프롬프트·추론 · **실무**

입문 빈칸만 바꿔 끼우면 되는 프롬프트 양식이다. 서식이 정해진 보고서 양식과 비슷하다.

심화 고정된 지시문에 {질문}, {문서}, {날짜} 같은 변수를 두고 실행 시 값을 채워 넣는 재사용 가능한 프롬프트 구조다. 애플리케이션 코드와 프롬프트를 분리해 관리·테스트·버전 관리를 쉽게 한다. Jinja 등 템플릿 엔진이나 LLM 프레임워크의 템플릿 기능으로 구현하며, 사용자 입력 삽입 위치는 인젝션에 대비해 구분자로 감싼다.

예시 '{기준일} 기준 {부서} 실적을 요약하라' 템플릿으로 부서별 일일 보고 요약을 자동 생성한다.

연관 프롬프트, 프롬프트 버전 관리, 퓨샷, 구분자

출처 OpenAI

플로우 매칭

Flow Matching

생성 AI·멀티모달 · **심화**

입문 잡음에서 그림으로 가는 길을 곧은 직선에 가깝게 배우게 해 더 빠르고 안정적으로 생성하는 학습 방법이다.

심화 노이즈 분포와 데이터 분포를 잇는 확률 경로를 정의하고, 그 경로를 따르는 속도장(vector field)을 신경망이 회귀하도록 학습하는 기법이다. 직선 경로(rectified flow)를 쓰면 적은 적분 단계로도 고품질 샘플을 얻을 수 있어, 최근 다수의 이미지·영상·음성 생성 모델이 확산 대신 또는 확산과 함께 채택한다.

연관 확산 모델, 노이즈 제거, 확산 트랜스포머, 영상 생성

출처 Hugging Face / 논문 Lipman et al. 2022 · Liu et al. 2022 · Esser et al. 2024

플롭스

FLOPS · Floating-Point Operations per Second

인프라·배포·LLMOps · **심화**

입문 컴퓨터가 1초에 할 수 있는 소수점 계산 횟수다. AI 칩의 연산 능력을 비교하는 단위로 쓴다.

심화 GPU 사양은 정밀도별(FP32, BF16, FP8 등) TFLOPS/PFLOPS로 표기된다. 학습 총 연산량은 FLOPs(초당이 아닌 총 횟수)로 나타내며 대략 파라미터 수와 학습 토큰 수의 곱에 비례한다. 실제 성능은 메모리 대역폭과 활용률(MFU)에 좌우되므로 명목 FLOPS만으로 비교하면 안 된다.

연관 GPU, 스케일링 법칙, 고대역폭 메모리, 사전학습

출처 Wikipedia / 논문 Kaplan et al. 2020

피처 스케일링(정규화·표준화)

Feature Scaling

AI 기초·머신러닝 · **실무**

입문 단위가 제각각인 값(원, 퍼센트, 횟수)을 비슷한 범위로 맞춰 AI가 공평하게 비교하게 하는 전처리다.

심화 값을 0~1로 변환하는 최소-최대 정규화(normalization), 평균 0·표준편차 1로 바꾸는 표준화(standardization), 이상치에 강한 로버스트 스케일링 등이 있다. 거리 기반 모델·경사하강 기반 모델에는 필수지만 트리 모델에는 영향이 거의 없다. 스케일러는 학습 데이터로만 적합해야 누수를 피한다.

예시 소득(수천만 원)과 연체 횟수(0~10)를 표준화한 뒤 로지스틱 회귀에 투입한다.

연관 피처 엔지니어링, 데이터 누수, 경사하강법, 배치 정규화

출처 Google for Developers · Wikipedia

피처 엔지니어링

Feature Engineering

AI 기초·머신러닝 · **실무**

입문 원본 데이터를 AI가 이해하기 좋은 형태로 가공하는 작업이다. 거래 내역에서 '최근 3개월 평균 사용액'을 뽑아내는 식이다.

심화 도메인 지식으로 원천 데이터를 변환·집계·조합해 예측력 있는 입력 변수를 만드는 과정이다. 집계(윈도우 통계), 비율·차분, 범주 인코딩, 결측 처리, 스케일링 등이 포함된다. 정형 데이터 모델 성능의 상당 부분을 좌우하며, 기준 시점 이후 정보가 섞이는 누수를 경계해야 한다.

예시 DW의 거래 원장에서 고객별 월말 기준 잔액 변동률, 연체 일수 피처를 생성해 피처 마트에 적재한다.

연관 피처(특성), 데이터 누수, 피처 스케일링(정규화·표준화), 데이터 파이프라인

출처 IBM · Wikipedia

피처(특성)

Feature

AI 기초·머신러닝 · **입문**

입문 AI가 판단할 때 참고하는 항목이다. 대출 심사라면 소득, 연체 횟수, 근속 연수 같은 값이 피처다.

심화 모델 입력으로 쓰이는 개별 변수다. 정형 데이터에서는 컬럼, 딥러닝에서는 학습된 내부 표현(잠재 특성)을 가리키기도 한다. 피처의 정보량과 누수 여부가 성능과 신뢰성을 좌우한다.

예시 최근 6개월 평균 잔액, 카드 사용 빈도를 피처로 만들어 이탈 예측에 사용한다.

연관 피처 엔지니어링, 모델, 데이터 누수, 임베딩, 피처 스케일링(정규화·표준화)

출처 Wikipedia · IBM

ㅎ

하이브리드 검색

Hybrid Search

RAG·검색·데이터 · **실무**

입문 키워드 검색과 의미 검색을 함께 써서 서로의 약점을 보완하는 검색 방식이다.

심화 BM25 같은 희소 검색과 임베딩 기반 밀집 검색 결과를 결합하는 방식이다. 점수 척도가 달라 RRF(Reciprocal Rank Fusion)처럼 순위 기반으로 합치거나 가중 합산한다. 정확 용어와 의미 유사성을 모두 잡을 수 있어 기업 RAG의 기본 구성으로 자리 잡았다.

예시 상품코드 검색은 키워드로, '노후 대비 상품' 같은 질문은 의미 검색으로 잡아 결과를 RRF로 합친다.

연관 BM25, 의미 검색, 재순위화, 검색(리트리벌)

출처 Microsoft / 논문 Cormack et al. 2009

하이브리드 모델

Hybrid Architecture Model

LLM·언어모델 · **심화**

입문 트랜스포머의 어텐션과 상태공간모델 같은 다른 구조를 섞어 장점을 함께 취하는 모델이다.

심화 대부분의 층을 SSM이나 선형 어텐션으로 두고 일부 층에만 전체 어텐션을 배치해 장문 처리 효율과 검색 능력을 절충한다. KV 캐시를 크게 줄여 긴 컨텍스트 서빙 비용을 낮출 수 있어 여러 오픈 웨이트 모델이 채택하고 있다. 서빙 엔진 지원과 커널 최적화가 아직 트랜스포머보다 덜 성숙했다.

연관 상태공간모델, 트랜스포머, KV 캐시, 롱 컨텍스트, 전문가 혼합

논문 Lieber et al. 2024 · Waleffe et al. 2024

하이브리드 클라우드

Hybrid Cloud

인프라·배포·LLMOps · **실무**

입문 회사 내부 시스템과 외부 퍼블릭 클라우드를 함께 연결해 쓰는 방식이다.

심화 민감 데이터와 핵심 업무는 온프레미스·프라이빗에, 탄력이 필요한 작업이나 최신 상용 모델 활용은 퍼블릭 클라우드에 둔다. 데이터 등급 분류, 네트워크 연결 통제, 통합 인증·모니터링이 설계 핵심이며 금융권은 망분리 규정과 클라우드 이용 절차를 함께 따라야 한다.

예시 가명처리된 데이터만 퍼블릭 클라우드 LLM으로 보내고 원본은 내부 DW에 남기는 하이브리드 구조를 설계했다.

연관 프라이빗 클라우드, 온프레미스, 모델 게이트웨이, 망분리 규제 개선

출처 IBM · NIST

하이퍼파라미터

Hyperparameter

AI 기초·머신러닝 · **실무**

입문 AI를 학습시키기 전에 사람이 정해주는 설정값이다. 요리로 치면 불 세기와 조리 시간이다.

심화 학습으로 결정되지 않고 사전에 지정하는 값으로 학습률, 배치 크기, 트리 깊이, 정규화 강도, 에폭 수 등이 있다. 그리드 서치, 랜덤 서치, 베이지안 최적화 등으로 검증셋 성능을 기준으로 탐색한다. 파라미터와 구분된다.

예시 XGBoost 이탈 예측 모델의 트리 깊이와 학습률을 교차검증으로 튜닝한다.

연관 파라미터, 학습률, 배치 크기, 교차검증, 데이터셋 분할(학습/검증/테스트)

출처 IBM · Wikipedia / 논문 Bergstra and Bengio 2012 · Snoek et al. 2012

학습률

LR · Learning Rate

딥러닝·신경망 · **실무**

입문 AI가 한 번 틀렸을 때 얼마나 크게 고칠지 정하는 보폭이다. 너무 크면 엉뚱한 데로 튀고, 너무 작으면 학습이 한없이 느려진다.

심화 경사하강법에서 기울기에 곱해 파라미터 갱신 크기를 정하는 하이퍼파라미터로, 가장 중요한 튜닝 대상이다. 초기에 점진적으로 올리는 워밍업과 이후 코사인 감쇠 등 스케줄을 함께 쓴다. 파인튜닝 시에는 사전학습보다 훨씬 작은 학습률을 쓴다.

연관 경사하강법, 옵티마이저, 하이퍼파라미터, 배치 크기, 파인튜닝

출처 IBM · Wikipedia / 논문 Loshchilov & Hutter 2016

학습 데이터

Training Data

AI 기초·머신러닝 · **입문**

입문 AI가 공부하는 교재에 해당하는 데이터다. 교재의 질과 양이 AI의 실력을 결정한다.

심화 모델 파라미터를 추정하는 데 사용하는 데이터셋이다. 대표성, 레이블 정확도, 편향, 최신성이 성능과 공정성에 직결된다. 검증·테스트 데이터와 엄격히 분리해야 하며, 개인정보·저작권 등 법적 이용 근거도 확인해야 한다.

예시 신용평가 모델 학습 데이터에 특정 연령층이 과소 대표되면 해당 집단 평가가 왜곡될 수 있다.

연관 데이터셋 분할(학습/검증/테스트), 데이터 레이블링, 편향, 합성 데이터, 데이터 프라이버시

출처 IBM · Wikipedia / 논문 Gebru et al. 2018

학습 토큰 수

Training Tokens

학습·튜닝·정렬 · **실무**

입문 모델이 학습하면서 읽은 데이터 양을 토큰 개수로 나타낸 것이다. 많을수록 대체로 더 많이 배운 모델이다.

심화 학습 연산량은 대략 6 × 파라미터 수 × 학습 토큰 수(FLOPs)로 추정한다. Chinchilla 연구는 연산 최적 비율로 파라미터당 약 20토큰을 제시했지만, 추론 비용을 줄이려 작은 모델에 그보다 훨씬 많은 토큰을 학습시키는 과잉 학습이 일반화되었다. 최신 모델은 수조~수십조 토큰으로 학습한다.

연관 스케일링 법칙, 사전학습, 토큰, 파라미터 수와 모델 크기

출처 Wikipedia / 논문 Hoffmann et al. 2022 · Kaplan et al. 2020

한국어 토큰 효율

Korean Token Efficiency

LLM·언어모델 · **실무**

입문 같은 내용의 한국어 글이 몇 개의 토큰으로 처리되는지를 말한다. 토큰이 많이 들수록 비용이 늘고 넣을 수 있는 분량은 줄어든다.

심화 영어 중심 어휘집에서는 한글이 바이트 단위로 쪼개져 같은 의미에 영어보다 많은 토큰이 들 수 있다. 다국어 비중을 높인 토크나이저나 한국어 특화 모델은 어휘 확장으로 이를 개선한다. 비용·지연·유효 컨텍스트 길이에 모두 영향을 주므로 모델 선정 시 실제 업무 문서로 측정해야 한다.

예시 후보 모델별로 동일한 한국어 상품설명서의 토큰 수를 비교해 건당 처리 비용을 산출한다.

연관 토크나이저, 토큰, 다국어 모델, AI 비용, 바이트 페어 인코딩

출처 OpenAI / 논문 Petrov et al. 2023 · Rust et al. 2021

함수 호출

Function Calling

AI 에이전트·도구 · **실무**

입문 AI가 대화 중 '이 함수를 이런 값으로 실행해 달라'는 요청을 정해진 형식으로 만들어 내는 기능이다. 실제 실행은 프로그램이 맡는다.

심화 모델 API에 함수 이름·설명·JSON Schema 형태의 매개변수를 정의해 전달하면, 모델이 사용자 요청에 맞는 함수와 인자를 JSON으로 반환한다. 애플리케이션이 이를 파싱해 실행하고 결과를 다시 모델에 넘겨 최종 응답을 생성한다. 모델 자체는 코드를 실행하지 않으므로 인자 검증, 예외 처리, 재시도는 호출 측 책임이며 도구 사용(tool use)을 API 수준에서 구현한 형태로 볼 수 있다.

예시 '지난달 카드 사용액 알려줘'라는 요청을 get_card_usage(month='2026-09') 호출로 변환해 계정계 API에 연결한다.

연관 도구 사용, 도구 스키마, 구조화된 출력, API

출처 OpenAI · Anthropic / 논문 Patil et al. 2023 · Schick et al. 2023

합성곱 신경망

CNN · Convolutional Neural Network

딥러닝·신경망 · **실무**

입문 작은 돋보기(필터)로 이미지를 훑으며 선, 모서리, 모양 같은 특징을 찾아내는 신경망이다. 이미지 인식의 대표 모델이다.

심화 학습 가능한 필터를 입력 위로 이동시키며 합성곱을 수행해 국소 패턴을 추출하고, 풀링으로 공간 해상도를 줄인다. 가중치 공유와 지역 연결로 파라미터가 적고 이동 불변성이 있다. ResNet 등이 대표적이며 이미지 분류·검출·OCR에 널리 쓰인다. 최근 비전 분야에서는 비전 트랜스포머(ViT)와 병용·경쟁한다.

예시 신분증 사진의 위변조 여부를 CNN으로 판별해 비대면 계좌 개설 심사에 활용한다.

연관 딥러닝, 광학 문자 인식, 잔차 연결, 신경망, 시각 언어 모델

출처 IBM · Wikipedia / 논문 LeCun et al. 1989 · He et al. 2015

합성 데이터

Synthetic Data

학습·튜닝·정렬 · **실무**

입문 실제 데이터 대신 AI나 규칙으로 만들어 낸 학습용 데이터다. 데이터가 부족하거나 개인정보 문제가 있을 때 유용하다.

심화 LLM으로 지시-응답 쌍, 추론 과정, 선호 쌍을 생성하거나 통계적 방법으로 표 형식 데이터를 생성한다. 데이터 부족·개인정보 제약을 완화하지만, 다양성 부족, 오류 전파, 자기 생성 데이터 반복 학습에 따른 모델 붕괴 위험이 있어 필터링·검증이 필수다.

예시 고객 개인정보 대신 실제 분포를 흉내 낸 합성 상담 대화를 만들어 챗봇을 학습시킨다.

연관 지식 증류, 사전학습 데이터 정제, 데이터 프라이버시, 지도 미세조정

출처 IBM · Hugging Face · Wikipedia / 논문 Wang et al. 2022 · Shumailov et al. 2023

핸드오프

Handoff

AI 에이전트·도구 · **실무**

입문 한 AI 에이전트가 맡던 일을 더 적합한 다른 에이전트나 사람에게 넘기는 것이다. 상담원이 전문 부서로 전화를 돌려주는 것과 같다.

심화 현재 에이전트가 작업 제어권과 필요한 맥락(대화 요약, 수집 정보)을 다른 에이전트 또는 사람 상담원에게 이관하는 패턴이다. 넘길 정보의 범위와 형식을 정의하지 않으면 맥락 손실로 같은 질문을 반복하게 되며, 사람에게 넘기는 기준(신뢰도, 고객 불만, 고위험 요청)을 명확히 해야 한다.

예시 AI 상담원이 이의 제기 민원을 감지하면 대화 요약과 함께 사람 상담원에게 연결한다.

연관 멀티 에이전트, 서브에이전트, 에이전트 간 프로토콜, 휴먼 인 더 루프

출처 OpenAI

헌법적 AI

CAI · Constitutional AI

학습·튜닝·정렬 · **심화**

입문 사람이 일일이 평가하는 대신 미리 정한 원칙 목록(헌법)을 기준으로 AI가 스스로 답변을 비판하고 고치게 하는 학습 방법이다.

심화 Anthropic이 제안한 기법으로, 원칙에 따라 모델이 자기 응답을 비평·수정한 데이터로 SFT를 하고, 원칙 기반 AI 선호 판단으로 RL(RLAIF)을 수행한다. 인간 레이블링 비용을 줄이고 행동 기준을 명시적 문서로 관리할 수 있다는 장점이 있다.

연관 AI 피드백 기반 강화학습, 정렬, 인간 피드백 기반 강화학습, 책임 있는 AI

출처 Anthropic · Anthropic / 논문 Bai et al. 2022

혼동행렬

Confusion Matrix

AI 기초·머신러닝 · **실무**

입문 AI가 맞힌 것과 틀린 것을 '진짜 정답 vs AI 답' 표로 정리한 것이다. 어떤 실수를 주로 하는지 한눈에 보인다.

심화 실제 클래스와 예측 클래스를 행·열로 교차 집계한 표다. 이진 분류에서는 TP, FP, FN, TN 네 칸으로 구성되며 정확도·정밀도·재현율·특이도 등 대부분의 분류 지표가 여기서 계산된다. 다중 클래스에서는 어떤 클래스끼리 혼동되는지 분석하는 데 유용하다.

예시 혼동행렬을 보고 오탐(FP) 건수에 건당 고객 응대 비용을 곱해 탐지 모델의 운영 비용을 산정한다.

연관 정밀도와 재현율, F1 점수, 정확도, 분류

출처 IBM · Google for Developers · Wikipedia / 논문 Fawcett 2006

혼합정밀도 학습

Mixed-Precision Training

학습·튜닝·정렬 · **심화**

입문 계산은 가벼운 숫자 형식으로 빠르게 하고 중요한 값만 정밀한 형식으로 보관해 학습 속도와 메모리를 아끼는 기법이다.

심화 순전파·역전파는 bf16(또는 fp16, 최근에는 fp8) 텐서 코어로 수행하고 마스터 가중치와 옵티마이저 상태는 fp32로 유지한다. bf16은 fp32와 지수 범위가 같아 fp16과 달리 손실 스케일링이 대체로 불필요하다. 메모리 절감과 처리량 향상이 크지만 수치 불안정 여부를 모니터링해야 한다.

연관 GPU, 양자화, 분산 학습, 전체 파인튜닝

출처 NVIDIA · Wikipedia / 논문 Micikevicius et al. 2017

화면 이해

Screen Understanding

생성 AI·멀티모달 · **심화**

입문 AI가 컴퓨터나 앱 화면을 보고 버튼, 입력칸, 메뉴가 어디 있고 무슨 기능인지 알아내는 능력이다.

심화 스크린샷에서 UI 요소의 종류·텍스트·위치를 인식하고(grounding), 사용자 지시를 특정 요소와 좌표로 연결하는 VLM의 능력이다. 컴퓨터 사용 에이전트의 핵심 기반이며, 고해상도 화면의 작은 요소, 비슷한 아이콘 구분, 동적으로 바뀌는 화면 상태 추적이 과제다. 접근성 트리 정보를 함께 쓰면 정확도가 높아진다.

연관 컴퓨터 사용, 시각 언어 모델, 브라우저 에이전트, 멀티모달

출처 Anthropic / 논문 Lee et al. 2022 · Hong et al. 2023 · Cheng et al. 2024

확률적 경사하강법

SGD · Stochastic Gradient Descent

딥러닝·신경망 · **심화**

입문 전체 데이터를 다 보고 고치는 대신, 일부만 뽑아 보고 자주 고쳐 나가는 경사하강법이다.

심화 전체 데이터 대신 무작위 표본(실무에서는 미니배치)으로 기울기를 추정해 파라미터를 갱신한다. 계산이 저렴하고 기울기 잡음이 국소 최솟값 탈출과 일반화에 도움을 줄 수 있다. 모멘텀을 더한 SGD는 비전 모델에서 여전히 쓰이며 Adam 등 적응형 옵티마이저의 기반이다.

연관 경사하강법, 옵티마이저, 배치 크기, 학습률

출처 Wikipedia / 논문 Robbins & Monro 1951

확산

Scale-up

AX·비즈니스 적용 · **실무**

입문 시범 적용에서 성공한 AI를 더 많은 부서와 업무로 넓혀 실제 운영 체계에 올리는 단계다.

심화 PoC·파일럿에서 검증한 사례를 전사 운영 환경으로 옮기며 보안 심의, 시스템 연계, 가용성·SLA, 운영 조직, 비용 모델, 교육을 갖춘다. 많은 AI 과제가 이 단계에서 멈추는데, 시범 단계에서 운영 요건과 성과 측정을 미리 설계하지 않은 것이 주된 원인이다.

예시 본점 2개 부서 파일럿 후 보안성 심의와 운영 이관을 거쳐 전 영업점으로 상담 요약 기능을 확산했다.

연관 개념 검증, AX 전환 로드맵, 서비스 수준 협약, LLMOps

출처 Google Cloud / 논문 Sculley et al. 2015

확산 모델

Diffusion Model

생성 AI·멀티모달 · **실무**

입문 잡음만 있는 화면에서 조금씩 잡음을 걷어 내며 그림을 완성해 가는 방식의 이미지 생성 AI다.

심화 데이터에 점진적으로 가우시안 노이즈를 더하는 순방향 과정과, 이를 역으로 되돌리는 노이즈 제거 신경망을 학습한다. 생성 시 순수 노이즈에서 시작해 여러 단계에 걸쳐 노이즈를 제거하며, 텍스트 조건으로 생성을 유도한다. 대부분 잠재 공간에서 동작해 계산량을 줄이며, GAN보다 학습이 안정적이고 다양성이 높지만 반복 단계 때문에 생성이 느려 단계 축소 기법이 연구된다.

연관 노이즈 제거, 잠재 공간, 플로우 매칭, 텍스트-이미지 생성, 확산 트랜스포머

출처 Wikipedia · Hugging Face · Hugging Face / 논문 Sohl-Dickstein et al. 2015 · Ho et al. 2020 · Rombach et al. 2021

확산 트랜스포머

DiT · Diffusion Transformer

생성 AI·멀티모달 · **심화**

입문 이미지 생성 AI의 핵심 신경망을 언어 모델과 같은 트랜스포머 구조로 바꾼 것이다.

심화 확산·플로우 모델의 노이즈 예측 네트워크로 기존 U-Net 대신 트랜스포머를 사용하는 구조다. 잠재 이미지를 패치 단위 토큰으로 나눠 처리하며, 텍스트 조건은 크로스 어텐션이나 텍스트·이미지 토큰 공동 어텐션으로 주입한다. 모델 크기에 따른 확장성이 좋아 최신 이미지·영상 생성 모델의 주류 백본이 되었다.

연관 확산 모델, 트랜스포머, 플로우 매칭, 영상 생성

출처 Hugging Face / 논문 Peebles, Xie 2022 · Esser et al. 2024

확장 사고

Extended Thinking

프롬프트·추론 · **실무**

입문 AI에게 답하기 전 충분히 생각할 시간을 주는 기능이다. 켜면 느려지지만 어려운 문제를 더 잘 푼다.

심화 하이브리드 추론 모델에서 최종 응답 전에 별도의 사고(thinking) 블록을 생성하도록 켜는 모드다. API에서 사고 토큰 예산이나 노력 수준(effort)을 지정해 깊이를 조절하며, 사고 내용은 요약되거나 숨겨져 반환되기도 한다. 도구 호출 사이사이에 사고하는 방식(interleaved thinking)으로 에이전트 작업 품질을 높이는 데도 쓰인다.

예시 규정 간 충돌 여부 검토처럼 여러 조항을 대조해야 하는 질의에 확장 사고를 켠다.

연관 추론 모델, 사고 예산, 사고의 연쇄, 테스트 타임 컴퓨트

출처 Anthropic · Anthropic

환각

Hallucination

평가·안전·규제 · **입문**

입문 AI가 사실이 아닌 내용을 그럴듯하게 지어내 말하는 현상이다. 모르는 것을 모른다고 하지 않고 자신 있게 틀린 답을 내놓는 것과 비슷하다.

심화 LLM은 다음 토큰의 확률 분포를 따라 문장을 생성하므로 학습 데이터에 없거나 불확실한 내용도 유창하게 만들어낸다. 사실과 다른 내용(사실성 오류)과 주어진 문서와 어긋나는 내용(근거성 오류)으로 나눠 본다. RAG로 근거 문서를 제공하고, 출처 인용 강제, 근거성 평가, 답변 거부 허용 프롬프트 등으로 줄일 수 있으나 완전히 없애기는 어렵다.

예시 약관 상담 챗봇이 존재하지 않는 특약 조항을 안내하지 않도록 RAG와 근거성 평가를 함께 적용한다.

연관 근거성, 검색 증강 생성, 대규모 언어모델, 평가, 가드레일

출처 Wikipedia / 논문 Ji et al. 2022 · Huang et al. 2023

활성화 함수

Activation Function

딥러닝·신경망 · **실무**

입문 신경망의 각 계산 단위가 신호를 얼마나 다음으로 넘길지 정하는 함수다. 이것이 있어야 복잡한 패턴을 표현할 수 있다.

심화 뉴런의 가중합에 적용하는 비선형 함수로, 없으면 층을 아무리 쌓아도 선형 변환에 불과하다. 시그모이드·tanh는 포화 구간에서 기울기 소실을 일으켜, 은닉층에는 ReLU와 그 변형이 주로 쓰인다. 최신 LLM은 GELU, SwiGLU 등을 사용하며 출력층에는 과제에 맞게 소프트맥스·시그모이드를 쓴다.

연관 신경망, 소프트맥스, 기울기 소실, 퍼셉트론

출처 Google for Developers · Wikipedia / 논문 Hendrycks & Gimpel 2016 · Shazeer 2020

활용 사례

Use Case

AX·비즈니스 적용 · **입문**

입문 AI를 적용할 구체적인 업무 장면이다. '누가, 어떤 업무에서, AI로 무엇을 하는가'로 정의한다.

심화 AX 추진 시 후보 사례를 발굴해 업무 효과(시간·비용·리스크), 기술 난이도, 데이터 준비도, 규제 위험 기준으로 우선순위를 매긴다. 효과가 크고 실패 비용이 낮은 내부 업무부터 시작해 고객 대면 업무로 넓히는 방식이 일반적이다.

예시 정보계 팀은 '현업 데이터 요청을 SQL 초안으로 바꾸는 Text-to-SQL'을 1순위 활용 사례로 선정했다.

연관 개념 검증, AX 전환 로드맵, 투자 대비 효과, 업무 재설계

출처 Wikipedia

회귀

Regression

AI 기초·머신러닝 · **입문**

입문 숫자 값을 맞히는 일이다. 집값, 다음 달 매출처럼 크기를 예측할 때 쓴다.

심화 입력으로부터 연속적인 수치를 예측하는 지도학습 과제다. 선형회귀부터 트리 앙상블, 신경망까지 다양한 모델이 쓰이며 MAE, RMSE, R^2 등으로 평가한다. 로지스틱 회귀는 이름과 달리 분류 모델이다.

예시 고객 특성으로 향후 12개월 예상 수익(CLV)을 회귀 모델로 추정한다.

연관 지도학습, 분류, 시계열 예측, 손실 함수

출처 IBM · Wikipedia

회귀 테스트

Regression Testing

평가·안전·규제 · **실무**

입문 프롬프트나 모델을 바꾼 뒤, 예전에 잘 되던 기능이 망가지지 않았는지 다시 확인하는 테스트다.

심화 LLM은 프롬프트 한 줄, 모델 버전 교체, 검색 설정 변경만으로 다른 사례의 출력이 예기치 않게 바뀐다. 골든 데이터셋과 과거 실패 사례를 CI 파이프라인에서 자동 실행하고, 기준 대비 점수 하락이 있으면 배포를 막는다. 출력이 비결정적이므로 정확 일치보다 루브릭·LLM 심판 기반 채점과 반복 실행 통계를 쓴다.

예시 시스템 프롬프트를 수정할 때마다 골든 데이터셋 300건을 자동 채점해 점수가 기준 이하로 떨어지면 반영을 보류한다.

연관 골든 데이터셋, 평가, 프롬프트 엔지니어링, LLMOps, LLM 심판 평가

출처 Anthropic · Wikipedia

회전 위치 임베딩

RoPE · Rotary Position Embedding

LLM·언어모델 · **심화**

입문 문장에서 각 단어의 순서 정보를 모델에 알려 주는 방법 중 하나로, 현재 LLM에서 널리 쓰인다.

심화 쿼리·키 벡터를 위치에 비례한 각도로 회전시켜 어텐션 점수가 토큰 간 상대 거리에 의존하도록 만든다. 상대 위치를 자연스럽게 반영하고, 주파수 스케일링(NTK, YaRN 등)으로 학습 길이보다 긴 컨텍스트로 확장하기 쉽다.

연관 어텐션, 트랜스포머, 롱 컨텍스트, 셀프 어텐션

논문 Su et al. 2021 · Peng et al. 2023

휴먼 인 더 루프

HITL · Human-in-the-Loop

AI 에이전트·도구 · **입문**

입문 AI가 일하는 중간중간 사람이 확인하고 승인하거나 수정하는 방식이다. 중요한 결정은 사람이 최종 확인한다.

심화 에이전트 실행 흐름에 사람의 승인·검토·수정 지점을 명시적으로 넣는 설계다. 송금·삭제·외부 발송처럼 되돌리기 어려운 행동 전에 실행을 일시 정지하고 승인을 받거나, 신뢰도가 낮은 결과만 사람에게 넘기는 방식으로 구현한다. 안전성과 책임 소재가 명확해지는 대신 처리 속도가 느려지므로 위험도에 따라 개입 지점을 차등화한다.

예시 AI가 작성한 고객 안내 문자는 준법감시 담당자의 승인 후에만 발송된다.

연관 에이전트 권한 관리, 자율성 수준, 가드레일, AI 거버넌스

출처 IBM · LangChain · Wikipedia

A

AI 거버넌스

AI Governance

AX·비즈니스 적용 · **실무**

입문 조직이 AI를 안전하고 책임 있게 쓰도록 정한 원칙, 조직, 절차, 통제 체계다.

심화 AI 활용 정책, 사용 사례 위험 등급 분류, 승인 절차, 모델 검증·모니터링, 데이터·개인정보 보호, 책임 소재, 감사 대응을 포함한다. 금융권은 금융당국의 AI 가이드라인과 AI 기본법, 모델 위험관리 체계와 연계해 운영해야 한다.

예시 생성형 AI 사용 사례를 위험 등급별로 분류하고 고위험 업무는 AI 위원회 승인 후 운영하도록 했다.

연관 책임 있는 AI, 인공지능 기본법, AI 전담 조직, 모델 레지스트리, 섀도 AI

출처 NIST · EUR-Lex (European Union) · IBM

AI 네이티브

AI Native

AX·비즈니스 적용 · **실무**

입문 처음부터 AI를 전제로 설계된 조직, 서비스, 업무 방식을 말한다.

심화 기존 업무에 AI를 덧붙이는 AI 적용(AI-enabled)과 달리, 업무 흐름·제품 구조·조직 역할이 AI 수행을 기본값으로 짜인 상태다. 데이터 접근성, 자동화 가능한 시스템 인터페이스, 사람의 역할을 감독·판단 중심으로 재정의하는 것이 특징이며 AX의 지향점으로 언급된다.

예시 신규 디지털 상품 조직은 기획 단계부터 AI 상담과 AI 문서 생성을 전제로 프로세스를 설계했다.

연관 AI 전환, 업무 재설계, AI 에이전트, AI 성숙도 모델

AI 도입

AI Adoption

AX·비즈니스 적용 · **입문**

입문 조직이 AI를 실제 업무에 들여와 꾸준히 쓰게 되는 과정이다.

심화 도입은 도구 배포가 아니라 실제 활용률이 오르는 것으로 판단한다. 주간 활성 사용자, 업무별 사용 빈도, 재사용률 같은 지표로 추적하며, 접근성(업무 시스템 내장), 신뢰(정확도), 교육, 규정 명확성이 활용률을 좌우한다.

예시 사내 LLM 포털 오픈 후 3개월간 부서별 주간 활성 사용자 비율을 추적해 저조 부서에 맞춤 교육을 진행했다.

연관 AI 성숙도 모델, 변화관리, 사내 LLM 포털, 생산성 지표

출처 Wikipedia · Wikipedia

AI 리터러시

AI Literacy

AX·비즈니스 적용 · **입문**

입문 AI가 무엇을 잘하고 못하는지 이해하고, 업무에 올바르고 안전하게 활용할 수 있는 기본 소양이다.

심화 생성형 AI의 원리와 한계(환각, 편향), 효과적인 프롬프트 작성, 결과 검증, 보안·개인정보 유의사항, 저작권 인식을 포함한다. 전 직원 대상 기초 교육과 직무별 심화 교육으로 계층화하며, EU AI Act 등 일부 규제는 AI 리터러시 확보를 사업자 의무로 두고 있다.

예시 전 직원 대상 AI 리터러시 교육에서 고객정보를 외부 AI 서비스에 입력하면 안 되는 이유를 사례로 다뤘다.

연관 리스킬링·업스킬링, 프롬프트 엔지니어링, 환각, AI 챔피언

출처 European Commission AI Act Service Desk · EU Artificial Intelligence Act (artificialintelligenceact.eu) / 논문 Long and Magerko 2020

AI 비용

AI Cost

AX·비즈니스 적용 · **실무**

입문 AI를 도입하고 운영하는 데 드는 모든 비용이다. 사용료뿐 아니라 인력, 인프라, 관리 비용까지 포함한다.

심화 API 토큰 요금이나 GPU·전력 등 인프라 비용, 데이터 준비·연계 개발, 평가·모니터링, 보안 통제, 교육·변화관리 비용으로 구성된다. 사용량 증가에 따라 비용이 비선형으로 늘 수 있어 부서별 사용량 배분(chargeback), 모델 라우팅, 캐싱으로 관리한다.

예시 사내 LLM 사용 비용을 부서별 토큰 사용량 기준으로 배분해 비용 인식을 높였다.

연관 토큰 비용, 총소유비용, 투자 대비 효과, 모델 게이트웨이

AI 성숙도 모델

AI Maturity Model

AX·비즈니스 적용 · **실무**

입문 조직의 AI 활용 수준을 단계별로 진단해 현재 위치와 다음 목표를 정하는 평가 틀이다.

심화 전략, 데이터, 인프라, 인재, 거버넌스, 활용 범위 등을 축으로 탐색-실험-운영-확산-내재화 같은 단계를 정의한다. 현황 진단과 로드맵 수립, 부서 간 비교의 공통 언어로 쓰이며, 점수 자체보다 다음 단계로 가기 위한 구체 과제 도출에 의미가 있다.

예시 AX 착수 전 전 부서를 대상으로 AI 성숙도를 진단해 데이터 준비도가 높은 정보계를 우선 실증 대상으로 정했다.

연관 AX 전환 로드맵, AI 도입, AI 전략, AI 네이티브

AI 안전연구소

AISI · AI Safety Institute

평가·안전·규제 · **실무**

입문 첨단 AI의 위험을 평가하고 안전 기준을 연구하는 정부 산하 기관이다.

심화 2023년 영국 AI 안전 정상회의를 계기로 영국·미국·일본 등이 설립했고, 한국도 2024년 11월 ETRI 산하에 AI안전연구소를 출범했다. 최첨단 모델의 출시 전후 위험 평가, 평가 방법론·기준 연구, 국제 연구소 네트워크를 통한 공동 평가를 수행한다. 이후 영국은 AI Security Institute, 미국은 CAISI로 명칭과 초점을 바꾸는 등 국가별로 역할이 조정되고 있다.

예시 국내 AI 안전 평가 기준이나 가이드를 확인할 때 AI안전연구소 발간 자료를 참고한다.

연관 평가, 레드티밍, 인공지능 기본법, 책임 있는 확장 정책, 파운데이션 모델

출처 AI안전연구소(한국) · UK AI Security Institute · Wikipedia

AI 에이전트

AI Agent

AI 에이전트·도구 · **입문**

입문 목표를 주면 스스로 계획을 세우고 도구를 써 가며 일을 끝까지 처리하는 AI다. 질문에 답만 하는 챗봇보다 '일을 맡길 수 있는 비서'에 가깝다.

심화 LLM을 추론 엔진으로 두고 관찰-판단-행동을 반복하는 루프 안에서 도구 호출, 메모리, 계획 수립을 결합한 시스템이다. 핵심 구성요소는 모델, 도구(API·코드 실행·검색), 상태·메모리, 종료 조건과 가드레일이다. 자율성이 높을수록 처리 범위는 넓어지지만 오류 누적, 비용 증가, 권한 오남용 위험도 커지므로 권한 범위와 사람의 승인 지점을 설계해야 한다.

예시 여신 심사 담당자가 요청하면 에이전트가 고객 거래내역 조회, 재무제표 요약, 내부 규정 검색을 차례로 수행해 심사 의견 초안을 만든다.

연관 에이전트 루프, 도구 사용, 계획 수립, 에이전트 메모리, 대규모 언어모델

출처 IBM · Anthropic · Wikipedia / 논문 Wang et al. 2023 · Xi et al. 2023

AI 위험관리 프레임워크

AI RMF · AI Risk Management Framework

평가·안전·규제 · **실무**

입문 AI로 생길 수 있는 위험을 찾고, 평가하고, 관리하는 절차를 체계적으로 정리한 틀이다.

심화 대표적으로 미국 NIST AI RMF는 Govern(거버넌스), Map(맥락·위험 식별), Measure(측정), Manage(대응)의 네 기능으로 구성되며 생성형 AI 프로파일도 제공한다. ISO/IEC 42001(AI 경영시스템)과 국내 금융분야 AI 위험관리 프레임워크도 같은 목적이다. 기업은 이를 바탕으로 AI 자산 목록, 위험 등급 분류, 통제 항목, 모니터링 지표를 정의한다.

예시 AI 과제별 위험 등급을 매겨 고위험 과제는 출시 전 독립 검증과 레드티밍을 의무화한다.

연관 AI 거버넌스, 책임 있는 AI, 금융분야 AI 가이드라인, 감사 추적, 고영향 인공지능

출처 NIST · NIST · ISO

AI 전담 조직

AI CoE · AI Center of Excellence

AX·비즈니스 적용 · **실무**

입문 회사 전체의 AI 활용을 이끌고 지원하는 전문 조직이다. 기술, 표준, 교육, 거버넌스를 한곳에서 맡는다.

심화 공통 플랫폼·도구 제공, 활용 사례 발굴 지원, 표준·가이드 수립, 인력 양성, 성과 관리를 담당한다. 중앙집중형, 현업 분산형, 허브앤스포크형이 있으며 초기에는 중앙에서 역량을 모은 뒤 현업으로 확산하는 허브앤스포크형이 흔하다.

예시 IT와 디지털 부서 인력을 모아 AI CoE를 만들고 각 사업부에 AI 챔피언을 두는 허브앤스포크 구조를 택했다.

연관 AI 거버넌스, AI 챔피언, AI 전략, 내재화

출처 Wikipedia · TechTarget

AI 전략

AI Strategy

AX·비즈니스 적용 · **실무**

입문 회사가 AI로 무엇을 달성할지, 어디에 투자하고 어떻게 추진할지 정한 큰 방향이다.

심화 사업 목표와 연결된 AI 비전, 우선 영역, 투자 규모, 인프라·모델 선택 원칙(구축/구매, 클라우드/온프레미스), 데이터 전략, 인재 확보, 거버넌스를 포함한다. 기술 도입 자체가 목표가 되지 않도록 비즈니스 성과 지표와 연결하는 것이 핵심이다.

예시 그룹 AI 전략에서 내부 생산성, 고객 경험, 리스크 관리의 3대 영역과 영역별 핵심 지표를 정했다.

연관 AX 전환 로드맵, AI 거버넌스, 자체 구축 대 구매, 데이터 기반 의사결정

AI 전환

AX · AI Transformation

AX·비즈니스 적용 · **입문**

입문 AI를 단순 도구로 쓰는 것을 넘어 일하는 방식, 조직, 사업 모델을 AI 중심으로 바꾸는 것이다.

심화 DX가 디지털화를 통한 효율화라면 AX는 AI가 업무 판단·생성·자동화를 맡도록 프로세스와 역할을 재설계하는 단계다. 전략, 데이터·인프라, 거버넌스, 인력 역량, 변화관리가 함께 움직여야 하며 개별 PoC 성공만으로는 전환이 이뤄지지 않는다.

예시 은행이 여신 심사 서류 검토, 콜센터 상담 요약, 내부 보고서 작성을 AI 기반으로 재설계하는 것이 AX의 예다.

연관 디지털 전환, AX 전환 로드맵, 업무 재설계, 변화관리, AI 전략

출처 IBM

AI 챔피언

AI Champion

AX·비즈니스 적용 · **실무**

입문 각 부서에서 AI 활용을 먼저 익히고 동료를 돕고 이끄는 현업 대표자다.

심화 부서 내 활용 사례 발굴, 동료 교육·질의 응대, 현업 요구사항을 AI CoE에 전달하는 가교 역할을 한다. 중앙 조직만으로는 전사 확산이 어려워 챔피언 네트워크가 변화관리의 핵심 수단이 되며, 역할 시간 보장과 성과 인정 체계가 있어야 지속된다.

예시 부서별 AI 챔피언 30명을 선발해 심화 교육 후 부서 내 활용 사례 발굴을 맡겼다.

연관 변화관리, AI 전담 조직, AI 리터러시, 프롬프트 라이브러리

AI 피드백 기반 강화학습

RLAIF · Reinforcement Learning from AI Feedback

학습·튜닝·정렬 · **심화**

입문 사람 대신 다른 AI가 답변의 좋고 나쁨을 평가해 주고, 그 평가로 모델을 강화학습시키는 방법이다.

심화 LLM 평가자가 원칙이나 루브릭에 따라 선호 레이블을 생성하고 이를 보상모델 학습이나 직접 보상으로 사용한다. 대규모 피드백을 저비용으로 얻을 수 있지만 평가 모델의 편향과 약점이 그대로 전이될 수 있다. 헌법적 AI가 대표적 적용 사례다.

연관 인간 피드백 기반 강화학습, 헌법적 AI, LLM 심판 평가, 보상모델

출처 Anthropic / 논문 Lee et al. 2023 · Bai et al. 2022

API

API · Application Programming Interface

인프라·배포·LLMOps · **입문**

입문 프로그램끼리 정해진 규칙으로 기능을 주고받는 창구다. AI 서비스에서는 모델을 호출하는 통로를 뜻한다.

심화 LLM API는 보통 HTTP(REST) 요청에 메시지·파라미터를 담아 보내고 텍스트나 스트리밍 응답을 받는다. 사용량은 입력·출력 토큰 단위로 과금되며 레이트 리밋이 걸린다. 여러 제공사가 OpenAI 호환 형식을 지원해 교체가 비교적 쉽지만 기능 차이로 완전 호환은 아니다.

예시 기존 Java 기반 업무 시스템에서 사내 LLM API를 호출해 민원 요약 기능을 붙였다.

연관 레이트 리밋, 토큰 비용, 모델 게이트웨이, 함수 호출

출처 AWS

AX 전환 로드맵

AX Transformation Roadmap

AX·비즈니스 적용 · **실무**

입문 AI 전환을 어떤 순서와 일정으로 추진할지 단계별로 정리한 계획이다.

심화 현황 진단(데이터, 인프라, 역량, 규제) → 활용 사례 발굴·우선순위 → PoC·파일럿 → 확산 → 내재화 순으로 구성하고, 각 단계에 목표 지표, 투자, 조직·거버넌스 과제를 배치한다. 기술 트렌드와 규제 변화가 빠르므로 반기 단위로 재검토하는 이동형 계획이 적합하다.

예시 1단계 내부 업무 코파일럿, 2단계 정보계 Text-to-SQL·보고 자동화, 3단계 고객 대면 서비스 순으로 3개년 로드맵을 수립했다.

연관 AI 전환, AI 전략, AI 성숙도 모델, 확산

출처 IBM

A/B 테스트

A/B Testing

인프라·배포·LLMOps · **실무**

입문 사용자를 두 그룹으로 나눠 서로 다른 버전을 써보게 하고 어느 쪽이 나은지 비교하는 실험이다.

심화 트래픽 일부를 새 모델·프롬프트로 보내 응답 품질, 사용자 만족도, 업무 완료율, 비용, 지연을 대조군과 비교한다. 오프라인 평가로 걸러진 후보를 실제 환경에서 검증하는 단계이며, 통계적 유의성 확보를 위한 표본 크기와 실험 기간을 사전에 정해야 한다. 카나리 배포와 함께 쓰인다.

예시 콜센터 요약 기능에서 신규 프롬프트를 상담사 10%에게 먼저 적용해 수정률을 비교했다.

연관 평가, LLMOps, 생산성 지표, 관측 가능성

출처 Wikipedia

B

BM25

BM25 · Best Matching 25

RAG·검색·데이터 · **심화**

입문 검색어 단어가 문서에 얼마나 자주, 얼마나 특별하게 나오는지로 점수를 매기는 전통적인 키워드 검색 방식이다.

심화 TF-IDF를 개선한 확률적 랭킹 함수로, 단어 빈도의 포화와 문서 길이 정규화를 반영한다. Elasticsearch·OpenSearch 등의 기본 랭킹이며 학습이 필요 없고 정확한 용어 일치에 강하다. 한국어는 형태소 분석기 선택이 성능을 좌우하며, RAG에서는 의미 검색과 결합하는 하이브리드의 한 축으로 쓰인다.

예시 'DSR 40%' 같은 정확한 용어·수치가 들어간 규정 검색에 BM25를 함께 사용한다.

연관 하이브리드 검색, 의미 검색, 검색(리트리벌), 재순위화

출처 Wikipedia · Elastic / 논문 Robertson and Zaragoza 2009

C

CUDA

CUDA · Compute Unified Device Architecture

인프라·배포·LLMOps · **심화**

입문 NVIDIA GPU에서 범용 계산을 할 수 있게 해주는 프로그래밍 플랫폼이다. 대부분의 AI 소프트웨어가 그 위에서 돌아간다.

심화 GPU 커널 작성 언어 확장, 런타임, 그리고 cuBLAS·cuDNN·NCCL 같은 라이브러리로 구성된다. PyTorch 등 주요 프레임워크와 추론 엔진이 CUDA에 최적화돼 있어 강한 생태계 종속을 만든다. 폐쇄망에서는 드라이버·CUDA·프레임워크 버전 호환을 맞춘 이미지를 사전에 준비해야 한다.

예시 폐쇄망 반입 전 GPU 드라이버와 CUDA, vLLM 버전 조합을 외부 검증 환경에서 미리 맞춰 두었다.

연관 GPU, TensorRT, 벤더 종속, 폐쇄망 배포

출처 NVIDIA

E

EU 인공지능법

EU AI Act · EU Artificial Intelligence Act

평가·안전·규제 · **입문**

입문 유럽연합이 AI를 위험 수준별로 나눠 규제하는 법이다. 위험이 클수록 더 엄격한 의무를 지운다.

심화 AI를 금지·고위험·투명성 의무·최소 위험으로 나누는 위험 기반 규제다. 2024년 8월 발효 후 단계적으로 적용돼 금지 관행은 2025년 2월, 범용 AI(GPAI) 모델 의무는 2025년 8월, 챗봇 고지·딥페이크 표시 등 투명성 의무는 2026년 8월부터 적용됐다. 2026년 7월 발효된 디지털 옴니버스 개정으로 고위험 AI 의무는 채용·신용평가 등 부속서 III 영역이 2027년 12월, 제품 안전 규제와 연계된 부속서 I 영역이 2028년 8월로 연기됐다. EU 시장에 제공되면 역외 기업에도 적용된다.

예시 유럽 고객 대상 신용평가 AI를 운영하는 금융사는 고위험 AI 요건(위험관리, 데이터 거버넌스, 기록, 사람의 감독) 준비 일정을 개정 일정에 맞춰 재수립한다.

연관 인공지능 기본법, 고영향 인공지능, 워터마킹, AI 거버넌스, 파운데이션 모델

출처 EUR-Lex (Publications Office of the EU) · European Commission · Wikipedia

F

F1 점수

F1 · F1 Score

AI 기초·머신러닝 · **실무**

입문 정밀도와 재현율을 하나로 합친 점수다. 둘 중 하나만 높으면 점수가 잘 오르지 않는다.

심화 정밀도와 재현율의 조화평균, 2PR/(P+R)이다. 두 지표의 균형을 단일 수치로 비교할 때 쓴다. 다중 클래스에서는 macro·micro·weighted 평균을 구분해야 하며, 재현율 비중을 키우려면 F-beta 점수를 쓴다.

예시 고객 민원 자동 분류 모델들을 macro F1로 비교해 소수 민원 유형까지 고르게 맞히는 모델을 고른다.

연관 정밀도와 재현율, 혼동행렬, 정확도, 평가

출처 Google for Developers · Wikipedia · scikit-learn / 논문 Sokolova and Lapalme 2009

G

GGUF

GGUF · GGUF (GPT-Generated Unified Format)

인프라·배포·LLMOps · **심화**

입문 양자화된 LLM을 파일 하나로 담아 일반 PC나 CPU 서버에서도 쉽게 실행할 수 있게 한 모델 파일 형식이다.

심화 llama.cpp 프로젝트에서 쓰는 형식으로 가중치, 토크나이저, 메타데이터를 단일 파일에 담고 Q4, Q5, Q8 등 다양한 양자화 수준을 지원한다. llama.cpp와 이를 기반으로 한 도구들은 CPU, Apple Silicon, 소비자용 GPU에서 추론을 수행해 GPU 서버 없이 시험 운영이 가능하다. 대규모 동시 접속 서빙에는 vLLM 등 전용 엔진이 더 적합하다.

예시 GPU 도입 전 폐쇄망 개발 PC에서 GGUF 모델로 업무 적용 가능성을 먼저 검증했다.

연관 양자화, 엣지 AI, 폐쇄망 배포, 오픈 웨이트 모델

출처 Hugging Face · ggml-org

GPU

GPU · Graphics Processing Unit

인프라·배포·LLMOps · **입문**

입문 원래 그래픽 처리용 칩이지만, 수천 개의 계산을 동시에 처리할 수 있어 AI 학습과 추론의 핵심 장비가 됐다.

심화 수천 개 코어로 행렬 곱셈을 병렬 수행해 신경망 연산에 적합하다. LLM 성능은 연산량뿐 아니라 GPU 메모리 용량과 대역폭(HBM)에 크게 좌우되며, 모델 크기가 메모리를 넘으면 여러 GPU에 텐서·파이프라인 병렬로 분산한다. 공급 부족과 높은 가격, 전력·냉각 부담이 도입 시 주요 제약이다.

예시 사내 LLM을 온프레미스로 운영하려면 70B급 모델 기준 고용량 메모리 GPU 여러 장을 갖춘 서버가 필요하다.

연관 NPU, 고대역폭 메모리, CUDA, 추론 서빙, 데이터센터 전력

출처 Wikipedia

H

HNSW

HNSW · Hierarchical Navigable Small World

RAG·검색·데이터 · **심화**

입문 벡터들을 여러 층의 연결망으로 엮어, 위층에서 큰 방향을 잡고 아래층에서 세밀하게 찾아가는 빠른 검색 구조다.

심화 계층형 근접 그래프 기반 ANN 인덱스로, 상위 층의 희소한 연결로 빠르게 이동한 뒤 하위 층에서 정밀 탐색한다. 높은 재현율과 낮은 지연으로 대부분 벡터 DB의 기본 인덱스지만 메모리 사용량이 크고 인덱스 구축 시간이 길다. M(연결 수), ef_construction, ef_search 파라미터로 성능을 조정한다.

예시 벡터 인덱스를 HNSW로 생성하고 ef_search를 조정해 응답 속도와 검색 정확도를 맞춘다.

연관 근사 최근접 이웃 검색, 벡터 인덱스, 벡터 데이터베이스

출처 Wikipedia · Microsoft / 논문 Malkov and Yashunin 2016

K

KL 패널티

KL Divergence Penalty

학습·튜닝·정렬 · **심화**

입문 강화학습 중 모델이 원래 모습에서 너무 멀어지지 않도록 거는 제동 장치다.

심화 정책과 기준(SFT) 모델 출력분포 간 KL 발산을 보상에서 빼거나 손실에 더해 과도한 분포 이동을 억제한다. 보상 해킹과 언어 품질 붕괴를 막는 역할을 하며, 계수 β로 탐색과 안정성 사이 균형을 조절한다. DPO에서도 같은 β가 암묵적으로 이 역할을 한다.

연관 근접 정책 최적화, 인간 피드백 기반 강화학습, 보상 해킹, 직접 선호 최적화

출처 Hugging Face · Wikipedia / 논문 Jaques et al. 2016 · Ziegler et al. 2019

KV 캐시

Key-Value Cache

LLM·언어모델 · **심화**

입문 앞에서 이미 계산한 내용을 저장해 두고 재사용해 답변 생성을 빠르게 하는 기법이다.

심화 자기회귀 생성 시 이전 토큰들의 어텐션 Key·Value 텐서를 저장해 매 스텝 재계산을 피한다. 메모리 사용량이 배치 크기×시퀀스 길이×층 수×헤드 차원에 비례해 긴 컨텍스트 서빙의 병목이 된다. GQA, 페이지드 어텐션, KV 양자화 등으로 메모리를 줄인다.

연관 어텐션, 추론 서빙, vLLM, 프롬프트 캐싱, 그룹 쿼리 어텐션

출처 Hugging Face / 논문 Kwon et al. 2023 · Shazeer 2019

L

LLMOps

LLMOps · Large Language Model Operations

인프라·배포·LLMOps · **실무**

입문 LLM 기반 서비스를 안정적으로 만들고 운영·개선하는 일련의 관리 체계다.

심화 MLOps를 LLM 특성에 맞게 확장한 개념으로 프롬프트·모델 버전 관리, 평가(eval) 파이프라인, 가드레일, 비용·토큰 모니터링, 트레이싱, 피드백 수집, 배포 롤백을 포함한다. 모델 자체를 학습하지 않더라도 프롬프트·RAG 구성 변경이 품질을 바꾸므로 회귀 평가가 핵심이다.

예시 프롬프트를 수정할 때마다 금융 상품 Q&A 평가셋으로 자동 회귀 테스트를 돌린 뒤 배포한다.

연관 MLOps, 관측 가능성, 평가, 모델 레지스트리, 가드레일

출처 Databricks

LLM 심판 평가

LLM-as-a-Judge

평가·안전·규제 · **실무**

입문 사람 대신 다른 AI에게 답변의 품질을 채점시키는 평가 방법이다.

심화 평가 기준(정확성, 근거성, 어조 등)과 채점 루브릭을 프롬프트로 주고 판정 모델이 점수나 쌍대 비교 결과를 내게 한다. 사람 평가보다 빠르고 저렴해 대량 회귀 테스트에 적합하다. 다만 긴 답을 선호하는 길이 편향, 앞에 제시된 답을 선호하는 위치 편향, 자기 모델 선호 편향이 있어 사람 평가와의 일치도를 주기적으로 검증해야 한다.

예시 프롬프트 수정 후 상담 답변 500건을 LLM 심판으로 채점하고, 일부를 표본 추출해 담당자가 교차 검토한다.

연관 평가, 인간 평가, 회귀 테스트, 골든 데이터셋, 근거성

출처 Anthropic (Claude Platform Docs) / 논문 Zheng et al. 2023

M

MCP 서버

MCP Server

AI 에이전트·도구 · **심화**

입문 특정 시스템이나 데이터를 MCP 규격으로 AI에 열어 주는 연결 프로그램이다.

심화 MCP 규격에 따라 도구(실행 가능한 함수), 리소스(읽기용 데이터), 프롬프트(템플릿)를 노출하는 프로세스나 서비스다. 로컬에서 stdio로 실행하거나 원격 HTTP 서비스로 배포하며, 원격 서버는 OAuth 기반 인가로 접근을 통제한다. 서버가 반환하는 도구 설명과 데이터도 모델 입력이 되므로 신뢰할 수 있는 서버만 연결하고 권한을 최소화해야 한다.

예시 사내 DW의 승인된 조회 뷰만 노출하는 읽기 전용 MCP 서버를 만들어 분석용 AI에 연결한다.

연관 모델 컨텍스트 프로토콜, MCP 클라이언트, 커넥터, 도구 스키마

출처 Model Context Protocol · Model Context Protocol · Model Context Protocol

MCP 클라이언트

MCP Client

AI 에이전트·도구 · **심화**

입문 AI 앱 안에서 MCP 서버에 접속해 도구와 데이터를 가져오는 연결 담당 부분이다.

심화 호스트 애플리케이션(챗 앱, IDE, 에이전트 런타임) 내부에서 MCP 서버와 1:1 연결을 맺고, 기능 협상, 도구 목록 조회, 도구 호출 전달, 결과 수신을 처리하는 구성요소다. 호스트는 여러 클라이언트를 통해 다수의 서버를 동시에 연결하며, 어떤 서버를 허용하고 어떤 도구 호출에 사용자 승인을 받을지 정책을 관리한다.

연관 모델 컨텍스트 프로토콜, MCP 서버, 커넥터, 에이전트 권한 관리

출처 Model Context Protocol · Model Context Protocol

MLOps

MLOps · Machine Learning Operations

인프라·배포·LLMOps · **실무**

입문 머신러닝 모델의 개발·배포·운영을 자동화하고 체계화하는 방법론이다. 소프트웨어의 DevOps를 ML에 적용한 것이다.

심화 데이터 버전 관리, 실험 추적, 학습 파이프라인, 모델 레지스트리, CI/CD, 서빙, 드리프트 모니터링, 재학습 주기를 포괄한다. 모델 성능은 데이터 변화에 따라 저하되므로 배포 후 지속 감시와 재학습 체계가 필수다.

예시 신용평가 모델의 입력 분포 변화를 매월 점검하고 기준 초과 시 재학습 파이프라인을 실행한다.

연관 LLMOps, 모델 레지스트리, 드리프트 모니터링, 데이터 파이프라인

출처 Wikipedia / 논문 Sculley et al. 2015 · Kreuzberger et al. 2022

MMLU

MMLU · Massive Multitask Language Understanding

평가·안전·규제 · **실무**

입문 수학·역사·법·의학 등 57개 분야 객관식 문제로 AI의 폭넓은 지식을 재는 대표 시험이다.

심화 4지선다 문제 약 1만 6천 개로 구성된 지식·이해 벤치마크로, 오랫동안 LLM 성능 비교의 기본 지표였다. 최신 모델들이 높은 점수에 도달하면서 변별력이 떨어지는 포화 문제와 문항 오류, 학습 데이터 오염 문제가 제기돼 더 어려운 MMLU-Pro 등 후속 벤치마크와 한국어 지식을 묻는 KMMLU 같은 변형이 쓰인다.

예시 한국어 업무용 모델 후보를 고를 때 MMLU 대신 KMMLU 점수를 참고 지표로 본다.

연관 벤치마크, 리더보드, 데이터 오염, SWE-bench, 대규모 언어모델

출처 Wikipedia / 논문 Hendrycks et al. 2020 · Wang et al. 2024

N

NPU

NPU · Neural Processing Unit

인프라·배포·LLMOps · **실무**

입문 AI 연산만을 위해 설계된 전용 칩이다. 범용성은 GPU보다 낮지만 전력 대비 효율이 높다.

심화 행렬 곱·합성곱 등 신경망 연산에 특화된 가속기로, 스마트폰·PC에 내장되는 온디바이스용과 데이터센터용 추론 가속기로 나뉜다. 전력 효율과 비용에서 이점이 있으나 소프트웨어 생태계(컴파일러, 커널, 프레임워크 지원)가 GPU보다 좁아 모델 이식 검증이 필요하다. 국내에서도 여러 기업이 데이터센터용 NPU를 개발하고 있다.

예시 공공·금융 분야에서는 국산 NPU 기반 추론 서버로 소버린 AI 인프라를 실증하는 사례가 늘고 있다.

연관 GPU, 엣지 AI, 소버린 AI, 추론 서빙

출처 Wikipedia

P

PII 마스킹

PII · PII Masking

평가·안전·규제 · **실무**

입문 이름·전화번호·계좌번호 같은 개인식별정보(PII)를 AI에 보내기 전에 가리거나 다른 값으로 바꾸는 처리다.

심화 정규식(주민번호·카드번호 패턴)과 개체명 인식 모델로 PII를 탐지한 뒤 별표 마스킹, 토큰 치환, 가명 대체를 한다. 치환 시 매핑을 보관해 응답에서 원래 값으로 복원하는 방식도 쓴다. 한국어 이름·주소는 패턴 탐지가 어려워 오탐·미탐 평가가 필요하며, 입력뿐 아니라 로그와 출력에도 적용해야 한다.

예시 상담 녹취록을 요약 모델에 보내기 전 고객 이름과 연락처를 [고객명], [전화번호]로 치환한다.

연관 데이터 프라이버시, 가명처리, 가드레일, 데이터 유출, 콘텐츠 필터

출처 Google Cloud · Microsoft

R

ROC 곡선과 AUC

AUC · ROC Curve and Area Under the Curve

AI 기초·머신러닝 · **심화**

입문 AI가 '위험한 것'을 '안전한 것'보다 얼마나 일관되게 더 위험하다고 점수 매기는지 보여주는 지표다. 1에 가까울수록 좋다.

심화 ROC는 임계값을 바꿔가며 재현율(TPR)과 위양성률(FPR)을 그린 곡선이고, AUC는 그 아래 면적이다. 임의의 양성·음성 쌍에서 양성 점수가 더 높을 확률로 해석되며 임계값에 독립적이다. 불균형이 심하면 PR 곡선의 AUC가 더 민감한 지표다. 신용평가에서는 AUC와 동치인 지니계수(2·AUC−1), KS 통계량도 흔히 쓴다.

예시 신규 신용평가 모델의 AUC와 KS를 기존 모델과 비교해 교체 여부를 판단한다.

연관 정밀도와 재현율, 분류, 로지스틱 회귀, 평가

출처 Google for Developers · Wikipedia / 논문 Hanley and McNeil 1982 · Fawcett 2006 · Davis and Goadrich 2006

S

SWE-bench

SWE-bench

평가·안전·규제 · 심화

입문 실제 오픈소스 프로젝트의 버그 이슈를 AI가 코드를 고쳐 해결할 수 있는지 시험하는 코딩 벤치마크다.

심화 GitHub 파이썬 저장소의 실제 이슈와 해당 수정을 검증하는 테스트로 구성되며, 모델이 저장소를 탐색해 패치를 만들고 테스트 통과 여부로 채점한다. 사람이 문제 품질을 검수한 Verified 등 하위 세트가 있다. 단순 코드 생성이 아니라 탐색·수정·검증을 반복하는 코딩 에이전트 능력을 재는 지표로 널리 쓰인다.

예시 사내 코딩 에이전트 도입 시 SWE-bench 점수를 참고하되, 자사 코드베이스 이슈로 별도 시범 평가를 한다.

연관 벤치마크, 코딩 에이전트, AI 에이전트, 리더보드, 평가

출처 SWE-bench / 논문 Jimenez et al. 2023

T

TensorRT

TensorRT

인프라·배포·LLMOps · 심화

입문 NVIDIA GPU에서 AI 모델을 최대한 빠르게 실행하도록 최적화해 주는 도구다.

심화 그래프 최적화, 커널 퓨전, FP8·INT8 양자화, 하드웨어별 커널 선택으로 추론을 가속하는 SDK다. LLM용 TensorRT-LLM은 인플라이트 배칭, 페이지드 KV 캐시, 텐서 병렬을 지원하며 Triton 서버와 함께 쓰인다. 성능은 높지만 모델별 엔진 빌드가 필요하고 NVIDIA 하드웨어에 종속된다.

연관 추론 서빙, vLLM, CUDA, 양자화

출처 NVIDIA · NVIDIA

Top-k 샘플링

Top-k Sampling

LLM·언어모델 · 실무

입문 확률이 가장 높은 k개 후보 안에서만 다음 단어를 고르게 하는 설정이다.

심화 상위 k개 토큰만 남기고 나머지 확률을 0으로 만든 뒤 재정규화해 샘플링한다. 구현이 단순하지만 분포 모양과 무관하게 후보 수가 고정되어, 확신이 높을 때는 불필요한 후보가, 불확실할 때는 후보가 부족할 수 있다. 그래서 Top-p와 병행하는 경우가 많다.

연관 Top-p 샘플링, 온도, 샘플링

출처 Hugging Face · Hugging Face / 논문 Fan et al. 2018

Top-p 샘플링

Top-p (Nucleus) Sampling

LLM·언어모델 · 실무

입문 확률이 높은 후보 단어들만 모아 그 안에서 고르게 하는 설정이다. 엉뚱한 단어가 나올 확률을 줄인다.

심화 누적 확률이 p 이상이 될 때까지 확률 순으로 토큰을 모은 최소 집합(nucleus)에서만 샘플링한다. 분포가 뾰족하면 후보가 적고 평평하면 많아져 Top-k보다 적응적이다. 보통 temperature와 함께 쓰며 둘을 동시에 크게 바꾸지 않는 것이 권장된다.

연관 온도, Top-k 샘플링, 샘플링, 로짓

출처 Hugging Face · Hugging Face / 논문 Holtzman et al. 2020

TPU

TPU · Tensor Processing Unit

인프라·배포·LLMOps · 심화

입문 구글이 AI 연산용으로 자체 설계한 전용 칩이다. 주로 구글 클라우드를 통해 쓸 수 있다.

심화 대규모 행렬 연산을 위한 시스톨릭 어레이 구조의 ASIC으로, 여러 칩을 고속 인터커넥트로 묶은 Pod 단위로 대형 모델을 학습·서빙한다. JAX, TensorFlow, PyTorch/XLA로 사용하며, GPU 대비 특정 워크로드의 비용 효율이 높을 수 있으나 클라우드 종속성이 있다.

연관 GPU, NPU, 플롭스, 벤더 종속

출처 Google Cloud · Wikipedia

V

vLLM

vLLM

인프라·배포·LLMOps · 심화

입문 LLM을 빠르고 효율적으로 서비스하기 위한 대표적인 오픈소스 추론 엔진이다.

심화 PagedAttention으로 KV 캐시를 페이지 단위로 관리해 메모리 단편화를 줄이고, 연속 배칭으로 GPU 사용률과 처리량을 높인다. OpenAI 호환 서버, 양자화 모델, 텐서 병렬, 프리픽스 캐싱, LoRA 어댑터 서빙 등을 지원한다. 오픈 웨이트 모델을 자체 인프라에서 서빙할 때 사실상 표준으로 쓰인다.

예시 폐쇄망 GPU 서버에 vLLM 컨테이너 이미지를 반입해 사내 LLM 엔드포인트를 구성했다.

연관 추론 서빙, KV 캐시, 처리량, TensorRT, 오픈 웨이트 모델

출처 vLLM / 논문 Kwon et al. 2023

X

XML 태그 구조화

XML Tag Structuring

프롬프트·추론 · **실무**

입문 프롬프트 안의 지시, 자료, 예시를 <문서>...</문서> 같은 태그로 감싸 AI가 각 부분을 헷갈리지 않게 하는 방법이다.

심화 프롬프트 구성요소를 <instructions>, <document>, <example> 같은 XML 스타일 태그로 구분하는 기법이다. 모델이 지시와 데이터를 명확히 구별해 오해와 인젝션 위험을 줄이고, 출력도 태그로 받으면 파싱이 쉽다. 태그 이름은 정해진 규격이 없으며 일관성 있게 쓰는 것이 중요하다.

예시 <규정>...</규정><질문>...</질문>으로 감싸 규정 원문과 직원 질문을 분리한다.

연관 구분자, 프롬프트 템플릿, 출력 형식 지정, 프롬프트 인젝션

출처 Anthropic · OpenAI

가나다 색인

한글 표제어와 수록 쪽

#

3D 생성 5

ㄱ

가드레일 5
가명처리 5
가상 문서 임베딩 5
간접 프롬프트 인젝션 5
감사 추적 6
강화학습 6
개념 검증 6
검색 증강 생성 6
검색(리트리벌) 6
검증가능 보상 기반 강화학습 6
게이트 순환 유닛 7
결정 트리 7
경사하강법 7
계획 수립 7
고대역폭 메모리 7
고영향 인공지능 8
골든 데이터셋 8
공정성 8
과소적합 8
과적합 8
관측 가능성 8
광학 문자 인식 9
교차검증 9
교차 엔트로피 9
구분자 9
구조화된 출력 9
군집화 9
규제 샌드박스 10
그래디언트 부스팅 10
그래프RAG 10
그래프 신경망 10
그룹 상대 정책 최적화 10
그룹 쿼리 어텐션 10
그리디 디코딩 11
근거성 11
근거 기반 응답(출처 인용) 11
근사 최근접 이웃 검색 11
근접 정책 최적화 11
금융분야 AI 가이드라인 11
기계적 해석가능성 12
기울기 소실 12

ㄴ

내재화 12
네거티브 프롬프트 12
네이티브 멀티모달 12
노이즈 제거 12

ㄷ

다국어 모델 13
다음 토큰 예측 13
다층 퍼셉트론 13
대규모 언어모델 13
데이터센터 전력 13
데이터셋 분할(학습/검증/테스트) 13
데이터 기반 의사결정 14
데이터 누수 14
데이터 레이블링 14
데이터 레이크하우스 14
데이터 병렬화 14
데이터 오염 14
데이터 유출 15
데이터 카탈로그 15
데이터 파이프라인 15
데이터 포이즈닝 15
데이터 품질 15
데이터 프라이버시 15
도구 사용 16
도구 스키마 16
도메인 적응 16
드롭아웃 16
드리프트 모니터링 16
디지털 전환 16
디코더 전용 모델 17
딥러닝 17
딥페이크 17
딥 리서치 17

ㄹ

랜덤 포레스트 17
레드티밍 17
레이어 정규화 18
레이트 리밋 18
로라 18
로지스틱 회귀 18
로짓 18
롱컨텍스트 대 RAG 18
롱 컨텍스트 19
리더보드 19
리스킬링·업스킬링 19
리액트(추론-행동) 19

ㅁ

망분리 규제 개선 19
매개변수 효율적 미세조정 19
맥락 검색 20
머신러닝 20
멀티모달 20
멀티모달 임베딩 20
멀티턴 대화 20
멀티헤드 어텐션 20
멀티홉 검색 21
멀티 에이전트 21
메타데이터 관리 21
메타데이터 필터링 21
메타 프롬프팅 21
모델 21
모델 게이트웨이 22
모델 레지스트리 22
모델 병합 22
모델 카드 22
모델 컨텍스트 프로토콜 22
모델 탈취 22
문맥 압축 23
문서 파싱 23
문서 AI 23

ㅂ

바이브 코딩 23
바이트 페어 인코딩 23
반복 패널티 23
반성(자기 성찰) 24
배치 정규화 24
배치 추론 24
배치 크기 24
범용 인공지능 24
벡터 데이터베이스 24
벡터 인덱스 25
벤더 종속 25
벤치마크 25
변분 오토인코더 25
변화관리 25
보상모델 25
보상 해킹 26
분류 26
분산 학습 26
브라우저 에이전트 26
비동기 처리 26
비정형 데이터 26
비지도학습 27
빔 서치 27

ㅅ

사고의 연쇄 27
사고 예산 27
사내 LLM 포털 27
사용자 프롬프트 27
사전학습 28
사전학습 데이터 정제 28
사후학습 28
상위 k개 검색 28
상태공간모델 28
샘플링 28
생산성 지표 29
생성물 저작권 29
생성적 적대 신경망 29
생성형 AI 29
생성형 AI 표시 의무 29
섀도 AI 29
서브에이전트 30
서비스 수준 협약 30
선호 데이터 30
설명 가능한 AI 30
셀프 어텐션 30
소버린 AI 30
소프트맥스 31
소형 언어모델 31
손실 마스킹 31
손실 함수 31
순환 신경망 31
스케일링 법칙 31
스텝백 프롬프팅 32
스톱 시퀀스 32
스트리밍 응답 32
시각 언어 모델 32
시각 질의응답 32
시계열 예측 32
시맨틱 레이어 33
시맨틱 캐시 33
시스템 카드 33
시스템 프롬프트 33
시티즌 개발자 33
신경망 33
실시간 음성 대화 34

ㅇ

아첨 34
앙상블 학습 34
약인공지능과 강인공지능 34
양자화 34
어댑터 34
어텐션 35
업무 재설계 35
업스케일링 35
에이전트 간 프로토콜 35
에이전트 권한 관리 35
에이전트 루프 35
에이전트 메모리 36
에이전트 상태 관리 36
에이전트 샌드박스 36
에이전트 스킬 36
에이전트 실행 궤적 36
에이전트 지시 파일 36
에이전트 평가 37
에이전트 프레임워크 37
에이전틱 워크플로 37
에이전틱 AI 37
에이전틱 RAG 37
에폭 37
엣지 AI 38
역전파 38
역할 부여(페르소나) 38
영상 생성 38
오케스트레이션 38
오토인코더 38
오프라인·온라인 평가 39
오픈소스 모델 39
오픈 웨이트 모델 39
온도 39
온프레미스 39
옵티마이저 39
요약·재작성 프롬프트 40
워크플로 자동화 40
워터마킹 40
원샷 40
월드 모델 40
위치 인코딩 40
은닉층 41
음성 복제 41
음성 에이전트 41
음성 인식 41
음성 합성 41
음악 생성 41
응답 미리 채우기 42
의미 검색 42
이미지 캡셔닝 42
이미지-이미지 변환 42
이상 탐지 42
인간 평가 42
인간 피드백 기반 강화학습 43
인공지능 43
인공지능 기본법 43
인컨텍스트 러닝 43
인코더 모델 43
인코더-디코더 43
인페인팅 44
임베딩 44
임베딩 모델 44

ㅈ

자기일관성 44
자기지도학습 44
자기회귀 모델 44
자기회귀 이미지 생성 45
자율성 수준 45
자체 구축 대 구매 45
잔차 연결 45
잠재 공간 45
장기 실행 작업 45
장단기 메모리 46
재순위화 46
재시도와 폴백 46
적대적 공격 46
전문가 혼합 46
전이 학습 46
전체 파인튜닝 47
정규화(규제) 47
정렬 47
정밀도와 재현율 47
정형 데이터 47
정확도 47
정확도 48
제로샷 48
조기 종료 48
준지도학습 48
중간 정보 손실 48
지도학습 48
지도 미세조정 49
지속학습 49
지속 사전학습 49
지시 튜닝 49
지식베이스 49
지식 그래프 49
지식 증류 50
지식 컷오프 50
지연 시간 50
직접 선호 최적화 50

ㅊ

차원 축소 50
창발적 능력 50
채팅 템플릿 51
책임 있는 확장 정책 51
책임 있는 AI 51
처리량 51
첫 토큰 지연 51
청크 오버랩 51
청킹 52
체크포인트 52
총소유비용 52
최대 토큰 수 52
추론 52
추론 모델 52
추론 서빙 53
추천 시스템 53
추측 디코딩 53
출력 형식 지정 53

ㅋ

캐시 증강 생성 53
커넥터 53
커리큘럼 학습 54
컨텍스트 엔지니어링 54
컨텍스트 윈도 54
컨트롤넷 54
컴퓨터 사용 54
코딩 에이전트 54
코사인 유사도 55
코파일럿 55
콘텐츠 출처 증명 55
콘텐츠 필터 55
콜드 스타트 55
쿠버네티스 55
쿼리 재작성 56
큐로라 56
클래스 불균형 56
클립(대조 언어-이미지 사전학습) 56

ㅌ

탈옥 56
탈옥 대응 56
테스트 타임 컴퓨트 57
텍스트 인코더 57
텍스트-이미지 생성 57
텍스트-투-SQL 57
텐서 57
텐서 병렬화 57
토크나이저 58
토큰 58
토큰 비용 58
투자 대비 효과 58
튜링 테스트 58
트랜스포머 58
트리 오브 소트 59

ㅍ

파국적 망각 59
파라미터 59
파라미터 수와 모델 크기 59
파운데이션 모델 59
파이프라인 병렬화 59
파인튜닝 60
퍼셉트론 60
편향 60
편향-분산 트레이드오프 60
평가 60
폐쇄망 배포 60
폴백 모델 61
퓨샷 61
프라이빗 클라우드 61
프런티어 모델 61
프롬프트 61
프롬프트 라이브러리 61
프롬프트 버전 관리 62
프롬프트 엔지니어링 62
프롬프트 인젝션 62
프롬프트 체이닝 62
프롬프트 최적화 62
프롬프트 캐싱 62
프롬프트 템플릿 63
플로우 매칭 63
플롭스 63
피처 스케일링(정규화·표준화) 63
피처 엔지니어링 63
피처(특성) 63

ㅎ

하이브리드 검색 64
하이브리드 모델 64
하이브리드 클라우드 64
하이퍼파라미터 64
학습률 64
학습 데이터 64
학습 토큰 수 65
한국어 토큰 효율 65
함수 호출 65
합성곱 신경망 65
합성 데이터 65
핸드오프 65
헌법적 AI 66
혼동행렬 66
혼합정밀도 학습 66
화면 이해 66
확률적 경사하강법 66
확산 66
확산 모델 67
확산 트랜스포머 67
확장 사고 67
환각 67
활성화 함수 67
활용 사례 67
회귀 68
회귀 테스트 68
회전 위치 임베딩 68
휴먼 인 더 루프 68

A

AI 거버넌스 68
AI 네이티브 68
AI 도입 69
AI 리터러시 69
AI 비용 69
AI 성숙도 모델 69
AI 안전연구소 69
AI 에이전트 69
AI 위험관리 프레임워크 70
AI 전담 조직 70
AI 전략 70
AI 전환 70
AI 챔피언 70
AI 피드백 기반 강화학습 70
API 71
AX 전환 로드맵 71
A/B 테스트 71

B

BM25 71

C

CUDA 71

E

EU 인공지능법 72

F

F1 점수 72

G

GGUF 72
GPU 72

H

HNSW 72

K

KL 패널티 73
KV 캐시 73

L

LLMOps 73
LLM 심판 평가 73

M

MCP 서버 73
MCP 클라이언트 73
MLOps 74
MMLU 74

N

NPU 74

P

PII 마스킹 74

R

ROC 곡선과 AUC 74

S

SWE-bench 75

T

TensorRT 75
Top-k 샘플링 75
Top-p 샘플링 75
TPU 75

V

vLLM 75

X

XML 태그 구조화 76

ABC 색인

영문 명칭(약어)으로 한글 표제어 쪽을 찾는다

#

3D Generation 5

A

A/B Testing 71
Accuracy 47
Accuracy 48
Activation Function 67
Adapter 34
Adversarial Attack 46
Agent Evaluation 37
Agent Framework 37
Agent Loop 35
Agent Memory 36
Agent Permission Management 35
Agent Sandbox 36
Agent Skills 36
Agent State Management 36
Agent Trajectory 36
Agent2Agent Protocol (A2A) 35
Agentic AI 37
Agentic RAG 37
Agentic Workflow 37
AGENTS.md 36
AI Adoption 69
AI Agent 69
AI Center of Excellence (AI CoE) 70
AI Champion 70
AI Cost 69
AI Governance 68
AI Insourcing 12
AI Literacy 69
AI Maturity Model 69
AI Native 68
AI Risk Management Framework (AI RMF) 70
AI Safety Institute (AISI) 69
AI Strategy 70
AI Transformation (AX) 70
AI Watermarking 40
AI-Generated Content Labeling Obligation 2 9
Air-Gapped Deployment 60
Alignment 47
Anomaly Detection 42
Application Programming Interface (API) 7 1
Approximate Nearest Neighbor (ANN) 11
Artificial General Intelligence (AGI) 24
Artificial Intelligence (AI) 43
Asynchronous Processing 26
Attention 35
Audit Trail 6
Autoencoder (AE) 38
Autoregressive Image Generation 45
Autoregressive Model 44
AX Transformation Roadmap 71

B

Backpropagation 38
Batch Inference 24
Batch Normalization (BN) 24
Batch Size 24
Beam Search 27
Benchmark 25
Best Matching 25 (BM25) 71
Bias 60
Bias-Variance Tradeoff 60
Browser Agent 26
Build vs. Buy 45
Byte Pair Encoding (BPE) 23

C

Cache-Augmented Generation (CAG) 53
Catastrophic Forgetting 59
Chain-of-Thought (CoT) 27
Change Management 25
Chat Template 51
Checkpoint 52
Chunk Overlap 51
Chunking 52
Citizen Developer 33
Class Imbalance 56
Classification 26
Clustering 9
Coding Agent 54
Cold Start 55
Compute Unified Device Architecture (CUDA) 7 1
Computer Use 54
Confusion Matrix 66
Connector 53
Constitutional AI (CAI) 66
Content Filter 55
Content Provenance (C2PA) (C2PA) 55
Context Engineering 54
Context Window 54
Contextual Compression 23
Contextual Retrieval 20
Continual Learning 49
Continued Pre-training (CPT) 49
Contrastive Language-Image Pre-training (CLIP) 5 6
ControlNet 54
Convolutional Neural Network (CNN) 65
Copilot 55
Copyright of AI-Generated Content 29
Cosine Similarity 55
Cross-Entropy 9
Cross-Validation (CV) 9
Curriculum Learning 54

D

Data Catalog 15
Data Center Power 13
Data Contamination 14
Data Labeling 14
Data Lakehouse 14
Data Leakage 14
Data Leakage 15
Data Parallelism 14
Data Pipeline 15
Data Poisoning 15
Data Privacy 15
Data Quality 15
Data-Driven Decision Making 14
Decision Tree 7
Decoder-Only Model 17
Deep Learning (DL) 17
Deep Research 17
Deepfake 17
Delimiter 9
Denoising 12
Diffusion Model 67
Diffusion Transformer (DiT) 67
Digital Transformation (DX) 16
Dimensionality Reduction 50
Direct Preference Optimization (DPO) 50
Distributed Training 26
Document AI 23
Document Parsing 23
Domain Adaptation 16
Drift Monitoring 16
Dropout 16

E

Early Stopping 48
Edge AI 38
Embedding 44
Embedding Model 44
Emergent Abilities 50
Encoder Model (BERT-style) 43
Encoder-Decoder 43
Ensemble Learning 34
Enterprise LLM Portal 27
Epoch 37
EU Artificial Intelligence Act (EU AI Act) 7 2
Evaluation (Evals) 60
Explainable AI (XAI) 30
Extended Thinking 67

F

F1 Score (F1) 72
Fairness 8
Fallback Model 61
Feature 63
Feature Engineering 63
Feature Scaling 63
Few-shot Prompting 61
Financial Sector AI Guidelines 11
Fine-tuning 60
Floating-Point Operations per Second (FLOPS) 63
Flow Matching 63
Foundation Model 59
Framework Act on the Development of Artificial Intelligence and Establishment of Trust (Korea AI Basic Act) 43
Frontier Model 61
Full Fine-Tuning 47
Function Calling 65

G

Gated Recurrent Unit (GRU) 7
Generative Adversarial Network (GAN) 29
Generative AI (GenAI) 29
GGUF (GPT-Generated Unified Format) (GGUF) 72
Golden Dataset 8
Gradient Boosting (GBM) 10
Gradient Descent 7
Graph Neural Network (GNN) 10
Graphics Processing Unit (GPU) 72
GraphRAG 10
Greedy Decoding 11
Groundedness 11
Grounding and Citation 11
Group Relative Policy Optimization (GRPO) 10
Grouped-Query Attention (GQA) 10
Guardrail 5

H

Hallucination 67
Handoff 65
Hidden Layer 41
Hierarchical Navigable Small World (HNSW) 72
High Bandwidth Memory (HBM) 7
High-Impact AI 8
Human Evaluation 42
Human-in-the-Loop (HITL) 68
Hybrid Architecture Model 64
Hybrid Cloud 64
Hybrid Search 64
Hyperparameter 64
Hypothetical Document Embeddings (HyDE) 5

I

Image Captioning 42
Image-to-Image (I2I) 42
In-Context Learning (ICL) 43
Indirect Prompt Injection 5
Inference 52
Inference Serving 53
Inpainting 44
Instruction Tuning 49

J

Jailbreak 56
Jailbreak Defense 56

K

Key-Value Cache 73
KL Divergence Penalty 73
Knowledge Base (KB) 49
Knowledge Cutoff 50
Knowledge Distillation 50
Knowledge Graph (KG) 49
Korean Token Efficiency 65
Kubernetes (K8s) 55

L

Large Language Model (LLM) 13
Large Language Model Operations (LLMOps) 73
Latency 50
Latent Space 45
Layer Normalization (LN) 18
Leaderboard 19
Learning Rate (LR) 64
Level of Autonomy 45
LLM-as-a-Judge 73
Logistic Regression 18
Logits 18
Long Context 19
Long Context vs RAG 18
Long Short-Term Memory (LSTM) 46
Long-Running Task 45
Loss Function 31
Loss Masking 31
Lost in the Middle 48
Low-Rank Adaptation (LoRA) 18

M

Machine Learning (ML) 20
Machine Learning Operations (MLOps) 74
Massive Multitask Language Understanding (MMLU) 74
Max Tokens 52
MCP Client 73
MCP Server 73
Mechanistic Interpretability 12
Meta Prompting 21
Metadata Filtering 21
Metadata Management 21
Mixed-Precision Training 66
Mixture of Experts (MoE) 46
Model 21
Model Card 22
Model Context Protocol (MCP) 22
Model Extraction 22
Model Gateway 22
Model Merging 22
Model Registry 22
Model Size (Parameter Count) 59
Multi-Agent System (MAS) 21
Multi-Head Attention (MHA) 20
Multi-hop Retrieval 21
Multi-Layer Perceptron (MLP) 13
Multi-Turn Conversation 20
Multilingual Model 13
Multimodal 20
Multimodal Embedding 20
Music Generation 41

N

Narrow AI and Strong AI 34
Native Multimodal Model 12
Negative Prompt 12
Network Separation Regulation Reform 19
Neural Network (NN) 33
Neural Processing Unit (NPU) 74
Next-Token Prediction 13

O

Observability 8
Offline and Online Evaluation 39
On-Premises 39
One-shot Prompting 40
Open-Source Model 39
Open-Weight Model 39
Optical Character Recognition (OCR) 9
Optimizer 39
Orchestration 38
Output Formatting 53
Overfitting 8

P

Parameter 59
Parameter-Efficient Fine-Tuning (PEFT) 19
Perceptron 60
PII Masking (PII) 74
Pipeline Parallelism (PP) 59
Planning 7
Positional Encoding 40
Post-training 28
Pre-training 28
Pre-training Data Curation 28
Precision and Recall 47
Preference Data 30
Private Cloud 61
Process Redesign 35
Productivity Metrics 29
Prompt 61
Prompt Caching 62
Prompt Chaining 62
Prompt Engineering 62
Prompt Injection 62
Prompt Library 61
Prompt Optimization 62
Prompt Template 63
Prompt Versioning 62
Proof of Concept (PoC) 6
Proximal Policy Optimization (PPO) 11
Pseudonymization 5

Q

Quantization 34
Quantized Low-Rank Adaptation (QLoRA) 56
Query Rewriting 56

R

Random Forest 17
Rate Limit 18
ReAct (Reasoning and Acting) (ReAct) 19
Real-time Voice Conversation 34
Reasoning Model 52
Recommender System 53
Recurrent Neural Network (RNN) 31
Red Teaming 17
Reflection 24
Regression 68
Regression Testing 68
Regularization 47
Regulatory Sandbox 10
Reinforcement Learning (RL) 6
Reinforcement Learning from AI Feedback (RLAIF) 70
Reinforcement Learning from Human Feedback (RLHF) 43
Reinforcement Learning with Verifiable Rewards (RLVR) 6
Repetition Penalty 23
Reranking 46
Residual Connection 45
Reskilling and Upskilling 19
Response Prefill 42
Responsible AI 51
Responsible Scaling Policy (RSP) 51
Retrieval 6
Retrieval-Augmented Generation (RAG) 6
Retry and Fallback 46
Return on Investment (ROI) 58
Reward Hacking 26
Reward Model (RM) 25
ROC Curve and Area Under the Curve (AUC) 74
Role Prompting 38
Rotary Position Embedding (RoPE) 68

S

Sampling (Decoding) 28
Scale-up 66
Scaling Law 31
Screen Understanding 66
Self-Attention 30
Self-Consistency 44
Self-Supervised Learning (SSL) 44
Semantic Cache 33
Semantic Layer 33
Semantic Search 42
Semi-Supervised Learning 48
Service Level Agreement (SLA) 30
Shadow AI 29
Small Language Model (SLM) 31
Softmax 31
Sovereign AI 30
Speculative Decoding 53
Speech-to-Text (STT) 41
State Space Model (SSM) 28
Step-back Prompting 32
Stochastic Gradient Descent (SGD) 66
Stop Sequence 32
Streaming Response 32
Structured Data 47
Structured Output 9
Subagent 30
Summarization and Rewriting Prompt 40
Supervised Fine-Tuning (SFT) 49
Supervised Learning 48
SWE-bench 75
Sycophancy 34
Synthetic Data 65
System Card 33
System Prompt 33

T

Temperature 39
Tensor 57
Tensor Parallelism (TP) 57
Tensor Processing Unit (TPU) 75
TensorRT 75
Test-time Compute 57
Text Encoder 57
Text-to-Image Generation (T2I) 57
Text-to-Speech (TTS) 41
Text-to-SQL (NL2SQL) 57
Thinking Budget 27
Throughput 51
Time Series Forecasting 32
Time To First Token (TTFT) 51
Token 58
Token Cost 58
Tokenizer 58
Tool Schema 16
Tool Use 16
Top-k Retrieval 28
Top-k Sampling 75
Top-p (Nucleus) Sampling 75
Total Cost of Ownership (TCO) 52
Train/Validation/Test Split 13
Training Data 64
Training Tokens 65
Transfer Learning 46
Transformer 58
Tree of Thoughts (ToT) 59
Turing Test 58

U

Underfitting 8
Unstructured Data 26
Unsupervised Learning 27
Upscaling (Super-Resolution) 35
Use Case 67
User Prompt 27

V

Vanishing Gradient 12
Variational Autoencoder (VAE) 25
Vector Database (Vector DB) 24
Vector Index 25
Vendor Lock-in 25
Vibe Coding 23
Video Generation 38
Vision-Language Model (VLM) 32
Visual Question Answering (VQA) 32
vLLM 75
Voice Agent 41
Voice Cloning 41

W

Workflow Automation 40
World Model 40

X

XML Tag Structuring 76

Z

Zero-shot Prompting 48